빅데이터분석기사 필기 모의고사 1회

80문항 · 120분 · 계산기 사용 불가 — 정답·해설은 문제부 종료 후 새 페이지부터

the0ne 학습용 · 2026-09-01 생성 · KDATA 공개 출제기준 기반 신규 창작 문항 (기출 복원 아님)

빅데이터분석기사 필기 모의고사 1회

> **빅데이터분석기사 필기 모의고사 1회 · 총 80문항 · 120분 · 4지선다 · 계산기 사용 불가 · 합격: 평균 60점(총 48문항) 이상 AND 전 과목 40점(과목당 8문항) 이상**

1과목 빅데이터 분석 기획 (1~20번)

1. 다음은 DIKW 피라미드를 마트의 우유 가격에 적용한 사례다. **지혜(Wisdom)** 에 해당하는 것은?

① A마트는 우유를 1,000원에, B마트는 1,200원에 판매한다.
② A마트의 다른 상품들도 B마트보다 저렴할 것이라 판단하여 A마트를 이용하기로 한다.
③ A마트의 우유가 B마트보다 200원 더 싸다.
④ 우유는 상대적으로 저렴한 A마트에서 구매해야겠다.

2. 다음 중 반정형(semi-structured) 데이터에 해당하는 것은?

① 관계형 데이터베이스의 고객 테이블
② 스마트폰으로 촬영한 동영상 파일
③ 웹 서버가 기록한 JSON 형식의 로그
④ 콜센터 상담 음성 녹음 파일

3. 데이터 사이언티스트의 역량 중 하드 스킬(hard skill)에 해당하는 것은?

① 빅데이터 분석 기술에 대한 숙련과 방법론 습득
② 스토리텔링을 통한 설득력 있는 전달
③ 창의적 사고와 호기심에 기반한 통찰력 있는 분석
④ 다분야 간 협력을 위한 커뮤니케이션

4. 빅데이터 분석 조직 구조의 특징에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 집중 구조는 현업 업무 부서의 분석 업무와 이중화·이원화될 가능성이 있다.
② 분산 구조는 분석 인력이 현업 부서에 배치되므로 부서의 분석 업무와 역할 분담을 명확히 하지 않아도 업무의 이중화가 발생하지 않는다.
③ 기능 구조는 전사적 관점의 핵심 분석이 어렵다.
④ 기능 구조는 특정 부서에 국한된 과거 실적 위주의 분석에 머무를 수 있다.

5. 대용량 파일을 블록(block) 단위로 나누어 여러 노드에 분산 저장하고, 블록의 복제본(replica)을 두어 노드 장애에 대비하는 하둡(Hadoop)의 분산 파일 저장 컴포넌트는?

① HDFS ② MapReduce ③ YARN ④ HBase

6. 디스크 입출력 중심의 MapReduce와 달리 인메모리(in-memory) 기반 연산을 수행하여 반복 연산·머신러닝 작업에서 빠른 처리 속도를 보이는 분산 데이터 처리 엔진은?

① MapReduce ② HBase ③ Spark ④ YARN

7. 2020년 개정·시행된 이른바 '데이터 3법'에 해당하지 **<u>않는</u>** 것은?

① 개인정보 보호법
② 정보통신망 이용촉진 및 정보보호 등에 관한 법률(정보통신망법)
③ 신용정보의 이용 및 보호에 관한 법률(신용정보법)
④ 위치정보의 보호 및 이용 등에 관한 법률(위치정보법)

8. 개인정보 보호법상 정보주체의 동의 없이 가명정보를 처리할 수 있는 목적에 해당하지 **<u>않는</u>** 것은?

① 통계작성
② 과학적 연구
③ 공익적 기록보존
④ 특정 개인을 대상으로 한 맞춤형 광고 발송

9. 비식별화 기법과 그 처리 방식(세부기술)의 연결로 옳지 **<u>않은</u>** 것은?

① 가명처리 — 휴리스틱 대체(heuristic pseudonymization): 미리 정한 규칙으로 이름 등을 다른 값으로 대체
② 데이터 마스킹 — 주민등록번호 등 식별자 항목 자체를 원본에서 완전히 삭제
③ 데이터 범주화 — 나이 '33세'를 '30대'라는 구간값으로 변환
④ 총계처리 — 라운딩(rounding)·재배열 등으로 개별 값 대신 통계값을 제공

10. CRISP-DM 방법론의 6단계를 순서대로 옳게 나열한 것은?

① 데이터 이해 → 업무 이해 → 데이터 준비 → 모델링 → 평가 → 전개
② 업무 이해 → 데이터 준비 → 데이터 이해 → 모델링 → 평가 → 전개
③ 업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개
④ 업무 이해 → 데이터 이해 → 데이터 준비 → 평가 → 모델링 → 전개

11. SAS사가 주도한 SEMMA 방법론에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 업무 이해(Business Understanding) 단계에서 출발하여 비즈니스 문제 정의를 가장 강조한다.
② 수정(Modify) 단계에서는 변수의 변환·생성·선택 등 데이터 가공을 수행한다.
③ 탐색(Explore) 단계에서는 시각화와 기초 통계를 통해 데이터의 패턴을 파악한다.
④ 샘플링(Sample) → 탐색(Explore) → 수정(Modify) → 모델링(Model) → 평가(Assess)의 5단계로 구성된다.

12. 하향식(top-down) 분석 과제 발굴 절차를 순서대로 옳게 나열한 것은?

① 문제 정의 → 문제 탐색 → 해결방안 탐색 → 타당성 검토
② 문제 탐색 → 문제 정의 → 해결방안 탐색 → 타당성 검토
③ 문제 탐색 → 해결방안 탐색 → 문제 정의 → 타당성 검토
④ 타당성 검토 → 문제 탐색 → 문제 정의 → 해결방안 탐색

13. A기업을 진단한 결과, 분석에 필요한 데이터·인력·조직 등 준비도(readiness)는 높지만 실제 분석 업무를 수행해 본 경험이 거의 없어 성숙도(maturity)는 낮은 것으로 나타났다. 분석 수준 진단의 사분면 분석에서 A기업이 속하는 유형은?

① 준비형 ② 정착형 ③ 도입형 ④ 확산형

14. 데이터 분석 목표 정의서의 구성요소에 해당하지 **<u>않는</u>** 것은?

① 원천 데이터 조사
② 분석 방안 및 적용 가능성 판단
③ 성과 평가 기준
④ 분석 모델의 최적 하이퍼파라미터(hyperparameter) 설정값

15. ETL 프로세스의 세 단계를 수행 순서대로 바르게 나열한 것은?

① 변환(Transform) → 추출(Extract) → 적재(Load)
② 추출(Extract) → 변환(Transform) → 적재(Load)
③ 적재(Load) → 추출(Extract) → 변환(Transform)
④ 추출(Extract) → 적재(Load) → 변환(Transform)

16. 수집 대상 서버에 설치된 에이전트(agent)가 로그를 수집하고 컬렉터(collector)가 이를 모아 HDFS에 저장하는, 하둡의 서브프로젝트로 개발된 로그 수집 기술은?

① 플룸(Flume)
② 카프카(Kafka)
③ 로그스태시(Logstash)
④ 척와(Chukwa)

17. 데이터 유형과 수집 기술의 연결로 옳지 **<u>않은</u>** 것은?

① 정형 데이터 — ETL, 스쿱(Sqoop)
② 반정형 데이터 — 플룸(Flume), 스크라이브(Scribe)
③ 비정형 데이터 — 크롤링(crawling), 스크래파이(Scrapy)
④ 정형 데이터 — 척와(Chukwa), 크롤링(crawling)

18. 데이터 변환 기법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 집계(aggregation)는 데이터를 요약·합산하여 규모를 축소하는 기법이다.
② 일반화(generalization)는 기존 속성을 조합해 새로운 속성을 추가함으로써 데이터의 차원을 늘리는 기법이다.
③ 정규화(normalization)는 데이터 값을 정해진 구간(예: 0~1)에 들어가도록 척도를 변환하는 기법이다.
④ 속성 생성(attribute construction)은 기존 속성들로부터 분석에 유용한 새로운 속성을 만들어내는 기법이다.

19. 어느 기업이 고객 데이터를 다음과 같이 전환했다.

- (가) 고객 나이 값 23, 35, 47을 각각 '20대', '30대', '40대'로 대체했다.
- (나) 일별 매출 데이터를 합산하여 월별 매출 데이터로 만들었다.

(가)와 (나)에 적용된 데이터 변환 기법을 순서대로 바르게 짝지은 것은?

① 평활화 — 집계
② 일반화 — 정규화
③ 평활화 — 속성 생성
④ 일반화 — 집계

20. 트랜잭션 속성 ACID와 BASE에 대한 설명으로 옳은 것은?

① BASE는 기본적 가용성(Basically Available), 소프트 상태(Soft state), 최종 일관성(Eventually consistent)을 의미하며 NoSQL이 주로 채택하는 느슨한 일관성 모델이다.
② ACID는 NoSQL의 특성이고, BASE는 관계형 데이터베이스의 트랜잭션 특성이다.
③ BASE 모델은 모든 시점에 강한 일관성(strong consistency)을 보장한다.
④ ACID의 D(Durability)는 트랜잭션을 언제든지 취소할 수 있음을 의미한다.

2과목 빅데이터 탐색 (21~40번)

21. 결측값의 발생이 해당 변수의 값이나 다른 어떤 변수와도 관계없이 완전히 무작위로 일어나는 결측 유형은?

① 무작위 결측(MAR)
② 완전 무작위 결측(MCAR)
③ 비무작위 결측(MNAR)
④ 이상값(outlier)

22. 데이터를 정렬하여 여러 구간(bin)으로 나눈 뒤, 각 구간의 평균·중앙값·경계값으로 구간 내 값을 대체하여 잡음(noise)을 완화하는 평활화(smoothing) 기법은?

① 군집화(clustering)
② 회귀(regression)
③ 구간화(binning)
④ 표준화(standardization)

23. 결측값 처리 방법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 완전분석법(complete case analysis)은 결측값이 하나라도 있는 관측치를 제외하고 완전한 관측치만으로 분석한다.
② 평균 대치법은 결측값을 관측된 값들의 평균으로 대체하며, 자료의 분산을 과소추정하는 단점이 있다.
③ 회귀 대치법은 결측이 없는 다른 변수들로 회귀모형을 만들어 그 예측값으로 결측값을 대체한다.
④ 다중 대치법(multiple imputation)은 결측값을 한 번만 대치하여 단 하나의 완성된 데이터셋을 만드는 방법이다.

24. 데이터 정제 대상 중 잡음(noise)에 대한 설명으로 가장 적절한 것은?

① 측정 과정에서 무작위로 섞여 들어간 오류값으로, 구간화·회귀·군집화 같은 평활화(smoothing) 기법으로 그 영향을 줄일 수 있다.
② 관측 자체가 이루어지지 않아 값이 비어 있는 상태를 말한다.
③ 정상 범위를 크게 벗어났으나 입력 오류가 아니라 실제로 발생한 극단적인 관측값을 말한다.
④ 발생 원인과 참값이 명확히 기록되어 있으므로 언제든 원래 값으로 복원할 수 있다.

25. 결측값 유형에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 완전 무작위 결측(MCAR)은 결측 발생이 결측된 값이나 다른 어떤 변수와도 무관하다.
- ㄴ. 무작위 결측(MAR)은 결측 발생이 결측된 값 자체 때문에 일어나는 경우를 말한다.
- ㄷ. 비무작위 결측(MNAR)에서는 결측 메커니즘을 무시할 수 없어 결측 행을 단순 삭제하면 편향이 생길 수 있다.
- ㄹ. MCAR이라면 완전분석법을 사용해도 추정의 편향은 발생하지 않는다.

① ㄱ, ㄷ, ㄹ ② ㄱ, ㄴ, ㄷ ③ ㄴ, ㄹ ④ ㄱ, ㄴ, ㄹ

26. 어떤 변수의 최솟값이 20, 최댓값이 100이다. 관측값 60을 민맥스 정규화(min-max normalization)한 값은?

① 0.5 ② 0.6 ③ 0.4 ④ 0.75

27. 변수 선택의 래퍼(wrapper) 기법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 전진 선택법(forward selection)은 변수가 없는 모델에서 시작해 유의한 변수를 하나씩 추가한다.
② 래퍼 기법은 모델 학습 없이 통계적 측도만으로 변수를 평가하므로 계산 비용이 가장 낮다.
③ 후진 제거법(backward elimination)은 전체 변수를 포함한 모델에서 기여도가 낮은 변수를 하나씩 제거한다.
④ 단계적 방법(stepwise method)은 변수의 추가와 제거를 번갈아 반복하며 최적 조합을 탐색한다.

28. 주성분분석(PCA)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 데이터의 분산이 최대가 되는 방향의 축을 첫 번째 주성분으로 한다.
② 주성분들은 서로 직교(orthogonal)하여 상관관계가 없다.
③ 변수의 측정 단위(스케일)에 영향을 받으므로 표준화 후 수행하는 것이 일반적이다.
④ 클래스(목표변수) 정보를 활용하여 클래스 간 분리가 최대가 되는 축을 찾는 지도학습 기법이다.

29. 불균형 데이터(imbalanced data) 처리에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 언더샘플링은 다수 클래스의 관측치를 줄여 균형을 맞추므로 유용한 정보가 손실될 수 있다.
② 클래스 가중치(class weight)는 데이터 수를 바꾸지 않고 학습 시 소수 클래스의 오분류에 더 큰 벌점을 부여하는 방법이다.
③ 랜덤 오버샘플링은 소수 클래스를 단순 복제하므로 과대적합(overfitting) 위험이 있다.
④ 오버샘플링은 다수 클래스의 관측치를 복제하여 전체 데이터 크기를 늘리는 방법이다.

30. 서로 다른 클래스에 속한 두 관측치가 서로에게 가장 가까운 이웃이 되는 쌍을 찾아, 그중 다수 클래스의 관측치를 제거함으로써 클래스 간 경계를 정리하는 언더샘플링 기법은?

① ENN(Edited Nearest Neighbours)
② 토멕 링크(Tomek Link)
③ SMOTE
④ 랜덤 오버샘플링(random oversampling)

31. 자료에 극단적인 이상값(outlier)이 포함될 때 그 값의 영향을 가장 크게 받는(민감한) 중심 경향치는?

① 평균(mean) ② 중앙값(median) ③ 최빈값(mode) ④ 절사평균(trimmed mean)

32. 측정 단위가 서로 다른 두 자료가 있다. A는 평균 100, 표준편차 20이고 B는 평균 50, 표준편차 5이다. 두 자료의 산포를 비교한 설명으로 옳은 것은?

① 표준편차가 큰 A와 B의 산포 비교는 분산 값만 비교하면 충분하다.
② B의 변동계수는 0.2이다.
③ A의 변동계수는 0.2로 B(0.1)보다 커서 A의 상대적 산포가 더 크다.
④ 측정 단위가 다른 자료끼리는 산포를 비교할 방법이 없다.

33. 데이터 탐색에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 줄기-잎 그림(stem-and-leaf plot)은 분포의 전체적인 모양을 보여주면서 개별 관측값의 정보도 함께 유지하는 탐색 도구다.
- ㄴ. 히스토그램(histogram)은 연속형 자료를 구간으로 나누어 도수를 막대로 표현하며, 막대 사이에 간격을 두는 막대그래프(bar chart)와 달리 막대를 붙여 그린다.
- ㄷ. 범위(range)는 최댓값에서 최솟값을 뺀 값으로, 두 극단값만으로 계산되므로 이상값에 민감하다.
- ㄹ. 두 범주형 변수 간의 관계를 탐색할 때는 산점도(scatter plot)가 가장 적절한 도구다.

① ㄱ, ㄴ, ㄷ ② ㄱ, ㄷ, ㄹ ③ ㄴ, ㄹ ④ ㄱ, ㄴ, ㄷ, ㄹ

34. 다변량 데이터 탐색에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 산점도 행렬(scatter plot matrix)은 여러 변수 쌍의 산점도를 행렬 형태로 배열하여 변수 간 관계를 한눈에 파악하게 한다.
② 상관행렬(correlation matrix)의 대각원소는 모두 1이며, 상관행렬은 대칭행렬이다.
③ 두 변수의 상관계수가 0이면 두 변수는 반드시 서로 독립이다.
④ 변수가 3개일 때 서로 다른 변수 쌍의 수는 3개이므로 산점도 행렬에는 3종류의 변수 쌍 산점도가 나타난다.

35. 측정 대상 간의 순위(서열)는 의미가 있지만, 값 사이의 간격은 일정하지 않아 의미가 없는 척도는?

① 명목척도(nominal scale)
② 순서척도(ordinal scale)
③ 구간척도(interval scale)
④ 비율척도(ratio scale)

36. 모집단 목록에 일련번호를 부여한 뒤 첫 표본만 무작위로 뽑고, 그로부터 일정한 간격 k마다 표본을 추출하는 방법은?

① 단순 무작위추출(simple random sampling)
② 층화추출(stratified sampling)
③ 계통추출(systematic sampling)
④ 군집추출(cluster sampling)

37. 확률변수 X가 이항분포 B(100, 0.2)를 따를 때, X의 기댓값과 분산을 순서대로 나열한 것은?

① 20, 16 ② 20, 20 ③ 16, 20 ④ 20, 4

38. 중심극한정리(central limit theorem)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 모집단이 정규분포를 따르는 경우에만 성립한다.
② 표본 크기 n이 충분히 크면 표본평균의 분포는 근사적으로 정규분포를 따른다.
③ 표본평균의 기댓값은 모평균 μ와 같다.
④ 표본평균의 분산은 σ^2/n으로, 표본 크기가 커질수록 작아진다.

39. 다음 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 섭씨온도는 절대영점이 없는 구간척도이므로 "20℃는 10℃보다 2배 덥다"는 비율 비교가 성립하지 않는다.
- ㄴ. 명목척도로 측정된 자료는 산술평균을 계산하여 대푯값으로 사용하는 것이 적절하다.
- ㄷ. 층화추출에서 각 층은 층 내부가 동질적이고 층 사이는 이질적이 되도록 구성한다.
- ㄹ. 표본 크기가 충분히 크면 모집단의 분포와 무관하게 표본평균의 분포는 근사적으로 정규분포를 따른다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄷ, ㄹ ④ ㄱ, ㄴ, ㄷ, ㄹ

40. 다음은 가설검정의 결과를 정리한 표다. (가)~(다)에 들어갈 내용으로 옳은 것은?

구분	H_0가 참	H_0가 거짓
H_0 기각	(가)	(나)
H_0 채택	옳은 결정	(다)

① (가) 2종 오류 (나) 검정력 (다) 1종 오류
② (가) 1종 오류 (나) 2종 오류 (다) 옳은 결정

③ (가) 2종 오류 (나) 1종 오류 (다) 옳은 결정
④ (가) 1종 오류 (나) 옳은 결정 (다) 2종 오류

3과목 빅데이터 모델링 (41~60번)

41. 다음 중 비지도학습(unsupervised learning)에 해당하는 것은?

① 로지스틱 회귀(logistic regression)
② K-평균 군집(K-means clustering)
③ 의사결정나무(decision tree)
④ 서포트 벡터 머신(SVM)

42. 다음 분석 과제 중 지도학습의 분류(classification)에 해당하는 것은?

① 고객의 계약·이용 데이터를 학습하여 서비스 해지 여부(이탈/유지)를 예측한다.
② 지역·면적 등의 정보를 학습하여 아파트의 매매 가격을 예측한다.
③ 과거 판매 실적을 학습하여 매장의 다음 달 매출액을 예측한다.
④ 기온 데이터를 학습하여 아이스크림 판매량을 예측한다.

43. 머신러닝의 학습 유형에 대한 설명으로 옳지 **않은** 것은?

① 지도학습은 정답(레이블)이 있는 데이터로 학습하며, 분류(classification)와 회귀(regression)로 구분된다.
② 비지도학습은 레이블 없는 데이터에서 구조·패턴을 찾으며 군집화, 연관 규칙 학습, 차원 축소가 대표적이다.
③ 강화학습은 행동에 대한 보상을 통해 정책을 학습하며, 명시적인 정답 레이블을 사용하지 않는다.
④ 준지도학습(semi-supervised learning)은 소량의 레이블 데이터와 대량의 무레이블 데이터를 함께 사용하며, 학습 데이터의 대부분이 무레이블이므로 비지도학습의 한 유형으로 분류된다.

44. 다음은 분석 모형 구축 절차의 각 단계다. 순서대로 옳게 나열한 것은?

- ㄱ. 모델링
- ㄴ. 요건 정의
- ㄷ. 적용
- ㄹ. 검증 및 테스트

① ㄴ → ㄹ → ㄱ → ㄷ
② ㄱ → ㄴ → ㄹ → ㄷ
③ ㄴ → ㄱ → ㄷ → ㄹ
④ ㄴ → ㄱ → ㄹ → ㄷ

45. 선형 회귀분석(linear regression)에서 잔차의 **독립성(비상관성)** 을 검정하기 위해 사용하는 통계량은?

① 샤피로-윌크(Shapiro-Wilk) 검정
② 더빈-왓슨(Durbin-Watson) 통계량
③ 분산팽창지수(VIF)
④ 콜모고로프-스미르노프(Kolmogorov-Smirnov) 검정

46. 다중공선성(multicollinearity)에 대한 설명으로 옳지 **않은** 것은?

① 일반적으로 분산팽창지수(VIF)가 10 이상이면 다중공선성이 있다고 판단한다.
② 다중공선성이 존재하면 회귀계수 추정치의 분산이 커져 해석의 신뢰성이 떨어진다.
③ 상관관계가 높은 변수 제거, 주성분 분석(PCA), 릿지(Ridge) 회귀 등으로 완화할 수 있다.
④ 다중공선성은 종속변수와 독립변수 사이의 상관관계가 지나치게 높을 때 발생한다.

47. 인공신경망(artificial neural network)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 단층 퍼셉트론(single-layer perceptron)은 XOR 문제와 같은 비선형 분류 문제를 해결할 수 있다.
② 다층 퍼셉트론(multi-layer perceptron)은 은닉층(hidden layer)을 추가하여 XOR 문제를 해결한다.
③ 역전파(backpropagation)는 출력층의 오차를 입력층 방향으로 거꾸로 전파하며 가중치를 갱신하는 학습 방법이다.
④ 시그모이드 계열 활성화 함수를 깊은 신경망에 사용하면 기울기 소실(gradient vanishing)이 발생할 수 있으며, ReLU 함수가 이를 완화한다.

48. 인공신경망의 다중 클래스 분류 문제에서 출력층에 사용되며, 각 클래스에 속할 확률을 출력하고 그 확률의 합이 1이 되도록 하는 활성화 함수는?

① 시그모이드(sigmoid) ② ReLU ③ 소프트맥스(softmax) ④ 하이퍼볼릭 탄젠트(tanh)

49. 전체 거래 10건 중 상품 A를 포함한 거래가 5건, 상품 B를 포함한 거래가 4건, A와 B를 모두 포함한 거래가 2건이다. 연관규칙 "A → B"의 지지도(support), 신뢰도(confidence), 향상도(lift)를 순서대로 구한 것은?

① 지지도 0.2, 신뢰도 0.4, 향상도 1.0
② 지지도 0.2, 신뢰도 0.5, 향상도 1.25
③ 지지도 0.4, 신뢰도 0.2, 향상도 0.5
④ 지지도 0.5, 신뢰도 0.4, 향상도 0.8

50. 로지스틱 회귀(logistic regression)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 종속변수가 범주형(예: 구매/미구매)일 때 사용하는 회귀 기법이다.
② 회귀계수 β를 지수 변환한 값 e^β는 오즈비(odds ratio)로 해석된다.
③ 시그모이드(sigmoid) 함수를 통해 출력값을 0과 1 사이의 확률로 변환한다.
④ 오즈(odds)는 확률과 마찬가지로 항상 0과 1 사이의 값을 가진다.

51. 계층적 군집분석에서 두 군집을 병합할 때 '군집 내 오차제곱합(분산)의 증가분이 최소가 되는 군집끼리 병합'하는 연결 방법은?

① 단일 연결법(single linkage)
② 완전 연결법(complete linkage)
③ 평균 연결법(average linkage)
④ 와드 연결법(Ward linkage)

52. 편의점 거래 데이터에서 연관규칙 "라면 → 김밥"의 신뢰도(confidence)는 0.6이고, 전체 거래 중 김밥이 포함된 거래의 비율은 0.3이다. 이 규칙의 향상도(lift)와 그 해석으로 옳은 것은?

① 향상도는 2이며, 1보다 크므로 라면과 김밥은 서로 독립이다.
② 향상도는 2이며, 라면 구매 고객이 김밥을 살 확률이 전체 고객 평균의 2배이므로 양(+)의 연관관계가 있다.
③ 향상도는 2이며, 1보다 크므로 라면 구매가 김밥 구매를 억제하는 음(-)의 연관관계가 있다.
④ 향상도는 신뢰도에 김밥 구매 비율을 곱한 0.18이다.

53. 분석기법과 학습 유형의 연결이 옳은 것만 모두 고른 것은?

- ㄱ. 로지스틱 회귀(logistic regression) – 지도학습
- ㄴ. K-평균 군집(K-means) – 지도학습
- ㄷ. 연관분석(association analysis) – 비지도학습
- ㄹ. 서포트 벡터 머신(SVM) – 지도학습
- ㅁ. 자기조직화지도(SOM) – 비지도학습

① ㄱ, ㄴ, ㄷ, ㄹ
② ㄱ, ㄷ, ㄹ
③ ㄱ, ㄷ, ㄹ, ㅁ
④ ㄴ, ㄷ, ㅁ

54. 시계열의 정상성(stationarity)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 정상 시계열의 평균은 시점에 관계없이 일정하다.
② 공분산은 시점 자체가 아니라 시차(lag)에만 의존한다.
③ 평균이 일정하지 않은 비정상 시계열은 차분(differencing)으로 정상화할 수 있다.
④ 정상 시계열의 분산은 시점에 따라 증가하거나 감소할 수 있다.

55. 시계열 분해(decomposition)의 구성 요소 중, 아이스크림 판매량이 매년 여름마다 증가하는 것처럼 '일정한 주기(1년 이내)로 반복되는 변동'에 해당하는 것은?

① 계절 요인(seasonal factor)
② 추세 요인(trend factor)
③ 순환 요인(cyclical factor)
④ 불규칙 요인(irregular factor)

56. LSTM(Long Short-Term Memory)에 대한 설명으로 옳은 것은?

① 합성곱 연산으로 이미지의 공간적 특징을 추출하기 위해 고안되었다.
② RNN의 기울기 소실(gradient vanishing)로 인한 장기 의존성 문제를 게이트 구조로 해결한 모델이다.
③ 생성자와 판별자를 적대적으로 학습시켜 새로운 데이터를 생성한다.
④ 순차 데이터를 처리할 수 없어 시계열 예측에는 사용되지 않는다.

57. 다음 각 업무에 가장 적합한 딥러닝 모델을 순서대로 바르게 연결한 것은?

- (가) 실제 인물처럼 보이는 가상의 얼굴 이미지를 새로 생성한다.
- (나) 라벨이 없는 센서 데이터를 저차원으로 압축한 뒤 복원 오차로 이상을 탐지한다.
- (다) 긴 문장에서 멀리 떨어진 앞부분의 문맥까지 반영하여 다음 단어를 예측한다.

① (가) GAN — (나) 오토인코더 — (다) LSTM
② (가) 오토인코더 — (나) GAN — (다) CNN
③ (가) LSTM — (나) 오토인코더 — (다) GAN
④ (가) CNN — (나) LSTM — (다) 오토인코더

58. 문서가 여러 잠재 토픽(topic)의 혼합으로 구성되고 각 토픽은 단어들의 확률분포로 표현된다고 가정하여, 문서 집합에 숨어 있는 주제를 추출하는 대표적인 토픽 모델링 기법은?

① 잠재 디리클레 할당(LDA)
② 감성 분석(sentiment analysis)

③ TF-IDF
④ 형태소 분석(morphological analysis)

59. 감성 분석(sentiment analysis)과 오피니언 마이닝(opinion mining)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 감성 분석은 텍스트에 담긴 긍정·부정·중립 등의 감성 극성을 판별하는 기법이다.
② 오피니언 마이닝은 텍스트에서 상품·서비스 등에 대한 사용자의 의견·평판을 추출하여 분석한다.
③ 상품 리뷰 텍스트로 고객의 만족 여부를 분류하는 것은 감성 분석의 대표적 활용 사례다.
④ 감성 분석은 정형화된 수치 데이터만을 대상으로 하므로 텍스트 데이터에는 적용할 수 없다.

60. 부스팅(boosting)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 이전 모델이 오분류한 데이터에 가중치를 높여 다음 모델을 학습시킨다.
② AdaBoost, GBM, XGBoost는 대표적인 부스팅 계열 알고리즘이다.
③ 약한 학습기(weak learner)들을 결합하여 강한 학습기를 만드는 방식이다.
④ 각 모델이 서로 독립적으로 병렬 학습되므로 이전 모델의 결과가 다음 모델에 영향을 주지 않는다.

4과목 빅데이터 결과 해석 (61~80번)

61. 오차(잔차)를 제곱하여 평균한 값에 다시 제곱근을 취한 것으로, 종속변수와 같은 단위로 오차 크기를 해석할 수 있는 회귀모형 평가지표는?

① 평균제곱오차(MSE) ② 평균제곱근오차(RMSE) ③ 평균절대오차(MAE) ④ 평균절대백분율오차(MAPE)

62. 회귀모형의 평가에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 전체제곱합(SST)은 회귀제곱합(SSR)과 오차제곱합(SSE)의 합과 같다.
② 결정계수(R^2)는 SSR/SST로, 회귀모형이 설명하는 변동의 비율을 의미한다.
③ 수정 결정계수(adjusted R^2)는 독립변수의 수가 늘어나는 것에 페널티를 부여한 지표다.
④ 결정계수(R^2)는 유의하지 않은 독립변수를 추가하면 그 값이 감소하므로 변수 선택에 그대로 사용해도 된다.

63. 혼동행렬 기반 분류 평가지표에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 특이도(specificity)는 양성으로 예측한 것 중 실제 양성의 비율이다.
② 정밀도(precision)는 양성으로 예측한 것 중 실제 양성의 비율이다.
③ 재현율(recall)은 민감도(sensitivity)와 같은 지표로, 실제 양성 중 양성으로 예측한 비율이다.
④ 거짓긍정률(FPR)은 1 − 특이도와 같다.

64. 분류모형의 시각적 평가 도구에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① ROC 곡선은 x축에 거짓긍정률(FPR), y축에 참긍정률(TPR, 민감도)을 놓고 그린다.
② AUC는 0.5~1의 값을 가지며, 1에 가까울수록 좋은 모형이고 0.5는 랜덤 분류 수준을 의미한다.
③ 향상도 곡선(lift curve)은 무작위 선택 대비 모형의 예측 성과가 얼마나 향상되었는지를 보여준다.
④ ROC 곡선이 대각선(45도 직선)에 가까울수록 분류 성능이 좋은 모형이다.

65. 어떤 분류모형의 혼동행렬(confusion matrix)이 TP=30, FP=10, FN=20, TN=40일 때, 정밀도(precision)는?

① 0.60 ② 0.75 ③ 0.70 ④ 0.80

66. 데이터 분할과 교차검증에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 홀드아웃(hold-out)에서 평가(test) 데이터는 모형 학습에 사용하지 않는다.
② 검증(validation) 데이터는 하이퍼파라미터 조정 등 모형 최적화 과정에 사용된다.
③ k-겹 교차검증에서 k를 크게 할수록 학습·평가 반복 횟수가 늘어나 계산량이 증가한다.
④ LpOCV(leave-p-out)는 LOOCV보다 반복 횟수가 적어 계산량이 항상 더 적다.

67. 어떤 분류모형의 혼동행렬이 TP=40, FN=10, FP=20, TN=80일 때, 이 모형이 ROC 공간에 찍히는 점의 좌표 (x, y)는?

① (0.8, 0.2) ② (0.2, 0.8) ③ (0.67, 0.8) ④ (0.2, 0.67)

68. 회귀 계수의 절댓값 합을 벌점(penalty)으로 부과하여 일부 계수를 정확히 0으로 만들고, 이를 통해 변수 선택 효과를 갖는 규제 기법은?

① L1 규제(라쏘, Lasso)
② L2 규제(릿지, Ridge)
③ 드롭아웃(dropout)
④ 조기 종료(early stopping)

69. 과대적합(overfitting)을 완화하기 위한 방법으로 적절하지 **<u>않은</u>** 것은?

① 은닉층과 노드 수를 늘려 모형의 복잡도를 높인다.
② 원본 데이터를 변형·확장하는 데이터 증강(data augmentation)으로 훈련 데이터를 늘린다.
③ L1·L2 규제(regularization)를 적용해 가중치가 과도하게 커지지 않도록 한다.
④ 검증 오차가 증가하기 시작하면 학습을 멈추는 조기 종료(early stopping)를 적용한다.

70. 심층 신경망의 역전파(backpropagation) 과정에서 출력층에서 입력층 방향으로 갈수록 기울기가 0에 가까워져 앞쪽 층의 가중치가 거의 갱신되지 않는 문제와, 이를 완화하기 위해 은닉층에 널리 사용되는 활성화 함수를 옳게 짝지은 것은?

① 기울기 소실(gradient vanishing) — ReLU
② 기울기 소실(gradient vanishing) — 시그모이드(sigmoid)
③ 과대적합(overfitting) — ReLU
④ 기울기 폭주(gradient exploding) — 시그모이드(sigmoid)

71. 배치 정규화(batch normalization)와 조기 종료(early stopping)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 배치 정규화는 미니배치 단위로 층의 입력 분포를 정규화하여 학습을 안정화한다.
② 조기 종료는 훈련 오차가 증가하기 시작하는 시점에 학습을 중단하는 기법이다.
③ 배치 정규화는 층을 지날 때마다 입력 분포가 변하는 문제를 완화해 학습 속도를 높인다.
④ 조기 종료는 불필요하게 오래 학습하여 발생하는 과대적합을 방지한다.

72. 분석모형 융합과 최종모형 선정에 대한 설명으로 옳은 것은?

① 최종모형은 훈련 데이터에서의 성능이 가장 높은 모형으로 선정하면 충분하다.
② 여러 모형을 융합(앙상블)하면 단일 모형보다 예측 결과의 해석이 항상 쉬워진다.
③ 최종모형 선정 시 평가 데이터의 성능 지표와 함께 해석 가능성, 운영 환경 적용 가능성 등 비즈니스 요건을 종합적으로 고려한다.
④ 보팅(voting)은 여러 모형의 예측을 결합하는 방법이 아니라 하나의 모형을 반복 학습시키는 방법이다.

73. 분석모형의 결과를 비즈니스 관점에서 해석·전달하는 방법으로 가장 적절한 것은?

① 정확성을 위해 통계 용어와 수식을 가공 없이 그대로 사용하여 보고한다.
② 분석 결과가 비즈니스 목표(KPI)에 미치는 영향과 기대 효과를 중심으로 전달한다.
③ 모형의 하이퍼파라미터 튜닝 과정을 상세히 나열하는 데 집중한다.
④ 의사결정자의 관심사보다 분석가가 사용한 알고리즘의 우수성을 우선 강조한다.

74. 어느 기업이 분석 시스템 구축에 1억 2,000만 원을 투자하였고, 이 시스템으로 매년 3,000만 원의 순이익이 균등하게 발생한다. 투자 회수 기간(payback period)은?

① 3년 ② 4년 ③ 5년 ④ 6년

75. 지역별 데이터 값(인구, 선거인 수 등)에 비례하도록 지도의 면적을 의도적으로 왜곡하여 표현하는 공간 시각화 기법은?

① 도트맵(dot map)
② 등치지역도(choropleth map)
③ 버블 플롯맵(bubble plot map)
④ 카토그램(cartogram)

76. 다음 중 비교 시각화 기법에 해당하지 **<u>않는</u>** 것은?

① 히트맵(heatmap)
② 스타 차트(star chart)
③ 평행 좌표 그래프(parallel coordinates)
④ 등치지역도(choropleth map)

77. 여러 노트북 제품을 가격·무게·성능·배터리 시간 등 4개 이상의 변수에 대해 한 화면에서 동시에 비교하려고 한다. 각 변수를 평행한 세로 축으로 배치하고 제품마다 축 위의 값을 선으로 이어 표현하기에 가장 적절한 기법은?

① 평행 좌표 그래프(parallel coordinates)
② 파이 차트(pie chart)
③ 선 그래프(line graph)
④ 도트맵(dot map)

78. 시각화 유형과 차트의 매칭에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 계단식 그래프(step chart)는 시간 시각화 기법이다.
- ㄴ. 트리맵(treemap)은 비교 시각화 기법이다.
- ㄷ. 버블 차트(bubble chart)는 관계 시각화 기법이다.
- ㄹ. 히트맵(heatmap)은 비교 시각화 기법이다.

① ㄱ, ㄴ, ㄷ ② ㄱ, ㄷ, ㄹ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄴ, ㄹ

79. 운영 시스템에 적용된 분석모형이 개발 당시의 성능을 유지하고 있는지 주기적으로 성능을 측정·추적하고, 성능 저하 여부를 점검하는 활동은?

① 분석모형 모니터링 ② 분석모형 전개 ③ 탐색적 데이터 분석(EDA) ④ 데이터 전처리

80. 개발이 완료된 분석모형을 서비스에 적용하여 운영하는 단계를 순서대로 옳게 나열한 것은?

- ㄱ. 분석모형을 운영 시스템에 적용·배포(전개)한다.
- ㄴ. 성능 저하를 감지한다.

- ㄷ. 주기적으로 모형의 성능을 측정한다(모니터링).
- ㄹ. 모형을 재학습·재개발한다(리모델링).

① ㄱ → ㄴ → ㄷ → ㄹ
② ㄷ → ㄱ → ㄴ → ㄹ
③ ㄱ → ㄷ → ㄹ → ㄴ
④ ㄱ → ㄷ → ㄴ → ㄹ

⚠️ 이 아래는 정답입니다 — 채점 전 스크롤 주의

✓ 정답 및 해설 보기

정답표

번호	정답	번호	정답	번호	정답	번호	정답
1	②	21	②	41	②	61	②
2	③	22	③	42	①	62	④
3	①	23	④	43	④	63	①
4	②	24	①	44	④	64	④
5	①	25	①	45	②	65	②
6	③	26	①	46	④	66	④
7	④	27	②	47	①	67	②
8	④	28	④	48	③	68	①
9	②	29	④	49	①	69	①
10	③	30	②	50	④	70	①
11	①	31	①	51	④	71	②
12	②	32	③	52	②	72	③
13	③	33	①	53	③	73	②
14	④	34	③	54	④	74	②
15	②	35	②	55	①	75	④
16	④	36	③	56	②	76	④
17	④	37	①	57	①	77	①
18	②	38	①	58	①	78	②
19	④	39	③	59	④	79	①
20	①	40	④	60	④	80	④

문항별 한 줄 해설

상세 해설은 문제집의 해당 원문항을 참조하세요.

1과목

1. 정답 ② | 원문항 Q1-001 | 사실=데이터, 비교=정보, 행동 방침=지식, 다른 상황 추론=지혜로 판별하는 DIKW 사례형.
2. 정답 ③ | 원문항 Q1-004 | 반정형 4대 예시는 XML·JSON·HTML·로그 — 태그·키가 보이면 반정형.

3. 정답 ① | 원문항 Q1-007 | 하드 스킬은 이론적 지식+분석 기술 숙련, 소프트 스킬은 통찰·전달·협력.
4. 정답 ② | 원문항 Q1-009 | 분산 구조도 역할 분담이 불명확하면 업무 이중화가 발생할 수 있어 역할 분담 명확화가 필요.
5. 정답 ① | 원문항 Q1-011 | 블록·복제·분산 저장 키워드는 HDFS — 하둡 3요소는 HDFS(저장)/MapReduce(처리)/YARN(자원).
6. 정답 ③ | 원문항 Q1-014 | 인메모리·반복 연산·MapReduce보다 빠름 키워드는 Spark.
7. 정답 ④ | 원문항 Q1-018 | 데이터 3법 = 개인정보 보호법+정보통신망법+신용정보법("개·망·신"), 위치정보법은 미포함.
8. 정답 ④ | 원문항 Q1-020 | 가명정보 특례 3목적은 통계작성·과학적 연구·공익적 기록보존 — 특정 개인 대상 마케팅은 불가.
9. 정답 ② | 원문항 Q1-022 | 식별자 항목 자체 삭제는 '데이터 삭제' 기법이고, 마스킹은 값을 남기되 기호로 가리는 것.
10. 정답 ③ | 원문항 Q1-027 | CRISP-DM 6단계 = 업무 이해→데이터 이해→데이터 준비→모델링→평가→전개.
11. 정답 ① | 원문항 Q1-030 | 업무 이해에서 출발하는 것은 CRISP-DM — SEMMA는 데이터 샘플링에서 출발하는 기술 중심 방법론.
12. 정답 ② | 원문항 Q1-032 | 하향식 4단계 = 문제 탐색→문제 정의→해결방안 탐색→타당성 검토("탐·정·해·타").
13. 정답 ③ | 원문항 Q1-034 | 준비도 높음+성숙도 낮음 = 도입형 (저저=준비형, 저고=정착형, 고고=확산형).
14. 정답 ④ | 원문항 Q1-038 | 목표 정의서 3요소는 원천 데이터 조사·분석 방안·성과 평가 기준 — 하이퍼파라미터는 모델링 단계 사항.
15. 정답 ② | 원문항 Q1-041 | ETL은 알파벳 순서 그대로 추출→변환→적재, T와 L을 바꾸면 ELT.
16. 정답 ④ | 원문항 Q1-044 | 하둡 서브프로젝트+에이전트–컬렉터 구조+HDFS 저장 = 척와(Chukwa).
17. 정답 ④ | 원문항 Q1-046 | 척와는 반정형(로그), 크롤링은 비정형 수집 기술 — 정형은 ETL·Sqoop.
18. 정답 ② | 원문항 Q1-049 | 새 속성 추가는 '속성 생성', 일반화는 하위 값을 상위 개념(연령대 등)으로 대체하는 기법.
19. 정답 ④ | 원문항 Q1-052 | 나이→연령대는 일반화, 일별→월별 합산은 집계 — 사례형은 '목적'으로 판별.
20. 정답 ① | 원문항 Q1-056 | BASE = 기본적 가용성+소프트 상태+최종 일관성, NoSQL의 느슨한 일관성 모델(ACID는 RDBMS).

2과목

21. 정답 ② | 원문항 Q2-001 | 어떤 변수와도 무관한 순수 우연 결측 = MCAR (다른 변수 의존=MAR, 결측값 자체 의존=MNAR).
22. 정답 ③ | 원문항 Q2-004 | 정렬 후 구간으로 나눠 대표값으로 대체하는 평활화 = 구간화(binning).
23. 정답 ④ | 원문항 Q2-005 | 다중 대치는 m회 반복해 m개 데이터셋을 만들고 결과를 결합 — "한 번만"은 단순 대치.
24. 정답 ① | 원문항 Q2-008 | 잡음은 무작위 오류값으로 평활화(구간화·회귀·군집화)로 완화 — 결측(없음)·이상값(범위 밖)과 구분.

25. 정답 ① | 원문항 Q2-011 | MAR/MNAR 정의 바꿔치기가 함정 — 완전분석법이 안전한 유일한 경우는 MCAR.
26. 정답 ① | 원문항 Q2-015 | 민맥스 = (60−20)/(100−20) = 0.5, 분자·분모 모두 최솟값 빼기.
27. 정답 ② | 원문항 Q2-017 | 모델 없이 통계 측도만 쓰는 것은 필터 기법 — 래퍼는 모델 반복 학습이라 비용이 큼.
28. 정답 ④ | 원문항 Q2-020 | 클래스 분리 최대화는 LDA — PCA는 분산 최대·직교·비지도.
29. 정답 ④ | 원문항 Q2-023 | 오버샘플링이 늘리는 대상은 소수 클래스 — 언더=다수 축소, 가중치=데이터 그대로.
30. 정답 ② | 원문항 Q2-025 | 서로 다른 클래스의 상호 최근접 쌍에서 다수 클래스를 제거 = 토멕 링크.
31. 정답 ① | 원문항 Q2-028 | 평균은 모든 값이 반영되어 이상값에 가장 민감 — 중앙값·최빈값·절사평균은 저항성 있음.
32. 정답 ③ | 원문항 Q2-032 | 변동계수 = 표준편차/평균, A=0.2 > B=0.1이므로 A의 상대적 산포가 큼.
33. 정답 ① | 원문항 Q2-036 | 범주형×범주형 관계는 산점도가 아니라 교차표(분할표)로 탐색.
34. 정답 ③ | 원문항 Q2-038 | 상관계수 0은 선형 관계 없음일 뿐 독립을 보장하지 않음(비선형 관계 가능).
35. 정답 ② | 원문항 Q2-041 | 순위는 있지만 간격이 불균등한 척도 = 순서척도(만족도 등급 등).
36. 정답 ③ | 원문항 Q2-044 | 일련번호+일정 간격 k마다 추출 = 계통추출(k=N/n).
37. 정답 ① | 원문항 Q2-046 | 이항분포 E(X)=np=20, V(X)=np(1−p)=16.
38. 정답 ① | 원문항 Q2-049 | 중심극한정리는 모집단 분포와 무관하게 성립 — "정규분포일 때만"은 정반대.
39. 정답 ③ | 원문항 Q2-052 | 명목척도는 산술평균 불가(최빈값 사용) — 나머지 ㄱ·ㄷ·ㄹ은 옳음.
40. 정답 ④ | 원문항 Q2-056 | 참인데 기각=1종 오류(α), 거짓인데 채택=2종 오류(β), 거짓-기각=옳은 결정(검정력 1−β).

3과목

41. 정답 ② | 원문항 Q3-001 | K-평균 군집은 레이블 없는 비지도학습 — 로지스틱 회귀는 이름과 달리 지도학습 분류.
42. 정답 ① | 원문항 Q3-003 | 목표변수가 범주형(이탈/유지)이면 분류, 연속형 수치(가격·매출)면 회귀.
43. 정답 ④ | 원문항 Q3-004 | 준지도학습은 레이블 정보를 활용하므로 비지도의 하위 유형이 아닌 별도 학습 유형.
44. 정답 ④ | 원문항 Q3-007 | 모형 구축 절차 = 요건 정의→모델링→검증 및 테스트→적용("요·모·검·적").
45. 정답 ② | 원문항 Q3-013 | 잔차 독립성(자기상관) 검정 = 더빈-왓슨 통계량(2에 가까우면 독립).
46. 정답 ④ | 원문항 Q3-014 | 다중공선성은 독립변수들 사이의 강한 상관 때문에 발생 — 종속-독립 간 상관은 무관.
47. 정답 ① | 원문항 Q3-019 | 단층 퍼셉트론은 선형 분리만 가능해 XOR 해결 불가 — 다층 퍼셉트론이 은닉층으로 해결.
48. 정답 ③ | 원문항 Q3-020 | 다중 클래스 확률 합=1 출력 = 소프트맥스(이진 출력은 시그모이드).
49. 정답 ① | 원문항 Q3-022 | 지지도=2/10=0.2, 신뢰도=2/5=0.4, 향상도=0.4/0.4=1.0(독립).
50. 정답 ④ | 원문항 Q3-026 | 오즈=p/(1−p)의 범위는 0~∞ — 0~1은 확률의 범위.
51. 정답 ④ | 원문항 Q3-029 | 분산(오차제곱합) 증가분 최소 병합 = 와드 연결법(단일=최단, 완전=최장, 평균=평균).
52. 정답 ② | 원문항 Q3-031 | 향상도=0.6/0.3=2 — >1이면 양의 연관, =1 독립, <1 음의 연관.

53. 정답 ③ | 원문항 Q3-034 | K-평균은 비지도 — 지도=로지스틱·SVM, 비지도=연관분석·SOM.
54. 정답 ④ | 원문항 Q3-038 | 정상성 3조건 = 평균 일정·분산 일정·공분산은 시차에만 의존.
55. 정답 ① | 원문항 Q3-039 | 고정 주기(1년 이내) 반복 변동 = 계절 요인(주기 불규칙·장기는 순환 요인).
56. 정답 ② | 원문항 Q3-044 | LSTM은 입력·망각·출력 게이트로 RNN의 기울기 소실·장기 의존성 문제를 해결.
57. 정답 ① | 원문항 Q3-047 | 생성→GAN, 라벨 없음·압축·복원 오차→오토인코더, 긴 순차·먼 문맥→LSTM.
58. 정답 ① | 원문항 Q3-050 | "문서=토픽 혼합, 토픽=단어 확률분포" 가정의 토픽 모델링 = LDA.
59. 정답 ④ | 원문항 Q3-051 | 감성 분석의 주 대상은 비정형 텍스트 — "정형 수치 전용"은 정반대 서술.
60. 정답 ④ | 원문항 Q3-056 | 부스팅은 오분류 가중치 기반 순차 학습 — 독립·병렬은 배깅의 특징.

4과목

61. 정답 ② | 원문항 Q4-001 | 제곱 평균의 제곱근 = RMSE, 종속변수와 같은 단위로 해석 가능.
62. 정답 ④ | 원문항 Q4-003 | R^2는 변수를 추가하면 감소하지 않으므로 변수 수 비교엔 수정 결정계수 사용.
63. 정답 ① | 원문항 Q4-007 | "예측 양성 중 실제 양성"은 정밀도 — 특이도는 실제 음성 중 음성 예측 비율 TN/(TN+FP).
64. 정답 ④ | 원문항 Q4-008 | ROC의 대각선은 무작위 분류(AUC=0.5) — 왼쪽 위 모서리에 가까울수록 좋은 모형.
65. 정답 ② | 원문항 Q4-010 | 정밀도 = TP/(TP+FP) = 30/40 = 0.75.
66. 정답 ④ | 원문항 Q4-014 | LpOCV는 ${}_nC_p$개 조합을 모두 반복하므로 LOOCV(n회)보다 계산량이 훨씬 많음.
67. 정답 ② | 원문항 Q4-018 | ROC 좌표 = (FPR, TPR) = (20/100, 40/50) = (0.2, 0.8).
68. 정답 ① | 원문항 Q4-020 | 절댓값 합 벌점으로 계수를 정확히 0으로 만드는 변수 선택 규제 = L1(라쏘).
69. 정답 ① | 원문항 Q4-023 | 복잡도 증가는 과대적합을 악화 — 해결책은 데이터 증강·단순화·규제·드롭아웃·조기 종료.
70. 정답 ① | 원문항 Q4-026 | 기울기가 0에 수렴하는 문제 = 기울기 소실, 양수 구간 기울기 1인 ReLU로 완화.
71. 정답 ② | 원문항 Q4-029 | 조기 종료의 중단 기준은 훈련 오차가 아니라 검증(validation) 오차 증가 시점.
72. 정답 ③ | 원문항 Q4-032 | 최종모형은 평가 데이터 성능+해석 가능성+운영 적용성을 종합 고려해 선정.
73. 정답 ② | 원문항 Q4-033 | 분석 결과는 비즈니스 목표(KPI)·기대 효과 중심의 언어로 의사결정자에게 전달.
74. 정답 ② | 원문항 Q4-037 | 회수 기간 = 투자비÷연간 순이익 = 12,000만÷3,000만 = 4년.
75. 정답 ④ | 원문항 Q4-042 | 값에 비례해 지도 면적을 왜곡하는 공간 시각화 = 카토그램.
76. 정답 ④ | 원문항 Q4-046 | 등치지역도는 공간 시각화 — 비교 시각화는 히트맵·스타 차트·평행 좌표·체르노프 페이스.
77. 정답 ① | 원문항 Q4-049 | 다변량+평행 축+선 연결 = 평행 좌표 그래프.
78. 정답 ② | 원문항 Q4-051 | 트리맵은 분포 시각화 — 계단식=시간, 버블 차트=관계, 히트맵=비교.
79. 정답 ① | 원문항 Q4-053 | 운영 중 주기적 성능 측정·저하 감지 = 모니터링(적용·배포는 전개).

> 80. 정답 ④ | 원문항 Q4-056 | 운영 사이클 = 전개→모니터링(측정)→저하 감지→리모델링.

채점표

문항당 **1.25점** 환산 (과목당 20문항 × 1.25점 = 25점, 총 100점 만점)

과목	맞힌 개수	점수(맞힌 개수 × 1.25)	과락 여부(8문항 미만 = 과락)
1과목 빅데이터 분석 기획 (1~20)	___ / 20	___ 점	통과 / 과락
2과목 빅데이터 탐색 (21~40)	___ / 20	___ 점	통과 / 과락
3과목 빅데이터 모델링 (41~60)	___ / 20	___ 점	통과 / 과락
4과목 빅데이터 결과 해석 (61~80)	___ / 20	___ 점	통과 / 과락
합계	___ / 80	___ / 100점	—

합격 판정

조건	기준	결과
총점	총 48문항(60점) 이상	충족 / 미달
과목별 과락	전 과목 8문항(40점) 이상	없음 / 있음
최종 판정	두 조건 모두 충족 시 **합격**	합격 / 불합격

이 문서는 LLM으로 생성 후 3중 검증(사실·논리·규격 / 중복 / 교체분 재검증)을 거친 학습 자료입니다. 교재별 표기가 갈리는 항목은 본문에 "※ 교재별 표기 차이 있음"으로 표시했으며, 상세 목록은 부록의 검증 필요 항목을 참고하세요.