빅데이터분석기사 필기 모의고사 2회

80문항 · 120분 · 계산기 사용 불가 — 정답·해설은 문제부 종료 후 새 페이지부터

the0ne 학습용 · 2026-09-01 생성 · KDATA 공개 출제기준 기반 신규 창작 문항 (기출 복원 아님)

빅데이터분석기사 필기 모의고사 2회

빅데이터분석기사 필기 모의고사 2회 · 총 80문항 · 120분 · 4지선다 · 계산기 사용 불가 · 합격: 평균 60점(총 48문항) 이상 AND 전 과목 40점(과목당 8문항) 이상

1과목 빅데이터 분석 기획 (1~20번)

1. 가트너(Gartner)가 제시한 빅데이터의 기본 3V에 해당하지 **않는** 것은?

① 규모(Volume) ② 속도(Velocity) ③ 다양성(Variety) ④ 신뢰성(Veracity)

2. 데이터 유형에 대한 설명으로 옳지 **않은** 것은?

① 정형 데이터는 미리 정의된 스키마에 따라 고정된 필드에 저장된다.
② 반정형 데이터는 스키마·메타데이터 정보를 데이터 내부에 포함하며 XML, JSON이 대표적이다.
③ 비정형 데이터는 정해진 구조가 없으며 동영상, 음성, 이미지 등이 해당한다.
④ 반정형 데이터는 메타데이터를 갖지 않으므로 구조 파악이 불가능하다.

3. 분석 전담 조직의 인력을 현업 부서에 직접 배치하여 분석 업무를 수행하게 하는 빅데이터 분석 조직 구조는?

① 집중 구조 ② 기능 구조 ③ 분산 구조 ④ 계층 구조

4. 빅데이터의 특성(V)에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 기본 3V는 규모(Volume), 속도(Velocity), 다양성(Variety)이다.
- ㄴ. 가치(Value)는 기본 3V에 포함되는 특성이다.
- ㄷ. 신뢰성(Veracity)은 수집한 데이터의 품질·정확성과 관련된 특성이다.
- ㄹ. 휘발성(Volatility)은 데이터가 의미를 갖고 저장·활용될 수 있는 기간과 관련된 특성이다.

① ㄱ, ㄷ, ㄹ ② ㄱ, ㄴ, ㄷ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄹ

5. 분산 환경에서 여러 서버가 공유하는 설정 정보의 유지·관리, 서버 간 동기화, 리더 선출(leader election) 등 분산 애플리케이션의 코디네이션(coordination)을 담당하는 하둡 에코시스템 컴포넌트는?

① Oozie ② Zookeeper ③ Avro ④ Hive

6. 클라우드 컴퓨팅 서비스 모델(IaaS/PaaS/SaaS)에 대한 설명으로 옳은 것은?

① IaaS는 응용 소프트웨어까지 완제품 형태로 제공한다.
② PaaS는 애플리케이션 개발·실행 환경을 제공하므로 이용자는 인프라를 직접 관리하지 않고 애플리케이션 개발·배포에 집중할 수 있다.
③ SaaS는 서버·스토리지·네트워크 등 인프라 자원만을 가상화하여 제공한다.
④ IaaS 이용자는 가상 서버의 운영체제(OS)를 직접 선택하거나 관리할 수 없다.

7. 개별 데이터 값을 데이터의 총합 또는 평균값으로 대체하여 개별 값이 드러나지 않도록 하는 비식별화(데이터 비식별 조치) 기법은?

① 총계처리 ② 가명처리 ③ 데이터 범주화 ④ 데이터 마스킹

8. 개인정보 보호법상 개인정보 처리(수집·이용)의 기본 원칙에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 적법하게 수집한 개인정보는 당초 수집 목적과 무관한 용도로도 제한 없이 이용할 수 있다.
② 개인정보의 처리 목적을 명확하게 하고, 그 목적에 필요한 최소한의 범위에서 수집하여야 한다.
③ 익명 처리로도 목적을 달성할 수 있는 경우에는 익명 처리를 우선하고, 익명 처리가 곤란하면 가명 처리에 의하도록 한다.
④ 처리 목적에 필요한 범위에서 개인정보의 정확성·완전성·최신성이 보장되도록 하여야 한다.

9. 분석 방법론과 각 방법론을 구성하는 단계 수의 연결이 모두 옳은 것은?

① KDD 5단계 — CRISP-DM 5단계 — SEMMA 6단계
② KDD 5단계 — CRISP-DM 6단계 — SEMMA 5단계
③ KDD 6단계 — CRISP-DM 5단계 — SEMMA 5단계
④ KDD 4단계 — CRISP-DM 6단계 — SEMMA 6단계

10. 다음 중 CRISP-DM 방법론의 6단계에 해당하지 **<u>않는</u>** 것은?

① 업무 이해(Business Understanding)
② 데이터 준비(Data Preparation)
③ 전개(Deployment)
④ 데이터 변환(Transformation)

11. 분석 과제 발굴의 상향식(bottom-up) 접근과 관련된 설명으로 옳지 **<u>않은</u>** 것은?

① 상향식 접근은 문제 정의 자체가 어려운 경우 데이터를 기반으로 통찰(insight)을 도출하는 방식이다.
② 프로토타이핑(prototyping) 접근은 일단 분석을 시도하고 결과를 확인하며 반복적으로 개선하는 시행착오 방식이다.
③ 디자인 씽킹(design thinking)은 상향식의 발산(diverge) 단계와 하향식의 수렴(converge) 단계를 반복하여 최적의 방안을 도출한다.
④ 상향식 접근은 문제가 명확히 주어진 상태에서 해법을 찾아가는 전통적 분석 과제 발굴 방식이다.

12. 빅데이터 분석 기획 단계에서 1차적으로 고려해야 할 사항으로 가장 적절한 것은?

① 분석 모형에 적용할 알고리즘의 하이퍼파라미터 튜닝 전략 수립
② 분석 결과 대시보드의 화면 배치와 차트 종류 확정
③ 분석 서버의 CPU 코어 수와 메모리 용량 확정
④ 활용 가능한 데이터의 존재 여부·유형 확인과 장애요소에 대한 사전계획 수립

13. 데이터 확보 계획 수립 절차를 순서대로 바르게 나열한 것은?

- ㄱ. 요구사항 도출 (필요 데이터·기술 지원 등)
- ㄴ. 예산안 수립
- ㄷ. 목표 정의 (성과 목표·성과 지표 설정)
- ㄹ. 계획 수립 (인력·일정·업무·예산 반영 계획서 작성)

① ㄷ → ㄴ → ㄱ → ㄹ
② ㄷ → ㄱ → ㄴ → ㄹ
③ ㄱ → ㄷ → ㄴ → ㄹ
④ ㄷ → ㄱ → ㄹ → ㄴ

14. 데이터 분석 프로젝트의 WBS(작업 분할 구조) 단계별 작업과 일정 계획에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 데이터 분석과제 정의 단계에서는 분석 목표 정의서를 기준으로 프로젝트 전체 일정에 맞춰 사전 준비를 한다.
- ㄴ. 데이터 준비 및 탐색 단계에서는 데이터 처리 담당자와 데이터 분석가의 역할을 구분하여 세부 일정을 수립한다.
- ㄷ. 데이터 분석 모델링 및 검증 단계는 데이터 준비 및 탐색 단계보다 먼저 수행한다.
- ㄹ. 산출물 정리 단계에서는 분석 결과와 산출물·프로그램(소스 코드)을 정리하여 프로젝트를 마무리한다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄴ, ㄹ ④ ㄱ, ㄷ, ㄹ

15. 서버-클라이언트 방식으로 동작하며, 수집 대상 시스템과 1:1로 연결하여 파일과 디렉터리를 동기화(미러링)하는 데 사용되는 데이터 수집 기술은?

① 리싱크(Rsync)
② FTP
③ RSS
④ Open API

16. 이벤트(event)와 에이전트(agent)를 기반으로 하며, 소스(source)–채널(channel)–싱크(sink) 구조로 대용량 로그 데이터를 안정적으로 수집하는 기술은?

① 플룸(Flume)
② 로그스태시(Logstash)
③ 스크라이브(Scribe)
④ 스쿱(Sqoop)

17. 파일 전송 프로토콜 FTP(File Transfer Protocol)에 대한 설명으로 옳은 것은?

① UDP 기반 프로토콜이므로 전송의 신뢰성을 보장하지 않는다.
② 능동(active) 모드에서는 클라이언트가 서버의 데이터 포트에 먼저 접속하여 데이터 연결을 생성한다.
③ 수동(passive) 모드에서는 서버가 알려 준 임의의 포트로 클라이언트가 접속하여 데이터 연결을 생성한다.
④ 제어(명령) 연결에는 기본적으로 20번 포트가 사용된다.

18. 문서 기반(Document Store) NoSQL 데이터베이스의 대표 제품은?

① Redis ② MongoDB ③ Neo4j ④ HBase

19. 하둡 분산 파일 시스템(HDFS)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 네임노드(NameNode)는 파일 시스템의 메타데이터를 관리한다.
② 데이터노드(DataNode)가 메타데이터를 저장하고, 네임노드가 실제 데이터 블록을 저장한다.
③ 파일은 블록(block) 단위로 분할되어 여러 데이터노드에 분산 저장된다.
④ 블록은 기본적으로 여러 노드에 복제 저장되어 일부 노드 장애 시에도 데이터를 보존할 수 있다.

20. 데이터 저장소에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 데이터 레이크는 원시(raw) 데이터를 원래 형식 그대로 저장하며, 스키마를 읽는 시점에 적용한다(Schema-on-Read).
② ODS는 데이터 웨어하우스 적재 전에 운영계 데이터를 임시로 통합·저장하는 저장소다.
③ 데이터 마트는 정형·비정형 원시 데이터를 가공 없이 그대로 축적한다는 점에서 데이터 레이크와 성격이 같

다.
④ 데이터 웨어하우스는 정제·통합된 정형 데이터를 적재 시점에 스키마에 맞춰 저장한다(Schema-on-Write).

2과목 빅데이터 탐색 (21~40번)

21. 소득 설문조사에서 고소득자일수록 자신의 소득 노출을 꺼려 소득 문항에 응답하지 않는 경향이 확인되었다. 이 소득 변수의 결측 유형은?

① 완전 무작위 결측(MCAR)
② 무작위 결측(MAR)
③ 표본 추출 오류
④ 비무작위 결측(MNAR)

22. 관측치 주변의 국소 밀도(local density)를 k-최근접 이웃들의 밀도와 비교하여, 이웃들에 비해 상대적으로 밀도가 낮은 곳에 있는 관측치를 이상값으로 판별하는 기법은?

① 아이솔레이션 포레스트(iForest, Isolation Forest)
② 국소 이상치 요인(LOF, Local Outlier Factor)
③ ESD(Extreme Studentized Deviate)
④ 사분위수 범위(IQR) 규칙

23. 건강 설문에서 성별에 따라 체중 문항의 무응답률이 다르게 나타났으나, 같은 성별 집단 안에서는 무응답이 체중 값 자체와는 무관하게 발생했다. 이 체중 변수의 결측 유형은?

① 완전 무작위 결측(MCAR)
② 무작위 결측(MAR)
③ 비무작위 결측(MNAR)
④ 잡음(noise)

24. 결측값 대치법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 핫덱(hot-deck) 대치는 현재 진행 중인 같은 조사(데이터셋) 안에서 유사한 특성을 가진 다른 응답자의 값을 가져와 대치한다.
② 콜드덱(cold-deck) 대치는 과거 조사나 외부 자료 등 다른 출처의 값을 가져와 대치한다.
③ 평균 대치법은 결측값을 평균으로 채우므로 자료의 분산이 실제보다 커지는 문제가 있다.
④ 확률적 회귀 대치는 회귀 예측값에 오차항을 더해 대치함으로써 단순 회귀 대치의 변동성 과소평가를 보완한다.

25. 모델 학습 없이 상관계수, 카이제곱 통계량, 정보 이득(information gain) 등 통계적 측도만으로 변수의 유의성을 평가하여 선택하는 변수 선택 방식은?

① 래퍼(wrapper) 기법 ② 필터(filter) 기법 ③ 임베디드(embedded) 기법 ④ 배깅(bagging) 기법

26. 파생변수(derived variable)에 대한 설명으로 가장 적절한 것은?

① 여러 관측치를 합계·평균 등으로 집계한 변수로, 재활용성이 높다.
② 원본 변수를 다른 이름으로 그대로 복사해 저장한 변수다.
③ 누구에게나 의미가 같은 객관적 변수이므로 별도의 정당성 검토가 필요 없다.

④ 분석자가 특정 목적에 따라 조건·함수 등 논리적 가공으로 새로 정의한 변수로, 주관적일 수 있어 타당한 근거가 필요하다.

27. 변수 선택의 임베디드(embedded) 기법에 해당하는 것으로만 묶인 것은?

① 라쏘(LASSO), 릿지(Ridge), 엘라스틱넷(Elastic Net)
② 전진 선택법, 후진 제거법, 단계적 방법
③ 상관계수, 카이제곱 검정, 정보 이득
④ 주성분분석(PCA), 요인분석, 다차원척도법(MDS)

28. 클래스(범주) 정보를 이용하여 클래스 간 분산은 최대화하고 클래스 내 분산은 최소화하는 축으로 데이터를 사영(projection)하는 차원축소 기법은?

① 주성분분석(PCA) ② 선형판별분석(LDA) ③ 다차원척도법(MDS) ④ 특이값분해(SVD)

29. 분석 변수 처리에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 원-핫 인코딩(one-hot encoding)은 범주마다 0/1의 이진 변수를 생성하여 명목형 변수를 수치화하며, 범주 수가 많으면 변수(차원)의 수가 크게 늘어난다.
- ㄴ. 레이블 인코딩(label encoding)은 각 범주에 정수를 부여하는 방식으로, 명목형 범주 사이에 실제로는 존재하지 않는 크기(순서) 관계가 생길 수 있다.
- ㄷ. 차원의 저주(curse of dimensionality)는 변수(차원)가 늘어날수록 데이터가 공간에 희소(sparse)해져 분석 성능이 저하되는 현상으로, 차원축소나 변수 선택으로 완화할 수 있다.
- ㄹ. 연속형 변수를 구간화(binning)하여 범주형으로 변환하면 정보의 손실은 전혀 발생하지 않는다.

① ㄱ, ㄷ, ㄹ ② ㄴ, ㄹ ③ ㄱ, ㄴ, ㄹ ④ ㄱ, ㄴ, ㄷ

30. 박스플롯(box plot)을 통해 직접 확인할 수 **<u>없는</u>** 것은?

① 중앙값 ② 사분위범위(IQR) ③ 최빈값 ④ 이상값

31. 자료 3, 4, 5, 6, 22 에 대한 설명으로 옳은 것은?

① 평균과 중앙값은 모두 5이다.
② 평균은 8, 중앙값은 5로 평균이 중앙값보다 크다.
③ 평균은 5, 중앙값은 8로 중앙값이 평균보다 크다.
④ 극단값 22를 제거해도 평균은 변하지 않는다.

32. 상관분석에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 피어슨(Pearson) 상관계수는 연속형 자료 간 선형 관계의 정도를 측정한다.
② 스피어만(Spearman) 상관계수는 두 변수가 정규분포를 따르는 연속형 자료일 때만 사용할 수 있다.
③ 스피어만 상관계수는 자료를 순위로 변환해 계산하므로 이상값의 영향을 덜 받는다.
④ 상관계수는 −1 이상 +1 이하의 값을 갖는다.

33. 비정형 데이터 유형별 탐색 방법에 대한 설명으로 옳은 것은?

① 이미지 데이터는 형태소 분석(morphological analysis)으로 품사 단위로 분해하여 탐색한다.
② 오디오 데이터는 픽셀(pixel) 값의 행렬로 표현하여 밝기 분포를 탐색한다.
③ 텍스트 데이터는 스펙트로그램(spectrogram)으로 변환하여 주파수 성분을 탐색한다.
④ 텍스트 데이터는 토큰화·형태소 분석을 거쳐 단어 빈도를 집계하고 워드클라우드 등으로 탐색한다.

34. 고급 데이터 탐색에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 코로플레스맵(choropleth map)은 면적이 넓은 지역이 실제 값보다 과대하게 인식될 수 있으며, 카토그램(cartogram)은 통계값에 비례해 지역 면적을 변형하여 이를 보완한다.
- ㄴ. 상관행렬을 히트맵(heatmap)으로 시각화하면 다변량 변수 간 상관 구조를 한눈에 파악할 수 있다.
- ㄷ. 산점도 행렬은 변수 쌍 간의 선형·비선형 관계와 이상값(outlier)을 시각적으로 탐색하는 데 활용된다.
- ㄹ. 두 변수의 상관계수 절댓값이 크면 두 변수 사이에 인과관계(causality)가 있다고 결론지을 수 있다.

① ㄱ, ㄴ, ㄷ ② ㄱ, ㄴ, ㄹ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄷ, ㄹ

35. 다음 중 비율척도(ratio scale)로 측정된 자료에 해당하는 것은?

① 환자의 혈액형(A, B, O, AB)
② 설문 응답의 만족도(매우 불만족~매우 만족)
③ 서울의 오늘 기온(섭씨 25도)
④ 택배 상자의 무게(3.2kg)

36. 연속확률분포에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 표준정규분포는 평균이 0, 분산이 1인 정규분포다.
② t분포는 모분산을 모르는 소표본에서 모평균을 추론할 때 사용한다.
③ 카이제곱분포는 모분산의 추론이나 적합도 검정 등에 사용한다.
④ F분포는 좌우 대칭인 분포로, 한 집단의 모평균 검정에 사용한다.

37. 이산확률분포에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 베르누이 시행은 결과가 성공 또는 실패 두 가지뿐인 1회의 시행이다.
② 이항분포는 서로 독립인 베르누이 시행을 n번 반복할 때 성공 횟수가 따르는 분포다.
③ 포아송분포는 단위 시간이나 단위 공간에서 드물게 발생하는 사건의 횟수를 모형화한다.
④ 포아송분포의 기댓값은 λ, 분산은 λ^2로 서로 다르다.

38. 표본에서 계산한 추정량(estimator)의 기댓값이 추정하려는 모수(parameter)와 일치하는 점추정량의 성질은?

① 효율성(efficiency) ② 불편성(unbiasedness) ③ 일치성(consistency) ④ 충족성(sufficiency)

39. 가설 설정과 양측·단측 검정에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 귀무가설(null hypothesis)은 "차이가 없다·효과가 없다"처럼 기존 입장을 나타내며 등호(=)를 포함해 설정한다.
② 대립가설이 "$\mu \neq 100$" 형태이면 기각역을 한쪽에만 두는 단측 검정을 수행한다.
③ 대립가설(alternative hypothesis)은 연구자가 표본의 증거로 입증하고자 하는 새로운 주장이다.
④ 대립가설이 "$\mu > 100$" 형태이면 기각역을 오른쪽 한쪽에 두는 단측 검정을 수행한다.

40. 1종 오류, 2종 오류, 검정력의 관계에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 1종 오류는 귀무가설이 참인데 기각하는 오류이며, 그 확률의 최대 허용치가 유의수준 α다.
② 다른 조건이 동일할 때 α를 작게 하면 β는 커지는 상충(trade-off) 관계가 있다.
③ 검정력(1-β)은 귀무가설이 거짓일 때 이를 올바르게 기각할 확률이다.
④ 표본의 크기를 늘리면 α와 β가 동시에 커져 검정의 정확도가 낮아진다.

3과목 빅데이터 모델링 (41~60번)

41. 에이전트(agent)가 환경(environment)과 상호작용하면서 행동에 대한 보상(reward)을 받고, 누적 보상을 최대화하는 행동 정책을 스스로 학습해 나가는 머신러닝 방식은?

① 지도학습(supervised learning)
② 비지도학습(unsupervised learning)
③ 강화학습(reinforcement learning)
④ 준지도학습(semi-supervised learning)

42. 분석 모형의 분류에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 회귀 분석, 분산 분석 등 통계 기반 모형은 가설 검정 없이 수행되므로 결과의 확률적 해석이 불가능하다.
② 데이터 마이닝(data mining) 모형은 대용량 데이터에서 유의미한 패턴·규칙을 발견하는 것으로 분류·예측·군집·연관 분석 등이 있다.
③ 머신러닝(machine learning) 모형은 데이터로부터 학습하여 성능을 개선하며, 지도·비지도·강화학습으로 구분된다.
④ 회귀 분석처럼 하나의 기법이 통계 기반 모형이면서 동시에 머신러닝의 지도학습 기법으로 분류되기도 한다.

43. 분석 모형 구축 절차의 단계별 수행 활동에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 요건 정의 단계에서는 분석 요구사항을 도출하고 우선순위를 정하여 분석 추진 계획을 수립한다.
- ㄴ. 모델링 단계에서는 분석용 데이터(마트)를 준비하고 탐색적 분석과 모델링을 수행한다.
- ㄷ. 검증 및 테스트 단계에서는 학습 데이터와 검증 데이터를 분리하지 않고 전체 데이터를 그대로 사용해 성능을 평가한다.
- ㄹ. 적용 단계에서는 모형을 운영 시스템에 배포하고 주기적인 모니터링과 재학습(모델 업데이트)을 수행한다.

① ㄱ, ㄴ, ㄷ
② ㄴ, ㄷ, ㄹ
③ ㄱ, ㄴ, ㄹ
④ ㄱ, ㄹ

44. 빅데이터 분석 환경으로서 R과 Python(파이썬)에 대한 설명으로 가장 적절한 것은?

① R은 통계 분석에 특화된 오픈소스 언어이며, Python은 범용 언어로 웹 개발 등 다른 시스템과의 연동·확장에 유리하다.
② Python의 pandas는 R의 CRAN에 해당하는 것으로, 패키지를 배포·설치하는 중앙 저장소 역할을 한다.
③ R은 데이터를 메모리에 올려 처리하는 인메모리(in-memory) 방식이 아니므로, 대용량 데이터 처리 시 메모리 용량의 제약을 받지 않는다.
④ R은 웹 개발 등 여러 분야에서 쓰이도록 설계된 범용 언어이고, Python은 통계학자를 위해 개발된 통계 전용 언어이다.

45. 로지스틱 회귀(logistic regression)에서 출력값을 0과 1 사이의 확률로 변환하기 위해 사용하는 시그모이드(sigmoid) 함수의 식은?

① $f(x) = 1 / (1 + e^{-x})$
② $f(x) = (e^{x} - e^{-x}) / (e^{x} + e^{-x})$

③ $f(x) = \max(0, x)$
④ $f(x) = e^{(x_i)} / \Sigma_j e^{(x_j)}$ (i번째 클래스 점수의 지수를 모든 클래스 j의 지수합으로 나눔)

46. 어떤 마케팅 캠페인에서 고객이 상품을 구매할 확률이 0.8이라고 한다. 이때 구매에 대한 오즈(odds)는?

① 0.25 ② 0.8 ③ 4 ④ 5

47. 서포트 벡터 머신(SVM, Support Vector Machine)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 두 클래스 사이의 마진(margin)을 최대화하는 결정 경계(초평면)를 찾는다.
② 서포트 벡터(support vector)는 결정 경계에서 가장 멀리 떨어져 있는 데이터들이다.
③ 커널 트릭(kernel trick)은 저차원에서 선형 분리가 어려운 데이터를 고차원 공간으로 매핑하여 분리하는 기법이다.
④ 슬랙 변수(slack variable)를 도입하면 일부 오분류를 허용하는 소프트 마진(soft margin) 분류가 가능하다.

48. 군집분석(clustering)에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. K-평균 군집(K-means)은 초기 중심값의 선택과 이상값(outlier)에 민감하다.
- ㄴ. 단일 연결법(single linkage)은 두 군집 간 관측치 쌍의 거리 중 가장 먼 거리를 군집 간 거리로 사용한다.
- ㄷ. DBSCAN은 밀도 기반 군집 방법으로, 군집 수를 사전에 지정할 필요가 없고 노이즈(noise)를 별도로 식별한다.
- ㄹ. 실루엣 계수(silhouette coefficient)는 -1에서 1 사이의 값을 가지며 1에 가까울수록 군집화가 잘 된 것이다.

① ㄱ, ㄴ, ㄷ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄴ ④ ㄱ, ㄷ, ㄹ

49. 선형 회귀분석의 가정 중 '잔차(오차항)의 분산이 독립변수의 값에 관계없이 일정해야 한다'는 것은?

① 선형성(linearity)
② 등분산성(homoscedasticity)
③ 정규성(normality)
④ 독립성(independence)

50. K-평균 군집(K-means clustering)의 수행 절차를 순서대로 바르게 나열한 것은?

- ㄱ. 군집 수 K를 정하고 초기 중심점(centroid)을 선택한다.
- ㄴ. 각 관측치를 가장 가까운 중심점의 군집에 할당한다.
- ㄷ. 각 군집에 속한 관측치들의 평균으로 중심점을 갱신한다.
- ㄹ. 중심점이 더 이상 변하지 않을 때까지 할당과 갱신을 반복한다.

① ㄱ → ㄷ → ㄴ → ㄹ
② ㄱ → ㄴ → ㄷ → ㄹ
③ ㄴ → ㄱ → ㄷ → ㄹ
④ ㄱ → ㄴ → ㄹ → ㄷ

51. 인공신경망의 활성화 함수(activation function)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 하이퍼볼릭 탄젠트(tanh) 함수의 출력 범위는 -1에서 1 사이다.
② ReLU 함수는 $f(x) = \max(0, x)$로, 양수 구간의 기울기가 1이어서 기울기 소실(gradient vanishing) 문제를 완화한다.
③ 시그모이드(sigmoid) 함수는 입력의 절댓값이 커지면 기울기가 0에 가까워져 깊은 신경망에서 기울기 소실

을 유발할 수 있다.
④ ReLU 함수는 출력 범위가 0과 1 사이이므로 이진 분류의 출력층에서 확률로 바로 사용된다.

52. 하나의 표본을 두 개의 범주형 변수로 교차분류한 분할표(contingency table)를 이용하여, 두 변수 사이에 연관성이 있는지를 검정하는 카이제곱 검정의 용도는?

① 적합도 검정 ② 독립성 검정 ③ 동질성 검정 ④ 등분산 검정

53. ARIMA(p, d, q) 모형의 각 차수에 대한 설명으로 옳은 것은?

① p는 이동평균 부분의 차수를 의미한다.
② d는 시계열을 정상화하기 위해 수행한 차분의 횟수를 의미한다.
③ q는 자기회귀 부분의 차수를 의미한다.
④ d는 계절 주기의 길이를 의미한다.

54. 시계열 모형에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. AR 모형은 자기 자신의 과거 관측값들의 선형결합으로 현재 값을 설명한다.
- ㄴ. MA 모형은 과거 예측 오차(백색잡음)들의 선형결합으로 현재 값을 설명한다.
- ㄷ. 백색잡음(white noise)은 평균이 0, 분산이 일정하며 자기상관이 없는 시계열이다.
- ㄹ. 평균이 일정하지 않은 비정상 시계열에는 차분 없이 ARMA 모형을 바로 적합하는 것이 원칙이다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄴ, ㄷ ④ ㄱ, ㄷ, ㄹ

55. 합성곱(convolution) 연산으로 이미지의 지역적 특징을 추출하고 풀링(pooling)으로 차원을 줄여, 이미지 인식에 특히 뛰어난 성능을 보이는 딥러닝 모델은?

① 합성곱 신경망(CNN)
② 순환 신경망(RNN)
③ 생성적 적대 신경망(GAN)
④ 오토인코더(autoencoder)

56. 생성적 적대 신경망(GAN)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 생성자(generator)는 실제와 유사한 가짜 데이터를 만들어 낸다.
② 판별자(discriminator)는 입력된 데이터가 실제인지 생성된 것인지 구별한다.
③ 생성자와 판별자는 동일한 목적함수를 최소화하며 서로 협력하도록 학습된다.
④ 학습이 진행될수록 생성자가 만든 데이터는 실제 데이터와 구별하기 어려워진다.

57. 사회 연결망 분석(SNA)에서 한 노드가 다른 노드들 사이의 최단 경로 위에 위치하여 정보 흐름을 중개하는 '다리(bridge) 역할'의 정도를 측정하는 중심성은?

① 연결 중심성(degree centrality)
② 매개 중심성(betweenness centrality)
③ 근접 중심성(closeness centrality)
④ 위세 중심성(eigenvector centrality)

58. 사회 연결망 분석(SNA)의 중심성 지표에 대한 설명 (ㄱ)~(ㄷ)과 명칭을 바르게 연결한 것은?

- ㄱ. 한 노드에 직접 연결된 노드의 수로 측정한다.
- ㄴ. 다른 모든 노드까지의 최단거리가 가까울수록 값이 커진다.
- ㄷ. 연결된 이웃 노드가 중요할수록 자신의 값도 커진다.

① ㄱ: 연결 중심성 — ㄴ: 매개 중심성 — ㄷ: 위세 중심성
② ㄱ: 근접 중심성 — ㄴ: 연결 중심성 — ㄷ: 위세 중심성
③ ㄱ: 연결 중심성 — ㄴ: 근접 중심성 — ㄷ: 위세 중심성
④ ㄱ: 연결 중심성 — ㄴ: 근접 중심성 — ㄷ: 매개 중심성

59. 배깅(bagging)과 부스팅(boosting)의 비교에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 배깅은 부트스트랩 표본으로 각 모델을 서로 독립적·병렬적으로 학습시킨다.
- ㄴ. 부스팅은 이전 모델의 오분류에 가중치를 부여하며 순차적으로 학습시킨다.
- ㄷ. 배깅은 주로 분산(variance)을 줄이고, 부스팅은 주로 편향(bias)을 줄이는 효과가 있다.
- ㄹ. 랜덤포레스트(random forest)는 부스팅 계열의 대표적인 알고리즘이다.

① ㄱ, ㄴ ② ㄱ, ㄴ, ㄷ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄷ, ㄹ

60. 비모수 검정(non-parametric test)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 모집단의 분포에 대한 엄격한 가정 없이 사용할 수 있다.
② 관측값 자체보다 관측값의 순위(rank)나 부호(sign)를 이용해 검정한다.
③ 런 검정(run test)은 표본 자료의 배열이 무작위인지를 검정하는 비모수 기법이다.
④ 모집단이 정규분포를 따르는 경우에도 비모수 검정이 모수 검정보다 검정력이 항상 높다.

4과목 빅데이터 결과 해석 (61~80번)

61. 어떤 회귀모형에서 전체제곱합(SST)이 100, 오차제곱합(SSE)이 25일 때, 결정계수(R^2)는?

① 0.25 ② 0.50 ③ 0.75 ④ 0.80

62. 모형 선택 기준인 AIC(아카이케 정보기준)와 BIC(베이즈 정보기준)에 대한 설명으로 옳은 것은?

① AIC와 BIC는 모두 값이 작을수록 좋은 모형으로 평가한다.
② AIC는 값이 클수록 적합도가 높은 좋은 모형을 의미한다.
③ BIC는 AIC보다 모형의 변수(모수) 수에 대한 벌점이 약하다.
④ AIC는 모형의 복잡도에 대한 벌점 없이 적합도만으로 계산한다.

63. 모형 평가를 위한 데이터 분할·재추출 기법에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 홀드아웃(hold-out)은 데이터를 학습용과 평가용으로 한 번만 나누므로, 분할 방식에 따라 평가 결과가 달라질 수 있다.
- ㄴ. k-겹 교차검증(k-fold cross validation)은 데이터를 k개의 폴드로 나누어 각 폴드를 한 번씩 평가용으로 사용하고 k번의 결과를 평균한다.
- ㄷ. LOOCV(leave-one-out cross validation)는 k-겹 교차검증에서 k를 전체 데이터 개수 n과 같게 한 특수한 경우다.
- ㄹ. 부트스트랩(bootstrap)에서 어떤 관측치가 하나의 부트스트랩 표본에 한 번도 포함되지 않을 확률은 표본이 충분히 클 때 약 63.2%다.

① ㄱ, ㄴ ② ㄱ, ㄴ, ㄷ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄴ, ㄷ, ㄹ

64. 관측도수와 기대도수의 차이를 이용하여 표본 데이터가 가정한 분포(비율)에 적합한지를 검정하는 방법은?

① 콜모고로프-스미르노프(K-S) 검정 ② 샤피로-윌크(Shapiro-Wilk) 검정 ③ 카이제곱(χ^2) 적합도 검정 ④ Q-Q 플롯(Q-Q plot)

65. 어떤 분류모형의 혼동행렬이 TP=30, FN=20, FP=5, TN=45일 때, 거짓긍정률(FPR, false positive rate)은?

① 0.10 ② 0.90 ③ 0.40 ④ 0.60

66. 어떤 마케팅 반응 예측 모형으로 점수 상위 10% 고객을 추출했더니 반응률이 20%였다. 전체 고객의 평균 반응률이 5%일 때, 이 구간의 향상도(lift)는?

① 0.25 ② 2 ③ 4 ④ 15

67. 신경망 학습 과정에서 매 반복(iteration)마다 일부 뉴런(노드)을 무작위로 제외하고 학습시켜 과대적합을 방지하는 기법은?

① 배치 정규화(batch normalization)
② 조기 종료(early stopping)
③ 드롭아웃(dropout)
④ 데이터 증강(data augmentation)

68. 경사하강법(gradient descent)의 세 가지 방식에 대한 설명으로 옳은 것은?

① 배치 경사하강법(batch GD)은 매 갱신마다 데이터 1건만 사용하므로 계산이 가장 빠르다.
② 확률적 경사하강법(SGD)은 전체 데이터를 모두 사용하므로 갱신 방향이 가장 안정적이다.
③ 미니배치 경사하강법(mini-batch GD)은 전체와 1건의 절충으로, 일정 크기의 묶음 단위로 갱신한다.
④ 확률적 경사하강법(SGD)은 배치 경사하강법보다 항상 안정적으로 수렴한다.

69. 경사하강법의 학습률(learning rate)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 학습률이 지나치게 크면 최적값을 지나쳐 진동하거나 발산할 수 있다.
② 학습률이 지나치게 작으면 수렴 속도가 매우 느려지고 지역 최소값에 머무를 수 있다.
③ 학습률은 학습 전에 사용자가 설정하는 하이퍼파라미터다.
④ 학습률은 클수록 항상 더 정확한 최적해에 도달한다.

70. 규제(regularization) 기법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 라쏘(Lasso)는 L1 벌점을 사용하여 희소(sparse)한 모형을 만든다.
② 릿지(Ridge)는 계수를 0에 가깝게 축소하지만 정확히 0으로 만들지는 않는다.
③ 엘라스틱넷(Elastic Net)은 L1과 L2 벌점을 함께 사용하는 절충 기법이다.
④ L2 규제는 일부 계수를 정확히 0으로 만들기 때문에 변수 선택 목적으로 주로 사용된다.

71. 투자안의 순현재가치(NPV)가 0이 되도록 만드는 할인율을 의미하는 비즈니스 기여도 평가 지표는?

① 투자 대비 이익률(ROI)
② 총 소유 비용(TCO)
③ 내부수익률(IRR)
④ 투자 회수 기간(payback period)

72. 비즈니스 기여도 평가 지표에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 투자 대비 이익률(ROI)은 순현재가치가 0이 되도록 하는 할인율을 의미한다.
② 순현재가치(NPV)는 미래 현금흐름의 현재가치에서 투자 비용을 뺀 값이다.

③ 총 소유 비용(TCO)은 자산의 획득뿐 아니라 운영·유지보수 등 전 기간의 비용을 합산한 것이다.
④ 투자 회수 기간(payback period)은 누적 이익이 투자 비용에 도달하는 데 걸리는 기간이다.

73. 분석 결과의 비즈니스 기여도 평가에 대한 설명으로 옳지 **않은** 것은?

① 순현재가치(NPV)가 0보다 크면 해당 투자는 타당성이 있다고 판단한다.
② 내부수익률(IRR)이 요구수익률보다 크면 투자 매력이 있다고 판단한다.
③ 투자 회수 기간(payback period)은 길수록 투자 위험이 낮다고 판단한다.
④ 총 소유 비용(TCO)은 도입 비용뿐 아니라 운영·유지보수 비용까지 포함하여 비교한다.

74. 순현재가치(NPV)와 내부수익률(IRR) 등에 대한 설명으로 옳지 **않은** 것은?

① 내부수익률(IRR)은 적용하는 할인율이 높아질수록 함께 커지는 지표다.
② 순현재가치(NPV)는 미래 현금흐름을 할인율로 현재가치화한 값에서 투자비를 뺀 것으로, 일반적인 투자안에서 할인율이 높아지면 작아진다.
③ 일반적인(초기 투자 후 이익이 발생하는) 투자안에서 IRR이 요구수익률보다 크면 그 투자안의 NPV는 0보다 크다.
④ 투자 회수 기간(payback period)은 화폐의 시간가치를 고려하지 않는 한계가 있다.

75. 다음 중 분포 시각화 기법에 해당하지 **않는** 것은?

① 산점도(scatter plot)
② 파이 차트(pie chart)
③ 도넛 차트(donut chart)
④ 트리맵(treemap)

76. 다음 중 관계 시각화 기법으로만 묶인 것은?

① 산점도, 버블 차트, 히스토그램
② 산점도, 파이 차트, 히트맵
③ 버블 차트, 트리맵, 선 그래프
④ 히스토그램, 도넛 차트, 카토그램

77. 인포그래픽(infographic)에 대한 설명으로 옳지 **않은** 것은?

① 정보(information)와 그래픽(graphic)의 합성어로, 복잡한 정보를 그래픽으로 표현한 것이다.
② 도표·일러스트 등을 활용해 정보를 쉽고 빠르게 전달하며 대중의 흥미를 유발한다.
③ 스토리텔링 방식으로 메시지를 전달할 수 있어 홍보·보도 자료 등에 널리 활용된다.
④ 분석 전문가를 대상으로 원시 데이터와 통계 수치를 표 형태로 빠짐없이 나열하는 것을 목적으로 한다.

78. 공간 시각화 기법의 특징에 대한 설명으로 옳지 **않은** 것은?

① 등치지역도(choropleth map)는 지역별 값을 색상의 음영·농도로 표현하며, 면적이 큰 지역이 실제 값보다 강조되어 보이는 왜곡이 생길 수 있다.
② 도트맵(dot map)은 데이터 값을 지도 위 점의 개수·밀도로 표현하여 분포 양상을 보여준다.
③ 카토그램(cartogram)은 지역의 실제 면적을 그대로 유지한 채 색상만으로 데이터 값을 표현한다.
④ 버블 플롯맵(bubble plot map)은 지도 위 해당 위치에 원의 크기로 데이터 값을 표현한다.

79. 분석모형 전개(deployment)에 대한 설명으로 옳지 **않은** 것은?

① 전개는 개발·검증이 완료된 분석모형을 실제 운영 환경에 적용하는 과정이다.
② 전개 시 운영 시스템과의 인터페이스, 데이터 연계, 호환성을 고려해야 한다.

③ 전개가 완료되면 분석모형에 대한 관리는 종료되며 이후 별도의 점검이 필요 없다.
④ 전개 이후에도 모형의 성능이 유지되는지 지속적으로 모니터링해야 한다.

80. 어느 통신사가 고객 이탈 예측 모형을 개발하였다. 다음 중 이 모형의 분석 결과 활용 시나리오(utilization scenario)가 가장 적절하게 수립된 사례는?

① 모형이 산출한 이탈 고위험 고객 목록을 매주 월요일 고객관리팀에 전달하고, 상담원이 해당 고객에게 맞춤 혜택을 안내하도록 업무 절차에 반영한다.
② 분석 결과를 회사 경영 전반의 발전에 다양한 방식으로 폭넓게 활용한다.
③ 모형의 예측 정확도를 95% 이상으로 끌어올리는 것을 활용 목표로 설정한다.
④ 분석 결과 보고서를 사내 공유 폴더에 업로드하여 보관하는 것으로 마무리한다.

⚠️ **이 아래는 정답입니다 — 채점 전 스크롤 주의**

✓ 정답 및 해설 보기

정답표

1과목	정답	2과목	정답	3과목	정답	4과목	정답
1	④	21	④	41	③	61	③
2	④	22	②	42	①	62	①
3	③	23	②	43	③	63	②
4	①	24	③	44	①	64	③
5	②	25	②	45	①	65	①
6	②	26	④	46	③	66	③
7	①	27	①	47	②	67	③
8	①	28	②	48	④	68	③
9	②	29	④	49	②	69	④
10	④	30	③	50	②	70	④
11	④	31	②	51	④	71	③
12	④	32	②	52	②	72	①
13	②	33	④	53	②	73	③
14	③	34	①	54	③	74	①
15	①	35	④	55	①	75	①
16	①	36	④	56	③	76	①
17	③	37	④	57	②	77	④
18	②	38	②	58	③	78	③
19	②	39	②	59	②	79	③
20	③	40	④	60	④	80	①

문항별 한 줄 해설

상세 해설은 문제집(문제은행)의 각 원문항을 참조하세요.

1과목

1. 정답 ④ | 원문항 Q1-002 | 3V = Volume·Velocity·Variety이며 Veracity는 5V에서 추가되는 요소.
2. 정답 ④ | 원문항 Q1-005 | 반정형은 메타데이터(태그·키)를 포함하므로 구조 파악이 가능하다.
3. 정답 ③ | 원문항 Q1-008 | 분산 구조 = 분석 전담 인력을 현업 부서에 직접 배치하는 조직 구조.

4. 정답 ① | 원문항 Q1-010 | Value는 3V가 아니라 5V에서 추가되는 특성 — 옳은 것은 ㄱ·ㄷ·ㄹ.
5. 정답 ② | 원문항 Q1-012 | Zookeeper = 분산 환경의 설정 관리·동기화·리더 선출 코디네이션 서비스.
6. 정답 ② | 원문항 Q1-017 | PaaS = 개발·실행 플랫폼 제공, 인프라 관리는 사업자 몫.
7. 정답 ① | 원문항 Q1-021 | 총계처리 = 개별 값을 총합·평균 등 통계값으로 대체하는 비식별화 기법.
8. 정답 ① | 원문항 Q1-024 | 개인정보는 수집 목적 범위 내에서만 처리 가능 — "제한 없이 이용"은 원칙 위반.
9. 정답 ② | 원문항 Q1-025 | 단계 수 = KDD 5 / CRISP-DM 6 / SEMMA 5 ("5-6-5").
10. 정답 ④ | 원문항 Q1-028 | 데이터 변환은 KDD의 단계이며 CRISP-DM에서는 데이터 준비에 포함된다.
11. 정답 ④ | 원문항 Q1-033 | 문제가 명확히 주어진 상태에서 해법을 찾는 것은 하향식 접근이다.
12. 정답 ④ | 원문항 Q1-036 | 기획 시 고려사항 = 가용 데이터·유스케이스·장애요소 사전계획.
13. 정답 ② | 원문항 Q1-039 | 데이터 확보 계획 절차 = 목표 정의 → 요구사항 도출 → 예산안 → 계획 수립.
14. 정답 ③ | 원문항 Q1-040 | 모델링·검증은 데이터 준비·탐색 이후 — WBS 4단계는 정의→준비→모델링→산출물.
15. 정답 ① | 원문항 Q1-042 | Rsync = 서버-클라이언트 1:1 파일·디렉터리 동기화(미러링) 기술.
16. 정답 ① | 원문항 Q1-047 | 플룸 = 이벤트·에이전트 기반, 소스–채널–싱크 구조의 로그 수집기.
17. 정답 ③ | 원문항 Q1-050 | 수동 모드 = 서버가 알려 준 임의 포트로 클라이언트가 접속해 데이터 연결 생성.
18. 정답 ② | 원문항 Q1-053 | 문서 기반 NoSQL의 대표 제품은 MongoDB (Redis=키-값, Neo4j=그래프, HBase=컬럼).
19. 정답 ② | 원문항 Q1-057 | 네임노드=메타데이터, 데이터노드=실제 블록 저장 — 역할을 뒤바꾼 선지.
20. 정답 ③ | 원문항 Q1-059 | 데이터 마트는 정제된 정형 데이터의 주제별 저장소로, 원시 데이터를 축적하는 레이크와 정반대.

2과목

21. 정답 ④ | 원문항 Q2-002 | 결측 원인이 결측된 값(소득) 자체 → MNAR의 대표 사례.
22. 정답 ② | 원문항 Q2-006 | LOF = 관측치의 국소 밀도를 k-최근접 이웃의 밀도와 비교하는 이상값 탐지.
23. 정답 ② | 원문항 Q2-009 | 결측이 관측된 다른 변수(성별)에만 의존 → MAR.
24. 정답 ③ | 원문항 Q2-012 | 평균 대치는 분산을 과소추정(작아짐)한다 — "커진다"는 반대 서술.
25. 정답 ② | 원문항 Q2-013 | 필터 기법 = 모델 학습 없이 통계적 측도만으로 변수 평가.
26. 정답 ④ | 원문항 Q2-016 | 파생변수 = 목적 지향·주관적 가공 변수로 타당한 근거 필요 (요약변수와 대비).
27. 정답 ① | 원문항 Q2-018 | 임베디드 대표 = 라쏘·릿지·엘라스틱넷(규제가 학습 과정에 내장).
28. 정답 ② | 원문항 Q2-021 | LDA = 클래스 간 분산 최대·클래스 내 분산 최소화하는 지도 차원축소.
29. 정답 ④ | 원문항 Q2-026 | 구간화는 구간 내 세부 정보 손실을 수반 — ㄹ만 틀림.
30. 정답 ③ | 원문항 Q2-029 | 박스플롯은 5수 요약+이상값만 제공 — 빈도 기반 최빈값은 확인 불가.
31. 정답 ② | 원문항 Q2-030 | 평균 8 > 중앙값 5 — 극단값 22가 평균만 끌어올린다.
32. 정답 ② | 원문항 Q2-033 | 스피어만은 순위 기반 비모수 상관계수로 정규성 가정이 불필요하다.
33. 정답 ④ | 원문항 Q2-039 | 텍스트 탐색 = 토큰화·형태소 분석 → 단어 빈도 → 워드클라우드.

34. 정답 ① | 원문항 Q2-040 | 상관관계는 인과관계를 의미하지 않는다 — ㄹ만 틀림.
35. 정답 ④ | 원문항 Q2-042 | 무게는 절대영점이 있는 비율척도 (온도는 구간척도).
36. 정답 ④ | 원문항 Q2-047 | F분포는 두 집단 분산비 비교용 비대칭 분포다.
37. 정답 ④ | 원문항 Q2-050 | 포아송분포는 기댓값과 분산이 모두 λ로 같다.
38. 정답 ② | 원문항 Q2-053 | 불편성 = 추정량의 기댓값이 모수와 일치(E(θ̂)=θ).
39. 정답 ② | 원문항 Q2-057 | "≠" 형태의 대립가설은 기각역을 양쪽에 두는 양측 검정이다.
40. 정답 ④ | 원문항 Q2-059 | 표본을 늘리면 α 고정 시 β가 줄어 검정력이 커진다 — "동시에 커진다"는 반대.

3과목

41. 정답 ③ | 원문항 Q3-002 | 에이전트·환경·보상·정책 키워드 → 강화학습.
42. 정답 ① | 원문항 Q3-005 | 통계 기반 모형은 가설 검정·추론에 기반해 확률적 해석이 가능하다.
43. 정답 ③ | 원문항 Q3-008 | 검증은 학습·검증 데이터를 분리해 일반화 성능을 평가해야 한다 — ㄷ만 틀림.
44. 정답 ① | 원문항 Q3-010 | R = 통계 특화 오픈소스, Python = 범용 언어로 연동·확장에 유리.
45. 정답 ① | 원문항 Q3-015 | 시그모이드 = $1/(1+e^{-x})$, 출력 범위 0~1의 S자 곡선.
46. 정답 ③ | 원문항 Q3-016 | 오즈 = p/(1-p) = 0.8/0.2 = 4.
47. 정답 ② | 원문항 Q3-021 | 서포트 벡터는 결정 경계에 가장 가까운 데이터다 — "가장 멀리"는 반대.
48. 정답 ④ | 원문항 Q3-023 | 단일 연결법은 최단 거리 사용(최장 거리는 완전 연결법) — 옳은 것은 ㄱ·ㄷ·ㄹ.
49. 정답 ② | 원문항 Q3-024 | 잔차 분산이 일정해야 한다는 가정 = 등분산성.
50. 정답 ② | 원문항 Q3-028 | K-평균 절차 = 초기화 → 할당 → 중심 갱신 → 수렴까지 반복.
51. 정답 ④ | 원문항 Q3-033 | ReLU의 출력 범위는 0~∞ — 확률 출력용은 시그모이드.
52. 정답 ② | 원문항 Q3-035 | 한 표본·두 범주형 변수의 연관성 검정 = 카이제곱 독립성 검정.
53. 정답 ② | 원문항 Q3-040 | ARIMA(p,d,q) — p:AR 차수, d:차분 횟수, q:MA 차수.
54. 정답 ③ | 원문항 Q3-041 | 비정상 시계열은 차분·변환으로 정상화 후 적합 — ㄹ만 틀림.
55. 정답 ① | 원문항 Q3-043 | 합성곱+풀링으로 이미지 특징을 추출하는 모델 = CNN.
56. 정답 ③ | 원문항 Q3-045 | GAN의 생성자·판별자는 협력이 아니라 적대적으로 경쟁 학습한다.
57. 정답 ② | 원문항 Q3-052 | 최단 경로 위 다리(중개) 역할 측정 = 매개 중심성.
58. 정답 ③ | 원문항 Q3-053 | 연결 수→연결, 최단거리→근접, 이웃 중요도→위세 중심성.
59. 정답 ② | 원문항 Q3-057 | 랜덤포레스트는 배깅 계열 — 옳은 것은 ㄱ·ㄴ·ㄷ.
60. 정답 ④ | 원문항 Q3-058 | 모수 검정의 가정이 충족되면 모수 검정의 검정력이 더 높다.

4과목

61. 정답 ③ | 원문항 Q4-002 | $R^2 = 1 - SSE/SST = 1 - 25/100 = 0.75$.
62. 정답 ① | 원문항 Q4-004 | AIC·BIC 모두 작을수록 좋으며 BIC의 복잡도 벌점이 더 크다.
63. 정답 ② | 원문항 Q4-009 | 부트스트랩 미포함 확률은 약 36.8%(1/e) — ㄹ만 틀림.
64. 정답 ③ | 원문항 Q4-011 | 관측도수 vs 기대도수 비교 = 카이제곱 적합도 검정.
65. 정답 ① | 원문항 Q4-012 | FPR = FP/(FP+TN) = 5/50 = 0.10 (= 1 − 특이도).
66. 정답 ③ | 원문항 Q4-015 | 향상도 = 구간 반응률 ÷ 전체 반응률 = 20%/5% = 4.

67. 정답 ③ | 원문항 Q4-021 | 뉴런을 무작위로 제외하는 과대적합 방지 기법 = 드롭아웃.
68. 정답 ③ | 원문항 Q4-024 | 미니배치 GD = 전체(배치)와 1건(SGD)의 절충, 묶음 단위 갱신.
69. 정답 ④ | 원문항 Q4-027 | 학습률이 크면 발산·진동 위험 — "클수록 항상 정확"은 틀림.
70. 정답 ④ | 원문항 Q4-030 | 계수를 정확히 0으로 만들어 변수 선택하는 것은 L1(라쏘)의 특징.
71. 정답 ③ | 원문항 Q4-034 | NPV=0이 되는 할인율 = IRR(내부수익률).
72. 정답 ① | 원문항 Q4-035 | "NPV=0인 할인율"은 IRR의 정의 — ROI는 투자비 대비 순이익 비율.
73. 정답 ③ | 원문항 Q4-038 | 투자 회수 기간은 짧을수록 위험이 낮다 — "길수록"은 반대.
74. 정답 ① | 원문항 Q4-039 | IRR은 현금흐름 자체로 결정되어 외부 할인율과 무관하다.
75. 정답 ① | 원문항 Q4-043 | 산점도는 관계 시각화 — 분포 시각화는 파이·도넛·트리맵.
76. 정답 ① | 원문항 Q4-047 | 관계 시각화 = 산점도·버블 차트·히스토그램.
77. 정답 ④ | 원문항 Q4-050 | 인포그래픽은 대중이 쉽게 이해하도록 요약·시각화하는 것이 목적.
78. 정답 ③ | 원문항 Q4-052 | 카토그램은 값에 비례해 면적을 왜곡 — "면적 유지+색상"은 등치지역도.
79. 정답 ③ | 원문항 Q4-054 | 전개는 운영·관리의 시작 — 이후 모니터링·리모델링이 이어져야 한다.
80. 정답 ① | 원문항 Q4-057 | 활용 시나리오 = 주체·시점·대상 업무·방법이 구체적으로 정의된 것.

채점표

문항당 1.25점 환산 (과목당 20문항 × 1.25점 = 25점, 총 80문항 = 100점)

과목	맞힌 개수	점수(개수×1.25)	과락 여부 (8문항 미만 = 과락)
1과목 빅데이터 분석 기획	___ / 20	___ 점	☐ 통과 (8개 이상) / ☐ 과락
2과목 빅데이터 탐색	___ / 20	___ 점	☐ 통과 (8개 이상) / ☐ 과락
3과목 빅데이터 모델링	___ / 20	___ 점	☐ 통과 (8개 이상) / ☐ 과락
4과목 빅데이터 결과 해석	___ / 20	___ 점	☐ 통과 (8개 이상) / ☐ 과락
총계	___ / 80	___ 점	

합격 판정

- ☐ 총 맞힌 개수 48문항(60점) 이상
- ☐ 전 과목 과락 없음 (모든 과목 8문항(40점) 이상)

→ 두 조건을 모두 만족하면 **합격**

이 문서는 LLM으로 생성 후 3중 검증(사실·논리·규격 / 중복 / 교체분 재검증)을 거친 학습 자료입니다. 교재별 표기가 갈리는 항목은 본문에 "※ 교재별 표기 차이 있음"으로 표시했으며, 상세 목록은 부록의 검증 필요 항목을 참고하세요.