빅데이터분석기사 필기 모의고사 3회

80문항 · 120분 · 계산기 사용 불가 — 정답·해설은 문제부 종료 후 새 페이지부터

the0ne 학습용 · 2026-09-01 생성 · KDATA 공개 출제기준 기반 신규 창작 문항 (기출 복원 아님)

빅데이터분석기사 필기 모의고사 3회

> 빅데이터분석기사 필기 모의고사 3회 · 총 80문항 · 120분 · 4지선다 · 계산기 사용 불가 · 합격: 평균 60점(총 48문항) 이상 AND 전 과목 40점(과목당 8문항) 이상

1과목 빅데이터 분석 기획 (1~20번)

1. 빅데이터의 특성 중 '데이터가 빠른 속도로 생성·유통되므로 수집·저장·분석이 실시간에 가깝게 처리되어야 함'을 의미하는 것은?

① 속도(Velocity) ② 규모(Volume) ③ 가치(Value) ④ 다양성(Variety)

2. 빅데이터 시대에 데이터의 가치 산정이 어려운 이유로 적절하지 **않은** 것은?

① 데이터가 재사용·재조합되고 다목적으로 개발되어 누가 언제 어디서 활용할지 예측하기 어렵다.
② 데이터의 가격이 거래소를 통해 표준화되어 있어 개별 산정이 무의미하기 때문이다.
③ 기존에 없던 새로운 가치를 창출하므로 그 가치를 측정하기 어렵다.
④ 분석 기술이 발전하면서 현재는 가치가 없는 데이터도 미래에 가치를 가질 수 있다.

3. 하둡 에코시스템 컴포넌트의 역할에 대한 설명으로 옳지 **않은** 것은?

① Hive는 SQL과 유사한 HiveQL로 하둡에 저장된 데이터를 질의·분석한다.
② Flume은 여러 서버에서 발생하는 대량의 로그 데이터를 수집하여 저장소로 전송한다.
③ Kafka는 발행-구독(publish-subscribe) 모델 기반의 분산 메시징 시스템으로 대용량 실시간 데이터 스트림을 처리한다.
④ Pig는 관계형 데이터베이스와 하둡 간의 대량 데이터 전송을 담당한다.

4. 하둡 에코시스템에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. YARN은 하둡 클러스터의 자원 관리와 작업 스케줄링을 담당한다.
- ㄴ. HBase는 HDFS 위에서 동작하는 컬럼(column) 기반 분산 NoSQL 데이터베이스다.
- ㄷ. Hive는 절차형 스크립트 언어인 Pig Latin으로 데이터 처리 흐름을 기술한다.
- ㄹ. Flume은 대량의 로그 데이터를 수집·집계하여 저장소로 전송한다.

① ㄱ, ㄴ, ㄹ ② ㄱ, ㄷ, ㄹ ③ ㄴ, ㄷ ④ ㄱ, ㄴ, ㄷ, ㄹ

5. 이용자가 별도의 설치 없이 웹 브라우저로 접속하여 전자우편·문서 편집 등의 응용 소프트웨어를 완성된 서비스 형태로 이용하는 클라우드 서비스 모델은?

① IaaS ② PaaS ③ SaaS ④ 온프레미스(on-premise)

6. 개인정보·가명정보·익명정보에 대한 설명으로 옳은 것은?

① 가명정보는 추가 정보 없이도 특정 개인을 쉽게 알아볼 수 있는 정보다.
② 익명정보는 개인정보 보호법의 보호 대상에 포함된다.
③ 가명정보는 추가 정보를 사용하지 않고는 특정 개인을 알아볼 수 없도록 처리한 정보로, 개인정보의 범위에 포함된다.
④ 개인정보는 살아 있는 개인뿐 아니라 사망한 사람에 관한 정보도 포함한다.

7. 마이데이터(MyData)에 대한 설명으로 옳은 것은?

① 기업이 정보주체의 동의 없이 보유 개인정보를 제3자에게 자유롭게 판매할 수 있도록 하는 제도다.
② 전송요구권은 신용정보법상 금융 분야에서만 인정되며 다른 분야로는 도입되지 않았다.
③ 정보주체가 자신의 개인정보를 본인 또는 제3자에게 전송하도록 개인정보처리자에게 요구할 수 있는 권리(개인정보 전송요구권)에 기반한다.
④ 전송 대상 개인정보는 반드시 종이 문서 형태로 제공되어야 한다.

8. KDD(Knowledge Discovery in Databases) 분석 절차를 순서대로 옳게 나열한 것은?

① 데이터셋 선택 → 데이터 전처리 → 데이터 변환 → 데이터 마이닝 → 해석·평가
② 데이터셋 선택 → 데이터 변환 → 데이터 전처리 → 데이터 마이닝 → 해석·평가
③ 데이터 전처리 → 데이터셋 선택 → 데이터 변환 → 해석·평가 → 데이터 마이닝
④ 데이터셋 선택 → 데이터 전처리 → 데이터 마이닝 → 데이터 변환 → 해석·평가

9. CRISP-DM의 4계층(레벨) 구조를 최상위 계층부터 순서대로 옳게 나열한 것은?

① 단계 → 세분화 태스크 → 일반화 태스크 → 프로세스 실행
② 단계 → 일반화 태스크 → 세분화 태스크 → 프로세스 실행
③ 프로세스 실행 → 단계 → 일반화 태스크 → 세분화 태스크
④ 일반화 태스크 → 단계 → 세분화 태스크 → 프로세스 실행

10. KDD, CRISP-DM, SEMMA 세 방법론의 단계 대응에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. KDD의 '데이터 변환' 단계는 CRISP-DM의 '데이터 준비' 단계에, '데이터셋 선택' 단계는 '데이터 이해' 단계에 대응한다.
- ㄴ. CRISP-DM의 '업무 이해'에 대응하는 단계는 SEMMA에 명시적으로 존재하지 않는다.
- ㄷ. KDD의 '해석·평가'는 CRISP-DM의 '평가', SEMMA의 '평가(Assess)'와 대응한다.
- ㄹ. SEMMA의 '샘플링(Sample)'은 CRISP-DM의 '전개(Deployment)'에 대응한다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄴ, ㄷ ④ ㄱ, ㄷ, ㄹ

11. 분석 마스터플랜 수립 시 분석 과제의 우선순위 평가에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 난이도(difficulty)는 전략적 중요도와 목표 가치(KPI)에 따라 평가한다.
② 시급성이 높고 난이도가 쉬운 과제가 가장 우선적으로 추진된다.
③ ROI 관점에서 빅데이터의 3V(규모·다양성·속도)는 투자비용 요소로서 난이도와 연결된다.
④ 난이도는 데이터 획득·저장·가공 비용과 분석 수준 등을 고려하여 평가하며, 기업 상황에 따라 조율할 수 있다.

12. 프로젝트의 전체 작업을 계층적으로 세분화하여 관리 가능한 최소 단위의 작업으로 나누고, 이를 기준으로 일정·산출물·담당자를 관리할 수 있게 하는 것은?

① WBS(작업 분할 구조)
② 간트 차트(Gantt chart)
③ 분석 목표 정의서
④ 위험 관리 대장

13. 블로그·뉴스 사이트 등에서 새로 갱신된 콘텐츠를 XML 기반 형식으로 배급하여, 구독자가 사이트에 방문하지 않고도 갱신 정보를 수집할 수 있게 하는 기술은?

① Open API
② FTP
③ RSS
④ 크롤링(crawling)

14. ETL과 ELT에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① ETL은 원천 데이터를 변환한 후 목표 시스템에 적재한다.
② ELT는 적재하기 전에 반드시 모든 변환을 완료해야 한다.
③ ELT는 원본 데이터를 먼저 적재한 뒤 필요할 때 목적지 시스템의 처리 능력으로 변환하며, 데이터 레이크(data lake) 환경에 적합하다.
④ ETL은 전통적으로 데이터 웨어하우스(DW) 구축에 주로 사용되어 왔다.

15. 데이터 품질 기준에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 정확성(accuracy): 데이터가 실세계의 사실·값을 올바르게 반영하는 정도
② 완전성(completeness): 필요한 데이터가 누락 없이 모두 존재하는 정도
③ 적시성(timeliness): 데이터의 표현 형식·단위·값 체계가 서로 모순되지 않는 정도
④ 일관성(consistency): 여러 시스템·항목에 저장된 동일 데이터가 서로 다르지 않고 일치하는 정도

16. 데이터 수집 기술과 품질 기준에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. FTP는 TCP/IP 기반의 파일 전송 프로토콜로, 대용량 파일 수집에 활용된다.
- ㄴ. Open API는 배포자가 갱신 콘텐츠를 XML 형식으로 밀어 보내면 구독자가 자동 수신하는 방식이다.
- ㄷ. 완전성(completeness)은 필요한 데이터가 누락 없이 존재하는 정도를 의미한다.
- ㄹ. 일관성(consistency)은 데이터가 서로 모순 없이 동일한 형식·값 체계를 유지하는 정도를 의미한다.

① ㄱ, ㄷ, ㄹ ② ㄱ, ㄴ, ㄷ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄴ, ㄹ

17. 데이터 웨어하우스(Data Warehouse)의 4가지 특징에 해당하지 **<u>않는</u>** 것은?

① 주제 지향성(subject-oriented)
② 통합성(integrated)
③ 시계열성(time-variant)
④ 휘발성(volatile)

18. 분산 데이터 저장 시스템에 관한 CAP 정리(CAP theorem)의 설명으로 옳은 것은?

① 일관성(Consistency)은 모든 노드가 언제든 요청에 응답할 수 있는 성질이다.
② 분산 데이터베이스는 세 가지 속성을 모두 동시에 보장하도록 설계된다.
③ 네트워크 분할이 발생한 상황에서는 일관성과 가용성 중 하나를 선택해야 한다.
④ 가용성(Availability)은 모든 노드가 같은 시점에 동일한 데이터를 보는 성질이다.

19. 어느 기업이 전사 데이터 웨어하우스에서 마케팅 부서가 필요로 하는 데이터만 추출하여, 마케팅 분석 전용의 소규모 주제 지향적 저장소를 구축하려 한다. 이에 해당하는 것은?

① 데이터 마트(Data Mart)
② 데이터 레이크(Data Lake)
③ ODS(Operational Data Store)
④ 데이터 웨어하우스(Data Warehouse)

20. NoSQL 데이터베이스에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. Redis는 키-값(Key-Value) 기반 저장소다.
- ㄴ. 컬럼 기반(Column-family) 저장소는 데이터를 행(row) 단위로만 저장하므로 특정 컬럼에 대한 조회·집계 분석에 불리하다.
- ㄷ. HBase와 Cassandra는 컬럼 기반(Column-family) 저장소다.
- ㄹ. NoSQL은 일반적으로 BASE 속성을 따르며 최종 일관성(eventual consistency)을 허용한다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄴ, ㄷ ④ ㄱ, ㄷ, ㄹ

2과목 빅데이터 탐색 (21~40번)

21. 자료가 정규분포를 따른다고 가정하고, 평균으로부터 표준편차의 ±3배(±3σ)를 벗어나는 값을 이상값으로 판별하는 기법은?

① ESD(Extreme Studentized Deviate)
② 사분위수 범위(IQR) 규칙
③ 마할라노비스 거리(Mahalanobis distance)
④ 카이제곱 검정(chi-square test)

22. 이상값 탐지 기법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 표준화 점수(Z-score)는 자료를 평균 0, 표준편차 1로 변환한 값으로, 절댓값이 3을 넘으면 이상값을 의심한다.
② IQR 규칙은 Q1 − 1.5×IQR 미만이거나 Q3 + 1.5×IQR을 초과하는 값을 이상값으로 본다.
③ 마할라노비스 거리는 변수 간 상관관계를 고려하지 못하므로 다변량 이상값 탐지에는 사용할 수 없다.
④ 사분위수 기반 판정 결과는 상자그림(box plot)으로 시각화하여 확인할 수 있다.

23. 이상값 처리 방법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 삭제는 이상값을 제거하는 방법으로, 표본 수가 줄고 추정에 편향이 생길 수 있다.
② 대체는 이상값을 하한값·상한값 등 정해진 경계값으로 바꾸어 극단성을 조정하는 방법이다.
③ 변환은 로그 변환(log transformation) 등을 적용해 극단적으로 큰 값의 영향을 줄이는 방법이다.
④ 분리는 이상값을 별도의 그룹으로 나누어 분석하는 방법으로, 분리된 이상값은 항상 분석에서 버려진다.

24. 불균형 데이터 처리에서, 소수 클래스의 관측치와 그 k-최근접 이웃(k-NN) 사이를 보간(interpolation)하여 실제로 존재하지 않던 새로운 합성(synthetic) 관측치를 생성하는 기법은?

① 랜덤 언더샘플링(random undersampling)
② 토멕 링크(Tomek Link)
③ SMOTE
④ 랜덤 오버샘플링(random oversampling)

25. 다차원척도법(MDS, Multidimensional Scaling)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 개체 간의 거리(근접성)를 계산하여 그 거리 구조를 최대한 보존하도록 개체들을 저차원 공간에 배치하는 차원축소 기법이다.
② 적합도는 스트레스(stress) 값으로 평가하며, 값이 0에 가까울수록 실제 거리 구조를 잘 보존한 것이다.
③ 수행하려면 목표변수(클래스) 정보가 반드시 필요하며, 클래스 간 분리가 최대가 되도록 개체를 배치한다.

④ 계량적(metric) MDS는 구간척도·비율척도 자료에, 비계량적(non-metric) MDS는 순서(서열)척도 자료에 적용한다.

26. 소득 데이터가 오른쪽으로 길게 치우친(양의 왜도) 분포를 보인다. 이를 정규분포에 가깝게 만들기 위한 변수 변환으로 가장 적절한 것은?

① 로그 변환(log transformation)
② 민맥스 정규화(min-max normalization)
③ 제곱 변환(square transformation)
④ 원-핫 인코딩(one-hot encoding)

27. 주성분분석(PCA)과 요인분석(factor analysis)의 비교로 옳지 **않은** 것은?

① 두 기법 모두 여러 변수를 소수의 새로운 변수로 축약하는 데 활용된다.
② 요인분석은 관측된 변수들 이면에 있는 잠재요인(latent factor)을 찾아내는 것이 목적이다.
③ 주성분분석에서 생성된 주성분들은 서로 대등하여 중요도의 순서가 없다.
④ 주성분은 원래 변수들의 선형 결합(linear combination)으로 표현된다.

28. 탐색적 데이터 분석(EDA)의 4가지 주제(원칙)에 해당하지 **않는** 것은?

① 저항성(resistance) ② 잔차 해석(residual) ③ 재표현(re-expression) ④ 정규성(normality)

29. 오른쪽으로 긴 꼬리를 갖는 양의 왜도(positive skewness) 분포에서 중심 경향치의 크기 순서로 옳은 것은?

① 평균 > 중앙값 > 최빈값
② 최빈값 > 중앙값 > 평균
③ 평균 > 최빈값 > 중앙값
④ 중앙값 > 평균 > 최빈값

30. 설문지의 여러 문항이 동일한 개념을 일관되게 측정하고 있는지, 즉 측정 도구의 내적 일관성(신뢰도)을 평가하는 데 사용하는 계수는?

① 피어슨 상관계수 ② 결정계수 ③ 크론바흐 알파(Cronbach's α) ④ 코헨의 카파(Cohen's κ)

31. 어떤 자료의 제1사분위수(Q1)가 10, 제3사분위수(Q3)가 30이다. 사분위범위(IQR)를 이용한 판정 기준(1.5×IQR)에 따를 때 이상값으로 판정되는 관측값은?

① 55 ② −10 ③ 0 ④ 65

32. 행정구역 같은 지역 단위별 통계 수치를 지도 위에 색상의 농도(음영 단계)로 구분하여 표현하는 공간 시각화 기법은?

① 카토그램(cartogram)
② 코로플레스맵(choropleth map)
③ 버블맵(bubble map)
④ 산점도 행렬(scatter plot matrix)

33. 어느 콜센터에 1시간 동안 걸려오는 전화 건수를 확률변수로 모형화할 때 가장 적절한 분포는?

① 포아송분포(Poisson distribution)
② 이항분포(binomial distribution)
③ 베르누이분포(Bernoulli distribution)
④ 정규분포(normal distribution)

34. 사건 A, B에 대하여 P(A) = 0.4, P(A∩B) = 0.1일 때, 조건부 확률 P(B|A)는?

① 0.10 ② 0.25 ③ 0.40 ④ 0.50

35. 표본추출 방법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 단순 무작위추출은 모집단의 모든 개체가 동일한 확률로 추출된다.
② 층화추출은 층 내부는 동질적, 층 사이는 이질적이 되도록 층을 나눈 후 각 층에서 표본을 추출한다.
③ 군집추출은 군집 내부의 개체들이 서로 동질적이 되도록 군집을 구성하며, 모든 군집에서 표본을 고르게 추출한다.
④ 계통추출은 추출 간격 k = N/n을 정해 목록에서 일정 간격마다 표본을 추출한다.

36. 어느 공장에서 제품의 60%는 A라인, 40%는 B라인에서 생산된다. 불량률은 A라인 2%, B라인 3%이다. 임의로 뽑은 제품이 불량품이었을 때, 그 제품이 A라인에서 생산되었을 확률은?

① 1/3 ② 1/2 ③ 2/5 ④ 3/5

37. 유의수준(significance level) α=0.05로 가설검정을 수행한 결과 유의확률(p-value)이 0.03으로 계산되었다. 올바른 판정은?

① 귀무가설을 기각하고 대립가설을 채택한다.
② p-value가 0보다 크므로 귀무가설을 채택한다.
③ 귀무가설이 참일 확률이 3%라고 결론 내린다.
④ 판정할 수 없으므로 표본을 더 수집해 재검정한다.

38. 모평균에 대한 95% 신뢰구간(confidence interval)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 동일한 방법으로 표본추출을 반복하여 신뢰구간을 만들면 그중 약 95%의 구간이 모평균을 포함한다.
② 다른 조건이 같을 때 신뢰수준을 95%에서 99%로 높이면 구간의 길이는 길어진다.
③ 하나의 표본에서 구한 신뢰구간이 [10, 20]이면, 모평균이 이 구간 안에 있을 확률이 95%이다.
④ 다른 조건이 같을 때 표본의 크기를 늘리면 구간의 길이는 짧아진다.

39. 한 학원이 A, B, C 세 가지 교수법으로 각각 다른 반을 가르친 뒤, 세 반의 시험 점수 평균에 차이가 있는지 검정하려 한다. 가장 적절한 분석 기법은?

① 독립표본 t-검정(independent samples t-test)
② 카이제곱 독립성 검정(chi-squared test)
③ 일원분산분석(one-way ANOVA)
④ 대응표본 t-검정(paired t-test)

40. 다음 상황 ㄱ~ㄹ에 적용할 검정 기법을 옳게 짝지은 것은?

- ㄱ. 모분산을 알고 있는 대표본에서 모평균을 검정
- ㄴ. 모분산을 모르는 소표본(n<30)에서 모평균을 검정
- ㄷ. 성별(남/여)과 구매 여부(구매/비구매) 두 범주형 변수의 독립성을 검정
- ㄹ. 네 개 지점의 일평균 매출액이 모두 같은지 검정

① ㄱ-Z검정, ㄴ-t검정, ㄷ-카이제곱 검정, ㄹ-분산분석
② ㄱ-t검정, ㄴ-Z검정, ㄷ-카이제곱 검정, ㄹ-분산분석
③ ㄱ-Z검정, ㄴ-t검정, ㄷ-분산분석, ㄹ-카이제곱 검정
④ ㄱ-t검정, ㄴ-Z검정, ㄷ-분산분석, ㄹ-카이제곱 검정

3과목 빅데이터 모델링 (41~60번)

41. 분석 모형 정의 및 변수 선정에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 분석 모형 정의 단계에서는 분석 목적에 맞는 기법을 선정하고, 모형에 사용할 데이터와 변수를 정의한다.
② 예측에 도움이 되는지와 무관하게 수집 가능한 모든 변수를 투입할수록 모형 성능은 항상 좋아진다.
③ 목표변수(종속변수)와의 관련성이 높고, 독립변수 간 중복(다중공선성(multicollinearity))이 적은 변수를 선정하는 것이 바람직하다.
④ 변수 선택 기법에는 전진 선택법(forward selection), 후진 소거법(backward elimination), 단계적 선택법(stepwise method)이 있다.

42. 분석가 A는 확보한 전체 데이터를 60:20:20의 비율로 세 부분으로 나누어 모델링을 진행하려 한다. 이 중 모델의 하이퍼파라미터(hyperparameter)를 튜닝하고 과대적합(overfitting) 발생 여부를 확인하는 데 사용하는 데이터는?

① 훈련 데이터(training data)
② 검증 데이터(validation data)
③ 평가 데이터(test data)
④ 원시 데이터(raw data)

43. 훈련·검증·평가 데이터의 역할에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 훈련 데이터는 모델의 파라미터(가중치)를 학습시키는 데 사용된다.
② 검증 데이터는 하이퍼파라미터 튜닝과 과대적합(overfitting) 발생 여부 확인에 사용된다.
③ 평가 데이터는 학습과 튜닝에 관여하지 않은 데이터로, 완성된 모델의 최종 성능 측정에 사용된다.
④ 평가 데이터로 하이퍼파라미터를 조정한 뒤 같은 평가 데이터로 최종 성능을 측정하면 일반화 성능을 객관적으로 평가할 수 있다.

44. 빅데이터 분석 도구의 선정에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. R과 Python은 오픈소스(open source) 언어로 라이선스 비용 없이 사용할 수 있으며, 커뮤니티가 개발한 패키지를 통해 기능을 확장한다.
- ㄴ. SAS와 SPSS는 라이선스를 구매하여 사용하는 상용(commercial) 분석 도구로, 공급 업체(벤더)의 공식 기술 지원을 받을 수 있다.
- ㄷ. SPSS는 메뉴 선택 방식의 그래픽 사용자 인터페이스(GUI)를 제공하여 프로그래밍에 익숙하지 않은 사용자도 비교적 쉽게 사용할 수 있다.
- ㄹ. 상용 분석 도구는 오픈소스 도구보다 최신 분석 기법이 더 신속하게 반영되는 것이 일반적이다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄴ, ㄷ ④ ㄱ, ㄷ, ㄹ

45. 의사결정나무(decision tree) 알고리즘과 분리(분할) 기준의 연결로 옳은 것은?

① CART - 카이제곱 통계량
② C4.5 - 엔트로피(entropy)
③ CHAID - 지니 지수(Gini index)
④ CART - 엔트로피(entropy)

46. 의사결정나무(decision tree)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 지니 지수(Gini index)가 낮을수록 노드의 순도(purity)가 높다.
② 각 노드는 분리 전후의 정보이득(information gain)이 최대가 되는 변수와 기준으로 분리한다.
③ 가지치기(pruning)는 나무가 지나치게 복잡해져 발생하는 과대적합(overfitting)을 방지하기 위해 수행한다.
④ 엔트로피(entropy)가 0이면 노드의 불순도가 최대인 상태를 의미한다.

47. 선형 회귀분석의 가정과 진단에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 선형성은 종속변수와 독립변수 사이에 선형 관계가 존재해야 한다는 가정이다.
② 정규성은 잔차가 정규분포를 따라야 한다는 가정으로, Q-Q 플롯이나 샤피로-윌크(Shapiro-Wilk) 검정으로 확인한다.
③ 잔차 산점도가 깔때기 모양으로 퍼지는 형태이면 등분산성 가정이 만족된 것이다.
④ 더빈-왓슨(Durbin-Watson) 통계량이 2에 가까우면 잔차의 자기상관이 없다고 판단한다.

48. 고차원의 입력 데이터를 저차원(주로 2차원)의 격자 형태 뉴런으로 매핑하여 입력 패턴 간의 위상적(topological) 관계를 보존하는 비지도학습 신경망 기법은?

① 자기조직화지도(SOM, Self-Organizing Map)
② DBSCAN
③ 다층 퍼셉트론(multi-layer perceptron)
④ 서포트 벡터 머신(SVM)

49. 군집분석에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 계층적 군집의 결과는 덴드로그램(dendrogram)으로 시각화하며, 절단 높이에 따라 군집 수를 사후에 결정할 수 있다.
② DBSCAN은 반경(ε)과 최소 관측치 수(minPts)로 밀도를 정의하여 군집을 형성하고, 저밀도 지역의 점은 노이즈(noise)로 분류한다.
③ 병합적 계층 군집에서는 한 번 같은 군집으로 병합된 관측치도 이후 단계에서 다른 군집으로 재배정될 수 있다.
④ 실루엣 계수(silhouette coefficient)가 0에 가까운 관측치는 두 군집의 경계 부근에 위치함을 의미한다.

50. 연관분석의 아프리오리(Apriori) 알고리즘에 대한 설명으로 옳은 것은?

① 항목집합 {A, B}가 최소 지지도를 만족하지 못하면, {A, B, C}는 후보 항목집합에서 제외할 수 있다.
② 어떤 항목집합의 지지도가 낮으면 그 부분집합(subset)의 지지도도 반드시 더 낮다.
③ 최소 향상도(lift)를 기준으로 후보 항목집합을 가지치기하여 탐색 공간을 줄인다.
④ 가능한 모든 항목집합 조합을 빠짐없이 탐색하므로 항목 수가 늘어도 계산량은 변하지 않는다.

51. 신약 투여 여부와 부작용 발생 여부를 2×2 분할표로 정리하였더니 표본 수가 매우 작아 기대빈도가 5 미만인 셀이 다수 발생하였다. 이 경우 두 변수의 연관성을 검정하기에 가장 적절한 방법은?

① 피셔 정확 검정(Fisher's exact test)
② 카이제곱 독립성 검정
③ 런 검정(run test)
④ F-검정

52. 전체 200명을 성별과 찬반으로 교차분류한 분할표에서 '남성' 행의 합계는 80명, '찬성' 열의 합계는 50명이다. 독립성 검정을 위한 (남성, 찬성) 셀의 기대빈도는?

① 10 ② 16 ③ 20 ④ 25

53. 나이브베이즈(naive Bayes) 분류에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 베이즈 정리(Bayes' theorem)를 이용해 사후확률이 가장 큰 범주로 분류한다.
② 클래스가 주어졌을 때 모든 입력 변수가 조건부 독립이라고 가정한다.
③ 계산이 단순하고 빨라 텍스트 분류(스팸 필터링 등)에 널리 사용된다.
④ 변수 간 상관관계가 강할수록 독립 가정이 더 잘 충족되어 분류 성능이 향상된다.

54. 오토인코더(autoencoder)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 입력을 압축하는 인코더와 이를 복원하는 디코더로 구성된다.
② 은닉층의 차원을 입력보다 작게 하여 데이터의 잠재 표현(latent representation)을 학습할 수 있다.
③ 복원 오차가 큰 관측치를 찾아 이상 탐지(anomaly detection)에 활용할 수 있다.
④ 별도의 정답 라벨이 반드시 필요하므로 지도학습(supervised learning) 기법으로 분류된다.

55. 텍스트 마이닝에서 '특정 문서에는 자주 등장하지만 전체 문서 집합에서는 드물게 나타나는 단어'에 높은 가중치를 부여하여 단어의 중요도를 평가하는 지표는?

① 불용어(stopword) 사전
② TF-IDF
③ 단순 단어 빈도(TF)
④ 형태소 분석(morphological analysis)

56. 텍스트 마이닝의 전처리 과정에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 코퍼스(corpus)는 분석을 위해 수집·정리한 대량의 텍스트 자료 집합이다.
② 토큰화(tokenization)는 텍스트를 단어·형태소 등 분석 가능한 단위로 분리하는 과정이다.
③ 불용어(stopword)는 문서의 주제를 대표하는 핵심 단어이므로 분석 전에 반드시 보존해야 한다.
④ 형태소 분석은 어절을 의미를 가진 가장 작은 단위인 형태소로 분해하는 과정이다.

57. 원자료로부터 복원추출한 여러 부트스트랩(bootstrap) 표본에 각각 모델을 병렬로 학습시킨 뒤 그 결과를 집계함으로써, 모델의 분산(variance)을 감소시키는 앙상블 기법은?

① 배깅(bagging)
② 부스팅(boosting)
③ 스태킹(stacking)
④ 교차검증(cross validation)

58. 여러 분류기가 예측한 **클래스별 확률을 평균**한 뒤, 평균 확률이 가장 높은 클래스를 최종 예측으로 선택하는 앙상블 결합 방식은?

① 하드 보팅(hard voting)
② 배깅(bagging)
③ 소프트 보팅(soft voting)
④ 부스팅(boosting)

59. 서로 독립인 두 집단의 분포(중위수) 차이를 비교하는 비모수 검정으로, 모수 검정의 독립표본 t-검정에 대응하는 것은?

① 만-휘트니 U 검정(Mann-Whitney U test)
② 크루스칼-왈리스 검정(Kruskal-Wallis test)

③ 윌콕슨 부호순위 검정(Wilcoxon signed-rank test)
④ 부호 검정(sign test)

60. 다음 각 상황에서 자료가 정규분포를 따른다고 보기 어려울 때, 가장 적절한 비모수 검정을 순서대로 바르게 연결한 것은?

- (가) 동일한 참가자들의 다이어트 프로그램 전·후 체중 차이를 비교한다.
- (나) 서로 독립인 세 지역 주민의 소득 수준을 비교한다.
- (다) 서로 독립인 두 학급의 시험 점수를 비교한다.

① (가) 부호 검정 — (나) 만-휘트니 U 검정 — (다) 크루스칼-왈리스 검정
② (가) 만-휘트니 U 검정 — (나) 크루스칼-왈리스 검정 — (다) 윌콕슨 부호순위 검정
③ (가) 윌콕슨 부호순위 검정 — (나) 크루스칼-왈리스 검정 — (다) 만-휘트니 U 검정
④ (가) 윌콕슨 부호순위 검정 — (나) 만-휘트니 U 검정 — (다) 크루스칼-왈리스 검정

4과목 빅데이터 결과 해석 (61~80번)

61. 어떤 분류모형의 혼동행렬(confusion matrix)이 TP=40, FN=10, FP=20, TN=30일 때, 재현율(recall)은?

① 약 0.67 ② 0.80 ③ 0.70 ④ 0.40

62. 어떤 분류모형의 정밀도(precision)가 0.75, 재현율(recall)이 0.5일 때, F1-점수(F1-score)는?

① 0.500 ② 0.625 ③ 0.600 ④ 0.750

63. 다음 공식으로 계산되는 회귀모형 평가지표는? (y_i: 실제 값, $\hat{y}_i$: 예측 값, n: 데이터 수)

$$\mathbf{(1/n) \times \Sigma \mid y_i - \hat{y}_i \mid}$$ (i = 1 … n 합산)

① 평균제곱오차(MSE) ② 평균제곱근오차(RMSE) ③ 평균절대백분율오차(MAPE) ④ 평균절대오차(MAE)

64. 적합도 검정과 관련 도구에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 카이제곱 적합도 검정은 관측도수와 기대도수의 차이를 이용한다.
② 콜모고로프-스미르노프(K-S) 검정은 경험적 누적분포함수와 이론적 분포의 누적분포함수 간 최대 차이를 검정통계량으로 사용한다.
③ Q-Q 플롯에서 점들이 대각 직선에 가깝게 늘어서면 데이터가 비교 대상 분포를 따른다고 볼 수 있다.
④ 샤피로-윌크(Shapiro-Wilk) 검정은 두 범주형 변수 간의 독립성을 검정하는 방법이다.

65. 전체 데이터 중 양성이 1%뿐인 희귀 사건 분류 문제에서의 평가지표 선택에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 이런 불균형 데이터에서는 정확도(accuracy)가 항상 가장 신뢰할 수 있는 평가지표다.
② 질병 진단처럼 실제 양성을 놓치는(FN) 비용이 클 때는 재현율(민감도)을 중시한다.
③ 스팸 필터처럼 정상을 양성으로 잘못 분류하는(FP) 비용이 클 때는 정밀도를 중시한다.
④ F1-점수는 정밀도와 재현율을 함께 반영하므로 불균형 데이터에서 정확도의 한계를 보완할 수 있다.

66. 어떤 분류 모형이 훈련 데이터에서는 정확도 98%를 기록했지만, 별도의 평가 데이터에서는 정확도가 70%에 그쳤다. 이 모형이 보이는 현상은?

① 과소적합(underfitting)
② 과대적합(overfitting)
③ 기울기 소실(gradient vanishing)
④ 차원의 저주(curse of dimensionality)

67. 다음 중 사용자가 설정하는 하이퍼파라미터(hyperparameter)가 아니라, 모형이 학습을 통해 스스로 결정하는 파라미터(parameter)에 해당하는 것은?

① 학습률(learning rate)
② 에폭(epoch) 수
③ 은닉층(hidden layer)의 수
④ 가중치(weight)와 편향(bias)

68. 다음 설명에 해당하는 옵티마이저(optimizer)는?

> 이전 갱신에서 이동하던 방향을 관성(inertia)처럼 현재 갱신에 반영하여, 진동을 줄이고 지역 최소값(local minimum)을 지나칠 수 있도록 돕는다.

① AdaGrad
② 모멘텀(Momentum)
③ RMSProp
④ Adam

69. 하이퍼파라미터 탐색 기법인 그리드 서치(grid search)와 랜덤 서치(random search)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 그리드 서치는 사용자가 지정한 후보 값들의 모든 조합을 빠짐없이 탐색한다.
② 랜덤 서치는 지정된 범위 안에서 하이퍼파라미터 값을 무작위로 추출해 탐색한다.
③ 그리드 서치는 하이퍼파라미터의 종류와 후보 값이 늘어나도 탐색해야 할 조합의 수가 증가하지 않는다.
④ 랜덤 서치는 탐색 공간이 넓을 때 그리드 서치보다 효율적일 수 있다.

70. 옵티마이저(optimizer)의 발전 과정에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 모멘텀(Momentum)은 이전 이동 방향을 관성으로 반영해 갱신의 진동을 줄인다.
- ㄴ. AdaGrad는 기울기 제곱을 계속 누적하므로 학습이 진행될수록 학습률이 감소해 0에 가까워지는 문제가 있다.
- ㄷ. RMSProp은 지수이동평균을 사용하여 AdaGrad의 학습률 소실 문제를 보완했다.
- ㄹ. Adam은 AdaGrad와 배치 정규화(batch normalization)를 결합한 방식이다.

① ㄱ, ㄴ, ㄷ ② ㄱ, ㄹ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄴ, ㄷ, ㄹ

71. 어느 기업이 빅데이터 분석 프로젝트에 총 2,000만 원을 투자하여 500만 원의 순이익을 얻었다. 이 프로젝트의 투자 대비 이익률(ROI)은?

① 15% ② 20% ③ 40% ④ 25%

72. 빅데이터 분석 시스템 도입을 검토하는 회의에서 나온 다음 발언을 비즈니스 기여도 평가 지표와 짝지은 것으로 옳은 것은?

- ㄱ. "서버 구매비뿐 아니라 5년간의 운영·유지보수·교육 비용까지 전부 합산해 봅시다."
- ㄴ. "누적 이익이 초기 투자비와 같아지는 시점이 언제인지 확인해 봅시다."

- ㄷ. "미래 현금흐름을 현재가치로 환산한 금액에서 투자비를 빼 봅시다."
- ㄹ. "투자 비용 대비 순이익이 몇 %인지 계산해 봅시다."

① ㄱ-ROI, ㄴ-투자 회수 기간, ㄷ-NPV, ㄹ-TCO
② ㄱ-TCO, ㄴ-IRR, ㄷ-NPV, ㄹ-ROI
③ ㄱ-TCO, ㄴ-투자 회수 기간, ㄷ-IRR, ㄹ-ROI
④ ㄱ-TCO, ㄴ-투자 회수 기간, ㄷ-NPV, ㄹ-ROI

73. 시간의 흐름에 따른 데이터의 변화·추세(trend)를 표현하는 시간 시각화 기법에 해당하는 것은?

① 파이 차트(pie chart)
② 선 그래프(line graph)
③ 산점도(scatter plot)
④ 히트맵(heatmap)

74. 다변량 데이터를 눈·코·입·귀 등 사람 얼굴의 각 요소에 대응시켜, 얼굴 모양의 차이로 여러 대상을 비교하는 시각화 기법은?

① 스타 차트(star chart)
② 평행 좌표 그래프(parallel coordinates)
③ 체르노프 페이스(Chernoff faces)
④ 히트맵(heatmap)

75. 빅데이터 시각화 절차 3단계를 순서대로 바르게 나열한 것은?

① 시각화 → 구조화 → 시각표현
② 구조화 → 시각화 → 시각표현
③ 구조화 → 시각표현 → 시각화
④ 시각표현 → 구조화 → 시각화

76. 다음 중 공간 시각화 기법으로만 묶인 것은?

① 도트맵, 트리맵, 카토그램
② 등치지역도, 히트맵, 버블 플롯맵
③ 등치지역도, 도트맵, 카토그램
④ 카토그램, 버블 차트, 계단식 그래프

77. 분석모형 모니터링과 리모델링에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 모니터링은 운영 중인 모형의 성능을 주기적으로 측정하여 성능 저하를 감지하는 활동이다.
② 리모델링은 모형의 성능을 측정·기록만 할 뿐 모형 자체를 변경하지는 않는 활동이다.
③ 리모델링은 데이터나 비즈니스 환경의 변화로 성능이 저하된 모형을 재개발하는 활동이다.
④ 모니터링 결과는 리모델링 수행 여부를 판단하는 근거로 활용된다.

78. 분석 결과 활용 시나리오 개발에 대한 설명으로 적절하지 **<u>않은</u>** 것은?

① 분석 결과를 누가, 언제, 어떤 업무에서, 어떻게 활용할 것인지 구체적으로 정의하는 활동이다.
② 활용 시나리오는 분석모형을 폐기하는 시점에 처음 수립하는 것이 바람직하다.
③ 시나리오에는 분석 결과가 반영될 업무 프로세스와 의사결정 지점이 포함되어야 한다.
④ 활용 시나리오는 분석 결과가 실제 비즈니스 가치 창출로 이어지도록 연결하는 역할을 한다.

79. 분석모형 모니터링에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 운영 중인 분석모형의 성능을 주기적으로 측정하여 성능 저하를 감지하는 활동이다.
- ㄴ. 성능 저하가 감지되어도 운영 안정성을 위해 모형은 수정하지 않고 그대로 계속 사용해야 한다.
- ㄷ. 입력 데이터의 분포가 모형 개발 시점과 달라지면 모형의 성능이 저하될 수 있다.
- ㄹ. 모니터링 결과는 리모델링 수행 여부를 판단하는 근거가 된다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄷ, ㄹ ④ ㄱ, ㄴ, ㄷ, ㄹ

80. 어느 카드사가 2년 전 개발한 이상거래 탐지 모형을 운영 중이다. 최근 신종 사기 수법이 확산되면서 모니터링 결과 모형의 탐지율이 수개월째 지속적으로 하락하고 있다. 이 상황에서 가장 적절한 조치는?

① 탐지율 하락이 보고되지 않도록 성능 측정 주기를 늘리고 모니터링을 최소화한다.
② 모형은 그대로 두고, 개발 당시의 과거 데이터로 성능을 재검증하여 이상이 없음을 확인한다.
③ 신종 수법은 예외 상황이므로 기존 모형의 판정 임계값만 조정하고 재학습은 하지 않는다.
④ 신종 사기 사례가 포함된 최신 데이터를 반영하여 모형을 재학습·재개발(리모델링)한다.

⚠️ 이 아래는 정답입니다 — 채점 전 스크롤 주의

✓ 정답 및 해설 보기

정답표

1과목	정답	2과목	정답	3과목	정답	4과목	정답
1	①	21	①	41	②	61	②
2	②	22	③	42	②	62	③
3	④	23	④	43	④	63	④
4	①	24	③	44	③	64	④
5	③	25	③	45	②	65	①
6	③	26	①	46	④	66	②
7	③	27	③	47	③	67	④
8	①	28	④	48	①	68	②
9	②	29	①	49	③	69	③
10	③	30	③	50	①	70	①
11	①	31	④	51	①	71	④
12	①	32	②	52	③	72	④
13	③	33	①	53	④	73	②
14	②	34	②	54	④	74	③
15	③	35	③	55	②	75	②
16	①	36	②	56	③	76	③
17	④	37	①	57	①	77	②
18	③	38	③	58	③	78	②
19	①	39	③	59	①	79	③
20	④	40	①	60	③	80	④

문항별 한 줄 해설

상세 해설은 문제집(문제은행)의 해당 원문항을 참조하세요.

1과목 (1~20)

- 1. 정답 ① | 원문항 Q1-003 | "실시간·생성 속도"가 보이면 Velocity — 형태는 Variety, 품질은 Veracity.
- 2. 정답 ② | 원문항 Q1-006 | 가치 산정이 어려운 이유 3가지는 활용(재사용·재조합)·창출·기술 발전 — 가격 표준화는 사실이 아님.

- 3. 정답 ④ | 원문항 Q1-013 | RDB↔하둡 전송은 Sqoop, Pig는 Pig Latin 스크립트로 데이터 흐름을 기술.
- 4. 정답 ① | 원문항 Q1-015 | Pig Latin은 Pig의 언어 — Hive는 HiveQL 사용, YARN·HBase·Flume 설명은 옳음.
- 5. 정답 ③ | 원문항 Q1-016 | 완성된 응용 소프트웨어를 서비스로 제공하면 SaaS — IaaS는 인프라, PaaS는 플랫폼까지.
- 6. 정답 ③ | 원문항 Q1-019 | 가명정보는 개인정보의 일종으로 법 적용 대상, 익명정보는 법 밖 — "가명은 법 안, 익명은 법 밖".
- 7. 정답 ③ | 원문항 Q1-023 | 마이데이터의 법적 기반은 정보주체의 개인정보 전송요구권 — 주체는 기업이 아니라 본인.
- 8. 정답 ① | 원문항 Q1-026 | KDD 5단계 = 선택→전처리→변환→마이닝→해석·평가("선-전-변-마-해").
- 9. 정답 ② | 원문항 Q1-029 | CRISP-DM 4계층 = 단계→일반화 태스크→세분화 태스크→프로세스 실행("단-일-세-프").
- 10. 정답 ③ | 원문항 Q1-031 | 샘플링은 데이터 준비 계열에 대응하며 전개(Deployment)는 CRISP-DM에만 있는 단계.
- 11. 정답 ① | 원문항 Q1-035 | 전략적 중요도·목표 가치로 평가하는 것은 시급성 — 난이도는 비용·기술 기준.
- 12. 정답 ① | 원문항 Q1-037 | "계층적 세분화 + 최소 관리 단위"는 WBS — 간트 차트는 일정 시각화 도구.
- 13. 정답 ③ | 원문항 Q1-043 | XML 기반 배급·구독은 RSS — Open API는 호출, 크롤링은 방문 수집.
- 14. 정답 ② | 원문항 Q1-045 | ELT는 원본을 먼저 적재한 뒤 목적지에서 변환 — "적재 전 변환 완료"는 ETL의 특징.
- 15. 정답 ③ | 원문항 Q1-048 | 형식·단위·값 체계의 무모순은 일관성 — 적시성은 필요한 시점에 최신 데이터 제공.
- 16. 정답 ① | 원문항 Q1-051 | XML 배급·구독은 RSS의 설명 — Open API는 수집자가 인터페이스를 호출(pull)하는 방식.
- 17. 정답 ④ | 원문항 Q1-054 | DW 4특징 = 주제 지향·통합·시계열·비휘발("주통시비") — 휘발성은 반대 개념.
- 18. 정답 ③ | 원문항 Q1-055 | CAP 정리: 분할 발생 시 일관성(CP)과 가용성(AP) 중 택일 — 셋 다 동시 보장 불가.
- 19. 정답 ① | 원문항 Q1-058 | 데이터 마트는 DW의 부분집합으로 특정 부서·주제 전용 소규모 저장소.
- 20. 정답 ④ | 원문항 Q1-060 | 컬럼 기반 저장소는 컬럼 단위 저장이라 컬럼 조회·집계에 유리 — Redis 키-값, HBase·Cassandra 컬럼, BASE 최종 일관성.

2과목 (21~40)

- 21. 정답 ① | 원문항 Q2-003 | 평균 ±3σ 기준 판별은 ESD — IQR은 사분위수, 마할라노비스는 다변량 거리 기반.
- 22. 정답 ③ | 원문항 Q2-007 | 마할라노비스 거리는 공분산을 반영하는 대표적 다변량 이상값 탐지 기법 — 정반대 서술이 함정.
- 23. 정답 ④ | 원문항 Q2-010 | 분리는 이상값을 버리는 게 아니라 그룹을 나누어 각각 분석·활용하는 방법.
- 24. 정답 ③ | 원문항 Q2-014 | SMOTE = 소수 클래스 + k-최근접 이웃 + 보간 생성 — 단순 복제는 랜덤 오버샘플링.
- 25. 정답 ③ | 원문항 Q2-019 | MDS는 목표변수 없이 거리(근접성) 행렬만으로 수행 — 클래스 분리 최대화는 LDA.
- 26. 정답 ① | 원문항 Q2-022 | 양의 왜도(오른쪽 꼬리)는 로그 변환으로 큰 값을 눌러 정규성 개선.
- 27. 정답 ③ | 원문항 Q2-024 | 주성분은 제1·제2… 순으로 중요도(설명력) 순서가 있음 — 대등한 것은 요인분석의 요인.
- 28. 정답 ④ | 원문항 Q2-027 | EDA 4원칙 = 저항성·잔차 해석·재표현·현시성("저·잔·재·현") — 정규성은 아님.
- 29. 정답 ① | 원문항 Q2-031 | 양의 왜도에서는 평균이 꼬리 쪽으로 끌려 평균>중앙값>최빈값.
- 30. 정답 ③ | 원문항 Q2-034 | 측정 도구의 내적 일관성(신뢰도) 평가는 크론바흐 알파 — 평가자 일치도는 카파.
- 31. 정답 ④ | 원문항 Q2-035 | IQR=20, 정상 범위 [−20, 60] — 65만 상한 초과로 이상값.
- 32. 정답 ② | 원문항 Q2-037 | 색상 농도로 지역 통계를 표현하면 코로플레스맵 — 면적 왜곡은 카토그램.
- 33. 정답 ① | 원문항 Q2-043 | 단위 시간당 발생 건수는 포아송분포 — n회 중 성공 횟수는 이항분포.
- 34. 정답 ② | 원문항 Q2-045 | P(B|A) = P(A∩B)/P(A) = 0.1/0.4 = 0.25 — 분모는 조건 사건 P(A).
- 35. 정답 ③ | 원문항 Q2-048 | 군집추출은 군집 내부가 이질적이고 일부 군집만 추출 — 층화(층 내 동질)와 바꿔치기 함정.
- 36. 정답 ② | 원문항 Q2-051 | 베이즈 정리: 0.012/(0.012+0.012) = 1/2 — A·B의 불량 기여분이 같아 반반.
- 37. 정답 ① | 원문항 Q2-054 | p(0.03) < α(0.05)이면 귀무가설 기각 — p-value는 "귀무가설이 참일 확률"이 아님.
- 38. 정답 ③ | 원문항 Q2-055 | 이미 구한 특정 구간에는 확률을 부여할 수 없음 — 95%는 반복 추출된 구간들의 성질.
- 39. 정답 ③ | 원문항 Q2-058 | 3개 이상 집단의 평균 비교는 일원분산분석(ANOVA) — t-검정 반복은 1종 오류 누적.
- 40. 정답 ① | 원문항 Q2-060 | 분산 알고 대표본=Z, 모르는 소표본=t, 범주형=카이제곱, 3집단 이상 평균=ANOVA.

3과목 (41~60)

- 41. 정답 ② | 원문항 Q3-006 | 무관한 변수 투입은 과대적합·차원의 저주 유발 — "항상 좋아진다"는 극단 서술은 오답.
- 42. 정답 ② | 원문항 Q3-009 | 하이퍼파라미터 튜닝·과적합 확인은 검증 데이터의 역할 — 평가 데이터는 최종 측정 전용.
- 43. 정답 ④ | 원문항 Q3-011 | 평가 데이터를 튜닝에 쓰면 일반화 성능이 과대평가됨 — 평가 데이터는 학습·튜닝에 사용 금지.
- 44. 정답 ③ | 원문항 Q3-012 | 최신 기법 반영은 오픈소스가 더 빠름 — 상용 도구의 장점은 벤더 기술 지원.
- 45. 정답 ② | 원문항 Q3-017 | CART=지니, C4.5=엔트로피, CHAID=카이제곱의 매칭.
- 46. 정답 ④ | 원문항 Q3-018 | 엔트로피 0은 완전히 순수한 상태 — 불순도 최대는 범주가 반반 섞인 경우.
- 47. 정답 ③ | 원문항 Q3-025 | 깔때기 모양 잔차는 등분산성 위배(이분산)의 신호 — 만족 시 패턴 없이 고르게 흩어짐.
- 48. 정답 ① | 원문항 Q3-027 | 저차원 격자·위상 보존·비지도 신경망 = SOM(코호넨 경쟁학습).
- 49. 정답 ③ | 원문항 Q3-030 | 계층적 군집은 한 번 병합되면 재배정 불가 — 재할당은 K-평균(비계층적)의 특징.
- 50. 정답 ① | 원문항 Q3-032 | 아프리오리 원리: 비빈발 항목집합의 상위집합은 빈발할 수 없어 후보에서 제외.
- 51. 정답 ① | 원문항 Q3-036 | 기대빈도 5 미만 셀이 많은 소표본 분할표는 피셔 정확 검정.
- 52. 정답 ③ | 원문항 Q3-037 | 기대빈도 = (행 합 × 열 합) ÷ 전체 = 80×50÷200 = 20.
- 53. 정답 ④ | 원문항 Q3-042 | 변수 간 상관이 강하면 조건부 독립 가정이 깨져 성능 저하 — 인과를 뒤집은 함정.
- 54. 정답 ④ | 원문항 Q3-046 | 오토인코더는 입력 자신을 목표값으로 쓰는 비지도 학습 — 별도 라벨 불필요.
- 55. 정답 ② | 원문항 Q3-048 | TF-IDF = 문서 내 빈도(TF) × 역문서 빈도(IDF) — 흔한 단어일수록 가중치가 낮아짐.
- 56. 정답 ③ | 원문항 Q3-049 | 불용어는 빈번하지만 의미 없는 단어로 제거 대상 — 핵심 단어와 바꿔치기 함정.
- 57. 정답 ① | 원문항 Q3-054 | 부트스트랩 + 병렬 학습 + 집계 + 분산 감소 = 배깅(대표: 랜덤포레스트).
- 58. 정답 ③ | 원문항 Q3-055 | 클래스별 확률 평균으로 결정하면 소프트 보팅 — 클래스 다수결은 하드 보팅.
- 59. 정답 ① | 원문항 Q3-059 | 독립 2표본의 비모수 대응은 만-휘트니 U — 대응 2표본은 윌콕슨 부호순위.
- 60. 정답 ③ | 원문항 Q3-060 | 대응 전·후=윌콕슨 부호순위, 독립 3집단=크루스칼-왈리스, 독립 2집단=만-휘트니 U.

4과목 (61~80)

- 61. 정답 ② | 원문항 Q4-005 | 재현율 = TP/(TP+FN) = 40/50 = 0.80 — 분모는 실제 양성.
- 62. 정답 ③ | 원문항 Q4-006 | F1은 조화평균 2PR/(P+R) = 0.75/1.25 = 0.6 — 산술평균(0.625)이 대표 함정.
- 63. 정답 ④ | 원문항 Q4-013 | 오차 절댓값의 평균은 MAE — 제곱이면 MSE, √가 있으면 RMSE, 실제값으로 나누면 MAPE.
- 64. 정답 ④ | 원문항 Q4-016 | 샤피로-윌크는 정규성 검정 전용 — 범주형 독립성 검정은 카이제곱의 역할.
- 65. 정답 ① | 원문항 Q4-017 | 양성 1% 데이터는 전부 음성 예측만 해도 정확도 99% — 불균형에서 정확도는 과대평가 위험.
- 66. 정답 ② | 원문항 Q4-019 | 훈련 성능↑·평가 성능↓의 큰 격차 = 과대적합.
- 67. 정답 ④ | 원문항 Q4-022 | 가중치·편향은 학습이 결정하는 파라미터 — 학습률·에폭·은닉층 수는 하이퍼파라미터.
- 68. 정답 ② | 원문항 Q4-025 | "이전 이동 방향을 관성처럼 반영" = 모멘텀 — AdaGrad는 학습률 조정, Adam은 결합형.
- 69. 정답 ③ | 원문항 Q4-028 | 그리드 서치의 조합 수는 후보 값 수의 곱으로 기하급수적으로 증가.
- 70. 정답 ① | 원문항 Q4-031 | Adam은 모멘텀 + RMSProp의 결합 — 배치 정규화는 옵티마이저가 아님.
- 71. 정답 ④ | 원문항 Q4-036 | ROI = 순이익/투자비 × 100 = 500/2,000 × 100 = 25%.
- 72. 정답 ④ | 원문항 Q4-040 | 총 비용=TCO, 회수 시점=투자 회수 기간, 현재가치−투자비=NPV, 비율(%)=ROI.
- 73. 정답 ② | 원문항 Q4-041 | 시간 흐름에 따른 추세 표현은 선 그래프(시간 시각화) — 파이는 분포, 산점도는 관계.
- 74. 정답 ③ | 원문항 Q4-044 | 변수를 얼굴 요소에 대응시키는 비교 시각화 = 체르노프 페이스.
- 75. 정답 ② | 원문항 Q4-045 | 시각화 절차 3단계 = 구조화 → 시각화 → 시각표현("구·시·표").
- 76. 정답 ③ | 원문항 Q4-048 | 공간 시각화 = 등치지역도·도트맵·카토그램·버블 플롯맵 — 트리맵은 분포, 히트맵은 비교.
- 77. 정답 ② | 원문항 Q4-055 | "측정만 하고 변경 안 함"은 모니터링 — 리모델링은 재학습·재개발로 모형을 변경.
- 78. 정답 ② | 원문항 Q4-058 | 활용 시나리오는 기획 단계부터 고려 — 폐기 시점 수립은 완전히 틀린 시점.
- 79. 정답 ③ | 원문항 Q4-059 | 성능 저하 감지 시 리모델링을 검토해야 함 — 감지하고 방치하는 선지는 항상 오답.
- 80. 정답 ④ | 원문항 Q4-060 | 데이터·환경 변화로 지속 성능 하락 시 최신 데이터 반영 리모델링이 정석.

채점표

문항당 1.25점 환산 (과목당 20문항 × 1.25점 = 25점, 총 100점 만점)

과목	맞힌 개수	환산 점수(×1.25)	과락 기준	과락 여부
1과목 빅데이터 분석 기획	___ / 20	___ 점	8문항(40점) 미만 시 과락	통과 / 과락
2과목 빅데이터 탐색	___ / 20	___ 점	8문항(40점) 미만 시 과락	통과 / 과락
3과목 빅데이터 모델링	___ / 20	___ 점	8문항(40점) 미만 시 과락	통과 / 과락
4과목 빅데이터 결과 해석	___ / 20	___ 점	8문항(40점) 미만 시 과락	통과 / 과락
합계	___ / 80	___ 점	—	—

합격 판정

조건	기준	결과
총점	48문항(60점) 이상	충족 / 미달
과락	전 과목 8문항(40점) 이상	없음 / 있음
최종 판정	두 조건 모두 충족 시 **합격**	합격 / 불합격

이 문서는 LLM으로 생성 후 3중 검증(사실·논리·규격 / 중복 / 교체분 재검증)을 거친 학습 자료입니다. 교재별 표기가 갈리는 항목은 본문에 "※ 교재별 표기 차이 있음"으로 표시했으며, 상세 목록은 부록의 검증 필요 항목을 참고하세요.