빅데이터분석기사 필기 문제집

1과목 · 빅데이터 분석 기획 — 60문항 (Q1-001 ~ Q1-060)

the0ne 학습용 · 2026-09-01 생성 · KDATA 공개 출제기준 기반 신규 창작 문항 (기출 복원 아님)

1-1 빅데이터 개요 및 활용

> 1과목 · 빅데이터 분석 기획 / 주요항목: 빅데이터의 이해
> 문항 수: 10 (Q1-001 ~ Q1-010) · 난이도 하3/중5/상2 · 정답 분포 ①3 ②3 ③2 ④2

Q1-001 [난이도: 하] [태그: 1과목/빅데이터의이해/DIKW]

다음은 DIKW 피라미드를 마트의 우유 가격에 적용한 사례다. **지혜(Wisdom)** 에 해당하는 것은?

① A마트는 우유를 1,000원에, B마트는 1,200원에 판매한다.
② A마트의 다른 상품들도 B마트보다 저렴할 것이라 판단하여 A마트를 이용하기로 한다.
③ A마트의 우유가 B마트보다 200원 더 싸다.
④ 우유는 상대적으로 저렴한 A마트에서 구매해야겠다.

✓ 정답 및 해설

정답: ②

- ① 가공되지 않은 객관적 사실 그 자체 → 데이터(Data).
- ② 축적된 지식에 추론·창의적 판단을 결합해 다른 상황까지 예측 → 지혜(Wisdom). ← 정답
- ③ 데이터를 비교·가공해 의미(패턴)를 부여한 것 → 정보(Information).
- ④ 정보를 구조화·내재화하여 행동 방침으로 만든 것 → 지식(Knowledge).

출제 포인트: 사례형이 나오면 "사실=데이터, 비교·의미=정보, 행동 방침=지식, 다른 상황 추론=지혜"로 판별.

근거: DIKW 피라미드는 데이터(Data)→정보(Information)→지식(Knowledge)→지혜(Wisdom)의 4계층으로 데이터가 가치로 발전하는 위계를 설명하는 모델이다.

Q1-002 [난이도: 하] [태그: 1과목/빅데이터의이해/빅데이터특성V]

가트너(Gartner)가 제시한 빅데이터의 기본 3V에 해당하지 **<u>않는</u>** 것은?

① 규모(Volume) ② 속도(Velocity) ③ 다양성(Variety) ④ 신뢰성(Veracity)

✓ 정답 및 해설

정답: ④

- ① Volume: 대용량 데이터의 규모 → 3V에 포함.
- ② Velocity: 데이터의 생성·처리 속도 → 3V에 포함.
- ③ Variety: 정형·반정형·비정형 등 형태의 다양성 → 3V에 포함.
- ④ Veracity: 데이터의 신뢰성. 3V가 아니라 **5V에서 추가**되는 요소. ← 정답

출제 포인트: 3V = Volume·Velocity·Variety(모두 V로 시작하는 규모·속도·다양성). 5V = 3V + Veracity(신뢰성) + Value(가치).

근거: 빅데이터의 기본 특성 3V는 규모(Volume)·속도(Velocity)·다양성(Variety)이며, 신뢰성(Veracity)과 가치(Value)를 더해 5V로 확장된다.

Q1-003 [난이도: 하] [태그: 1과목/빅데이터의이해/빅데이터특성V]

빅데이터의 특성 중 '데이터가 빠른 속도로 생성·유통되므로 수집·저장·분석이 실시간에 가깝게 처리되어야 함'을 의미하는 것은?

① 속도(Velocity) ② 규모(Volume) ③ 가치(Value) ④ 다양성(Variety)

✓ 정답 및 해설

정답: ①

- ① Velocity: 생성·유통·처리의 속도, 실시간 처리 요구. ← 정답
- ② Volume: 데이터의 양적 규모(대용량)를 의미. 속도와 무관.
- ③ Value: 데이터 분석으로 얻는 유용성·가치. 5V에서 추가되는 요소.
- ④ Variety: 데이터 형태(정형/반정형/비정형)의 다양함을 의미.

출제 포인트: "실시간", "생성 속도"가 보이면 Velocity. "형태"는 Variety, "품질·정확성"은 Veracity로 즉시 연결할 것.

근거: 속도(Velocity)는 데이터가 생성·이동·처리되는 속도를 의미하며, 실시간 또는 준실시간 처리 요구를 나타내는 빅데이터의 기본 특성이다.

Q1-004 [난이도: 중] [태그: 1과목/빅데이터의이해/데이터유형]

다음 중 반정형(semi-structured) 데이터에 해당하는 것은?

① 관계형 데이터베이스의 고객 테이블
② 스마트폰으로 촬영한 동영상 파일
③ 웹 서버가 기록한 JSON 형식의 로그
④ 콜센터 상담 음성 녹음 파일

✓ 정답 및 해설

정답: ③

- ① 미리 정의된 고정 스키마의 테이블에 저장 → 정형 데이터.
- ② 정해진 구조가 없는 멀티미디어 → 비정형 데이터.
- ③ JSON·XML·HTML·웹로그는 스키마(구조) 정보를 데이터 안에 포함 → 반정형 데이터. ← 정답
- ④ 음성은 구조가 없는 미디어 → 비정형 데이터.

출제 포인트: 반정형 4대 예시 = XML·JSON·HTML·로그. "테이블이면 정형, 태그·키가 보이면 반정형, 미디어·자유 텍스트면 비정형."

근거: 반정형 데이터는 고정된 스키마는 없지만 메타데이터나 스키마 정보를 데이터 자체에 포함하는 데이터로, XML·JSON·HTML·웹로그가 대표적이다.

Q1-005 [난이도: 중] [태그: 1과목/빅데이터의이해/데이터유형]

데이터 유형에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 정형 데이터는 미리 정의된 스키마에 따라 고정된 필드에 저장된다.
② 반정형 데이터는 스키마·메타데이터 정보를 데이터 내부에 포함하며 XML, JSON이 대표적이다.
③ 비정형 데이터는 정해진 구조가 없으며 동영상, 음성, 이미지 등이 해당한다.
④ 반정형 데이터는 메타데이터를 갖지 않으므로 구조 파악이 불가능하다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. RDB 테이블·스프레드시트처럼 행·열이 고정된 형태.
- ② 옳은 설명. 스키마를 데이터와 함께 제공하는 것이 반정형의 핵심 특징.
- ③ 옳은 설명. 구조가 없어 그대로는 연산이 불가능한 데이터.
- ④ 반정형은 오히려 **메타데이터(태그·키)를 포함**하므로 구조 파악이 가능하다. 틀린 설명. ← 정답

출제 포인트: 반정형의 정의 자체가 "메타데이터를 포함한다"이다. 부정형 문제에서 반정형·비정형의 특징을 서로 바꿔치기하는 선지가 단골.

근거: 반정형 데이터는 고정 스키마 없이도 태그나 키-값 등 메타정보를 데이터에 포함하여 구조를 파악할 수 있는 데이터 유형이다.

Q1-006 [난이도: 중] [태그: 1과목/빅데이터의이해/가치산정]

빅데이터 시대에 데이터의 가치 산정이 어려운 이유로 적절하지 **<u>않은</u>** 것은?

① 데이터가 재사용·재조합되고 다목적으로 개발되어 누가 언제 어디서 활용할지 예측하기 어렵다.
② 데이터의 가격이 거래소를 통해 표준화되어 있어 개별 산정이 무의미하기 때문이다.

③ 기존에 없던 새로운 가치를 창출하므로 그 가치를 측정하기 어렵다.
④ 분석 기술이 발전하면서 현재는 가치가 없는 데이터도 미래에 가치를 가질 수 있다.

✓ 정답 및 해설

정답: ②

- ① 옳은 이유. 재사용·재조합(mashup)·다목적 개발이 일반화되어 활용 주체와 시점을 예측할 수 없다.
- ② 데이터 가격이 표준화되어 있다는 전제 자체가 사실이 아니며, 가치 산정 곤란의 이유와 무관. ← 정답
- ③ 옳은 이유. 없던 가치를 새로 만들어내므로 사전 측정이 곤란하다.
- ④ 옳은 이유. 분석 기술 발전으로 데이터의 잠재 가치가 계속 변한다.

출제 포인트: 가치 산정이 어려운 이유 3가지 = **활용**(재사용·재조합·다목적화), **창출**(새로운 가치), **기술**(분석 기술 발전). "활·창·기"로 암기.

근거: 빅데이터의 가치 산정이 어려운 이유는 데이터 활용 방식의 다변화, 새로운 가치의 창출, 분석 기술의 발전이라는 세 가지로 정리된다.

Q1-007 [난이도: 중] [태그: 1과목/빅데이터의이해/데이터사이언티스트]

데이터 사이언티스트의 역량 중 하드 스킬(hard skill)에 해당하는 것은?

① 빅데이터 분석 기술에 대한 숙련과 방법론 습득
② 스토리텔링을 통한 설득력 있는 전달
③ 창의적 사고와 호기심에 기반한 통찰력 있는 분석
④ 다분야 간 협력을 위한 커뮤니케이션

✓ 정답 및 해설

정답: ①

- ① 이론적 지식과 분석 기술 숙련은 하드 스킬. ← 정답
- ② 설득력 있는 전달(스토리텔링·시각화)은 소프트 스킬.
- ③ 통찰력 있는 분석(창의적 사고·호기심·논리적 비판)은 소프트 스킬.
- ④ 다분야 간 협력(커뮤니케이션)은 소프트 스킬.

출제 포인트: 하드 스킬 2개 = **이론적 지식 + 분석 기술 숙련**. 소프트 스킬 3개 = **통찰(창의·호기심·비판) / 전달(스토리텔링·시각화) / 협력(커뮤니케이션)**. "하드는 기술, 소프트는 사람"으로 구분.

근거: 데이터 사이언티스트의 역량은 빅데이터 관련 이론적 지식과 분석 기술 숙련(하드 스킬), 통찰력 있는 분석·설득력 있는 전달·다분야 간 협력(소프트 스킬)로 구분된다.

Q1-008 [난이도: 중] [태그: 1과목/빅데이터의이해/조직구조]

분석 전담 조직의 인력을 현업 부서에 직접 배치하여 분석 업무를 수행하게 하는 빅데이터 분석 조직 구조는?

① 집중 구조 ② 기능 구조 ③ 분산 구조 ④ 계층 구조

✓ 정답 및 해설

정답: ③

- ① 집중 구조: 전사의 분석 업무를 **별도 분석 전담 조직**이 담당. 현업 배치가 아님.
- ② 기능 구조: 별도 전담 조직 없이 **해당 업무 부서가 직접** 분석. 전담 인력 배치 개념이 없음.
- ③ 분산 구조: 분석 전문 인력을 **현업 부서에 직접 배치**. 전사 우선순위 수행 + 신속한 실무 적용. ← 정답
- ④ 계층 구조: 빅데이터 분석 조직 구조 3유형에 없는 용어.

출제 포인트: 조직 구조 3유형 = 집중(전담 조직 별도) / 기능(부서가 스스로) / 분산(전담 인력을 현업에 배치). "누가 분석하는가"로 구분.

근거: 빅데이터 분석 조직 구조는 집중 구조·기능 구조·분산 구조로 나뉘며, 분산 구조는 분석 조직 인력을 현업 부서에 직접 배치해 분석 업무를 수행하는 형태다.

Q1-009 [난이도: 상] [태그: 1과목/빅데이터의이해/조직구조]

빅데이터 분석 조직 구조의 특징에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 집중 구조는 현업 업무 부서의 분석 업무와 이중화·이원화될 가능성이 있다.
② 분산 구조는 분석 인력이 현업 부서에 배치되므로 부서의 분석 업무와 역할 분담을 명확히 하지 않아도 업무의 이중화가 발생하지 않는다.
③ 기능 구조는 전사적 관점의 핵심 분석이 어렵다.
④ 기능 구조는 특정 부서에 국한된 과거 실적 위주의 분석에 머무를 수 있다.

✓ 정답 및 해설

정답: ②

- ① 옳은 설명. 전담 조직과 현업 부서가 같은 분석을 따로 수행할 수 있는 것이 집중 구조의 단점.
- ② 분산 구조도 현업 부서의 기존 분석 업무와 **업무 과다·이중화(이원화) 가능성**이 있으며, 그래서 **역할 분담의 명확화가 반드시 필요**하다. "역할 분담 없이도 이중화가 없다"는 틀린 설명. ← 정답
- ③ 옳은 설명. 부서별로 따로 분석하므로 전사 핵심 분석이 어렵다.
- ④ 옳은 설명. 기능 구조의 전형적 한계.

출제 포인트: 장단점 바꿔치기 함정 주의 — "이중화·이원화"는 집중 구조의 단점(분산 구조에서도 부서 업무와 역할 분담이 불명확하면 발생 가능), "신속한 실무 적용·베스트 프랙티스 공유"는 분산 구조의 장점, "전사 분석 곤란·과거 실적 위주"는 기능 구조의 단점.

근거: 분산 구조는 분석 인력을 현업 부서에 배치해 전사 차원의 우선순위를 수행하면서 분석 결과를 신속하게 실무에 적용할 수 있는 조직 구조다.

Q1-010 [난이도: 상] [태그: 1과목/빅데이터의이해/빅데이터특성V]

빅데이터의 특성(V)에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 기본 3V는 규모(Volume), 속도(Velocity), 다양성(Variety)이다.
- ㄴ. 가치(Value)는 기본 3V에 포함되는 특성이다.
- ㄷ. 신뢰성(Veracity)은 수집한 데이터의 품질·정확성과 관련된 특성이다.
- ㄹ. 휘발성(Volatility)은 데이터가 의미를 갖고 저장·활용될 수 있는 기간과 관련된 특성이다.

① ㄱ, ㄷ, ㄹ ② ㄱ, ㄴ, ㄷ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄹ

✓ 정답 및 해설

정답: ①

- **ㄱ (O)** 가트너의 기본 3V = Volume·Velocity·Variety.
- **ㄴ (X)** Value는 3V가 아니라 **5V에서 추가**되는 특성이다.
- **ㄷ (O)** Veracity는 데이터의 신뢰성·품질을 의미한다.
- **ㄹ (O)** Volatility는 7V에서 추가되는 특성으로, 데이터의 유효 기간(휘발성)을 의미한다.

따라서 옳은 것은 ㄱ, ㄷ, ㄹ → **①**. (②·③은 틀린 ㄴ을 포함, ④는 옳은 ㄷ을 누락)

출제 포인트: V 확장 순서 = 3V(규모·속도·다양성) → 5V(+신뢰성 Veracity·가치 Value) → 7V(+정확성 Validity·휘발성 Volatility). ※ 교재별 표기 차이 있음 — 7V의 구성 요소는 교재에 따라 다르게 제시될 수 있으므로 "3V·5V는 확정, 7V는 대표 표기"로 암기.

근거: 빅데이터 특성은 3V(Volume·Velocity·Variety)에서 Veracity·Value를 더한 5V, Validity·Volatility를 더한 7V로 확장되는 개념 체계다.

1-2 빅데이터 기술 및 제도

> 1과목 · 빅데이터 분석 기획 / 주요항목: 빅데이터의 이해
> 범위: 하둡 에코시스템, 분산컴퓨팅·클라우드, 데이터 3법, 개인정보·가명정보·익명정보, 가명정보 처리 특례, 비식별화 기법, 마이데이터, 개인정보 수집·이용 원칙
> 문항 수: 14 (Q1-011 ~ Q1-024) · 난이도 하4/중7/상3 · 정답 분포 ①4 ②3 ③4 ④3

Q1-011 [난이도: 하] [태그: 1과목/빅데이터의이해/하둡에코시스템]

대용량 파일을 블록(block) 단위로 나누어 여러 노드에 분산 저장하고, 블록의 복제본(replica)을 두어 노드 장애에 대비하는 하둡(Hadoop)의 분산 파일 저장 컴포넌트는?

① HDFS ② MapReduce ③ YARN ④ HBase

✓ 정답 및 해설

정답: ①

- ① HDFS(Hadoop Distributed File System): 블록 단위 분산 저장 + 복제를 통한 장애 허용(fault tolerance). ← 정답
- ② MapReduce: 저장이 아니라 분산 **처리**(Map→Reduce 연산) 프레임워크.
- ③ YARN: 클러스터의 **자원 관리·작업 스케줄링** 담당. 저장 기능 아님.
- ④ HBase: HDFS 위에서 동작하는 컬럼 기반 NoSQL **데이터베이스**. 파일 시스템 자체가 아님.

출제 포인트: 하둡 핵심 3요소 = HDFS(저장) / MapReduce(처리) / YARN(자원 관리). "블록·복제·분산 저장"이 보이면 HDFS.

근거: HDFS는 대용량 파일을 블록 단위로 분할해 여러 노드에 분산 저장하고 복제본을 유지하여 장애에 대비하는 하둡의 분산 파일 시스템이다.

Q1-012 [난이도: 하] [태그: 1과목/빅데이터의이해/하둡에코시스템]

분산 환경에서 여러 서버가 공유하는 설정 정보의 유지·관리, 서버 간 동기화, 리더 선출(leader election) 등 분산 애플리케이션의 코디네이션(coordination)을 담당하는 하둡 에코시스템 컴포넌트는?

① Oozie ② Zookeeper ③ Avro ④ Hive

✓ 정답 및 해설

정답: ②

- ① Oozie(우지): 하둡 작업(MapReduce·Pig 등)의 **워크플로(workflow)를 정의·스케줄링**하는 관리 도구. 코디네이션 서비스가 아님.
- ② Zookeeper(주키퍼): 분산 환경의 **설정 관리·동기화·네이밍·리더 선출**을 담당하는 분산 코디네이션 서비스. ← 정답
- ③ Avro(에이브로): 데이터 구조를 정의해 저장·교환하는 **데이터 직렬화(serialization)** 시스템.
- ④ Hive(하이브): SQL 유사 언어(HiveQL)로 하둡 데이터를 **질의·분석**하는 도구.

출제 포인트: 관리·운영 계열 컴포넌트 구분 — Zookeeper=분산 코디네이션(설정·동기화·리더 선출), Oozie=워크플로 스케줄링, Avro=직렬화. "동물원 사육사(Zookeeper)가 분산된 동물들을 조율한다"로 암기.

근거: 주키퍼(Zookeeper)는 분산 환경에서 설정 정보 관리, 동기화, 리더 선출 등의 기능을 제공하여 분산 애플리케이션의 코디네이션을 지원하는 하둡 에코시스템의 서비스다.

Q1-013 [난이도: 중] [태그: 1과목/빅데이터의이해/하둡에코시스템]

하둡 에코시스템 컴포넌트의 역할에 대한 설명으로 옳지 **않은** 것은?

① Hive는 SQL과 유사한 HiveQL로 하둡에 저장된 데이터를 질의·분석한다.
② Flume은 여러 서버에서 발생하는 대량의 로그 데이터를 수집하여 저장소로 전송한다.
③ Kafka는 발행-구독(publish-subscribe) 모델 기반의 분산 메시징 시스템으로 대용량 실시간 데이터 스트림을 처리한다.
④ Pig는 관계형 데이터베이스와 하둡 간의 대량 데이터 전송을 담당한다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. Hive = 데이터 웨어하우스 도구, HiveQL로 SQL식 질의.
- ② 옳은 설명. Flume = 로그 수집·집계·이동.
- ③ 옳은 설명. Kafka = pub-sub 분산 메시지 큐, 실시간 스트림 처리 기반.
- ④ RDB ↔ 하둡 전송은 **Sqoop**의 역할. Pig는 절차형 스크립트 언어 **Pig Latin**으로 데이터 흐름(변환·처리)을 기술하는 도구. ← 정답

출제 포인트: Pig와 Sqoop 바꿔치기가 단골 함정. Pig=Pig Latin 스크립트 처리, Sqoop=RDB 전송, Hive=SQL식 질의. "돼지(Pig)는 라틴어(Pig Latin)를 쓴다"로 암기.

근거: 피그(Pig)는 절차형 스크립트 언어인 Pig Latin을 사용해 대용량 데이터의 변환·처리 흐름을 기술하는 하둡 기반 데이터 처리 도구이다.

Q1-014 [난이도: 중] [태그: 1과목/빅데이터의이해/하둡에코시스템]

디스크 입출력 중심의 MapReduce와 달리 인메모리(in-memory) 기반 연산을 수행하여 반복 연산·머신러닝 작업에서 빠른 처리 속도를 보이는 분산 데이터 처리 엔진은?

① MapReduce ② HBase ③ Spark ④ YARN

✓ 정답 및 해설

정답: ③

- ① MapReduce: 중간 결과를 **디스크에 기록**하며 처리. 반복 연산에 상대적으로 느림 → 문제의 비교 대상.
- ② HBase: 컬럼 기반 NoSQL 데이터베이스. 처리 엔진이 아니라 저장소.
- ③ Spark: **메모리 상에서** 데이터를 유지하며 연산 → 반복 연산·머신러닝·실시간 처리에 유리. ← 정답
- ④ YARN: 자원 관리·스케줄링 컴포넌트. 데이터 처리 엔진 아님.

출제 포인트: "인메모리", "반복 연산", "MapReduce보다 빠름" 키워드 → Spark. 처리 방식 비교: MapReduce=디스크 기반 배치, Spark=메모리 기반(배치+스트림+ML).

근거: 스파크(Spark)는 인메모리 기반의 분산 데이터 처리 엔진으로, 디스크 기반 MapReduce에 비해 반복 연산과 대화형 분석에서 빠른 성능을 제공한다.

Q1-015 [난이도: 상] [태그: 1과목/빅데이터의이해/하둡에코시스템]

하둡 에코시스템에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. YARN은 하둡 클러스터의 자원 관리와 작업 스케줄링을 담당한다.
- ㄴ. HBase는 HDFS 위에서 동작하는 컬럼(column) 기반 분산 NoSQL 데이터베이스다.
- ㄷ. Hive는 절차형 스크립트 언어인 Pig Latin으로 데이터 처리 흐름을 기술한다.
- ㄹ. Flume은 대량의 로그 데이터를 수집·집계하여 저장소로 전송한다.

① ㄱ, ㄴ, ㄹ ② ㄱ, ㄷ, ㄹ ③ ㄴ, ㄷ ④ ㄱ, ㄴ, ㄷ, ㄹ

✓ 정답 및 해설

정답: ①

- **ㄱ (O)** YARN(Yet Another Resource Negotiator) = 자원 관리 + 작업 스케줄링.
- **ㄴ (O)** HBase = HDFS 기반 컬럼형 NoSQL DB. 실시간 랜덤 읽기·쓰기 지원.
- **ㄷ (X)** Pig Latin을 쓰는 것은 **Pig**. Hive는 SQL 유사 언어 **HiveQL**을 사용.
- **ㄹ (O)** Flume = 로그 수집·집계·이동 도구.

따라서 옳은 것은 ㄱ, ㄴ, ㄹ → **①**. (②·③은 틀린 ㄷ을 포함, ④도 ㄷ을 포함)

출제 포인트: 질의·스크립트 도구 구분 — Hive=HiveQL(SQL식, 선언형), Pig=Pig Latin(스크립트, 절차형). 조합형에서 이 둘을 바꾼 지문이 오답 축으로 반복 등장.

근거: 하둡 에코시스템은 저장(HDFS·HBase), 자원 관리(YARN), 처리(MapReduce·Spark), 수집(Flume·Sqoop·Kafka), 질의(Hive·Pig) 등 역할별 컴포넌트의 집합이다.

Q1-016 [난이도: 하] [태그: 1과목/빅데이터의이해/클라우드컴퓨팅]

이용자가 별도의 설치 없이 웹 브라우저로 접속하여 전자우편·문서 편집 등의 응용 소프트웨어를 완성된 서비스 형태로 이용하는 클라우드 서비스 모델은?

① IaaS ② PaaS ③ SaaS ④ 온프레미스(on-premise)

✓ 정답 및 해설

정답: ③

- ① IaaS(Infrastructure as a Service): 서버·스토리지·네트워크 등 **인프라 자원**을 제공. 소프트웨어는 이용자가 직접 구성.
- ② PaaS(Platform as a Service): 애플리케이션 **개발·실행 환경(플랫폼)** 을 제공. 완성된 앱이 아님.
- ③ SaaS(Software as a Service): **응용 소프트웨어 완제품**을 서비스로 제공. 웹 메일·웹 오피스가 대표 사례. ← 정답
- ④ 온프레미스: 클라우드가 아니라 자체 전산실에 직접 구축·운영하는 방식.

출제 포인트: 제공 범위로 구분 — IaaS=인프라까지, PaaS=플랫폼까지, SaaS=소프트웨어까지. "완성된 앱을 그냥 쓴다 = SaaS."

근거: SaaS는 응용 소프트웨어를 클라우드 사업자가 완성된 서비스 형태로 제공하고 이용자는 네트워크를 통해 접속하여 사용하는 클라우드 서비스 모델이다.

Q1-017 [난이도: 중] [태그: 1과목/빅데이터의이해/클라우드컴퓨팅]

클라우드 컴퓨팅 서비스 모델(IaaS/PaaS/SaaS)에 대한 설명으로 옳은 것은?

① IaaS는 응용 소프트웨어까지 완제품 형태로 제공한다.
② PaaS는 애플리케이션 개발·실행 환경을 제공하므로 이용자는 인프라를 직접 관리하지 않고 애플리케이션 개발·배포에 집중할 수 있다.
③ SaaS는 서버·스토리지·네트워크 등 인프라 자원만을 가상화하여 제공한다.
④ IaaS 이용자는 가상 서버의 운영체제(OS)를 직접 선택하거나 관리할 수 없다.

> **✓ 정답 및 해설**
>
> **정답:** ②
>
> - ① 응용 소프트웨어 완제품 제공은 **SaaS**의 특징. IaaS는 인프라 자원 제공.
> - ② 옳은 설명. PaaS = 개발·실행 플랫폼 제공, 인프라 관리는 사업자 몫. ← 정답
> - ③ 인프라 자원만 제공하는 것은 **IaaS**. SaaS는 소프트웨어까지 제공.
> - ④ IaaS는 이용자가 **OS부터 직접 설치·관리**하는 모델. 관리할 수 없다는 설명은 반대.
>
> **출제 포인트:** 이용자 관리 범위 — IaaS: OS부터 위는 이용자 / PaaS: 애플리케이션·데이터만 이용자 / SaaS: 전부 사업자. 특징 바꿔치기 선지에 주의.
>
> **근거:** PaaS는 애플리케이션의 개발·실행에 필요한 플랫폼 환경을 서비스로 제공하여 이용자가 인프라 운영 부담 없이 개발에 집중하도록 하는 클라우드 서비스 모델이다.

Q1-018 [난이도: 하] [태그: 1과목/빅데이터의이해/데이터3법]

2020년 개정·시행된 이른바 '데이터 3법'에 해당하지 **<u>않는</u>** 것은?

① 개인정보 보호법
② 정보통신망 이용촉진 및 정보보호 등에 관한 법률(정보통신망법)
③ 신용정보의 이용 및 보호에 관한 법률(신용정보법)
④ 위치정보의 보호 및 이용 등에 관한 법률(위치정보법)

> **✓ 정답 및 해설**
>
> **정답:** ④
>
> - ① 데이터 3법 포함. 가명정보 개념 도입, 개인정보보호위원회로 감독 일원화.
> - ② 데이터 3법 포함. 온라인 개인정보 보호 규정이 개인정보 보호법으로 이관·정비됨.
> - ③ 데이터 3법 포함. 금융 분야 가명정보(가명처리된 신용정보) 활용 근거 마련.
> - ④ 위치정보법은 데이터 3법에 **포함되지 않음**. ← 정답
>
> **출제 포인트:** 데이터 3법 = 개인정보 보호법 + 정보통신망법 + 신용정보법. "개·망·신"으로 암기. 위치정보법·전자정부법 등을 끼워 넣는 선지가 단골.
>
> **근거:** 데이터 3법은 개인정보 보호법, 정보통신망법, 신용정보법의 세 법률 개정안을 통칭하며 가명정보 도입과 개인정보 감독체계 일원화를 골자로 한다.

Q1-019 [난이도: 중] [태그: 1과목/빅데이터의이해/가명정보익명정보]

개인정보·가명정보·익명정보에 대한 설명으로 옳은 것은?

① 가명정보는 추가 정보 없이도 특정 개인을 쉽게 알아볼 수 있는 정보다.
② 익명정보는 개인정보 보호법의 보호 대상에 포함된다.
③ 가명정보는 추가 정보를 사용하지 않고는 특정 개인을 알아볼 수 없도록 처리한 정보로, 개인정보의 범위에 포함된다.
④ 개인정보는 살아 있는 개인뿐 아니라 사망한 사람에 관한 정보도 포함한다.

✓ 정답 및 해설

정답: ③

- ① 반대 설명. 가명정보는 **추가 정보 없이는 식별 불가**하도록 가명처리한 정보.
- ② 익명정보는 더 이상 개인을 알아볼 수 없는 정보로, 개인정보 보호법의 **적용 대상이 아님**(자유롭게 활용 가능).
- ③ 옳은 설명. 가명정보는 개인정보의 일종이므로 법의 적용을 받되, 특례에 따라 동의 없는 활용이 일부 허용된다. ← 정답
- ④ 개인정보는 **살아 있는 개인**에 관한 정보. 사망자 정보는 원칙적으로 해당 없음.

출제 포인트: 식별 가능성 스펙트럼 — 개인정보(식별 가능) > 가명정보(추가 정보 결합 시 식별 가능, 법 적용 O) > 익명정보(식별 불가능, 법 적용 X). "가명은 법 안, 익명은 법 밖."

근거: 가명정보는 개인정보를 가명처리하여 추가 정보의 사용·결합 없이는 특정 개인을 알아볼 수 없게 한 정보로, 개인정보 보호법상 개인정보에 포함된다.

Q1-020 [난이도: 중] [태그: 1과목/빅데이터의이해/가명정보특례]

개인정보 보호법상 정보주체의 동의 없이 가명정보를 처리할 수 있는 목적에 해당하지 **<u>않는</u>** 것은?

① 통계작성
② 과학적 연구
③ 공익적 기록보존
④ 특정 개인을 대상으로 한 맞춤형 광고 발송

✓ 정답 및 해설

정답: ④

- ① 특례 목적에 포함. 시장조사 등 상업적 목적의 통계작성도 포함된다.
- ② 특례 목적에 포함. 기술 개발·실증 등 산업적 연구도 과학적 연구에 포함된다.
- ③ 특례 목적에 포함. 공익적 가치가 있는 기록의 보존.
- ④ 특정 개인에게 연락·광고하려면 그 개인을 식별해야 하므로 가명정보 특례의 취지에 반함. 특례 목적이 **아님**. ← 정답

출제 포인트: 가명정보 특례 3목적 = **통계작성 · 과학적 연구 · 공익적 기록보존**. "통·과·공"으로 암기. 함정 포인트: 상업적 통계·산업적 연구는 포함되지만, 특정 개인 식별·마케팅 접촉은 불가.

근거: 개인정보 보호법은 통계작성, 과학적 연구, 공익적 기록보존 등의 목적에 한해 정보주체의 동의 없이 가명정보를 처리할 수 있도록 특례를 두고 있다.

Q1-021 [난이도: 중] [태그: 1과목/빅데이터의이해/비식별화기법]

개별 데이터 값을 데이터의 총합 또는 평균값으로 대체하여 개별 값이 드러나지 않도록 하는 비식별화(데이터 비식별 조치) 기법은?

① 총계처리 ② 가명처리 ③ 데이터 범주화 ④ 데이터 마스킹

✓ 정답 및 해설

정답: ①

- ① 총계처리(aggregation): 개별 값을 총합·평균 등 통계값으로 대체. 예: 학생별 키 → 학급 평균 키. ← 정답
- ② 가명처리(pseudonymization): 식별 값을 다른 값(가명)으로 대체. 예: 홍길동 → 임꺽정.
- ③ 데이터 범주화(data suppression/categorization): 값을 범주·구간으로 변환. 예: 33세 → 30대.
- ④ 데이터 마스킹(data masking): 식별 값의 일부를 공백·노이즈·기호(*)로 가림. 예: 홍길동 → 홍**.

출제 포인트: 비식별화 5대 기법 = 가명처리·총계처리·데이터 삭제·데이터 범주화·데이터 마스킹. 예시 하나씩 짝지어 암기: 가명(이름 바꿈)/총계(평균)/삭제(지움)/범주화(30대)/마스킹(홍**).

근거: 총계처리는 데이터의 개별 값을 총합이나 평균 등의 통계값으로 대체하여 개별 데이터의 값이 드러나지 않도록 하는 비식별화 기법이다.

Q1-022 [난이도: 상] [태그: 1과목/빅데이터의이해/비식별화기법]

비식별화 기법과 그 처리 방식(세부기술)의 연결로 옳지 **<u>않은</u>** 것은?

① 가명처리 — 휴리스틱 대체(heuristic pseudonymization): 미리 정한 규칙으로 이름 등을 다른 값으로 대체
② 데이터 마스킹 — 주민등록번호 등 식별자 항목 자체를 원본에서 완전히 삭제

③ 데이터 범주화 — 나이 '33세'를 '30대'라는 구간값으로 변환
④ 총계처리 — 라운딩(rounding)·재배열 등으로 개별 값 대신 통계값을 제공

> **✓ 정답 및 해설**
>
> **정답:** ②
>
> - ① 옳은 연결. 휴리스틱 대체(가명화)는 가명처리의 세부기술.
> - ② 식별자 항목 자체를 삭제하는 것은 **데이터 삭제** 기법. 마스킹은 삭제가 아니라 값의 일부를 기호(*)·노이즈 등으로 **가리는** 것. ← 정답
> - ③ 옳은 연결. 구간값(범주) 변환은 데이터 범주화의 대표 방식.
> - ④ 옳은 연결. 라운딩·재배열은 총계처리 계열의 세부기술. ※ 교재별 표기 차이 있음 — 라운딩을 범주화(랜덤 라운딩)로 분류하는 교재도 있다.
>
> **출제 포인트:** "삭제"와 "마스킹"의 구분이 핵심 — 삭제는 항목을 없애는 것, 마스킹은 남기되 가리는 것. 세부기술 매칭형에서는 소속 기법을 바꿔 끼운 선지를 먼저 의심할 것.
>
> **근거:** 데이터 마스킹은 개인 식별에 기여하는 값의 전부 또는 일부를 공백·노이즈·대체 기호 등으로 가려 알아볼 수 없게 하는 비식별화 기법이다.

Q1-023 [난이도: 중] [태그: 1과목/빅데이터의이해/마이데이터]

마이데이터(MyData)에 대한 설명으로 옳은 것은?

① 기업이 정보주체의 동의 없이 보유 개인정보를 제3자에게 자유롭게 판매할 수 있도록 하는 제도다.
② 전송요구권은 신용정보법상 금융 분야에서만 인정되며 다른 분야로는 도입되지 않았다.
③ 정보주체가 자신의 개인정보를 본인 또는 제3자에게 전송하도록 개인정보처리자에게 요구할 수 있는 권리(개인정보 전송요구권)에 기반한다.
④ 전송 대상 개인정보는 반드시 종이 문서 형태로 제공되어야 한다.

✓ 정답 및 해설

정답: ③

- ① 반대 설명. 마이데이터의 주체는 기업이 아니라 **정보주체 본인**이며, 본인의 요구·통제가 핵심.
- ② 금융 분야(신용정보법)에서 먼저 시행된 후, 개인정보 보호법 개정으로 **전 분야 확대**의 법적 근거가 마련되었다.
- ③ 옳은 설명. 마이데이터 = 정보주체 중심의 개인정보 이동·활용, 법적 기반은 **개인정보 전송요구권**. ← 정답
- ④ 전송은 **컴퓨터 등 정보처리장치로 처리 가능한 형태**로 이루어져야 한다. 종이 문서 한정은 반대 설명.

출제 포인트: 마이데이터 핵심 3요소 = 주체(정보주체 본인) / 권리(전송요구권) / 형태(기계 판독 가능한 형태). "내(My) 데이터의 이동을 내가 결정한다."

근거: 마이데이터는 정보주체가 자신의 개인정보를 본인 또는 제3자에게 전송하도록 요구할 수 있는 개인정보 전송요구권을 기반으로, 정보주체가 개인정보의 이동과 활용을 통제하는 제도다.

Q1-024 [난이도: 상] [태그: 1과목/빅데이터의이해/개인정보수집이용원칙]

개인정보 보호법상 개인정보 처리(수집·이용)의 기본 원칙에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 적법하게 수집한 개인정보는 당초 수집 목적과 무관한 용도로도 제한 없이 이용할 수 있다.
② 개인정보의 처리 목적을 명확하게 하고, 그 목적에 필요한 최소한의 범위에서 수집하여야 한다.
③ 익명 처리로도 목적을 달성할 수 있는 경우에는 익명 처리를 우선하고, 익명 처리가 곤란하면 가명 처리에 의하도록 한다.
④ 처리 목적에 필요한 범위에서 개인정보의 정확성·완전성·최신성이 보장되도록 하여야 한다.

✓ 정답 및 해설

정답: ①

- ① 개인정보는 **수집 목적의 범위에서** 적합하게 처리해야 하며, 목적 외 용도로 활용하는 것은 원칙적으로 금지된다. "제한 없이 이용"은 틀린 설명. ← 정답
- ② 옳은 설명. 목적 명확화 + 최소 수집의 원칙.
- ③ 옳은 설명. 익명 처리 우선, 곤란 시 가명 처리의 원칙.
- ④ 옳은 설명. 정확성·완전성·최신성 보장의 원칙.

출제 포인트: 기본 원칙의 뼈대 = 목적 명확·최소 수집 / 목적 범위 내 처리(목적 외 이용 금지) / 정확성·최신성 / 안전한 관리 / 익명·가명 처리 우선. 부정형에서는 "제한 없이", "자유롭게" 같은 절대 표현이 들어간 선지가 대개 정답.

근거: 개인정보 보호법의 기본 원칙상 개인정보는 처리 목적을 명확히 하여 필요한 최소한의 범위에서 수집하고, 그 목적 범위를 벗어나 활용해서는 안 된다.

1-3 분석 방안 수립

> 1과목 · 빅데이터 분석 기획 / 주요항목: 데이터분석 계획
> 문항 수: 12 (Q1-025 ~ Q1-036) · 난이도 하4/중6/상2 · 정답 분포 ①3 ②3 ③3 ④3
> 범위: KDD·CRISP-DM·SEMMA 분석 방법론, 하향식·상향식 접근, 분석 성숙도·준비도, 분석 마스터플랜 우선순위, 분석 기획 고려사항

Q1-025 [난이도: 하] [태그: 1과목/데이터분석계획/방법론단계수]

분석 방법론과 각 방법론을 구성하는 단계 수의 연결이 모두 옳은 것은?

① KDD 5단계 — CRISP-DM 5단계 — SEMMA 6단계
② KDD 5단계 — CRISP-DM 6단계 — SEMMA 5단계
③ KDD 6단계 — CRISP-DM 5단계 — SEMMA 5단계
④ KDD 4단계 — CRISP-DM 6단계 — SEMMA 6단계

✓ 정답 및 해설

정답: ②

- ① CRISP-DM을 5단계, SEMMA를 6단계로 표기 → 둘 다 틀림.
- ② KDD 5단계 / CRISP-DM 6단계 / SEMMA 5단계 → 모두 옳음. ← 정답
- ③ KDD는 6단계가 아니라 5단계, CRISP-DM은 5단계가 아니라 6단계.
- ④ KDD는 4단계가 아니라 5단계, SEMMA는 6단계가 아니라 5단계.

출제 포인트: 단계 수 암기 = **KDD 5 / CRISP-DM 6 / SEMMA 5**. "5-6-5"로 묶어서 외울 것. ※ 교재별 표기 차이 있음 — KDD를 Fayyad의 원 논문에 따라 9개 프로세스로 세분화해 제시하는 교재도 있으나, 시험 기준 분석 절차는 5단계.

근거: KDD는 선택→전처리→변환→데이터 마이닝→해석·평가의 5단계, CRISP-DM은 업무 이해→데이터 이해→데이터 준비→모델링→평가→전개의 6단계, SEMMA는 샘플링→탐색→수정→모델링→평가의 5단계로 구성된 분석 방법론이다.

Q1-026 [난이도: 하] [태그: 1과목/데이터분석계획/KDD]

KDD(Knowledge Discovery in Databases) 분석 절차를 순서대로 옳게 나열한 것은?

① 데이터셋 선택 → 데이터 전처리 → 데이터 변환 → 데이터 마이닝 → 해석·평가
② 데이터셋 선택 → 데이터 변환 → 데이터 전처리 → 데이터 마이닝 → 해석·평가
③ 데이터 전처리 → 데이터셋 선택 → 데이터 변환 → 해석·평가 → 데이터 마이닝
④ 데이터셋 선택 → 데이터 전처리 → 데이터 마이닝 → 데이터 변환 → 해석·평가

✓ 정답 및 해설

정답: ①

- ① 선택(Selection) → 전처리(Preprocessing) → 변환(Transformation) → 데이터 마이닝(Data Mining) → 해석·평가(Interpretation/Evaluation). ← 정답
- ② 전처리와 변환의 순서가 바뀜. 잡음·이상값을 정제(전처리)한 뒤에 분석 목적에 맞게 변수를 생성·축소(변환)한다.
- ③ 선택이 가장 먼저다. 분석 대상 데이터셋을 골라야 전처리가 가능하며, 마이닝 후에 해석·평가가 온다.
- ④ 변환은 데이터 마이닝 이전의 준비 작업이다. 마이닝 후에 변환하는 절차는 없다.

출제 포인트: KDD 5단계 = "**선-전-변-마-해**"로 암기. 전처리(정제)가 먼저, 변환(변수 생성·차원 축소)이 나중.

근거: KDD는 데이터베이스에서 유용한 지식을 발견하는 프로세스로, 데이터셋 선택→전처리→변환→데이터 마이닝→해석·평가의 5단계로 수행된다.

Q1-027 [난이도: 중] [태그: 1과목/데이터분석계획/CRISP-DM]

CRISP-DM 방법론의 6단계를 순서대로 옳게 나열한 것은?

① 데이터 이해 → 업무 이해 → 데이터 준비 → 모델링 → 평가 → 전개
② 업무 이해 → 데이터 준비 → 데이터 이해 → 모델링 → 평가 → 전개
③ 업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개
④ 업무 이해 → 데이터 이해 → 데이터 준비 → 평가 → 모델링 → 전개

✓ 정답 및 해설

정답: ③

- ① 업무 이해가 데이터 이해보다 먼저다. 비즈니스 목적 파악이 출발점.
- ② 데이터 이해가 데이터 준비보다 먼저다. 데이터를 파악(수집·탐색)한 뒤에 정제·가공한다.
- ③ 업무 이해(Business Understanding) → 데이터 이해(Data Understanding) → 데이터 준비(Data Preparation) → 모델링(Modeling) → 평가(Evaluation) → 전개(Deployment). ← 정답
- ④ 모델링이 평가보다 먼저다. 모델을 만든 뒤 비즈니스 목적 달성 여부를 평가한다.

출제 포인트: CRISP-DM 6단계 = "**업-데이-데준-모-평-전**". 단계 간 피드백(업무 이해↔데이터 이해, 데이터 준비↔모델링, 평가→업무 이해)이 존재하는 반복적 모형이라는 점도 함께 기억.

근거: CRISP-DM(Cross Industry Standard Process for Data Mining)은 업무 이해→데이터 이해→데이터 준비→모델링→평가→전개의 6단계로 구성된 계층적·반복적 데이터 마이닝 표준 방법론이다.

Q1-028 [난이도: 중] [태그: 1과목/데이터분석계획/CRISP-DM]

다음 중 CRISP-DM 방법론의 6단계에 해당하지 **않는** 것은?

① 업무 이해(Business Understanding)
② 데이터 준비(Data Preparation)
③ 전개(Deployment)
④ 데이터 변환(Transformation)

✓ 정답 및 해설

정답: ④

- ① 업무 이해: CRISP-DM의 1단계. 비즈니스 관점의 목적·요구사항 파악.
- ② 데이터 준비: CRISP-DM의 3단계. 정제·통합·포맷팅 등 분석용 데이터셋 구성.
- ③ 전개: CRISP-DM의 6단계. 모델을 실제 업무에 적용하고 유지보수 계획 수립.
- ④ 데이터 변환은 CRISP-DM이 아니라 **KDD의 3단계**다. CRISP-DM에서는 변환 작업이 '데이터 준비' 단계 안에 포함된다. ← 정답

출제 포인트: 단골 함정 = KDD 단계(선택·전처리·변환)를 CRISP-DM 선지에 끼워 넣는 바꿔치기. "변환(Transformation)이 독립 단계면 KDD, 준비(Preparation)에 흡수돼 있으면 CRISP-DM."

근거: CRISP-DM의 6단계는 업무 이해, 데이터 이해, 데이터 준비, 모델링, 평가, 전개이며 데이터 변환은 KDD 분석 절차의 단계명이다.

Q1-029 [난이도: 중] [태그: 1과목/데이터분석계획/CRISP-DM4계층]

CRISP-DM의 4계층(레벨) 구조를 최상위 계층부터 순서대로 옳게 나열한 것은?

① 단계 → 세분화 태스크 → 일반화 태스크 → 프로세스 실행
② 단계 → 일반화 태스크 → 세분화 태스크 → 프로세스 실행
③ 프로세스 실행 → 단계 → 일반화 태스크 → 세분화 태스크
④ 일반화 태스크 → 단계 → 세분화 태스크 → 프로세스 실행

✓ 정답 및 해설

정답: ②

- ① 일반화 태스크가 세분화 태스크보다 상위다. 일반적 활동을 먼저 정의하고 이를 구체화한다.
- ② 단계(Phases) → 일반화 태스크(Generic Tasks) → 세분화 태스크(Specialized Tasks) → 프로세스 실행(Process Instances). ← 정답
- ③ 프로세스 실행은 최하위 계층이다. 실제 프로젝트에서 수행된 기록이 가장 구체적 수준.
- ④ 단계가 최상위 계층이다. 일반화 태스크는 단계를 구성하는 하위 요소.

출제 포인트: 4계층 = "**단-일-세-프**"(위→아래). 위로 갈수록 추상적·일반적, 아래로 갈수록 구체적·개별 프로젝트 수준.

근거: CRISP-DM은 최상위의 단계(Phases), 각 단계를 구성하는 일반화 태스크(Generic Tasks), 이를 구체화한 세분화 태스크(Specialized Tasks), 실제 수행 기록인 프로세스 실행(Process Instances)의 4계층 구조로 이루어진 계층적 프로세스 모델이다.

Q1-030 [난이도: 중] [태그: 1과목/데이터분석계획/SEMMA]

SAS사가 주도한 SEMMA 방법론에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 업무 이해(Business Understanding) 단계에서 출발하여 비즈니스 문제 정의를 가장 강조한다.
② 수정(Modify) 단계에서는 변수의 변환·생성·선택 등 데이터 가공을 수행한다.
③ 탐색(Explore) 단계에서는 시각화와 기초 통계를 통해 데이터의 패턴을 파악한다.
④ 샘플링(Sample) → 탐색(Explore) → 수정(Modify) → 모델링(Model) → 평가(Assess)의 5단계로 구성된다.

✓ 정답 및 해설

정답: ①

- ① 업무 이해에서 출발하는 것은 **CRISP-DM**이다. SEMMA는 분석 대상 데이터의 샘플링에서 출발하는 **기술(통계·모델링) 중심** 방법론으로, 비즈니스 이해 단계가 명시적으로 없다. ← 정답
- ② 옳은 설명. Modify = 변수 변환·생성·선택, 데이터 가공.
- ③ 옳은 설명. Explore = 시각화·기초 통계로 패턴·이상값 탐색.
- ④ 옳은 설명. S-E-M-M-A 5단계.

출제 포인트: SEMMA는 머리글자 그대로 **S**ample-**E**xplore-**M**odify-**M**odel-**A**ssess. "비즈니스에서 출발하면 CRISP-DM, 데이터(샘플)에서 출발하면 SEMMA"로 구분.

근거: SEMMA는 SAS사가 주도한 데이터 마이닝 방법론으로 샘플링→탐색→수정→모델링→평가의 5단계로 구성되며, 데이터에서 출발하는 기술 중심적 접근이 특징이다.

Q1-031 [난이도: 상] [태그: 1과목/데이터분석계획/방법론비교]

KDD, CRISP-DM, SEMMA 세 방법론의 단계 대응에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. KDD의 '데이터 변환' 단계는 CRISP-DM의 '데이터 준비' 단계에, '데이터셋 선택' 단계는 '데이터 이해' 단계에 대응한다.
- ㄴ. CRISP-DM의 '업무 이해'에 대응하는 단계는 SEMMA에 명시적으로 존재하지 않는다.
- ㄷ. KDD의 '해석·평가'는 CRISP-DM의 '평가', SEMMA의 '평가(Assess)'와 대응한다.
- ㄹ. SEMMA의 '샘플링(Sample)'은 CRISP-DM의 '전개(Deployment)'에 대응한다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄴ, ㄷ ④ ㄱ, ㄷ, ㄹ

> **✓ 정답 및 해설**
>
> **정답: ③**
>
> - **ㄱ (O)** 표준 대응표(Azevedo & Santos 비교표 기반) 기준으로 KDD의 데이터셋 선택·데이터 전처리는 CRISP-DM의 **데이터 이해**에, 데이터 변환은 **데이터 준비**에 대응한다.
> - **ㄴ (O)** SEMMA는 데이터 샘플링에서 출발하는 기술 중심 방법론으로, 비즈니스 이해 단계가 없다.
> - **ㄷ (O)** 세 방법론 모두 마지막에 결과 해석·평가 단계를 둔다(KDD 해석·평가 / CRISP-DM 평가 / SEMMA Assess).
> - **ㄹ (X)** 샘플링은 분석용 데이터를 추출하는 활동으로 **데이터 준비·선택 계열**에 대응한다. 전개는 모델의 실무 적용 단계로 성격이 전혀 다르며, SEMMA에는 전개에 해당하는 단계가 없다.
>
> 따라서 옳은 것은 ㄱ, ㄴ, ㄷ → **③**. (①은 옳은 ㄷ 누락, ②·④는 틀린 ㄹ 포함)
>
> **출제 포인트:** 대응 관계 축 = "데이터 파악(선택·전처리 = 데이터 이해)", "데이터 가공(변환 = 데이터 준비 = Sample·Modify)", "모델 구축(마이닝 = 모델링 = Model)", "결과 확인(해석·평가 = 평가 = Assess)". 전개(Deployment)는 **CRISP-DM에만 있는 단계**라는 점이 핵심.
>
> **근거:** KDD·CRISP-DM·SEMMA는 데이터 준비→모델링→평가라는 공통 흐름을 공유하지만, 업무 이해와 전개 단계는 CRISP-DM에만 명시적으로 존재한다.

Q1-032 [난이도: 하] [태그: 1과목/데이터분석계획/하향식접근]

하향식(top-down) 분석 과제 발굴 절차를 순서대로 옳게 나열한 것은?

① 문제 정의 → 문제 탐색 → 해결방안 탐색 → 타당성 검토
② 문제 탐색 → 문제 정의 → 해결방안 탐색 → 타당성 검토
③ 문제 탐색 → 해결방안 탐색 → 문제 정의 → 타당성 검토
④ 타당성 검토 → 문제 탐색 → 문제 정의 → 해결방안 탐색

✓ 정답 및 해설

정답: ②

- ① 탐색이 정의보다 먼저다. 비즈니스 모델 등에서 문제 후보를 발굴(탐색)한 뒤 데이터 분석 문제로 변환(정의)한다.
- ② 문제 탐색(Problem Discovery) → 문제 정의(Problem Definition) → 해결방안 탐색(Solution Search) → 타당성 검토(Feasibility Study). ← 정답
- ③ 문제를 정의해야 그 문제의 해결방안을 탐색할 수 있다. 순서가 바뀜.
- ④ 타당성 검토는 도출된 해결방안에 대해 마지막에 수행한다.

출제 포인트: 하향식 4단계 = "**탐-정-해-타**". 문제 탐색에서는 비즈니스 모델 캔버스·분석 유스케이스 활용, 문제 정의에서는 비즈니스 문제를 데이터 분석 문제로 변환, 타당성 검토는 경제적 타당성과 데이터·기술적 타당성 평가.

근거: 하향식 접근은 문제가 주어진 상태에서 문제 탐색→문제 정의→해결방안 탐색→타당성 검토의 순서로 해법을 찾아가는 분석 과제 발굴 방식이다.

Q1-033 [난이도: 중] [태그: 1과목/데이터분석계획/상향식접근]

분석 과제 발굴의 상향식(bottom-up) 접근과 관련된 설명으로 옳지 **<u>않은</u>** 것은?

① 상향식 접근은 문제 정의 자체가 어려운 경우 데이터를 기반으로 통찰(insight)을 도출하는 방식이다.
② 프로토타이핑(prototyping) 접근은 일단 분석을 시도하고 결과를 확인하며 반복적으로 개선하는 시행착오 방식이다.
③ 디자인 씽킹(design thinking)은 상향식의 발산(diverge) 단계와 하향식의 수렴(converge) 단계를 반복하여 최적의 방안을 도출한다.
④ 상향식 접근은 문제가 명확히 주어진 상태에서 해법을 찾아가는 전통적 분석 과제 발굴 방식이다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. 문제를 사전에 정의하기 어려울 때 데이터 자체에서 인사이트를 발굴.
- ② 옳은 설명. 프로토타이핑 = "먼저 분석 시도 → 결과 확인 → 반복 개선". 사용자가 요구사항을 명확히 모를 때 유용.
- ③ 옳은 설명. 디자인 씽킹은 발산(상향식)과 수렴(하향식)을 반복하는 상호보완적 접근.
- ④ 문제가 명확히 주어진 상태에서 해법을 찾는 것은 **하향식** 접근이다. 상향식은 문제 정의가 어려운 상황에서 데이터로부터 출발한다. ← 정답

출제 포인트: "문제가 주어짐 → 하향식(수렴적) / 문제 정의 곤란 → 상향식(발산적)". 하향식·상향식 정의를 서로 바꿔치기하는 선지가 단골.

근거: 상향식 접근은 문제의 정의 자체가 어려운 경우 데이터를 기반으로 문제를 지속적으로 개선하면서 통찰을 도출하는 분석 과제 발굴 방식이다.

Q1-034 [난이도: 상] [태그: 1과목/데이터분석계획/성숙도준비도]

A기업을 진단한 결과, 분석에 필요한 데이터·인력·조직 등 준비도(readiness)는 높지만 실제 분석 업무를 수행해 본 경험이 거의 없어 성숙도(maturity)는 낮은 것으로 나타났다. 분석 수준 진단의 사분면 분석에서 A기업이 속하는 유형은?

① 준비형 ② 정착형 ③ 도입형 ④ 확산형

✓ 정답 및 해설

정답: ③

- ① 준비형: 준비도·성숙도 **모두 낮음** → 분석을 위한 사전 준비가 필요한 기업.
- ② 정착형: **준비도는 낮으나** 조직·인력 등을 제한적으로 사용하며 성숙도가 어느 정도 있는 기업 → 1차적으로 정착이 필요.
- ③ 도입형: **준비도는 높으나 성숙도는 낮음** → 데이터 분석을 바로 도입할 수 있는 기업. A기업이 해당. ← 정답
- ④ 확산형: 준비도·성숙도 **모두 높음** → 지속적 확산이 가능한 기업.

출제 포인트: 사분면 4유형 = 준비도·성숙도 (低·低)=**준비형**, (低·高)=**정착형**, (高·低)=**도입형**, (高·高)=**확산형**. 함께 나오는 성숙도 4단계는 **도입→활용→확산→최적화**(도입: 분석 시작·환경 구축, 활용: 분석 결과를 업무에 적용, 확산: 전사 차원 관리·공유, 최적화: 분석의 진화로 혁신·가치 창출).

근거: 분석 수준 진단은 분석 준비도와 분석 성숙도 두 축의 사분면으로 조직을 준비형·정착형·도입형·확산형의 4개 유형으로 구분하는 진단 방법이다.

Q1-035 [난이도: 중] [태그: 1과목/데이터분석계획/마스터플랜우선순위]

분석 마스터플랜 수립 시 분석 과제의 우선순위 평가에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 난이도(difficulty)는 전략적 중요도와 목표 가치(KPI)에 따라 평가한다.
② 시급성이 높고 난이도가 쉬운 과제가 가장 우선적으로 추진된다.
③ ROI 관점에서 빅데이터의 3V(규모·다양성·속도)는 투자비용 요소로서 난이도와 연결된다.
④ 난이도는 데이터 획득·저장·가공 비용과 분석 수준 등을 고려하여 평가하며, 기업 상황에 따라 조율할 수 있다.

✓ 정답 및 해설

정답: ①

- ① 전략적 중요도와 목표 가치에 따라 평가하는 것은 **시급성(urgency)**이다. 난이도는 비용·기술 등 실행 측면의 기준. ← 정답
- ② 옳은 설명. 시급성 高 + 난이도 易 과제가 최우선 추진 대상.
- ③ 옳은 설명. ROI 관점에서 3V(Volume·Variety·Velocity)는 투자비용(Investment) 요소 → 난이도, 가치(Value)는 비즈니스 효과 요소 → 시급성과 연결.
- ④ 옳은 설명. 난이도 = 데이터 획득·저장·가공 비용 + 분석 적용 비용 + 분석 수준. 기업 여건에 따라 난이도를 조율(易↔難)해 우선순위를 조정할 수 있다.

출제 포인트: 우선순위 2대 기준 = **시급성(전략적 중요도·목표 가치 → Value) / 난이도(비용·기술 → 3V)**. "중요하면 시급성, 비싸고 어려우면 난이도." ※ 교재별 표기 차이 있음 — 사분면 번호(I~IV)와 축 배치는 교재마다 다르게 그려지므로 번호보다 "시급성 높고 쉬운 과제부터"라는 원리로 기억할 것.

근거: 분석 마스터플랜의 과제 우선순위는 전략적 중요도와 목표 가치로 평가하는 시급성, 그리고 데이터 비용과 분석 수준으로 평가하는 난이도의 두 기준을 고려하여 결정한다.

Q1-036 [난이도: 하] [태그: 1과목/데이터분석계획/분석기획고려사항]

빅데이터 분석 기획 단계에서 1차적으로 고려해야 할 사항으로 가장 적절한 것은?

① 분석 모형에 적용할 알고리즘의 하이퍼파라미터 튜닝 전략 수립
② 분석 결과 대시보드의 화면 배치와 차트 종류 확정
③ 분석 서버의 CPU 코어 수와 메모리 용량 확정
④ 활용 가능한 데이터의 존재 여부·유형 확인과 장애요소에 대한 사전계획 수립

✓ 정답 및 해설

정답: ④

- ① 하이퍼파라미터 튜닝은 **모델링(분석 수행) 단계**의 세부 작업. 기획 단계의 고려사항이 아님.
- ② 대시보드 설계는 **결과 시각화·전개 단계**의 작업. 기획 단계에서 확정할 사항이 아님.
- ③ 서버 사양 확정은 **시스템 구현 단계**의 세부사항. 기획 단계에서는 가용성 수준만 검토.
- ④ 기획 시 고려사항 = **가용 데이터**(존재 여부·유형), **적절한 유스케이스 탐색**, **장애요소에 대한 사전계획 수립**. ← 정답

출제 포인트: 분석 기획 시 고려사항 3가지 = "**데이터(가용성) · 유스케이스(활용 방안) · 장애요소(사전계획)**". 데이터 유형(정형·반정형·비정형)에 따라 수집·저장·분석 방식이 달라지므로 데이터 확인이 출발점.

근거: 분석 기획 시에는 분석에 활용 가능한 데이터의 확보 여부와 유형, 기존 유스케이스의 탐색·활용, 그리고 장애요소에 대한 사전계획 수립을 우선적으로 고려해야 한다.

1-4 분석 작업 계획

> 1과목 · 빅데이터 분석 기획 / 주요항목: 데이터 분석 계획
> 문항 수: 4 (Q1-037 ~ Q1-040) · 난이도 하1/중2/상1 · 정답 분포 ①1 ②1 ③1 ④1

Q1-037 [난이도: 하] [태그: 1과목/데이터분석계획/WBS]

프로젝트의 전체 작업을 계층적으로 세분화하여 관리 가능한 최소 단위의 작업으로 나누고, 이를 기준으로 일정·산출물·담당자를 관리할 수 있게 하는 것은?

① WBS(작업 분할 구조)
② 간트 차트(Gantt chart)
③ 분석 목표 정의서
④ 위험 관리 대장

✓ 정답 및 해설

정답: ①

- ① WBS(Work Breakdown Structure): 전체 작업을 계층적으로 **분할**해 최소 관리 단위로 만든 구조. 일정·산출물·담당자 관리의 기준. ← 정답
- ② 간트 차트: 작업별 일정을 **막대(bar) 형태로 시각화**하는 도구. 작업을 분할하는 구조가 아니라 분할된 작업의 일정을 표현하는 수단.
- ③ 분석 목표 정의서: 분석 목표·원천 데이터·평가 기준을 정의한 **문서**. 작업 분할·일정 관리 도구가 아님.
- ④ 위험 관리 대장: 프로젝트 위험 요소를 식별·기록·추적하는 문서. 작업 분할과 무관.

출제 포인트: "계층적 세분화 + 최소 관리 단위"가 보이면 WBS. 간트 차트는 '일정 시각화', WBS는 '작업 분할'로 역할을 구분해 둘 것.

근거: WBS(작업 분할 구조, Work Breakdown Structure)는 프로젝트의 작업을 계층적으로 분할하여 관리 가능한 최소 단위로 정의하고 일정·산출물 관리의 기준으로 삼는 구조다.

Q1-038 [난이도: 중] [태그: 1과목/데이터분석계획/분석목표정의서]

데이터 분석 목표 정의서의 구성요소에 해당하지 **<u>않는</u>** 것은?

① 원천 데이터 조사
② 분석 방안 및 적용 가능성 판단
③ 성과 평가 기준
④ 분석 모델의 최적 하이퍼파라미터(hyperparameter) 설정값

✓ 정답 및 해설

정답: ④

- ① 필요 데이터의 존재 여부·수집 난이도·용량 등 원천 데이터 정보를 조사 → 구성요소 맞음.
- ② 분석 목표를 달성할 분석 방안과 그 적용 가능성(현실성)을 판단 → 구성요소 맞음.
- ③ 정성적·정량적 평가 기준을 사전에 정의 → 구성요소 맞음.
- ④ 하이퍼파라미터 설정값은 **모델링(분석 수행) 단계**에서 실험으로 결정하는 사항. 기획 단계 문서인 목표 정의서의 구성요소가 아님. ← 정답

출제 포인트: 분석 목표 정의서 3요소 = **원천 데이터 조사 / 분석 방안·적용 가능성 판단 / 성과 평가 기준**. "원·방·평"으로 암기. 모델링 단계의 세부 사항(파라미터, 알고리즘 튜닝)이 섞여 나오면 오답. ※ 교재별 표기 차이 있음 — 구성요소의 명칭·세분화 수준은 교재마다 다르게 제시될 수 있다.

근거: 분석 목표 정의서는 원천 데이터 조사, 분석 방안 및 적용 가능성 판단, 성과 평가 기준을 담아 분석 목표를 구체화하는 기획 단계 문서다.

Q1-039 [난이도: 중] [태그: 1과목/데이터분석계획/데이터확보계획]

데이터 확보 계획 수립 절차를 순서대로 바르게 나열한 것은?

- ㄱ. 요구사항 도출 (필요 데이터·기술 지원 등)
- ㄴ. 예산안 수립
- ㄷ. 목표 정의 (성과 목표·성과 지표 설정)
- ㄹ. 계획 수립 (인력·일정·업무·예산 반영 계획서 작성)

① ㄷ → ㄴ → ㄱ → ㄹ
② ㄷ → ㄱ → ㄴ → ㄹ
③ ㄱ → ㄷ → ㄴ → ㄹ
④ ㄷ → ㄱ → ㄹ → ㄴ

✓ 정답 및 해설

정답: ②

- ② 목표 정의(ㄷ) → 요구사항 도출(ㄱ) → 예산안 수립(ㄴ) → 계획 수립(ㄹ). ← 정답
- ① 요구사항을 모르는 상태에서 예산부터 세울 수 없다. 예산은 요구사항 도출 **뒤**.
- ③ 목표가 정의되어야 그 목표 달성에 필요한 요구사항을 도출할 수 있다. 목표 정의가 **첫 단계**.
- ④ 계획 수립은 예산까지 반영해 작성하는 **마지막 단계**. 예산안 수립보다 앞설 수 없다.

출제 포인트: 데이터 확보 계획 절차 = **목표 → 요구 → 예산 → 계획**. "목·요·예·계"로 암기. 논리 흐름(목표가 있어야 요구가 나오고, 요구가 있어야 예산이 나온다)을 이해하면 나열 순서를 외우지 않아도 복원 가능.

근거: 데이터 확보 계획은 성과 목표·지표를 정의한 뒤 요구사항을 도출하고, 예산안을 수립한 다음 인력·일정·업무·예산을 반영한 계획서를 작성하는 순서로 수립한다.

Q1-040 [난이도: 상] [태그: 1과목/데이터분석계획/작업분할일정계획]

데이터 분석 프로젝트의 WBS(작업 분할 구조) 단계별 작업과 일정 계획에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 데이터 분석과제 정의 단계에서는 분석 목표 정의서를 기준으로 프로젝트 전체 일정에 맞춰 사전 준비를 한다.
- ㄴ. 데이터 준비 및 탐색 단계에서는 데이터 처리 담당자와 데이터 분석가의 역할을 구분하여 세부 일정을 수립한다.
- ㄷ. 데이터 분석 모델링 및 검증 단계는 데이터 준비 및 탐색 단계보다 먼저 수행한다.
- ㄹ. 산출물 정리 단계에서는 분석 결과와 산출물·프로그램(소스 코드)을 정리하여 프로젝트를 마무리한다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄴ, ㄹ ④ ㄱ, ㄷ, ㄹ

✓ 정답 및 해설

정답: ③

- **ㄱ (O)** 1단계(데이터 분석과제 정의): 분석 목표 정의서 기준으로 전체 일정에 맞춘 사전 준비.
- **ㄴ (O)** 2단계(데이터 준비 및 탐색): 데이터 처리와 분석의 **역할을 구분**해 세부 일정 수립.
- **ㄷ (X)** 순서가 반대. 데이터가 준비·탐색된 **뒤에** 모델링 및 검증(3단계)을 수행한다.
- **ㄹ (O)** 4단계(산출물 정리): 분석 결과·산출물·프로그램을 정리하며 프로젝트 종료.

따라서 옳은 것은 ㄱ, ㄴ, ㄹ → **③**. (①은 옳은 ㄹ을 누락, ②·④는 틀린 ㄷ을 포함)

출제 포인트: 데이터 분석 WBS 4단계 = **과제 정의 → 데이터 준비·탐색 → 분석 모델링·검증 → 산출물 정리**. "정·준·모·산"으로 암기. 단계 순서를 뒤집는 선지가 단골 함정. ※ 교재별 표기 차이 있음 — 단계 명칭은 교재에 따라 다소 다르게 표기될 수 있다.

근거: 데이터 분석 프로젝트의 WBS는 데이터 분석과제 정의, 데이터 준비 및 탐색, 데이터 분석 모델링 및 검증, 산출물 정리의 4단계로 작업을 분할하여 일정을 계획한다.

1-5 데이터 수집 및 전환

> 1과목 · 빅데이터 분석 기획 / 주요항목: 데이터 수집 및 저장 계획
> 문항 수: 12 (Q1-041 ~ Q1-052) · 난이도 하4/중6/상2 · 정답 분포 ①3 ②3 ③3 ④3
> 범위: ETL·ELT, 데이터 유형별 수집 기술, Open API·RSS·FTP, 로그 수집기, 데이터 품질 기준, 데이터 변환 기법 5종

Q1-041 [난이도: 하] [태그: 1과목/데이터수집및저장계획/ETL]

ETL 프로세스의 세 단계를 수행 순서대로 바르게 나열한 것은?

① 변환(Transform) → 추출(Extract) → 적재(Load)
② 추출(Extract) → 변환(Transform) → 적재(Load)
③ 적재(Load) → 추출(Extract) → 변환(Transform)
④ 추출(Extract) → 적재(Load) → 변환(Transform)

✓ 정답 및 해설

정답: ②

- ① 원천에서 꺼내기(추출) 전에 변환할 대상이 없으므로 순서가 성립하지 않는다.
- ② 원천 시스템에서 **추출** → 규칙에 따라 **변환** → 목표 시스템에 **적재**. ETL의 정의 그 자체. ← 정답
- ③ 적재가 맨 앞에 오는 순서는 존재하지 않는다.
- ④ 추출 → 적재 → 변환은 ETL이 아니라 **ELT**의 순서다. 함정 선지.

출제 포인트: ETL은 이름의 알파벳 순서(E→T→L)가 곧 수행 순서. ④처럼 T와 L을 바꾼 선지는 ELT를 묻는 함정이다.

근거: ETL은 원천 데이터를 추출(Extract)하고 목표 형식에 맞게 변환(Transform)한 뒤 목표 시스템에 적재(Load)하는 데이터 수집·통합 프로세스다.

Q1-042 [난이도: 하] [태그: 1과목/데이터수집및저장계획/수집기술매칭]

서버-클라이언트 방식으로 동작하며, 수집 대상 시스템과 1:1로 연결하여 파일과 디렉터리를 동기화(미러링)하는 데 사용되는 데이터 수집 기술은?

① 리싱크(Rsync)
② FTP
③ RSS
④ Open API

✓ 정답 및 해설

정답: ①

- ① 리싱크(Rsync, Remote Sync): 서버-클라이언트 방식으로 수집 대상 시스템과 **1:1로 파일·디렉터리를 동기화**하는 응용 프로그램. ← 정답
- ② FTP(File Transfer Protocol): TCP/IP 기반으로 파일을 **송수신(전송)** 하는 프로토콜. 전송이 목적이지 동기화(미러링)가 목적이 아님.
- ③ RSS(Rich Site Summary): 갱신 콘텐츠를 XML 기반으로 **배급·구독**하는 기술.
- ④ Open API: 공개된 인터페이스를 **호출**하여 데이터를 받아오는 방식.

출제 포인트: 파일 계열 수집 기술 구분 — FTP=파일 전송, Rsync=1:1 동기화(미러링). "동기화·미러링" 키워드가 보이면 Rsync.

근거: 리싱크(Rsync)는 서버-클라이언트 방식으로 수집 대상 시스템과 1:1로 파일과 디렉터리를 동기화하는 데이터 수집(응용) 프로그램이다.

Q1-043 [난이도: 하] [태그: 1과목/데이터수집및저장계획/OpenAPI·RSS·FTP]

블로그·뉴스 사이트 등에서 새로 갱신된 콘텐츠를 XML 기반 형식으로 배급하여, 구독자가 사이트에 방문하지 않고도 갱신 정보를 수집할 수 있게 하는 기술은?

① Open API
② FTP
③ RSS
④ 크롤링(crawling)

✓ 정답 및 해설

정답: ③

- ① Open API: 서비스 제공자가 **공개한 인터페이스를 호출**하여 데이터를 받아오는 방식. 배급·구독 형식이 아님.
- ② FTP: TCP/IP 기반 **파일 전송 프로토콜**. 대용량 파일 송수신에 사용.
- ③ RSS: 갱신 콘텐츠를 XML 기반으로 **배급(syndication)·구독**하는 형식. ← 정답
- ④ 크롤링: 웹 페이지를 **직접 방문·탐색**하며 긁어오는 수집 방식. "방문하지 않고도"와 반대.

출제 포인트: Open API=호출, RSS=구독(XML 배급), FTP=파일 전송, 크롤링=방문 수집. "XML 배급·구독" 키워드는 RSS로 즉시 연결.

근거: RSS(Rich Site Summary)는 웹 사이트의 갱신 콘텐츠를 XML 기반 표준 형식으로 배급하여 구독자가 자동으로 수집할 수 있게 하는 기술이다.

Q1-044 [난이도: 하] [태그: 1과목/데이터수집및저장계획/로그수집기]

수집 대상 서버에 설치된 에이전트(agent)가 로그를 수집하고 컬렉터(collector)가 이를 모아 HDFS에 저장하는, 하둡의 서브프로젝트로 개발된 로그 수집 기술은?

① 플룸(Flume)
② 카프카(Kafka)
③ 로그스태시(Logstash)
④ 척와(Chukwa)

✓ 정답 및 해설

정답: ④

- ① 플룸: 이벤트·에이전트 기반 로그 수집기이지만 내부 구조가 **소스(source)–채널(channel)–싱크(sink)** 로 구성. 하둡 서브프로젝트로 출발한 에이전트–컬렉터 구조가 아님.
- ② 카프카: 발행-구독(pub-sub) 모델의 분산 **메시징 시스템**. 로그 수집기 자체가 아님.
- ③ 로그스태시: 엘라스틱 스택(Elastic Stack)의 수집 파이프라인. 구조는 **입력(input)–필터(filter)–출력(output)**.
- ④ 척와: **에이전트(수집)–컬렉터(저장)** 구조로 분산 시스템의 로그를 모아 **HDFS에 저장**하는 하둡 서브프로젝트. ← 정답

출제 포인트: 로그 수집기 구조 매칭 — 척와: 에이전트–컬렉터·HDFS 저장 / 플룸: 소스–채널–싱크 / 로그스태시: 입력–필터–출력. "하둡 서브프로젝트 + 컬렉터"가 보이면 척와.

근거: 척와(Chukwa)는 에이전트가 수집한 로그 데이터를 컬렉터가 받아 HDFS에 저장하는, 하둡 기반 분산 시스템 모니터링·로그 수집 기술이다.

Q1-045 [난이도: 중] [태그: 1과목/데이터수집및저장계획/ETL·ELT차이]

ETL과 ELT에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① ETL은 원천 데이터를 변환한 후 목표 시스템에 적재한다.
② ELT는 적재하기 전에 반드시 모든 변환을 완료해야 한다.
③ ELT는 원본 데이터를 먼저 적재한 뒤 필요할 때 목적지 시스템의 처리 능력으로 변환하며, 데이터 레이크(data lake) 환경에 적합하다.
④ ETL은 전통적으로 데이터 웨어하우스(DW) 구축에 주로 사용되어 왔다.

✓ 정답 및 해설

정답: ②

- ① 옳은 설명. 변환(T)이 적재(L)보다 먼저인 것이 ETL의 정의.
- ② ELT는 **변환 전에 원본을 먼저 적재**하는 방식이다. "적재 전에 변환 완료"는 ETL의 특징을 뒤집어 놓은 틀린 설명. ← 정답
- ③ 옳은 설명. 원본 보존 + 목적지에서 변환 = ELT, 데이터 레이크와 궁합.
- ④ 옳은 설명. 정해진 스키마로 변환해 적재하는 ETL은 DW의 전통적 방식.

출제 포인트: 변환 위치로 구분 — ETL은 **적재 전(중간 단계)** 변환·DW용, ELT는 **적재 후(목적지)** 변환·데이터 레이크용. 부정형에서 두 방식의 특징을 서로 바꿔 출제하는 것이 단골.

근거: ELT는 원천 데이터를 변환 없이 먼저 적재(Load)한 후 목적지 시스템에서 필요 시점에 변환(Transform)하는 방식이다.

Q1-046 [난이도: 중] [태그: 1과목/데이터수집및저장계획/수집기술매칭]

데이터 유형과 수집 기술의 연결로 옳지 **<u>않은</u>** 것은?

① 정형 데이터 — ETL, 스쿱(Sqoop)
② 반정형 데이터 — 플룸(Flume), 스크라이브(Scribe)
③ 비정형 데이터 — 크롤링(crawling), 스크래파이(Scrapy)
④ 정형 데이터 — 척와(Chukwa), 크롤링(crawling)

✓ 정답 및 해설

정답: ④

- ① 옳은 연결. 스키마가 고정된 정형 데이터는 ETL·스쿱으로 수집.
- ② 옳은 연결. 로그(반정형)는 플룸·스크라이브 같은 로그 수집기로 수집.
- ③ 옳은 연결. 웹 문서·텍스트 등 비정형은 크롤링·스크래파이로 수집.
- ④ 척와는 **반정형(로그)** 수집 기술, 크롤링은 **비정형** 수집 기술이다. 정형과의 연결은 틀림. ← 정답

출제 포인트: 유형별 3줄 암기 — 정형: ETL·Sqoop / 반정형: Flume·Scribe·Chukwa(로그 수집기 계열) / 비정형: 크롤링·Scrapy. 함정은 항상 기술을 다른 유형 칸에 옮겨 놓는 방식으로 나온다.

근거: 데이터 수집 기술은 데이터 유형에 따라 정형(ETL·Sqoop), 반정형(Flume·Scribe·Chukwa 등 로그 수집기), 비정형(크롤링·Scrapy 등)으로 구분하여 적용한다.

Q1-047 [난이도: 중] [태그: 1과목/데이터수집및저장계획/로그수집기]

이벤트(event)와 에이전트(agent)를 기반으로 하며, 소스(source)–채널(channel)–싱크(sink) 구조로 대용량 로그 데이터를 안정적으로 수집하는 기술은?

① 플룸(Flume)
② 로그스태시(Logstash)
③ 스크라이브(Scribe)
④ 스쿱(Sqoop)

> **✓ 정답 및 해설**
>
> **정답:** ①
>
> - ① 플룸: **이벤트·에이전트 기반**, 에이전트 내부가 **소스–채널–싱크** 3요소로 구성. ← 정답
> - ② 로그스태시: 엘라스틱 스택(Elastic Stack)의 수집 파이프라인. 구조는 **입력(input)–필터(filter)–출력(output)**.
> - ③ 스크라이브: 페이스북이 개발한 실시간 스트리밍 로그 수집기. 소스–채널–싱크 구조가 아님.
> - ④ 스쿱: RDB↔하둡 간 **정형 데이터** 전송 도구. 로그 수집기가 아님.
>
> **출제 포인트:** 로그 수집기 식별 키워드 — 플룸: 이벤트·에이전트·소스/채널/싱크 / 플루언티드(Fluentd): 태그 기반 라우팅·JSON 통합 / 스크라이브: 페이스북·실시간 스트리밍 / 로그스태시: 엘라스틱 스택·입력/필터/출력.
>
> **근거:** 플룸(Flume)은 이벤트와 에이전트를 기반으로 소스·채널·싱크로 구성된 에이전트를 통해 대용량 로그 데이터를 수집·전송하는 기술이다.

Q1-048 [난이도: 중] [태그: 1과목/데이터수집및저장계획/데이터품질기준]

데이터 품질 기준에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 정확성(accuracy): 데이터가 실세계의 사실·값을 올바르게 반영하는 정도
② 완전성(completeness): 필요한 데이터가 누락 없이 모두 존재하는 정도
③ 적시성(timeliness): 데이터의 표현 형식·단위·값 체계가 서로 모순되지 않는 정도
④ 일관성(consistency): 여러 시스템·항목에 저장된 동일 데이터가 서로 다르지 않고 일치하는 정도

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 정확성 = 실제 값과의 부합.
- ② 옳은 설명. 완전성 = 누락 없음.
- ③ "형식·단위·값 체계의 무모순"은 **일관성**의 정의다. 적시성은 **필요한 시점에 최신 상태의 데이터가 제공되는 정도**를 의미한다. ← 정답
- ④ 옳은 설명. 일관성 = 시스템·항목 간 무모순·일치.

출제 포인트: 품질 4대 기준 한 줄 암기 — 정확성=맞는 값, 완전성=빠짐 없음, 적시성=제때 최신, 일관성=서로 모순 없음. 부정형은 적시성↔일관성 정의 바꿔치기가 단골. ※ 교재별 표기 차이 있음 — 품질 기준 목록에 유효성·접근성 등을 추가하는 교재도 있다.

근거: 적시성(timeliness)은 데이터가 필요한 시점에 최신 상태로 제공되어 활용 가능한 정도를 나타내는 데이터 품질 기준이다.

Q1-049 [난이도: 중] [태그: 1과목/데이터수집및저장계획/데이터변환기법]

데이터 변환 기법에 대한 설명으로 옳지 **않은** 것은?

① 집계(aggregation)는 데이터를 요약·합산하여 규모를 축소하는 기법이다.
② 일반화(generalization)는 기존 속성을 조합해 새로운 속성을 추가함으로써 데이터의 차원을 늘리는 기법이다.
③ 정규화(normalization)는 데이터 값을 정해진 구간(예: 0~1)에 들어가도록 척도를 변환하는 기법이다.
④ 속성 생성(attribute construction)은 기존 속성들로부터 분석에 유용한 새로운 속성을 만들어내는 기법이다.

✓ 정답 및 해설

정답: ②

- ① 옳은 설명. 일별 매출 → 월별 합계처럼 요약하는 것이 집계.
- ② "새 속성 추가"는 **속성 생성**의 정의다. 일반화는 **낮은 수준의 값을 상위 개념(범주·구간)으로 대체**하는 기법(예: 나이 → 연령대). ← 정답
- ③ 옳은 설명. 최소-최대 정규화, Z-점수(z-score) 정규화 등이 해당.
- ④ 옳은 설명. 예: 키·몸무게로 BMI 속성을 새로 만드는 것.

출제 포인트: 부정형의 단골 수법 = 일반화와 속성 생성의 정의 바꿔치기. 일반화는 "위로 뭉뚱그리기", 속성 생성은 "새로 만들기"로 구분. ※ 교재별 표기 차이 있음 — 일반화를 '특정 구간에 분포하도록 값의 스케일을 변화시키는 기법'으로 서술하는 교재도 있다.

근거: 일반화(generalization)는 세부적인 하위 수준의 데이터 값을 연령대·지역 등 상위 개념의 값으로 대체하는 데이터 변환 기법이다.

Q1-050 [난이도: 중] [태그: 1과목/데이터수집및저장계획/OpenAPI·RSS·FTP]

파일 전송 프로토콜 FTP(File Transfer Protocol)에 대한 설명으로 옳은 것은?

① UDP 기반 프로토콜이므로 전송의 신뢰성을 보장하지 않는다.
② 능동(active) 모드에서는 클라이언트가 서버의 데이터 포트에 먼저 접속하여 데이터 연결을 생성한다.
③ 수동(passive) 모드에서는 서버가 알려 준 임의의 포트로 클라이언트가 접속하여 데이터 연결을 생성한다.
④ 제어(명령) 연결에는 기본적으로 20번 포트가 사용된다.

✓ 정답 및 해설

정답: ③

- ① FTP는 **TCP/IP 기반** 프로토콜로 연결 지향적이며 전송 신뢰성을 보장한다. UDP 기반이라는 설명은 틀림.
- ② 능동 모드에서는 **서버가** 클라이언트가 알려 준 포트로 **먼저 접속**하여 데이터 연결을 만든다. 클라이언트가 서버에 접속한다는 설명은 수동 모드와 뒤바뀐 것.
- ③ 옳은 설명. 수동 모드 = 서버가 데이터 연결용 임의 포트를 알려 주고 **클라이언트가 그 포트로 접속**. ← 정답
- ④ 제어(명령) 연결의 기본 포트는 **21번**이다. 20번은 **능동 모드의 데이터 연결**에 사용되는 포트.

출제 포인트: FTP 모드는 "데이터 연결을 누가 시작하는가"로 구분 — 능동: 서버→클라이언트, 수동: 클라이언트→서버. 포트는 제어 21번 / 능동 모드 데이터 20번 짝으로 암기.

근거: FTP는 TCP/IP 기반 파일 전송 프로토콜로 제어 연결(21번 포트)과 데이터 연결을 분리하며, 능동 모드는 서버가, 수동 모드는 클라이언트가 데이터 연결을 시작한다.

Q1-051 [난이도: 상] [태그: 1과목/데이터수집및저장계획/수집기술·품질종합]

데이터 수집 기술과 품질 기준에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. FTP는 TCP/IP 기반의 파일 전송 프로토콜로, 대용량 파일 수집에 활용된다.
- ㄴ. Open API는 배포자가 갱신 콘텐츠를 XML 형식으로 밀어 보내면 구독자가 자동 수신하는 방식이다.
- ㄷ. 완전성(completeness)은 필요한 데이터가 누락 없이 존재하는 정도를 의미한다.
- ㄹ. 일관성(consistency)은 데이터가 서로 모순 없이 동일한 형식·값 체계를 유지하는 정도를 의미한다.

① ㄱ, ㄷ, ㄹ ② ㄱ, ㄴ, ㄷ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄴ, ㄹ

✓ 정답 및 해설

정답: ①

- **ㄱ (O)** FTP = TCP/IP 기반 파일 전송 프로토콜, 대용량 파일 송수신에 사용.
- **ㄴ (X)** XML 배급·구독 방식은 **RSS**의 설명이다. Open API는 이용자가 공개된 인터페이스를 **호출(요청)**하여 데이터를 받는 방식.
- **ㄷ (O)** 완전성 = 누락 없음.
- **ㄹ (O)** 일관성 = 형식·값 체계의 무모순.

따라서 옳은 것은 ㄱ, ㄷ, ㄹ → ①. (②·④는 틀린 ㄴ을 포함, ③은 옳은 ㄱ을 누락하고 ㄴ을 포함)

출제 포인트: Open API와 RSS의 구분은 "누가 움직이는가" — Open API는 수집자가 호출(pull), RSS는 갱신 콘텐츠의 배급을 구독. 품질 기준은 정확성·완전성·적시성·일관성 4개를 정의와 1:1로 묶어 암기.

근거: Open API는 서비스 제공자가 공개한 프로그래밍 인터페이스를 호출하여 실시간으로 데이터를 수집하는 방식이고, FTP는 TCP/IP 기반으로 서버-클라이언트 간 파일을 송수신하는 프로토콜이다.

Q1-052 [난이도: 상] [태그: 1과목/데이터수집및저장계획/데이터변환기법]

어느 기업이 고객 데이터를 다음과 같이 전환했다.

- (가) 고객 나이 값 23, 35, 47을 각각 '20대', '30대', '40대'로 대체했다.
- (나) 일별 매출 데이터를 합산하여 월별 매출 데이터로 만들었다.

(가)와 (나)에 적용된 데이터 변환 기법을 순서대로 바르게 짝지은 것은?

① 평활화 — 집계
② 일반화 — 정규화
③ 평활화 — 속성 생성
④ 일반화 — 집계

✓ 정답 및 해설

정답: ④

- **(가)** 세부 값(나이)을 상위 개념(연령대)으로 대체 → **일반화**. 구간을 나눈다는 점 때문에 평활화(구간화)로 착각하기 쉬우나, 평활화의 목적은 **노이즈 제거**이고 여기서는 상위 개념화가 목적이다.
- **(나)** 일별 데이터를 합산해 요약 → **집계**.
- ① (가)를 평활화로 본 함정. 목적이 노이즈 제거가 아니므로 틀림.
- ② (나)는 척도 변환이 아니라 요약·합산이므로 정규화가 아님.
- ③ (가)는 평활화가 아니고, (나)는 새 속성을 만든 것이 아니라 요약한 것.
- ④ 일반화 — 집계. ← 정답

출제 포인트: 사례형 판별 기준은 "목적" — 노이즈 제거면 평활화, 상위 개념 대체면 일반화, 요약·합산이면 집계, 척도 변환이면 정규화, 새 속성이면 속성 생성. 나이→연령대는 일반화의 대표 예시.

근거: 데이터 전환에서 일반화는 하위 수준 값을 상위 개념으로 대체하는 기법이고, 집계는 데이터를 합산·요약하여 축약된 형태로 만드는 기법이다.

1-6 데이터 적재 및 저장

> 1과목 · 빅데이터 분석 기획 / 주요항목: 데이터 수집 및 저장 계획
> 문항 수: 8 (Q1-053 ~ Q1-060) · 난이도 하2/중4/상2 · 정답 분포 ①2 ②2 ③2 ④2

Q1-053 [난이도: 하] [태그: 1과목/데이터수집및저장계획/NoSQL유형]

문서 기반(Document Store) NoSQL 데이터베이스의 대표 제품은?

① Redis ② MongoDB ③ Neo4j ④ HBase

✓ 정답 및 해설

정답: ②

- ① Redis: 키-값(Key-Value) 저장소. 인메모리 기반의 단순 키-값 구조.
- ② MongoDB: JSON 유사 문서(BSON) 단위로 저장하는 문서 기반(Document Store) 저장소. ← 정답
- ③ Neo4j: 노드·엣지로 관계를 표현하는 그래프(Graph) 저장소.
- ④ HBase: 컬럼 패밀리 단위로 저장하는 컬럼 기반(Column-family) 저장소.

출제 포인트: NoSQL 4유형-제품 매칭 = **Key-Value: Redis / Document: MongoDB / Column: HBase·Cassandra / Graph: Neo4j**. "몽고는 문서, 레디스는 키-값, 네오는 그래프, 나머지(HBase·Cassandra)는 컬럼"으로 암기.

근거: 문서 기반 NoSQL은 JSON·XML 등 문서 단위로 데이터를 저장·조회하는 유형으로, MongoDB가 대표 제품이다.

Q1-054 [난이도: 하] [태그: 1과목/데이터수집및저장계획/데이터웨어하우스]

데이터 웨어하우스(Data Warehouse)의 4가지 특징에 해당하지 **않는** 것은?

① 주제 지향성(subject-oriented)
② 통합성(integrated)
③ 시계열성(time-variant)
④ 휘발성(volatile)

✓ **정답 및 해설**

정답: ④

- ① 주제 지향성: 업무 기능이 아니라 고객·상품 등 분석 **주제 중심**으로 데이터를 구성 → 특징에 포함.
- ② 통합성: 여러 운영 시스템의 데이터를 **일관된 형식·코드로 통합** 저장 → 특징에 포함.
- ③ 시계열성: **시점 정보를 함께 보관**하여 과거 이력 분석이 가능 → 특징에 포함.
- ④ DW는 휘발성이 아니라 **비휘발성(non-volatile)** — 일단 적재된 데이터는 일괄 적재 외에 수시 갱신·삭제되지 않는다. ← 정답

출제 포인트: DW 특징 4 = **주제 지향·통합·시계열·비휘발**("주통시비"). 부정형에서 "휘발성", "실시간 갱신"으로 바꿔치기하는 선지가 단골.

근거: 데이터 웨어하우스는 의사결정 지원을 위해 주제 지향적·통합적·시계열적·비휘발적으로 구축되는 데이터 저장소다.

Q1-055 [난이도: 중] [태그: 1과목/데이터수집및저장계획/CAP정리]

분산 데이터 저장 시스템에 관한 CAP 정리(CAP theorem)의 설명으로 옳은 것은?

① 일관성(Consistency)은 모든 노드가 언제든 요청에 응답할 수 있는 성질이다.
② 분산 데이터베이스는 세 가지 속성을 모두 동시에 보장하도록 설계된다.
③ 네트워크 분할이 발생한 상황에서는 일관성과 가용성 중 하나를 선택해야 한다.
④ 가용성(Availability)은 모든 노드가 같은 시점에 동일한 데이터를 보는 성질이다.

✓ **정답 및 해설**

정답: ③

- ① 언제든 응답 가능한 성질은 **가용성(Availability)**. 일관성의 정의와 바꿔치기한 선지.
- ② CAP 정리의 핵심이 바로 "**세 속성을 동시에 모두 만족할 수 없다**"이다. 정면으로 어긋나는 설명.
- ③ 분산 환경에서 분할 허용성(Partition tolerance)은 사실상 포기할 수 없으므로, 분할 발생 시 **일관성(CP)과 가용성(AP) 중 택일**해야 한다. ← 정답
- ④ 모든 노드가 동일 데이터를 보는 성질은 **일관성(Consistency)**. 가용성의 정의와 바꿔치기한 선지.

출제 포인트: CAP = **C**onsistency(모든 노드 동일 데이터) · **A**vailability(항상 응답) · **P**artition tolerance(분할에도 동작). **최대 2개만 보장** — 분산 시스템은 P가 전제이므로 실질 선택지는 CP vs AP.

근거: CAP 정리는 분산 시스템이 일관성·가용성·분할 허용성 세 속성 중 최대 두 가지만 동시에 보장할 수 있다는 원리다.

Q1-056 [난이도: 중] [태그: 1과목/데이터수집및저장계획/ACID·BASE]

트랜잭션 속성 ACID와 BASE에 대한 설명으로 옳은 것은?

① BASE는 기본적 가용성(Basically Available), 소프트 상태(Soft state), 최종 일관성(Eventually consistent)을 의미하며 NoSQL이 주로 채택하는 느슨한 일관성 모델이다.
② ACID는 NoSQL의 특성이고, BASE는 관계형 데이터베이스의 트랜잭션 특성이다.
③ BASE 모델은 모든 시점에 강한 일관성(strong consistency)을 보장한다.
④ ACID의 D(Durability)는 트랜잭션을 언제든지 취소할 수 있음을 의미한다.

> **✓ 정답 및 해설**
>
> **정답:** ①
>
> - ① BASE = **B**asically **A**vailable(기본적 가용성) + **S**oft state(소프트 상태) + **E**ventually consistent(최종 일관성). 일관성을 일부 늦추는 대신 가용성을 우선하는 NoSQL의 모델. ← 정답
> - ② 반대로 서술한 선지. **ACID는 RDBMS**의 트랜잭션 특성, **BASE는 NoSQL**의 특성.
> - ③ BASE는 강한 일관성이 아니라 **최종 일관성**(시간이 지나면 결국 일치)을 허용한다.
> - ④ D(Durability, 지속성)는 **완료(commit)된 트랜잭션의 결과가 영구 보존**됨을 의미. 취소 가능성과 무관.
>
> **출제 포인트:** ACID = 원자성(Atomicity)·일관성(Consistency)·독립성(Isolation)·지속성(Durability) → RDBMS·강한 일관성. BASE = 기본적 가용성·소프트 상태·최종 일관성 → NoSQL·가용성 우선. "ACID는 은행(정확), BASE는 SNS(빠름)"로 암기.
>
> **근거:** BASE는 강한 일관성 대신 기본적 가용성·소프트 상태·최종 일관성을 채택하여 가용성과 확장성을 우선하는 NoSQL의 트랜잭션 모델이다.

Q1-057 [난이도: 중] [태그: 1과목/데이터수집및저장계획/HDFS]

하둡 분산 파일 시스템(HDFS)에 대한 설명으로 옳지 **않은** 것은?

① 네임노드(NameNode)는 파일 시스템의 메타데이터를 관리한다.
② 데이터노드(DataNode)가 메타데이터를 저장하고, 네임노드가 실제 데이터 블록을 저장한다.
③ 파일은 블록(block) 단위로 분할되어 여러 데이터노드에 분산 저장된다.
④ 블록은 기본적으로 여러 노드에 복제 저장되어 일부 노드 장애 시에도 데이터를 보존할 수 있다.

✓ 정답 및 해설

정답: ②

- ① 옳은 설명. 네임노드는 파일명·디렉터리 구조·블록 위치 등 **메타데이터**를 관리하는 마스터 노드.
- ② 역할을 뒤바꾼 선지. **네임노드=메타데이터, 데이터노드=실제 블록 저장**이 올바른 구조다. ← 정답
- ③ 옳은 설명. 대용량 파일을 블록으로 쪼개 여러 데이터노드에 분산 저장한다.
- ④ 옳은 설명. 블록 복제(기본 복제 계수 3)로 장애 허용(fault tolerance)을 확보한다.

출제 포인트: HDFS = 마스터(네임노드: 메타데이터) + 슬레이브(데이터노드: 실제 블록). 블록 복제 계수 기본 3. 블록 크기 기본 128MB ※ 교재별 표기 차이 있음(하둡 2.x 이상 기본 128MB, 1.x는 64MB).

근거: HDFS는 네임노드가 메타데이터를, 데이터노드가 실제 데이터 블록을 담당하며 블록 복제를 통해 장애 허용성을 확보하는 분산 파일 시스템이다.

Q1-058 [난이도: 중] [태그: 1과목/데이터수집및저장계획/데이터마트]

어느 기업이 전사 데이터 웨어하우스에서 마케팅 부서가 필요로 하는 데이터만 추출하여, 마케팅 분석 전용의 소규모 주제 지향적 저장소를 구축하려 한다. 이에 해당하는 것은?

① 데이터 마트(Data Mart)
② 데이터 레이크(Data Lake)
③ ODS(Operational Data Store)
④ 데이터 웨어하우스(Data Warehouse)

✓ 정답 및 해설

정답: ①

- ① 데이터 마트: DW의 일부를 **특정 부서·주제** 단위로 추출한 소규모 저장소. "마케팅 전용·소규모"에 부합. ← 정답
- ② 데이터 레이크: 정형·비정형 **원시(raw) 데이터를 가공 없이** 대규모로 축적하는 저장소. 부서 전용 추출과 무관.
- ③ ODS: DW 적재 전 **운영계 데이터를 임시 통합**하는 중간 저장소. 분석 전용 저장소가 아님.
- ④ 데이터 웨어하우스: **전사** 차원의 통합 저장소. 문제의 "전사 DW에서 추출"한 결과물이 아니라 원천에 해당.

출제 포인트: 규모·목적으로 구분 — **ODS(운영계 임시 통합) → DW(전사 통합) → 마트(부서·주제별 부분집합)**, 레이크는 별도로 "원시 데이터 그대로" 축적. "마트는 DW의 부분집합"이 핵심.

근거: 데이터 마트는 데이터 웨어하우스의 데이터 중 특정 부서나 주제 영역에 필요한 부분만 추출하여 구축한 소규모 주제 지향적 저장소다.

Q1-059 [난이도: 상] [태그: 1과목/데이터수집및저장계획/데이터레이크]

데이터 저장소에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 데이터 레이크는 원시(raw) 데이터를 원래 형식 그대로 저장하며, 스키마를 읽는 시점에 적용한다(Schema-on-Read).
② ODS는 데이터 웨어하우스 적재 전에 운영계 데이터를 임시로 통합·저장하는 저장소다.
③ 데이터 마트는 정형·비정형 원시 데이터를 가공 없이 그대로 축적한다는 점에서 데이터 레이크와 성격이 같다.
④ 데이터 웨어하우스는 정제·통합된 정형 데이터를 적재 시점에 스키마에 맞춰 저장한다(Schema-on-Write).

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 레이크는 가공 전 원시 데이터를 그대로 두고, **분석(읽기) 시점에 구조를 부여**한다.
- ② 옳은 설명. ODS는 운영계와 DW 사이의 **중간 임시 통합** 저장소.
- ③ 데이터 마트는 **정제·요약된 정형 데이터를 특정 주제별로** 담는 저장소로, 원시 데이터를 무가공 축적하는 레이크와 정반대 성격이다. 레이크의 특징을 마트에 뒤집어씌운 함정. ← 정답
- ④ 옳은 설명. DW는 **적재 시점에 정해진 스키마**로 정제·변환 후 저장한다.

출제 포인트: 함정 구분 — **마트/DW = 정제된 정형 + Schema-on-Write**, **레이크 = 원시 데이터(정형·비정형) + Schema-on-Read**. "레이크는 날것, 마트는 완제품"으로 암기.

근거: 데이터 레이크는 정형·비정형 원시 데이터를 가공하지 않고 원래 형식 그대로 저장했다가 활용 시점에 스키마를 적용하는 대규모 저장소다.

Q1-060 [난이도: 상] [태그: 1과목/데이터수집및저장계획/NoSQL유형]

NoSQL 데이터베이스에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. Redis는 키-값(Key-Value) 기반 저장소다.
- ㄴ. 컬럼 기반(Column-family) 저장소는 데이터를 행(row) 단위로만 저장하므로 특정 컬럼에 대한 조회·집계 분석에 불리하다.
- ㄷ. HBase와 Cassandra는 컬럼 기반(Column-family) 저장소다.
- ㄹ. NoSQL은 일반적으로 BASE 속성을 따르며 최종 일관성(eventual consistency)을 허용한다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄴ, ㄷ ④ ㄱ, ㄷ, ㄹ

✓ 정답 및 해설

정답: ④

- **ㄱ (O)** Redis는 인메모리 기반의 키-값(Key-Value) 저장소다.
- **ㄴ (X)** 컬럼 기반 저장소는 행이 아니라 **컬럼(패밀리) 단위로 저장**하므로, 특정 컬럼만 읽어 조회·집계하는 분석에 오히려 **유리**하다. 특징을 정반대로 뒤집은 서술.
- **ㄷ (O)** HBase·Cassandra는 컬럼 패밀리 단위로 저장하는 컬럼 기반 저장소다.
- **ㄹ (O)** NoSQL은 ACID 대신 BASE를 채택하여 가용성을 우선하고 최종 일관성을 허용하는 것이 일반적이다.

따라서 옳은 것은 ㄱ, ㄷ, ㄹ → ④. (①·③은 틀린 ㄴ을 포함하거나 옳은 ㄹ을 누락, ②는 틀린 ㄴ을 포함)

출제 포인트: 제품-유형 매칭(**Redis=키-값 / MongoDB=문서 / HBase·Cassandra=컬럼 / Neo4j=그래프**)에 유형별 특징·트랜잭션 모델까지 조합형으로 얹는 문제 — 컬럼 저장소는 **컬럼 단위 저장 → 컬럼 조회·집계에 유리**, NoSQL의 트랜잭션 모델은 **BASE(최종 일관성)**.

근거: NoSQL은 키-값·문서·컬럼·그래프의 4가지 유형으로 분류되고, 컬럼 기반 저장소는 컬럼 단위 저장으로 컬럼 조회·집계에 유리하며, NoSQL은 일반적으로 BASE 속성에 기반한 최종 일관성 모델을 채택한다.

이 문서는 LLM으로 생성 후 3중 검증(사실·논리·규격 / 중복 / 교체분 재검증)을 거친 학습 자료입니다. 교재별 표기가 갈리는 항목은 본문에 "※ 교재별 표기 차이 있음"으로 표시했으며, 상세 목록은 부록의 검증 필요 항목을 참고하세요.