빅데이터분석기사 필기 문제집

2과목 · 빅데이터 탐색 — 60문항 (Q2-001 ~ Q2-060)

the0ne 학습용 · 2026-09-01 생성 · KDATA 공개 출제기준 기반 신규 창작 문항 (기출 복원 아님)

2-1 데이터 정제

> 2과목 · 빅데이터 탐색 / 주요항목: 데이터 전처리
> 범위: 결측값 유형(MCAR·MAR·MNAR)과 대치법, 이상값 탐지·처리, 노이즈 처리
> 문항 수: 12 (Q2-001 ~ Q2-012) · 난이도 하4/중6/상2 · 정답 분포 ①3 ②3 ③3 ④3

Q2-001 [난이도: 하] [태그: 2과목/데이터전처리/결측값유형]

결측값의 발생이 해당 변수의 값이나 다른 어떤 변수와도 관계없이 완전히 무작위로 일어나는 결측 유형은?

① 무작위 결측(MAR)
② 완전 무작위 결측(MCAR)
③ 비무작위 결측(MNAR)
④ 이상값(outlier)

> **✓ 정답 및 해설**
>
> **정답:** ②
>
> - ① MAR: 결측 발생이 결측된 값 자체가 아니라 **관측된 다른 변수**에 의존. "완전히 무관"이 아님.
> - ② MCAR: 결측 발생이 어떤 변수와도 무관하게 순수한 우연으로 발생. ← 정답
> - ③ MNAR: 결측 발생이 **결측된 값 자체**와 관련. 무작위가 아님.
> - ④ 이상값은 관측은 되었으나 정상 범위를 벗어난 값으로, 결측(관측 안 됨)의 유형이 아님.
>
> **출제 포인트:** "무엇에 의존해 결측이 생기는가"로 3유형 구분 — 아무것도(MCAR) / 관측된 다른 변수(MAR) / 결측된 값 자체(MNAR).
>
> **근거:** 완전 무작위 결측(MCAR)은 결측 발생이 결측된 값 자체나 다른 변수와 아무 관련 없이 완전히 무작위로 일어나는 결측 유형이다.

Q2-002 [난이도: 하] [태그: 2과목/데이터전처리/결측값유형사례]

소득 설문조사에서 고소득자일수록 자신의 소득 노출을 꺼려 소득 문항에 응답하지 않는 경향이 확인되었다. 이 소득 변수의 결측 유형은?

① 완전 무작위 결측(MCAR)
② 무작위 결측(MAR)
③ 표본 추출 오류
④ 비무작위 결측(MNAR)

✓ 정답 및 해설

정답: ④

- ① MCAR이려면 무응답이 소득 수준과 무관해야 하는데, 고소득일수록 무응답이 많으므로 아님.
- ② MAR이려면 무응답이 성별·연령 등 **관측된 다른 변수**에만 의존해야 함. 여기서는 결측된 값(소득) 자체에 의존하므로 아님.
- ③ 표본 추출 오류는 표본이 모집단을 대표하지 못하는 문제로, 결측 유형 분류가 아님.
- ④ 무응답 확률이 **결측된 소득 값 자체**에 의존 → MNAR. ← 정답

출제 포인트: "소득이 높을수록 소득을 안 밝힌다" = 결측 원인이 결측값 그 자체 → MNAR의 대표 사례. 시험 단골 시나리오.

근거: 비무작위 결측(MNAR)은 결측 발생 확률이 결측된 값 자체와 관련되어 있는 결측 유형이다.

Q2-003 [난이도: 하] [태그: 2과목/데이터전처리/이상값탐지]

자료가 정규분포를 따른다고 가정하고, 평균으로부터 표준편차의 ±3배(±3σ)를 벗어나는 값을 이상값으로 판별하는 기법은?

① ESD(Extreme Studentized Deviate)
② 사분위수 범위(IQR) 규칙
③ 마할라노비스 거리(Mahalanobis distance)
④ 카이제곱 검정(chi-square test)

✓ 정답 및 해설

정답: ①

- ① ESD: 평균 ±3σ를 벗어난 값을 이상값으로 판별. ← 정답
- ② IQR 규칙: 평균·표준편차가 아니라 **사분위수**(Q1−1.5×IQR, Q3+1.5×IQR)를 경계로 사용.
- ③ 마할라노비스 거리: 변수 간 상관을 반영한 **다변량** 거리 기반 판별. 단일 변수 ±3σ 규칙이 아님.
- ④ 카이제곱 검정: 범주형 자료의 적합도·독립성 검정에 쓰이는 기법으로, 본 문항의 정의(평균 ±3σ 규칙)에 해당하지 않음. ※ 일부 교재는 자료 수가 적은 정규분포 자료의 이상값 검색에 카이제곱 검정을 활용한다고 소개하나, 이는 ±3σ 규칙과는 다른 접근이다.

출제 포인트: ESD = "평균 기준 ±3σ", IQR = "사분위수 기준 1.5배", Z-점수 = "표준화 후 |Z|>3". 기준이 되는 통계량으로 구분. ※ 교재별 표기 차이 있음 — ±3σ 규칙을 ESD로 부르는 표기는 국내 수험 교재의 통용 표기다.

근거: ESD는 정규분포 가정하에 평균에서 ±3 표준편차를 벗어나는 관측값을 이상값으로 판별하는 기법이다.

Q2-004 [난이도: 하] [태그: 2과목/데이터전처리/노이즈처리]

데이터를 정렬하여 여러 구간(bin)으로 나눈 뒤, 각 구간의 평균·중앙값·경계값으로 구간 내 값을 대체하여 잡음(noise)을 완화하는 평활화(smoothing) 기법은?

① 군집화(clustering)
② 회귀(regression)
③ 구간화(binning)
④ 표준화(standardization)

✓ 정답 및 해설

정답: ③

- ① 군집화: 유사한 값들을 군집으로 묶고 군집 밖의 값을 이상값·잡음으로 식별하는 방식. 구간 대체가 아님.
- ② 회귀: 데이터를 회귀 함수에 적합시켜 함수값으로 평활화하는 방식. 구간 개념이 없음.
- ③ 구간화: 정렬 → 구간 분할 → 구간의 평균/중앙값/경계값으로 대체. ← 정답
- ④ 표준화: 평균 0·표준편차 1로 척도를 변환하는 것으로, 잡음 제거 기법이 아님.

출제 포인트: 노이즈(잡음) 처리 3형제 = 구간화(bin 대체) · 군집화(군집 밖 식별) · 회귀(함수 적합). "정렬 후 구간"이 보이면 구간화.

근거: 구간화(binning)는 정렬된 데이터를 구간으로 나누고 각 구간의 대표값(평균·중앙값·경계값)으로 대체하여 잡음을 평활화하는 기법이다.

Q2-005 [난이도: 중] [태그: 2과목/데이터전처리/결측값대치법]

결측값 처리 방법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 완전분석법(complete case analysis)은 결측값이 하나라도 있는 관측치를 제외하고 완전한 관측치만으로 분석한다.
② 평균 대치법은 결측값을 관측된 값들의 평균으로 대체하며, 자료의 분산을 과소추정하는 단점이 있다.
③ 회귀 대치법은 결측이 없는 다른 변수들로 회귀모형을 만들어 그 예측값으로 결측값을 대체한다.
④ 다중 대치법(multiple imputation)은 결측값을 한 번만 대치하여 단 하나의 완성된 데이터셋을 만드는 방법이다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. 단, 표본 수 감소와 편향(MCAR가 아닐 때) 위험이 단점.
- ② 옳은 설명. 같은 값(평균)으로 채우므로 흩어짐이 줄어 분산이 실제보다 작아짐.
- ③ 옳은 설명. 회귀식의 예측값으로 대치하는 방법.
- ④ 다중 대치는 대치를 **m회 반복해 m개의 완성 데이터셋**을 만들고, 각각 분석한 뒤 결과를 결합한다. "한 번만·하나만"은 단순 대치법의 설명. ← 정답

출제 포인트: 다중 대치 3단계 = 대치(imputation) → 분석(analysis) → 결합(pooling/combination). "1회·1개"가 보이면 오답.

근거: 다중 대치법은 결측값 대치를 여러 번 수행해 m개의 완성된 데이터셋을 생성한 뒤 각 분석 결과를 결합하여 대치의 불확실성을 반영하는 방법이다.

Q2-006 [난이도: 중] [태그: 2과목/데이터전처리/LOF이상값탐지]

관측치 주변의 국소 밀도(local density)를 k-최근접 이웃들의 밀도와 비교하여, 이웃들에 비해 상대적으로 밀도가 낮은 곳에 있는 관측치를 이상값으로 판별하는 기법은?

① 아이솔레이션 포레스트(iForest, Isolation Forest)
② 국소 이상치 요인(LOF, Local Outlier Factor)
③ ESD(Extreme Studentized Deviate)
④ 사분위수 범위(IQR) 규칙

✓ 정답 및 해설

정답: ②

- ① 아이솔레이션 포레스트: 무작위 분할(트리)로 관측치를 **고립(isolation)**시킬 때, **적은 분할 횟수로 쉽게 고립되는** 관측치를 이상값으로 판별. 밀도 비교 방식이 아님.
- ② LOF: 관측치 자신의 국소 밀도와 **k-최근접 이웃들의 밀도의 비율**로 점수를 계산하고, 주변보다 밀도가 낮을수록(점수가 클수록) 이상값으로 판별. ← 정답
- ③ ESD: 정규분포 가정하에 **평균 ±3σ**를 벗어나는 값을 판별하는 통계 기반 기법. 밀도·이웃 개념이 없음.
- ④ IQR 규칙: **사분위수 경계**(Q1−1.5×IQR, Q3+1.5×IQR)를 벗어나는 값을 판별하는 통계 기반 기법.

출제 포인트: 머신러닝 기반 이상값 탐지 구분 — **LOF = "이웃과의 밀도 비교", iForest = "적은 분할로 고립"**. 통계 기반(ESD·IQR·Z-점수)과 방식 자체가 다르며, "국소 밀도"라는 단어가 보이면 LOF.

근거: LOF(Local Outlier Factor)는 관측치의 국소 밀도를 k-최근접 이웃들의 밀도와 비교하여 상대적으로 밀도가 낮은 관측치를 이상값으로 판별하는 밀도 기반 이상값 탐지 기법이다.

Q2-007 [난이도: 중] [태그: 2과목/데이터전처리/이상값탐지]

이상값 탐지 기법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 표준화 점수(Z-score)는 자료를 평균 0, 표준편차 1로 변환한 값으로, 절댓값이 3을 넘으면 이상값을 의심한다.
② IQR 규칙은 Q1 − 1.5×IQR 미만이거나 Q3 + 1.5×IQR을 초과하는 값을 이상값으로 본다.
③ 마할라노비스 거리는 변수 간 상관관계를 고려하지 못하므로 다변량 이상값 탐지에는 사용할 수 없다.
④ 사분위수 기반 판정 결과는 상자그림(box plot)으로 시각화하여 확인할 수 있다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. Z = (x−평균)/표준편차, 통상 |Z| > 3이면 이상값 의심.
- ② 옳은 설명. IQR 1.5배 규칙의 정의 그대로.
- ③ 마할라노비스 거리는 공분산(변수 간 상관)을 **반영하는** 거리로, 오히려 **다변량 이상값 탐지에 사용하는 대표 기법**이다. 정반대로 서술한 틀린 설명. ← 정답
- ④ 옳은 설명. 상자그림의 수염 밖 점이 IQR 규칙의 이상값.

출제 포인트: 마할라노비스 거리의 키워드 = "공분산 반영·다변량". 특징을 정반대로 뒤집는 함정이 단골.

근거: 마할라노비스 거리는 변수 간 공분산(상관관계)을 반영하여 관측치가 분포 중심에서 얼마나 떨어져 있는지 측정하는 다변량 이상값 탐지 기법이다.

Q2-008 [난이도: 중] [태그: 2과목/데이터전처리/노이즈처리]

데이터 정제 대상 중 잡음(noise)에 대한 설명으로 가장 적절한 것은?

① 측정 과정에서 무작위로 섞여 들어간 오류값으로, 구간화·회귀·군집화 같은 평활화(smoothing) 기법으로 그 영향을 줄일 수 있다.
② 관측 자체가 이루어지지 않아 값이 비어 있는 상태를 말한다.
③ 정상 범위를 크게 벗어났으나 입력 오류가 아니라 실제로 발생한 극단적인 관측값을 말한다.
④ 발생 원인과 참값이 명확히 기록되어 있으므로 언제든 원래 값으로 복원할 수 있다.

✓ 정답 및 해설

정답: ①

- ① 잡음 = 측정(수집) 과정에서 **무작위로 개입된 오류(random error)**. 구간화(binning)·회귀·군집화 등의 평활화로 영향을 완화한다. ← 정답
- ② 값이 비어 있는 것은 **결측값(missing value)**의 설명. 잡음은 값이 존재하되 왜곡되어 있는 경우다.
- ③ 실제로 발생한 극단 관측값은 **이상값(outlier)**의 설명. 이상값은 오류일 수도, 의미 있는 특이 현상일 수도 있어 잡음과 구분된다.
- ④ 잡음은 참값을 알기 어려워 **완전한 제거·복원이 곤란**하며, 평활화 등으로 최소화하는 것이 현실적인 처리 방향이다.

출제 포인트: 정제 대상 3형제 구분 — **결측값 = 값이 없음 / 잡음 = 값이 왜곡됨(무작위 오류) / 이상값 = 값이 정상 범위 밖**. 잡음 처리의 키워드는 평활화(구간화·회귀·군집화).

근거: 잡음(noise)은 측정 과정에서 무작위로 포함된 오류로, 값이 존재하지 않는 결측값이나 정상 범위를 벗어난 이상값과 구분되며 구간화·회귀·군집화 등의 평활화 기법으로 완화한다.

Q2-009 [난이도: 중] [태그: 2과목/데이터전처리/결측값유형사례]

건강 설문에서 성별에 따라 체중 문항의 무응답률이 다르게 나타났으나, 같은 성별 집단 안에서는 무응답이 체중 값 자체와는 무관하게 발생했다. 이 체중 변수의 결측 유형은?

① 완전 무작위 결측(MCAR)
② 무작위 결측(MAR)
③ 비무작위 결측(MNAR)
④ 잡음(noise)

✓ 정답 및 해설

정답: ②

- ① MCAR이려면 성별과도 무관해야 하는데, 성별에 따라 무응답률이 다르므로 아님.
- ② 결측이 **관측된 다른 변수(성별)** 에는 의존하지만, 결측된 값(체중) 자체와는 무관 → MAR. ← 정답
- ③ MNAR이려면 체중 값 자체(예: 체중이 많이 나갈수록 무응답)에 의존해야 함. 문제에서 "체중 값과는 무관"이라 했으므로 아님.
- ④ 잡음은 측정 과정에서 섞인 오류값으로, 결측 유형이 아님.

출제 포인트: 사례형 판별 공식 — 결측 원인이 "다른 관측 변수"면 MAR, "결측값 그 자체"면 MNAR, "아무것도 아니면" MCAR.

근거: 무작위 결측(MAR)은 결측 발생이 결측된 값 자체가 아니라 관측된 다른 변수에만 의존하는 결측 유형이다.

Q2-010 [난이도: 중] [태그: 2과목/데이터전처리/이상값처리]

이상값 처리 방법에 대한 설명으로 옳지 **않은** 것은?

① 삭제는 이상값을 제거하는 방법으로, 표본 수가 줄고 추정에 편향이 생길 수 있다.
② 대체는 이상값을 하한값·상한값 등 정해진 경계값으로 바꾸어 극단성을 조정하는 방법이다.
③ 변환은 로그 변환(log transformation) 등을 적용해 극단적으로 큰 값의 영향을 줄이는 방법이다.
④ 분리는 이상값을 별도의 그룹으로 나누어 분석하는 방법으로, 분리된 이상값은 항상 분석에서 버려진다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. 가장 간단하지만 정보 손실·편향 위험이 삭제의 단점.
- ② 옳은 설명. 경계값(상·하한)으로 조정하는 대체 처리.
- ③ 옳은 설명. 로그·제곱근 변환 등으로 분포의 꼬리를 눌러 영향 완화.
- ④ 분리는 이상값을 **버리는 것이 아니라** 이상값 포함/제외 등 그룹을 나누어 **각각 분석·활용**하는 방법이다. "항상 버려진다"가 틀림. ← 정답

출제 포인트: 이상값 처리 4가지 = 삭제(제거) · 대체(경계값) · 변환(로그 등) · 분리(그룹 나눠 각각 분석). 분리 ≠ 폐기.

근거: 분리는 이상값을 포함한 경우와 제외한 경우 등으로 데이터를 나누어 각각 분석함으로써 이상값의 영향을 파악·활용하는 이상값 처리 방법이다.

Q2-011 [난이도: 상] [태그: 2과목/데이터전처리/결측값유형종합]

결측값 유형에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 완전 무작위 결측(MCAR)은 결측 발생이 결측된 값이나 다른 어떤 변수와도 무관하다.
- ㄴ. 무작위 결측(MAR)은 결측 발생이 결측된 값 자체 때문에 일어나는 경우를 말한다.
- ㄷ. 비무작위 결측(MNAR)에서는 결측 메커니즘을 무시할 수 없어 결측 행을 단순 삭제하면 편향이 생길 수 있다.
- ㄹ. MCAR이라면 완전분석법을 사용해도 추정의 편향은 발생하지 않는다.

① ㄱ, ㄷ, ㄹ ② ㄱ, ㄴ, ㄷ ③ ㄴ, ㄹ ④ ㄱ, ㄴ, ㄹ

✓ 정답 및 해설

정답: ①

- **ㄱ (O)** MCAR의 정의 그대로.
- **ㄴ (X)** "결측된 값 자체 때문"은 **MNAR**의 설명. MAR은 관측된 **다른** 변수에 의존하는 경우다.
- **ㄷ (O)** MNAR은 결측 자체가 정보를 가지므로 단순 삭제·단순 대치 시 편향 위험.
- **ㄹ (O)** MCAR이면 남은 완전한 관측치가 여전히 무작위 표본이므로 편향은 없다(단, 표본 수 감소로 효율은 떨어짐).

따라서 옳은 것은 ㄱ, ㄷ, ㄹ → **①**. (②·④는 틀린 ㄴ 포함, ③은 옳은 ㄱ·ㄷ 누락)

출제 포인트: MAR과 MNAR의 정의 바꿔치기가 최다 빈출 함정. "완전분석법이 안전한 유일한 경우 = MCAR"까지 세트로 암기.

근거: 결측값은 발생 원인에 따라 완전 무작위 결측(MCAR)·무작위 결측(MAR)·비무작위 결측(MNAR)으로 분류되며, MCAR에서만 완전한 관측치가 전체의 무작위 표본이 된다.

Q2-012 [난이도: 상] [태그: 2과목/데이터전처리/대치법종합]

결측값 대치법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 핫덱(hot-deck) 대치는 현재 진행 중인 같은 조사(데이터셋) 안에서 유사한 특성을 가진 다른 응답자의 값을 가져와 대치한다.
② 콜드덱(cold-deck) 대치는 과거 조사나 외부 자료 등 다른 출처의 값을 가져와 대치한다.
③ 평균 대치법은 결측값을 평균으로 채우므로 자료의 분산이 실제보다 커지는 문제가 있다.
④ 확률적 회귀 대치는 회귀 예측값에 오차항을 더해 대치함으로써 단순 회귀 대치의 변동성 과소평가를 보완한다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 핫덱의 키워드 = "같은(현재) 조사 내부의 유사 응답자".
- ② 옳은 설명. 콜드덱의 키워드 = "외부·과거 자료". 출처가 안(핫)/밖(콜드)로 갈린다.
- ③ 평균 대치는 같은 값으로 채워 흩어짐이 줄어들므로 분산이 **과소추정**된다(작아짐). "커진다"는 정반대의 틀린 설명. ← 정답
- ④ 옳은 설명. 예측값 + 무작위 오차항으로 대치값의 변동성을 살리는 방식.

출제 포인트: 핫덱 = 조사 내부 / 콜드덱 = 외부·과거. 단순 대치(평균·회귀)의 공통 부작용 = 분산·변동성 과소추정 → 보완책이 확률적 회귀 대치와 다중 대치.

근거: 핫덱 대치는 동일한 조사 내에서 유사한 특성을 가진 응답자의 관측값으로 결측값을 대치하는 방법이고, 콜드덱 대치는 외부 출처나 과거 조사의 값으로 대치하는 방법이다.

2-2 분석 변수 처리

> 2과목 · 빅데이터 탐색 / 주요항목: 데이터 전처리 / 세부항목: 분석 변수 처리
> 문항 수: 14 (Q2-013 ~ Q2-026) · 난이도 하4/중7/상3 · 정답 분포 ①3 ②4 ③3 ④4

Q2-013 [난이도: 하] [태그: 2과목/데이터전처리/변수선택필터기법]

모델 학습 없이 상관계수, 카이제곱 통계량, 정보 이득(information gain) 등 통계적 측도만으로 변수의 유의성을 평가하여 선택하는 변수 선택 방식은?

① 래퍼(wrapper) 기법 ② 필터(filter) 기법 ③ 임베디드(embedded) 기법 ④ 배깅(bagging) 기법

✓ 정답 및 해설

정답: ②

- ① 래퍼: 변수의 부분집합마다 **모델을 반복 학습**하여 성능으로 평가(전진 선택·후진 제거·단계적). 통계적 측도만 쓰는 방식이 아님.
- ② 필터: 모델과 무관하게 **통계적 기준**(상관계수·카이제곱·정보 이득)으로 변수 평가. 계산 비용이 가장 낮음. ← 정답
- ③ 임베디드: 라쏘(LASSO)처럼 **모델 학습 과정 자체에 변수 선택이 내장**된 방식.
- ④ 배깅: 부트스트랩 표본으로 여러 모델을 만드는 앙상블 기법. 변수 선택 3방식과 무관.

출제 포인트: 변수 선택 3방식 = **필터(통계로 먼저 거름) / 래퍼(모델을 감싸서 반복 평가) / 임베디드(학습 안에 내장)**. "모델 학습 여부"와 "학습이 반복인가 내장인가"로 구분.

근거: 필터 기법은 모델 학습을 수반하지 않고 상관계수·카이제곱·정보 이득 등 통계적 측도만으로 변수와 목표변수의 관련성을 평가하여 변수를 선택하는 방식이다.

Q2-014 [난이도: 하] [태그: 2과목/데이터전처리/SMOTE]

불균형 데이터 처리에서, 소수 클래스의 관측치와 그 k-최근접 이웃(k-NN) 사이를 보간(interpolation)하여 실제로 존재하지 않던 새로운 합성(synthetic) 관측치를 생성하는 기법은?

① 랜덤 언더샘플링(random undersampling)
② 토멕 링크(Tomek Link)
③ SMOTE
④ 랜덤 오버샘플링(random oversampling)

✓ 정답 및 해설

정답: ③

- ① 랜덤 언더샘플링: **다수 클래스**를 무작위로 **제거**. 생성이 아니라 삭제.
- ② 토멕 링크: 서로 다른 클래스의 최근접 쌍을 찾아 **다수 클래스 쪽을 제거**하는 언더샘플링.
- ③ SMOTE: 소수 클래스 관측치와 이웃 사이를 **보간해 합성 데이터를 새로 생성**하는 오버샘플링. ← 정답
- ④ 랜덤 오버샘플링: 소수 클래스를 **단순 복제**. 새로운 값을 만들지 않아 과대적합(overfitting) 위험.

출제 포인트: SMOTE 정의의 3요소 = **소수 클래스 + k-최근접 이웃 + 보간 생성**. "복제"가 보이면 랜덤 오버샘플링, "합성·생성"이 보이면 SMOTE.

근거: SMOTE(Synthetic Minority Over-sampling TEchnique)는 소수 클래스 관측치와 그 k-최근접 이웃 사이의 직선상에서 새로운 합성 관측치를 생성하는 오버샘플링 기법이다.

Q2-015 [난이도: 하] [태그: 2과목/데이터전처리/민맥스정규화]

어떤 변수의 최솟값이 20, 최댓값이 100이다. 관측값 60을 민맥스 정규화(min-max normalization)한 값은?

① 0.5 ② 0.6 ③ 0.4 ④ 0.75

✓ 정답 및 해설

정답: ①

- ① (60−20)/(100−20) = 40/80 = **0.5**. ← 정답
- ② 0.6 = 60/100. 최솟값을 빼지 않고 최댓값으로만 나눈 오답.
- ③ 0.4 = 40/100. 분자만 (값−최소)로 계산하고 분모를 범위(최대−최소)가 아닌 최댓값으로 쓴 오답.
- ④ 0.75 = 60/80. 분모는 맞게 쓰고 분자에서 최솟값을 빼지 않은 오답.

출제 포인트: 민맥스 공식 = **(x − 최소) / (최대 − 최소)**, 결과 범위는 [0, 1]. 분자·분모 모두 "최솟값 빼기"가 들어가는 점이 함정 포인트.

근거: 민맥스 정규화는 (x−min)/(max−min) 공식으로 변수 값을 0과 1 사이 범위로 변환하는 스케일링 기법이다.

Q2-016 [난이도: 하] [태그: 2과목/데이터전처리/파생변수요약변수]

파생변수(derived variable)에 대한 설명으로 가장 적절한 것은?

① 여러 관측치를 합계·평균 등으로 집계한 변수로, 재활용성이 높다.
② 원본 변수를 다른 이름으로 그대로 복사해 저장한 변수다.
③ 누구에게나 의미가 같은 객관적 변수이므로 별도의 정당성 검토가 필요 없다.

④ 분석자가 특정 목적에 따라 조건·함수 등 논리적 가공으로 새로 정의한 변수로, 주관적일 수 있어 타당한 근거가 필요하다.

> **✓ 정답 및 해설**
>
> **정답:** ④
>
> - ① 집계(합계·평균) 중심 + 재활용성 높음 → **요약변수**의 특징.
> - ② 단순 복사는 새로운 의미를 부여하지 않으므로 파생변수가 아님.
> - ③ 객관적·범용적이라 재사용이 쉬운 것은 **요약변수**. 파생변수는 반대로 주관이 개입.
> - ④ 파생변수 = 분석자의 **특정 목적 + 논리적 가공 + 주관적 정의** → 세우려면 타당한 근거 필요. ← 정답
>
> **출제 포인트: 요약변수 = 집계·객관적·재활용 높음 / 파생변수 = 목적 지향·주관적·근거 필요**. "주관"이라는 단어가 붙는 쪽이 파생변수.
>
> **근거:** 파생변수는 분석자가 특정 분석 목적을 위해 기존 변수를 논리적으로 가공하여 새로 정의한 변수로, 주관적 판단이 개입되므로 생성 시 타당한 근거를 갖추어야 한다.

Q2-017 [난이도: 중] [태그: 2과목/데이터전처리/래퍼기법]

변수 선택의 래퍼(wrapper) 기법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 전진 선택법(forward selection)은 변수가 없는 모델에서 시작해 유의한 변수를 하나씩 추가한다.
② 래퍼 기법은 모델 학습 없이 통계적 측도만으로 변수를 평가하므로 계산 비용이 가장 낮다.
③ 후진 제거법(backward elimination)은 전체 변수를 포함한 모델에서 기여도가 낮은 변수를 하나씩 제거한다.
④ 단계적 방법(stepwise method)은 변수의 추가와 제거를 번갈아 반복하며 최적 조합을 탐색한다.

> **✓ 정답 및 해설**
>
> **정답:** ②
>
> - ① 옳은 설명. 전진 선택 = "빈 모델 → 하나씩 **추가**", 한번 추가된 변수는 제거하지 않는 것이 원칙.
> - ② 모델 학습 없이 통계적 측도만 쓰는 것은 **필터 기법**. 래퍼는 부분집합마다 **모델을 반복 학습**하므로 계산 비용이 오히려 큼. ← 정답
> - ③ 옳은 설명. 후진 제거 = "전체 모델 → 하나씩 **제거**".
> - ④ 옳은 설명. 단계적 방법 = 전진 선택 + 후진 제거의 결합(추가·제거 반복).
>
> **출제 포인트:** 래퍼 3형제 = **전진(추가만) / 후진(제거만) / 단계적(추가·제거 반복)**. 래퍼의 본질은 "모델 성능으로 평가 = 반복 학습 = 비용 큼, 성능 좋음".
>
> **근거:** 래퍼 기법은 변수의 부분집합마다 예측 모델을 반복적으로 학습·평가하여 최적의 변수 조합을 찾는 방식으로, 전진 선택법·후진 제거법·단계적 방법이 대표적이다.

Q2-018 [난이도: 중] [태그: 2과목/데이터전처리/임베디드기법]

변수 선택의 임베디드(embedded) 기법에 해당하는 것으로만 묶인 것은?

① 라쏘(LASSO), 릿지(Ridge), 엘라스틱넷(Elastic Net)
② 전진 선택법, 후진 제거법, 단계적 방법
③ 상관계수, 카이제곱 검정, 정보 이득
④ 주성분분석(PCA), 요인분석, 다차원척도법(MDS)

✓ 정답 및 해설

정답: ①

- ① 라쏘·릿지·엘라스틱넷은 규제(penalty)가 **모델 학습 과정 안에 내장**되어 학습과 동시에 계수 축소(라쏘·엘라스틱넷은 계수를 0으로 만드는 변수 선택까지)가 일어남 → 임베디드. ← 정답
- ② 모델을 반복 학습하며 변수 조합을 탐색 → **래퍼** 기법.
- ③ 모델 없이 통계적 측도로 평가 → **필터** 기법.
- ④ 기존 변수를 새로운 축으로 변환하는 **차원축소** 기법이지, 변수 선택 3방식의 분류가 아님.

출제 포인트: 임베디드 대표 3개 = **라쏘·릿지·엘라스틱넷**(규제 회귀). 의사결정나무 계열의 변수 중요도도 임베디드로 분류된다. "학습하면서 동시에 고른다"가 키워드.

근거: 임베디드 기법은 모델 학습 알고리즘 자체에 변수 선택 기능이 내장된 방식으로, L1·L2 규제를 사용하는 라쏘·릿지·엘라스틱넷이 대표적이다.

Q2-019 [난이도: 중] [태그: 2과목/데이터전처리/다차원척도법]

다차원척도법(MDS, Multidimensional Scaling)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 개체 간의 거리(근접성)를 계산하여 그 거리 구조를 최대한 보존하도록 개체들을 저차원 공간에 배치하는 차원축소 기법이다.
② 적합도는 스트레스(stress) 값으로 평가하며, 값이 0에 가까울수록 실제 거리 구조를 잘 보존한 것이다.
③ 수행하려면 목표변수(클래스) 정보가 반드시 필요하며, 클래스 간 분리가 최대가 되도록 개체를 배치한다.
④ 계량적(metric) MDS는 구간척도·비율척도 자료에, 비계량적(non-metric) MDS는 순서(서열)척도 자료에 적용한다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. MDS의 본질 = 개체 간 **거리(유사성·근접성) 보존** 배치.
- ② 옳은 설명. 스트레스는 실제 거리와 저차원 좌표상 거리의 불일치 정도로, **0에 가까울수록 적합이 좋다**.
- ③ 클래스 정보를 이용해 클래스 간 분리를 최대화하는 것은 **선형판별분석(LDA)**의 설명. MDS는 목표변수 없이 **개체 간 거리(근접성) 행렬만으로** 수행한다. ← 정답
- ④ 옳은 설명. 자료의 측정 척도 수준에 따라 계량적 MDS와 비계량적 MDS로 구분한다.

출제 포인트: MDS 3대 키워드 = **거리 보존 · 스트레스(0에 가까울수록 좋음) · 계량/비계량 구분**. 클래스 정보를 쓰는 LDA와 뒤섞는 선지가 함정 포인트.

근거: 다차원척도법(MDS)은 개체 간 거리(근접성) 정보를 저차원 공간에서 최대한 보존하도록 개체를 배치하는 차원축소 기법으로, 적합도는 스트레스 값으로 평가하며 목표변수 정보를 사용하지 않는다.

Q2-020 [난이도: 중] [태그: 2과목/데이터전처리/PCA]

주성분분석(PCA)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 데이터의 분산이 최대가 되는 방향의 축을 첫 번째 주성분으로 한다.
② 주성분들은 서로 직교(orthogonal)하여 상관관계가 없다.
③ 변수의 측정 단위(스케일)에 영향을 받으므로 표준화 후 수행하는 것이 일반적이다.
④ 클래스(목표변수) 정보를 활용하여 클래스 간 분리가 최대가 되는 축을 찾는 지도학습 기법이다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. 제1주성분 = 분산 최대 축, 제2주성분 = 그와 직교하는 축 중 분산 최대.
- ② 옳은 설명. 직교 변환이므로 주성분 간 상관 = 0.
- ③ 옳은 설명. 분산 기준이라 단위가 큰 변수가 주성분을 지배 → 표준화(또는 상관행렬 기반)가 일반적.
- ④ 클래스 분리 최대화는 **선형판별분석(LDA)**의 설명. PCA는 목표변수를 쓰지 않는 **비지도** 기법. ← 정답

출제 포인트: PCA = 분산 최대·직교·비지도 / LDA = 클래스 분리 최대·지도. 부정형에서 둘의 정의를 서로 바꿔 넣는 것이 단골 함정.

근거: 주성분분석(PCA)은 목표변수 없이 데이터의 분산을 최대한 보존하는 서로 직교하는 새로운 축(주성분)으로 변수를 변환하는 비지도 차원축소 기법이다.

Q2-021 [난이도: 중] [태그: 2과목/데이터전처리/LDA차원축소]

클래스(범주) 정보를 이용하여 클래스 간 분산은 최대화하고 클래스 내 분산은 최소화하는 축으로 데이터를 사영(projection)하는 차원축소 기법은?

① 주성분분석(PCA) ② 선형판별분석(LDA) ③ 다차원척도법(MDS) ④ 특이값분해(SVD)

✓ 정답 및 해설

정답: ②

- ① PCA: 클래스 정보 없이 **전체 분산 최대** 축을 찾는 비지도 기법.
- ② LDA: 클래스 레이블을 사용해 **클래스 간 분산/클래스 내 분산 비를 최대화**하는 지도 기법. ← 정답
- ③ MDS: 개체 간 **거리(근접성)를 보존**하면서 저차원 공간에 배치하는 기법. 클래스 분리와 무관.
- ④ SVD: 임의의 행렬을 세 행렬의 곱($U\Sigma V^T$)으로 **분해**하는 기법. 클래스 정보를 쓰지 않음.

출제 포인트: 차원축소 매칭 = **분산 최대 → PCA / 클래스 분리 → LDA / 거리 보존 → MDS / 행렬 분해 → SVD / 잠재요인 → 요인분석**. 문제 지문의 키워드 하나로 즉답.

근거: 선형판별분석(LDA)은 클래스 간 분산을 최대화하고 클래스 내 분산을 최소화하는 판별 축으로 데이터를 사영하는 지도학습 기반 차원축소 기법이다.

Q2-022 [난이도: 중] [태그: 2과목/데이터전처리/로그변환]

소득 데이터가 오른쪽으로 길게 치우친(양의 왜도) 분포를 보인다. 이를 정규분포에 가깝게 만들기 위한 변수 변환으로 가장 적절한 것은?

① 로그 변환(log transformation)
② 민맥스 정규화(min-max normalization)
③ 제곱 변환(square transformation)
④ 원-핫 인코딩(one-hot encoding)

✓ 정답 및 해설

정답: ①

- ① 로그 변환: 큰 값을 강하게 눌러 **오른쪽 꼬리(양의 왜도)를 줄이고** 정규성에 가깝게 만듦. ← 정답
- ② 민맥스: 값의 **범위만 [0,1]로 축소**할 뿐 분포의 모양(왜도)은 그대로 유지 → 정규성 개선 효과 없음.
- ③ 제곱 변환: 큰 값을 더 키우므로 **왼쪽으로 치우친(음의 왜도)** 분포에 쓰는 변환. 방향 반대.
- ④ 원-핫 인코딩: **범주형** 변수를 0/1 더미로 바꾸는 인코딩. 연속형 분포 교정과 무관.

출제 포인트: 양의 왜도(오른쪽 꼬리) → 로그·제곱근 변환 / 음의 왜도(왼쪽 꼬리) → 제곱 변환. 박스콕스(Box-Cox) 변환은 로그·거듭제곱을 포괄하여 정규성을 높이는 일반화된 변환. **정규성 계열(로그·박스콕스) vs 스케일링 계열(민맥스·표준화)**을 구분할 것.

근거: 로그 변환은 오른쪽으로 치우친 분포의 큰 값을 압축하여 왜도를 줄이고 데이터의 정규성을 개선하는 변수 변환 기법이다.

Q2-023 [난이도: 중] [태그: 2과목/데이터전처리/불균형데이터]

불균형 데이터(imbalanced data) 처리에 대한 설명으로 옳지 **않은** 것은?

① 언더샘플링은 다수 클래스의 관측치를 줄여 균형을 맞추므로 유용한 정보가 손실될 수 있다.
② 클래스 가중치(class weight)는 데이터 수를 바꾸지 않고 학습 시 소수 클래스의 오분류에 더 큰 벌점을 부여하는 방법이다.
③ 랜덤 오버샘플링은 소수 클래스를 단순 복제하므로 과대적합(overfitting) 위험이 있다.
④ 오버샘플링은 다수 클래스의 관측치를 복제하여 전체 데이터 크기를 늘리는 방법이다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. 언더샘플링의 대가 = **정보 손실**.
- ② 옳은 설명. 클래스 가중치는 **데이터를 늘리거나 줄이지 않고** 손실 함수에서 소수 클래스 오류의 비중을 키움.
- ③ 옳은 설명. 랜덤 오버샘플링의 대가 = 같은 관측치 반복 학습에 의한 **과대적합**.
- ④ 오버샘플링이 늘리는 대상은 **소수 클래스**다. 다수 클래스를 복제하면 불균형이 더 심해짐. ← 정답

출제 포인트: 언더 = 다수를 줄임(정보 손실) / 오버 = 소수를 늘림(과대적합) / 가중치 = 데이터 그대로, 벌점만 조정. "무엇을 늘리고 줄이는가"를 바꿔치기하는 선지가 단골.

근거: 오버샘플링은 소수 클래스의 관측치를 복제하거나 합성하여 늘리는 방법이고, 언더샘플링은 다수 클래스의 관측치를 줄이는 방법이며, 클래스 가중치는 데이터 수 변경 없이 손실 함수에서 소수 클래스 오류에 더 큰 가중을 두는 방법이다.

Q2-024 [난이도: 상] [태그: 2과목/데이터전처리/PCA요인분석]

주성분분석(PCA)과 요인분석(factor analysis)의 비교로 옳지 **않은** 것은?

① 두 기법 모두 여러 변수를 소수의 새로운 변수로 축약하는 데 활용된다.
② 요인분석은 관측된 변수들 이면에 있는 잠재요인(latent factor)을 찾아내는 것이 목적이다.
③ 주성분분석에서 생성된 주성분들은 서로 대등하여 중요도의 순서가 없다.
④ 주성분은 원래 변수들의 선형 결합(linear combination)으로 표현된다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 둘 다 데이터 축약(차원축소)이라는 공통 목적을 가짐.
- ② 옳은 설명. 요인분석의 본질 = 변수들 뒤에 숨은 **잠재요인** 규명.
- ③ 주성분은 **제1주성분(분산 최대) → 제2주성분 → …** 순으로 설명력의 **순서(위계)가 있음**. 생성된 변수들이 서로 대등한 것은 **요인분석의 요인**이다. ← 정답
- ④ 옳은 설명. 주성분 = 원 변수들의 가중 선형 결합.

출제 포인트: 함정 비교 — **PCA: 주성분에 중요도 순서 있음(제1·제2…) / 요인분석: 요인들은 대등, 잠재요인이 목적**. "순서 유무"와 "잠재요인 유무"를 서로 바꿔 넣는 것이 전형적 함정.

근거: 주성분분석은 분산 설명력이 큰 순서대로 제1주성분, 제2주성분 등 위계가 있는 새 변수를 만들고, 요인분석은 서로 대등한 잠재요인으로 변수들을 축약한다는 점에서 구분된다.

Q2-025 [난이도: 상] [태그: 2과목/데이터전처리/TomekLink]

서로 다른 클래스에 속한 두 관측치가 서로에게 가장 가까운 이웃이 되는 쌍을 찾아, 그중 다수 클래스의 관측치를 제거함으로써 클래스 간 경계를 정리하는 언더샘플링 기법은?

① ENN(Edited Nearest Neighbours)
② 토멕 링크(Tomek Link)
③ SMOTE
④ 랜덤 오버샘플링(random oversampling)

✓ 정답 및 해설

정답: ②

- ① ENN: 자신의 k-최근접 이웃 다수의 클래스와 **자신의 클래스가 다른** 관측치를 잡음으로 보고 제거. "서로 최근접인 쌍"이 아니라 "이웃 다수결"이 기준.
- ② 토멕 링크: **서로 다른 클래스 + 상호 최근접 쌍**(링크)을 찾아 다수 클래스 쪽을 제거 → 경계가 명확해짐. ← 정답
- ③ SMOTE: 소수 클래스를 보간으로 **생성**하는 오버샘플링. 제거 기법이 아님.
- ④ 랜덤 오버샘플링: 소수 클래스 **복제**. 언더샘플링이 아님.

출제 포인트: 언더샘플링 정밀 기법 구분 = **토멕 링크: "서로 최근접인 이질 쌍" 제거 / ENN: "이웃 다수결과 어긋나는 관측치" 제거**. 둘 다 경계·잡음 정리가 목적이며 SMOTE와 결합(SMOTE+Tomek, SMOTE+ENN)해 쓰기도 한다.

근거: 토멕 링크(Tomek Link)는 서로 다른 클래스에 속하면서 상호 최근접 이웃인 관측치 쌍을 찾아 다수 클래스 관측치를 제거하는 언더샘플링 기법이다.

Q2-026 [난이도: 상] [태그: 2과목/데이터전처리/변수처리종합]

분석 변수 처리에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 원-핫 인코딩(one-hot encoding)은 범주마다 0/1의 이진 변수를 생성하여 명목형 변수를 수치화하며, 범주 수가 많으면 변수(차원)의 수가 크게 늘어난다.
- ㄴ. 레이블 인코딩(label encoding)은 각 범주에 정수를 부여하는 방식으로, 명목형 범주 사이에 실제로는 존재하지 않는 크기(순서) 관계가 생길 수 있다.
- ㄷ. 차원의 저주(curse of dimensionality)는 변수(차원)가 늘어날수록 데이터가 공간에 희소(sparse)해져 분석 성능이 저하되는 현상으로, 차원축소나 변수 선택으로 완화할 수 있다.
- ㄹ. 연속형 변수를 구간화(binning)하여 범주형으로 변환하면 정보의 손실은 전혀 발생하지 않는다.

① ㄱ, ㄷ, ㄹ ② ㄴ, ㄹ ③ ㄱ, ㄴ, ㄹ ④ ㄱ, ㄴ, ㄷ

✓ 정답 및 해설

정답: ④

- **ㄱ (O)** 원-핫 인코딩은 범주 하나당 이진 변수 하나를 만들므로 범주 수만큼 차원이 증가한다. 범주가 매우 많으면 차원 증가가 부담이 된다.
- **ㄴ (O)** 레이블 인코딩은 예컨대 서울=0, 부산=1, 대구=2처럼 정수를 부여하므로, 순서가 없는 명목형 범주에 **허구적인 크기·순서 관계**가 생길 수 있다.
- **ㄷ (O)** 차원이 늘수록 같은 수의 관측치가 훨씬 넓은 공간에 흩어져 희소해지고 학습이 어려워짐 → 차원축소(PCA 등)·변수 선택이 처방.
- **ㄹ (X)** 구간화하면 **구간 내 개별 값들의 차이가 사라지므로 정보 손실이 발생**한다. 대신 이상값의 영향 완화·해석 용이라는 이점을 얻는 상충(trade-off) 관계다.

따라서 옳은 것은 ㄱ, ㄴ, ㄷ → **④**. (①·②·③은 모두 틀린 ㄹ을 포함하며, ②는 옳은 ㄱ·ㄷ, ③은 옳은 ㄷ을 누락)

출제 포인트: 인코딩 비교 — **원-핫 = 이진 변수·차원 증가 / 레이블 = 정수 부여·허구적 순서 위험**. 여기에 **차원의 저주(희소화 → 차원축소로 완화)**와 **구간화의 상충 관계(정보 손실 ↔ 이상값 완화)**를 세트로 정리.

근거: 원-핫 인코딩은 범주형 변수의 각 범주를 0과 1의 이진 변수로 변환하여 범주 수만큼 차원이 증가하는 인코딩 기법이며, 연속형 변수의 구간화는 구간 내 세부 정보의 손실을 수반한다.

2-3 데이터 탐색 기초

> 2과목 · 빅데이터 탐색 / 주요항목: 데이터 탐색
> 문항 수: 10 (Q2-027 ~ Q2-036) · 난이도 하3/중5/상2 · 정답 분포 ①3 ②2 ③3 ④2

Q2-027 [난이도: 하] [태그: 2과목/데이터탐색/EDA4원칙]

탐색적 데이터 분석(EDA)의 4가지 주제(원칙)에 해당하지 **않는** 것은?

① 저항성(resistance) ② 잔차 해석(residual) ③ 재표현(re-expression) ④ 정규성(normality)

✓ 정답 및 해설

정답: ④

- ① 저항성: 이상값·오류에 크게 흔들리지 않는 성질. 저항성 있는 통계량(중앙값 등)을 활용 → 4원칙에 포함.
- ② 잔차 해석: 주 경향(적합값)에서 벗어난 잔차를 검토해 특이점·구조를 발견 → 4원칙에 포함.
- ③ 재표현: 로그·제곱근 등 척도 변환으로 분포를 대칭화하고 해석을 단순화 → 4원칙에 포함.
- ④ 정규성: 자료가 정규분포를 따르는지의 성질로, EDA 4원칙이 아니라 **통계적 가정 검토(정규성 검정)**의 개념. ← 정답

출제 포인트: EDA 4원칙 = **저항성 · 잔차 해석 · 재표현 · 현시성(그래프 표현)**. "저·잔·재·현"으로 암기. 현시성을 빼고 엉뚱한 용어(정규성·독립성 등)를 끼워 넣는 선지가 단골.

근거: EDA의 4가지 주제는 저항성(resistance), 잔차 해석(residual), 재표현(re-expression), 현시성(representation, 그래프를 통한 시각적 표현)이다.

Q2-028 [난이도: 하] [태그: 2과목/데이터탐색/중심경향치]

자료에 극단적인 이상값(outlier)이 포함될 때 그 값의 영향을 가장 크게 받는(민감한) 중심 경향치는?

① 평균(mean) ② 중앙값(median) ③ 최빈값(mode) ④ 절사평균(trimmed mean)

✓ 정답 및 해설

정답: ①

- ① 평균: 모든 관측값을 더해 나누므로 극단값 하나에도 크게 끌려간다 → 이상값에 가장 민감. ← 정답
- ② 중앙값: 크기 순서상 가운데 위치만 보므로 극단값이 커져도 거의 변하지 않음(저항성 큼).
- ③ 최빈값: 가장 자주 나타나는 값이므로 극단값 소수에 영향받지 않음.
- ④ 절사평균: 양 극단 일정 비율을 잘라내고 평균을 내므로 이상값의 영향이 줄어듦.

출제 포인트: 이상값 민감도 — **평균은 민감, 중앙값·최빈값·절사평균은 저항성 있음**. EDA의 저항성 원칙과 연결해 "이상값 있으면 중앙값 사용"으로 암기.

근거: 평균은 모든 관측값의 합을 관측값 개수로 나눈 중심 경향치로, 계산에 모든 값이 반영되어 이상값에 민감하다.

Q2-029 [난이도: 하] [태그: 2과목/데이터탐색/박스플롯]

박스플롯(box plot)을 통해 직접 확인할 수 **없는** 것은?

① 중앙값 ② 사분위범위(IQR) ③ 최빈값 ④ 이상값

✓ 정답 및 해설

정답: ③

- ① 상자 내부의 선이 중앙값(제2사분위수) → 확인 가능.
- ② 상자의 길이 자체가 Q3−Q1, 즉 사분위범위 → 확인 가능.
- ③ 최빈값은 값의 빈도 정보가 필요한데 박스플롯은 위치(분위수) 요약만 제공 → 확인 불가. ← 정답
- ④ 수염(whisker) 바깥의 점으로 이상값을 표시 → 확인 가능.

출제 포인트: 박스플롯 구성 = **최솟값·Q1·중앙값·Q3·최댓값(5수 요약) + 이상값 점**. 빈도 기반 통계량(최빈값)과 분포 모양의 봉우리는 박스플롯으로 알 수 없다 → 히스토그램의 역할.

근거: 박스플롯은 최솟값, 제1사분위수, 중앙값, 제3사분위수, 최댓값의 다섯 수치 요약과 이상값을 상자와 수염으로 시각화하는 그래프다.

Q2-030 [난이도: 중] [태그: 2과목/데이터탐색/간단계산]

자료 3, 4, 5, 6, 22 에 대한 설명으로 옳은 것은?

① 평균과 중앙값은 모두 5이다.
② 평균은 8, 중앙값은 5로 평균이 중앙값보다 크다.
③ 평균은 5, 중앙값은 8로 중앙값이 평균보다 크다.
④ 극단값 22를 제거해도 평균은 변하지 않는다.

✓ 정답 및 해설

정답: ②

- 중앙값: 크기순 정렬 시 3번째 값 = **5**. 평균: (3+4+5+6+22)/5 = 40/5 = **8**.
- ① 중앙값은 5가 맞지만 평균은 8이므로 틀림.
- ② 극단값 22가 평균을 끌어올려 평균(8) > 중앙값(5). ← 정답
- ③ 평균과 중앙값의 값을 서로 바꿔 쓴 함정.
- ④ 22 제거 시 평균 = (3+4+5+6)/4 = 4.5로 크게 변한다. 평균은 이상값에 민감.

출제 포인트: 큰 극단값이 있으면 **평균 > 중앙값**(오른쪽 꼬리, 양의 왜도 방향). 중앙값은 극단값 제거 전후 거의 불변.

근거: 중앙값은 자료를 크기순으로 정렬했을 때 가운데에 위치하는 값이고, 평균은 전체 합을 개수로 나눈 값이어서 극단값의 영향은 평균에만 크게 나타난다.

Q2-031 [난이도: 중] [태그: 2과목/데이터탐색/왜도]

오른쪽으로 긴 꼬리를 갖는 양의 왜도(positive skewness) 분포에서 중심 경향치의 크기 순서로 옳은 것은?

① 평균 > 중앙값 > 최빈값
② 최빈값 > 중앙값 > 평균
③ 평균 > 최빈값 > 중앙값
④ 중앙값 > 평균 > 최빈값

✓ 정답 및 해설

정답: ①

- ① 양의 왜도: 오른쪽 꼬리의 큰 값들이 평균을 꼬리 방향으로 끌어당김 → **평균 > 중앙값 > 최빈값**. ← 정답
- ② 이는 왼쪽 꼬리 분포, 즉 **음의 왜도**에서의 순서(최빈값 > 중앙값 > 평균).
- ③ 일반적으로 중앙값은 평균과 최빈값 사이에 위치하므로 성립하지 않는 순서.
- ④ 중앙값이 평균보다 커지는 것은 음의 왜도 쪽 특징이며, 순서 자체도 성립하지 않음.

출제 포인트: 평균은 꼬리 쪽으로, 최빈값은 봉우리에, 중앙값은 그 사이. 양의 왜도(왜도>0, 오른쪽 꼬리) = 평균>중앙값>최빈값, 음의 왜도는 정확히 반대. 좌우대칭(왜도=0)이면 셋이 일치.

근거: 왜도는 분포의 비대칭 정도를 나타내는 통계량으로, 양의 왜도 분포에서는 꼬리 방향으로 끌려간 평균이 가장 크고 최빈값이 가장 작아 평균>중앙값>최빈값 순서가 된다.

Q2-032 [난이도: 중] [태그: 2과목/데이터탐색/변동계수]

측정 단위가 서로 다른 두 자료가 있다. A는 평균 100, 표준편차 20이고 B는 평균 50, 표준편차 5이다. 두 자료의 산포를 비교한 설명으로 옳은 것은?

① 표준편차가 큰 A와 B의 산포 비교는 분산 값만 비교하면 충분하다.
② B의 변동계수는 0.2이다.
③ A의 변동계수는 0.2로 B(0.1)보다 커서 A의 상대적 산포가 더 크다.
④ 측정 단위가 다른 자료끼리는 산포를 비교할 방법이 없다.

✓ 정답 및 해설

정답: ③

- 변동계수(CV) = 표준편차 ÷ 평균. A = 20/100 = **0.2**, B = 5/50 = **0.1**.
- ① 분산·표준편차는 측정 단위에 의존하므로 단위가 다른 자료의 비교 기준이 될 수 없음.
- ② B의 변동계수는 5/50 = 0.1. 0.2는 A의 값.
- ③ CV가 큰 A의 상대적 산포가 더 크다. ← 정답
- ④ 단위가 달라도 **변동계수(무단위 상대 산포)** 로 비교 가능하므로 틀림.

출제 포인트: 변동계수 = 표준편차/평균 (단위 없는 상대 산포). "단위가 다르다" 또는 "평균 크기가 크게 다르다"가 보이면 무조건 변동계수. 분산은 편차 제곱의 평균, 표준편차는 분산의 양의 제곱근.

근거: 변동계수(coefficient of variation)는 표준편차를 평균으로 나눈 값으로, 측정 단위나 평균 수준이 다른 자료 간 상대적 산포를 비교하는 지표다.

Q2-033 [난이도: 중] [태그: 2과목/데이터탐색/상관분석]

상관분석에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 피어슨(Pearson) 상관계수는 연속형 자료 간 선형 관계의 정도를 측정한다.
② 스피어만(Spearman) 상관계수는 두 변수가 정규분포를 따르는 연속형 자료일 때만 사용할 수 있다.
③ 스피어만 상관계수는 자료를 순위로 변환해 계산하므로 이상값의 영향을 덜 받는다.
④ 상관계수는 −1 이상 +1 이하의 값을 갖는다.

✓ 정답 및 해설

정답: ②

- ① 옳은 설명. 피어슨은 두 연속형 변수의 **선형** 관계 강도·방향을 측정.
- ② 스피어만은 **순위(서열) 기반 비모수** 상관계수로 정규성 가정이 필요 없고 서열 자료·비선형 단조 관계에도 사용 가능. "정규분포 연속형만"은 피어슨 쪽 조건을 뒤집어 놓은 함정. ← 정답
- ③ 옳은 설명. 원값 대신 순위를 쓰므로 극단값에 저항성이 있다.
- ④ 옳은 설명. 피어슨·스피어만 모두 −1 ~ +1 범위.

출제 포인트: 피어슨 = 연속형·선형·모수적 / 스피어만 = 순위·단조(비선형 가능)·비모수. "서열 자료", "이상값 많음", "비선형 단조"가 보이면 스피어만.

근거: 스피어만 상관계수는 두 변수의 값을 순위로 변환한 뒤 순위 간 상관을 구하는 비모수적 상관계수로, 정규성 가정 없이 단조 관계를 측정한다.

Q2-034 [난이도: 중] [태그: 2과목/데이터탐색/크론바흐알파]

설문지의 여러 문항이 동일한 개념을 일관되게 측정하고 있는지, 즉 측정 도구의 내적 일관성(신뢰도)을 평가하는 데 사용하는 계수는?

① 피어슨 상관계수 ② 결정계수 ③ 크론바흐 알파(Cronbach's α) ④ 코헨의 카파(Cohen's κ)

✓ 정답 및 해설

정답: ③

- ① 피어슨 상관계수: 두 변수 간 선형 관계의 측정. 문항 묶음의 일관성 지표가 아님.
- ② 결정계수(R^2): 회귀모형이 종속변수 변동을 설명하는 비율. 신뢰도와 무관.
- ③ 크론바흐 알파: 여러 문항 간 일관성으로 측정 도구의 **신뢰도(내적 일관성)** 를 평가. 통상 0과 1 사이의 값을 가지며 높을수록 신뢰도가 높다. ← 정답
- ④ 코헨의 카파: 두 평가자 간 **판정 일치도**를 우연 일치를 보정해 측정하는 계수. 문항 일관성이 아님.

출제 포인트: 신뢰도(일관성) = 크론바흐 알파, 평가자 일치도 = 카파, 설명력 = 결정계수. 통상 0.7 이상이면 신뢰도가 수용 가능한 수준으로 본다. ※ 교재별 표기 차이 있음 — 수용 기준을 0.6 또는 0.7로 제시하는 등 교재마다 다름.

근거: 크론바흐 알파는 하나의 개념을 측정하는 여러 문항 간의 내적 일관성을 0과 1 사이 값으로 나타내는 신뢰도 계수다.

Q2-035 [난이도: 상] [태그: 2과목/데이터탐색/IQR이상값]

어떤 자료의 제1사분위수(Q1)가 10, 제3사분위수(Q3)가 30이다. 사분위범위(IQR)를 이용한 판정 기준(1.5×IQR)에 따를 때 이상값으로 판정되는 관측값은?

① 55 ② −10 ③ 0 ④ 65

> **✓ 정답 및 해설**
>
> **정답: ④**
>
> - IQR = Q3 − Q1 = 30 − 10 = **20**. 하한 = Q1 − 1.5×IQR = 10 − 30 = **−20**. 상한 = Q3 + 1.5×IQR = 30 + 30 = **60**.
> - ① 55 ≤ 60 → 정상 범위.
> - ② −10 ≥ −20 → 정상 범위(음수라고 무조건 이상값이 아님을 노린 함정).
> - ③ 0 ≥ −20 → 정상 범위.
> - ④ 65 > 상한 60 → 이상값. ← 정답
>
> **출제 포인트:** 이상값 판정 공식 = **[Q1 − 1.5×IQR, Q3 + 1.5×IQR] 범위 밖**. 계산 순서: IQR → 1.5배 → Q1에서 빼고 Q3에 더하기. 박스플롯 수염의 한계와 같은 기준.
>
> **근거:** 사분위범위(IQR)는 Q3에서 Q1을 뺀 값이며, Q1−1.5×IQR 미만이거나 Q3+1.5×IQR 초과인 관측값을 이상값으로 판정한다.

Q2-036 [난이도: 상] [태그: 2과목/데이터탐색/종합]

데이터 탐색에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 줄기-잎 그림(stem-and-leaf plot)은 분포의 전체적인 모양을 보여주면서 개별 관측값의 정보도 함께 유지하는 탐색 도구다.
- ㄴ. 히스토그램(histogram)은 연속형 자료를 구간으로 나누어 도수를 막대로 표현하며, 막대 사이에 간격을 두는 막대그래프(bar chart)와 달리 막대를 붙여 그린다.
- ㄷ. 범위(range)는 최댓값에서 최솟값을 뺀 값으로, 두 극단값만으로 계산되므로 이상값에 민감하다.
- ㄹ. 두 범주형 변수 간의 관계를 탐색할 때는 산점도(scatter plot)가 가장 적절한 도구다.

① ㄱ, ㄴ, ㄷ ② ㄱ, ㄷ, ㄹ ③ ㄴ, ㄹ ④ ㄱ, ㄴ, ㄷ, ㄹ

✓ 정답 및 해설

정답: ①

- **ㄱ (O)** 줄기-잎 그림은 자릿수를 줄기, 나머지를 잎으로 정리해 분포 모양과 **원래 관측값** 정보를 동시에 보존한다.
- **ㄴ (O)** 히스토그램 = **연속형·구간·막대 붙임** / 막대그래프 = **범주형·막대 사이 간격**. 두 그래프 구분의 핵심.
- **ㄷ (O)** 범위 = 최댓값 − 최솟값. 극단값 두 개만 사용하므로 이상값 하나에도 크게 변한다(저항성 없음).
- **ㄹ (X)** 산점도는 **연속형 두 변수**의 관계 탐색 도구. 범주형 두 변수의 관계는 **교차표(분할표, contingency table)**나 모자이크 플롯 등으로 탐색한다. 함정 선지.

따라서 옳은 것은 ㄱ, ㄴ, ㄷ → **①**. (②·③·④는 모두 틀린 ㄹ을 포함하며, ②는 옳은 ㄴ, ③은 옳은 ㄱ·ㄷ을 누락)

출제 포인트: 자료 유형별 탐색 도구 매칭 — **연속형 분포 = 히스토그램·줄기-잎 그림 / 연속형×연속형 = 산점도 / 범주형×범주형 = 교차표·모자이크 플롯**. 도구와 자료 유형을 바꿔치기하는 선지가 단골 함정.

근거: 산점도는 두 연속형 변수 간 관계를 좌표평면 위의 점으로 표현하는 도구이며, 범주형 변수 간의 관계 탐색에는 범주 조합별 빈도를 정리한 교차표(분할표)를 사용한다.

2-4 고급 데이터 탐색

> 2과목 · 빅데이터 탐색 / 주요항목: 데이터 탐색
> 범위: 시공간 데이터 탐색(공간 시각화 연계), 다변량 데이터 탐색(산점도 행렬·상관행렬), 비정형 데이터 탐색(텍스트·이미지·오디오)
> 문항 수: 4 (Q2-037 ~ Q2-040) · 난이도 하1/중2/상1 · 정답 분포 ①1 ②1 ③1 ④1

Q2-037 [난이도: 하] [태그: 2과목/데이터탐색/시공간데이터탐색]

행정구역 같은 지역 단위별 통계 수치를 지도 위에 색상의 농도(음영 단계)로 구분하여 표현하는 공간 시각화 기법은?

① 카토그램(cartogram)
② 코로플레스맵(choropleth map)
③ 버블맵(bubble map)
④ 산점도 행렬(scatter plot matrix)

✓ 정답 및 해설

정답: ②

- ① 카토그램: 통계값의 크기에 **비례하여 지역의 면적 자체를 왜곡·변형**해 그리는 지도. 색 농도 구분이 핵심이 아님.
- ② 코로플레스맵(단계구분도): 지역별 수치를 **색상 농도·음영 단계**로 표현하는 대표적 공간 시각화. ← 정답
- ③ 버블맵: 지도 위 해당 위치에 **원(버블)의 크기**로 수치를 표현. 색 단계 구분 방식이 아님.
- ④ 산점도 행렬: 다변량 변수 쌍들의 산점도를 행렬로 배열한 것. 지도 기반 시각화가 아님.

출제 포인트: 공간 시각화 구분 — "색 농도=코로플레스맵, 면적 변형=카토그램, 원 크기=버블맵". 시공간 데이터 탐색은 지도 시각화와 연계해 출제된다.

근거: 코로플레스맵(choropleth map)은 지역 단위로 집계된 통계값을 지도의 색상 농도나 음영 단계로 구분하여 표현하는 공간 시각화 기법이다.

Q2-038 [난이도: 중] [태그: 2과목/데이터탐색/다변량데이터탐색]

다변량 데이터 탐색에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 산점도 행렬(scatter plot matrix)은 여러 변수 쌍의 산점도를 행렬 형태로 배열하여 변수 간 관계를 한눈에 파악하게 한다.
② 상관행렬(correlation matrix)의 대각원소는 모두 1이며, 상관행렬은 대칭행렬이다.
③ 두 변수의 상관계수가 0이면 두 변수는 반드시 서로 독립이다.
④ 변수가 3개일 때 서로 다른 변수 쌍의 수는 3개이므로 산점도 행렬에는 3종류의 변수 쌍 산점도가 나타난다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 산점도 행렬은 다변량 자료의 변수 쌍별 관계를 격자 형태로 동시에 보여준다.
- ② 옳은 설명. 자기 자신과의 상관은 1(대각원소), corr(X,Y)=corr(Y,X)이므로 대칭.
- ③ 상관계수 0은 **선형 관계가 없다**는 뜻일 뿐, 곡선(비선형) 관계는 존재할 수 있으므로 독립을 보장하지 않는다. ← 정답
- ④ 옳은 설명. 변수 p개의 서로 다른 쌍 = p(p−1)/2개. p=3이면 3×2/2 = 3쌍.

출제 포인트: "상관 0 = 무상관(선형 관계 없음) ≠ 독립"은 단골 함정. 방향은 "독립이면 상관 0"만 성립. 변수 쌍 개수 공식 p(p−1)/2도 함께 암기.

근거: 상관계수는 두 변수 간 선형 관계의 방향과 강도를 −1~1로 나타내는 척도로, 값이 0이면 선형 관계가 없음을 의미할 뿐 두 변수의 독립을 보장하지는 않는다.

Q2-039 [난이도: 중] [태그: 2과목/데이터탐색/비정형데이터탐색]

비정형 데이터 유형별 탐색 방법에 대한 설명으로 옳은 것은?

① 이미지 데이터는 형태소 분석(morphological analysis)으로 품사 단위로 분해하여 탐색한다.
② 오디오 데이터는 픽셀(pixel) 값의 행렬로 표현하여 밝기 분포를 탐색한다.
③ 텍스트 데이터는 스펙트로그램(spectrogram)으로 변환하여 주파수 성분을 탐색한다.
④ 텍스트 데이터는 토큰화·형태소 분석을 거쳐 단어 빈도를 집계하고 워드클라우드 등으로 탐색한다.

✓ 정답 및 해설

정답: ④

- ① 형태소 분석은 **텍스트** 데이터의 탐색 방법. 이미지는 픽셀 값 행렬·색상 채널·히스토그램으로 탐색한다.
- ② 픽셀 값 행렬은 **이미지** 데이터의 표현 방식. 오디오는 파형(waveform)·스펙트로그램 등으로 탐색한다.
- ③ 스펙트로그램은 **오디오** 데이터의 시간-주파수 표현. 텍스트 탐색 방법이 아니다.
- ④ 텍스트 탐색의 정석: 토큰화 → 형태소 분석·품사 태깅 → 단어 빈도 집계 → 워드클라우드 등 시각화. ← 정답

출제 포인트: 유형-방법 짝 암기 — "텍스트=형태소·단어 빈도·워드클라우드 / 이미지=픽셀·채널·히스토그램 / 오디오=파형·스펙트로그램". 부정형·매칭형에서 짝을 서로 바꿔치기하는 선지가 단골.

근거: 비정형 데이터 탐색은 유형별로 다른 표현을 사용하며, 텍스트는 토큰화와 형태소 분석 후 단어 빈도 기반으로, 이미지는 픽셀 값 행렬로, 오디오는 파형·스펙트로그램으로 데이터를 표현하여 탐색한다.

Q2-040 [난이도: 상] [태그: 2과목/데이터탐색/다변량데이터탐색]

고급 데이터 탐색에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 코로플레스맵(choropleth map)은 면적이 넓은 지역이 실제 값보다 과대하게 인식될 수 있으며, 카토그램(cartogram)은 통계값에 비례해 지역 면적을 변형하여 이를 보완한다.
- ㄴ. 상관행렬을 히트맵(heatmap)으로 시각화하면 다변량 변수 간 상관 구조를 한눈에 파악할 수 있다.
- ㄷ. 산점도 행렬은 변수 쌍 간의 선형·비선형 관계와 이상값(outlier)을 시각적으로 탐색하는 데 활용된다.
- ㄹ. 두 변수의 상관계수 절댓값이 크면 두 변수 사이에 인과관계(causality)가 있다고 결론지을 수 있다.

① ㄱ, ㄴ, ㄷ ② ㄱ, ㄴ, ㄹ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄷ, ㄹ

✓ 정답 및 해설

정답: ①

- **ㄱ (O)** 코로플레스맵의 한계 = 면적이 큰 지역의 과대 인식. 카토그램은 값에 비례해 면적을 왜곡시켜 이를 보완한다.
- **ㄴ (O)** 상관행렬 + 히트맵(색 농도) 조합은 다변량 상관 구조 탐색의 대표 기법.
- **ㄷ (O)** 산점도 행렬은 관계의 형태(직선·곡선)와 이상값까지 시각적으로 드러낸다.
- **ㄹ (X)** 상관관계는 인과관계를 의미하지 않는다(상관 ≠ 인과). 제3의 변수에 의한 허위 상관일 수 있다.

따라서 옳은 것은 ㄱ, ㄴ, ㄷ → **①**. (②·③·④는 모두 틀린 ㄹ을 포함)

출제 포인트: 두 가지 함정을 한 번에 — 공간 시각화에서 "코로플레스맵의 면적 왜곡 ↔ 카토그램 보완", 다변량 탐색에서 "상관 ≠ 인과". 조합형에서는 확실히 틀린 보기(ㄹ)를 먼저 지우면 선지가 즉시 좁혀진다.

근거: 카토그램(cartogram)은 지역의 면적을 통계값에 비례하도록 변형해 그리는 지도로, 면적 차이에 따른 코로플레스맵의 왜곡을 보완하는 공간 시각화 기법이다.

2-5 기술통계

> 2과목 · 탐색적 데이터 분석 / 주요항목: 통계기법 이해
> 범위: 척도의 종류, 표본추출 방법, 확률(조건부 확률·베이즈 정리), 이산·연속확률분포, 중심극한정리
> 문항 수: 12 (Q2-041 ~ Q2-052) · 난이도 하4/중6/상2 · 정답 분포 ①3 ②3 ③3 ④3

Q2-041 [난이도: 하] [태그: 2과목/통계기법이해/척도]

측정 대상 간의 순위(서열)는 의미가 있지만, 값 사이의 간격은 일정하지 않아 의미가 없는 척도는?

① 명목척도(nominal scale)
② 순서척도(ordinal scale)
③ 구간척도(interval scale)
④ 비율척도(ratio scale)

> **✓ 정답 및 해설**
>
> **정답:** ②
>
> - ① 명목척도: 단순 분류·구분만 가능(성별, 혈액형). 순위 자체가 없음.
> - ② 순서척도: 순위는 있으나 간격이 불균등(만족도 상·중·하, 학점 등급). ← 정답
> - ③ 구간척도: 순위 + **간격까지 일정**(온도, 연도). 절대영점은 없음.
> - ④ 비율척도: 간격 일정 + **절대영점 존재**(무게, 길이). 비율 비교 가능.
>
> **출제 포인트:** 척도 판별 3단계 — "순위 있나? → 간격 일정한가? → 절대영점 있나?" 하나씩 추가될 때마다 명목→순서→구간→비율.
>
> **근거:** 순서척도는 측정 대상 간 순위·서열 관계는 나타내지만 값 사이의 간격이 동일하다고 보장하지 못하는 척도다.

Q2-042 [난이도: 하] [태그: 2과목/통계기법이해/척도]

다음 중 비율척도(ratio scale)로 측정된 자료에 해당하는 것은?

① 환자의 혈액형(A, B, O, AB)
② 설문 응답의 만족도(매우 불만족~매우 만족)
③ 서울의 오늘 기온(섭씨 25도)
④ 택배 상자의 무게(3.2kg)

✓ 정답 및 해설

정답: ④

- ① 혈액형: 분류만 가능 → 명목척도.
- ② 만족도 등급: 순위만 의미 → 순서척도.
- ③ 섭씨온도: 간격은 일정하지만 0℃가 "온도 없음"이 아님(절대영점 없음) → 구간척도. 20℃가 10℃의 "2배 덥다"고 할 수 없음.
- ④ 무게: 0kg = "무게 없음"이라는 절대영점 존재, 배수 비교 가능 → 비율척도. ← 정답

출제 포인트: 단골 함정 = **온도는 구간척도, 무게·길이·시간(소요시간)·소득은 비율척도**. "0이 진짜 없음을 뜻하면 비율척도."

근거: 비율척도는 절대영점이 존재하여 사칙연산과 배수(비율) 비교가 모두 가능한 최상위 수준의 척도다.

Q2-043 [난이도: 하] [태그: 2과목/통계기법이해/이산확률분포]

어느 콜센터에 1시간 동안 걸려오는 전화 건수를 확률변수로 모형화할 때 가장 적절한 분포는?

① 포아송분포(Poisson distribution)
② 이항분포(binomial distribution)
③ 베르누이분포(Bernoulli distribution)
④ 정규분포(normal distribution)

✓ 정답 및 해설

정답: ①

- ① 포아송분포: **단위 시간·단위 공간**에서 발생하는 사건의 횟수를 모형화 → 시간당 전화 건수에 적합. ← 정답
- ② 이항분포: 정해진 **n회 시행 중 성공 횟수**. 시행 횟수가 미리 정해져 있지 않으므로 부적합.
- ③ 베르누이분포: 성공/실패 **1회 시행**의 분포. 횟수 세기가 아님.
- ④ 정규분포: **연속**확률분포. 전화 건수는 0, 1, 2, …인 이산형이므로 부적합.

출제 포인트: 사례 매칭 공식 — "1회 성공/실패=베르누이, n회 중 성공 횟수=이항, 단위 시간·공간당 발생 건수=포아송."

근거: 포아송분포는 단위 시간이나 단위 공간에서 어떤 사건이 발생하는 횟수를 나타내는 이산확률분포다.

Q2-044 [난이도: 하] [태그: 2과목/통계기법이해/표본추출]

모집단 목록에 일련번호를 부여한 뒤 첫 표본만 무작위로 뽑고, 그로부터 일정한 간격 k마다 표본을 추출하는 방법은?

① 단순 무작위추출(simple random sampling)
② 층화추출(stratified sampling)
③ 계통추출(systematic sampling)
④ 군집추출(cluster sampling)

> **✓ 정답 및 해설**
>
> **정답:** ③
>
> - ① 단순 무작위추출: 모든 개체를 **동일한 확률**로 무작위 추출. 일정 간격 개념 없음.
> - ② 층화추출: 모집단을 동질적인 **층(strata)** 으로 나눈 뒤 각 층에서 추출.
> - ③ 계통추출: 첫 표본 무작위 선정 후 **매 k번째** 추출(k = N/n). ← 정답
> - ④ 군집추출: 모집단을 군집으로 나눠 **일부 군집을 통째로** 추출.
>
> **출제 포인트:** "일련번호 + 일정 간격"이 보이면 무조건 계통추출. 추출 간격 k = 모집단 크기 N ÷ 표본 크기 n.
>
> **근거:** 계통추출은 모집단 목록에서 첫 번째 표본을 무작위로 선정한 후 일정한 간격마다 표본을 추출하는 확률표본추출 방법이다.

Q2-045 [난이도: 중] [태그: 2과목/통계기법이해/조건부확률]

사건 A, B에 대하여 P(A) = 0.4, P(A∩B) = 0.1일 때, 조건부 확률 P(B|A)는?

① 0.10 ② 0.25 ③ 0.40 ④ 0.50

> **✓ 정답 및 해설**
>
> **정답:** ②
>
> - 공식: P(B|A) = P(A∩B) / P(A) = 0.1 / 0.4 = **0.25**
> - ① 0.10: P(A∩B)를 그대로 답한 오답. 조건부 확률은 교집합을 조건 사건의 확률로 **나눠야** 함.
> - ② 0.25 ← 정답.
> - ③ 0.40: P(A)를 그대로 답한 오답.
> - ④ 0.50: 조건부 확률 공식과 무관한 값. 주어진 정보(P(A), P(A∩B))로는 어떤 올바른 계산으로도 나오지 않는다.
>
> **출제 포인트:** P(B|A)는 "A가 일어났다는 조건에서"이므로 **분모가 P(A)**. 분모를 P(B)로 쓰는 실수가 최다 오답 유형.
>
> **근거:** 조건부 확률 P(B|A)는 사건 A가 일어났을 때 사건 B가 일어날 확률로, P(A∩B)를 P(A)로 나눈 값이다.

Q2-046 [난이도: 중] [태그: 2과목/통계기법이해/이항분포]

확률변수 X가 이항분포 B(100, 0.2)를 따를 때, X의 기댓값과 분산을 순서대로 나열한 것은?

① 20, 16 ② 20, 20 ③ 16, 20 ④ 20, 4

> **✓ 정답 및 해설**
>
> **정답:** ①
>
> - 기댓값 E(X) = np = 100 × 0.2 = **20**
> - 분산 V(X) = np(1−p) = 100 × 0.2 × 0.8 = **16**
> - ① (20, 16) ← 정답.
> - ② (20, 20): 분산을 np로 잘못 계산. 기댓값=분산은 **포아송분포**의 특징.
> - ③ (16, 20): 기댓값과 분산을 서로 바꿔 쓴 오답.
> - ④ (20, 4): 분산이 아니라 표준편차(√16 = 4)를 답한 오답.
>
> **출제 포인트:** 이항분포 공식 세트 — E(X) = np, V(X) = np(1−p). 분산에 (1−p)를 빼먹으면 포아송과 혼동한 것.
>
> **근거:** 이항분포 B(n, p)의 기댓값은 np, 분산은 np(1−p)이다.

Q2-047 [난이도: 중] [태그: 2과목/통계기법이해/연속확률분포]

연속확률분포에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 표준정규분포는 평균이 0, 분산이 1인 정규분포다.
② t분포는 모분산을 모르는 소표본에서 모평균을 추론할 때 사용한다.
③ 카이제곱분포는 모분산의 추론이나 적합도 검정 등에 사용한다.
④ F분포는 좌우 대칭인 분포로, 한 집단의 모평균 검정에 사용한다.

> **✓ 정답 및 해설**
>
> **정답:** ④
>
> - ① 옳은 설명. Z ~ N(0, 1)로 표기하며, 정규분포를 표준화(Z = (X−μ)/σ)한 것.
> - ② 옳은 설명. 소표본 + 모분산 미지 → t분포. 자유도가 커지면 표준정규분포에 근사.
> - ③ 옳은 설명. 카이제곱분포는 모분산 추론, 적합도·독립성 검정에 사용.
> - ④ F분포는 **두 집단의 분산비** 비교(분산분석·등분산 검정)에 쓰이며, 오른쪽 꼬리가 긴 **비대칭** 분포다. 두 가지 모두 틀린 설명. ← 정답
>
> **출제 포인트:** 용도 매칭 — "모평균(소표본·모분산 미지)=t, 모분산 1개=카이제곱, 분산비 2개=F". t분포는 좌우 대칭, 카이제곱·F는 비대칭(오른쪽 꼬리).
>
> **근거:** F분포는 서로 독립인 두 카이제곱 확률변수를 각각의 자유도로 나눈 비로 정의되며, 두 집단의 분산 비교에 사용되는 비대칭 연속확률분포다.

Q2-048 [난이도: 중] [태그: 2과목/통계기법이해/표본추출]

표본추출 방법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 단순 무작위추출은 모집단의 모든 개체가 동일한 확률로 추출된다.
② 층화추출은 층 내부는 동질적, 층 사이는 이질적이 되도록 층을 나눈 후 각 층에서 표본을 추출한다.
③ 군집추출은 군집 내부의 개체들이 서로 동질적이 되도록 군집을 구성하며, 모든 군집에서 표본을 고르게 추출한다.
④ 계통추출은 추출 간격 k = N/n을 정해 목록에서 일정 간격마다 표본을 추출한다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 단순 무작위추출의 정의 그 자체.
- ② 옳은 설명. 층화추출 = **층 내 동질 · 층 간 이질**. 각 층에서 모두 표본을 뽑는다.
- ③ 군집추출은 각 군집이 모집단의 축소판이 되도록 **군집 내부는 이질적**으로 구성하고, **일부 군집만 선택**하여 그 안을 조사한다. 동질/이질과 추출 범위를 모두 반대로 쓴 함정. ← 정답
- ④ 옳은 설명. 계통추출의 정의.

출제 포인트: 최다 출제 함정 — 층화와 군집의 동질·이질 바꿔치기. "**층화 = 층 내 동질**(층에서 모두 뽑음) / **군집 = 군집 내 이질**(군집을 일부만 뽑음)"로 쌍을 통째로 암기.

근거: 군집추출은 모집단을 서로 유사한 여러 군집으로 나눈 뒤 일부 군집만 무작위로 선택해 조사하는 방법으로, 각 군집 내부는 모집단처럼 이질적일수록 바람직하다.

Q2-049 [난이도: 중] [태그: 2과목/통계기법이해/중심극한정리]

중심극한정리(central limit theorem)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 모집단이 정규분포를 따르는 경우에만 성립한다.
② 표본 크기 n이 충분히 크면 표본평균의 분포는 근사적으로 정규분포를 따른다.
③ 표본평균의 기댓값은 모평균 μ와 같다.
④ 표본평균의 분산은 σ^2/n으로, 표본 크기가 커질수록 작아진다.

✓ 정답 및 해설

정답: ①

- ① 중심극한정리의 핵심은 **모집단의 분포와 관계없이** n이 충분히 크면 표본평균이 정규분포에 근사한다는 것. "정규분포일 때만"은 정리의 의의를 정반대로 뒤집은 설명. ← 정답
- ② 옳은 설명. 정리의 정의 그 자체(통상 $n \geq 30$을 기준으로 봄).
- ③ 옳은 설명. $E(\bar{X}) = \mu$.
- ④ 옳은 설명. $V(\bar{X}) = \sigma^2/n \rightarrow$ 표준오차는 $\sigma/\sqrt{n}$.

출제 포인트: 중심극한정리 3종 세트 — "모집단 분포 무관 / $\bar{X}$ ~ 근사 $N(\mu, \sigma^2/n)$ / n이 클수록 퍼짐 감소". "모집단이 정규여야 한다"가 나오면 무조건 틀린 선지.

근거: 중심극한정리는 모집단의 분포와 무관하게 표본 크기가 충분히 크면 표본평균의 분포가 평균 μ, 분산 σ^2/n인 정규분포에 근사한다는 정리다.

Q2-050 [난이도: 중] [태그: 2과목/통계기법이해/이산확률분포]

이산확률분포에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 베르누이 시행은 결과가 성공 또는 실패 두 가지뿐인 1회의 시행이다.
② 이항분포는 서로 독립인 베르누이 시행을 n번 반복할 때 성공 횟수가 따르는 분포다.
③ 포아송분포는 단위 시간이나 단위 공간에서 드물게 발생하는 사건의 횟수를 모형화한다.
④ 포아송분포의 기댓값은 λ, 분산은 λ^2로 서로 다르다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. 베르누이분포 = 성공/실패 이분 결과의 **1회 시행** 분포.
- ② 옳은 설명. 이항분포 = 베르누이 시행의 n회 독립 반복에서의 **성공 횟수**.
- ③ 옳은 설명. 포아송분포의 정의(희귀 사건의 발생 건수).
- ④ 포아송분포는 **기댓값과 분산이 모두 λ로 같다**는 것이 최대 특징. λ^2이 아님. ← 정답

출제 포인트: 분포별 (기댓값, 분산) — 베르누이 $(p, p(1-p))$ / 이항 $(np, np(1-p))$ / 포아송 (λ, λ). "기댓값 = 분산"이면 포아송.

근거: 포아송분포는 발생률 λ를 모수로 가지며 기댓값과 분산이 모두 λ인 이산확률분포다.

Q2-051 [난이도: 상] [태그: 2과목/통계기법이해/베이즈정리]

어느 공장에서 제품의 60%는 A라인, 40%는 B라인에서 생산된다. 불량률은 A라인 2%, B라인 3%이다. 임의로 뽑은 제품이 불량품이었을 때, 그 제품이 A라인에서 생산되었을 확률은?

① 1/3 ② 1/2 ③ 2/5 ④ 3/5

✓ 정답 및 해설

정답: ②

- 베이즈 정리: P(A|불량) = P(A)P(불량|A) / [P(A)P(불량|A) + P(B)P(불량|B)]
- 분자 = 0.6 × 0.02 = 0.012 / 분모 = 0.012 + (0.4 × 0.03) = 0.012 + 0.012 = 0.024
- P(A|불량) = 0.012 / 0.024 = **1/2**
- ① 1/3: 분모(전확률)에 분자를 한 번 더 더해 0.012 / (0.024 + 0.012) = 1/3로 계산하는 실수에서 나오는 값. 전확률 0.024에는 A라인 몫이 이미 포함되어 있음.
- ② 1/2 ← 정답. A·B의 불량 기여분이 0.012로 같으므로 반반.
- ③ 2/5: 사전확률 P(B) = 0.4를 그대로 답한 오답. 사후확률로 갱신하지 않음.
- ④ 3/5: 사전확률 P(A) = 0.6을 그대로 답한 오답. "불량"이라는 정보를 반영해야 함.

출제 포인트: 베이즈 계산 절차 — ① 경로별 결합확률(사전확률 × 조건부확률) 계산 → ② 전확률(분모) = 경로 합 → ③ 해당 경로 ÷ 전확률. 사전확률을 그대로 고르게 하는 것이 대표 함정.

근거: 베이즈 정리는 사전확률과 우도(조건부확률)를 이용해 어떤 결과가 관측되었을 때 각 원인의 사후확률을 구하는 정리다.

Q2-052 [난이도: 상] [태그: 2과목/통계기법이해/척도표본추출종합]

다음 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 섭씨온도는 절대영점이 없는 구간척도이므로 "20℃는 10℃보다 2배 덥다"는 비율 비교가 성립하지 않는다.
- ㄴ. 명목척도로 측정된 자료는 산술평균을 계산하여 대푯값으로 사용하는 것이 적절하다.
- ㄷ. 층화추출에서 각 층은 층 내부가 동질적이고 층 사이는 이질적이 되도록 구성한다.
- ㄹ. 표본 크기가 충분히 크면 모집단의 분포와 무관하게 표본평균의 분포는 근사적으로 정규분포를 따른다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄷ, ㄹ ④ ㄱ, ㄴ, ㄷ, ㄹ

✓ 정답 및 해설

정답: ③

- **ㄱ (O)** 구간척도는 간격만 의미가 있고 절대영점이 없어 배수 비교 불가. 온도가 대표 사례.
- **ㄴ (X)** 명목척도는 분류 기호일 뿐이므로 산술평균이 무의미하며, 대푯값은 **최빈값**을 사용한다.
- **ㄷ (O)** 층화추출 = 층 내 동질 · 층 간 이질.
- **ㄹ (O)** 중심극한정리의 내용 그대로.

따라서 옳은 것은 ㄱ, ㄷ, ㄹ → **③**. (①은 틀린 ㄴ 포함·ㄷ ㄹ 누락, ②·④는 틀린 ㄴ을 포함)

출제 포인트: 척도별 사용 가능한 통계량 — 명목: 최빈값 / 순서: 중앙값·최빈값 / 구간: + 평균·표준편차 / 비율: + 기하평균·변동계수(모든 연산).

근거: 명목척도는 측정 대상을 범주로 분류하는 기호에 불과하므로 산술 연산이 불가능하며 대푯값으로 최빈값만 사용할 수 있다.

2-6 추론통계

> 2과목 · 빅데이터 탐색 / 주요항목: 통계기법 이해
> 문항 수: 8 (Q2-053 ~ Q2-060) · 난이도 하2/중4/상2 · 정답 분포 ①2 ②2 ③2 ④2
> 범위: 점추정량의 성질, 신뢰구간 해석, 가설 설정, 1종·2종 오류와 검정력, p-value 판정, 양측·단측 검정, 검정 기법 선택(Z·t·카이제곱·ANOVA)

Q2-053 [난이도: 하] [태그: 2과목/통계기법이해/점추정량의성질]

표본에서 계산한 추정량(estimator)의 기댓값이 추정하려는 모수(parameter)와 일치하는 점추정량의 성질은?

① 효율성(efficiency) ② 불편성(unbiasedness) ③ 일치성(consistency) ④ 충족성(sufficiency)

✓ 정답 및 해설

정답: ②

- ① 효율성: 불편추정량 중 **분산이 가장 작은** 추정량이 좋다는 성질. 기댓값이 아니라 분산 기준.
- ② 불편성: 추정량의 기댓값 = 모수, 즉 $E(\hat{\theta})=\theta$. 편의(bias)가 0인 성질. ← 정답
- ③ 일치성: 표본의 크기 n이 커질수록 추정량이 모수에 **확률적으로 수렴**하는 성질. "n이 커지면"이 핵심.
- ④ 충족성: 추정량이 모수에 대한 **표본의 정보를 모두 담고 있는** 성질.

출제 포인트: 4대 성질 판별 키워드 — "기댓값=모수"는 불편성, "분산 최소"는 효율성, "n 커질수록 수렴"은 일치성, "정보를 모두 제공"은 충족성. ※ 교재별 표기 차이 있음 — 충족성은 "충분성"으로도 표기.

근거: 불편성(unbiasedness)은 추정량의 기댓값이 추정 대상인 모수와 같아 편의가 0이 되는 점추정량의 성질이다.

Q2-054 [난이도: 하] [태그: 2과목/통계기법이해/p-value판정]

유의수준(significance level) $\alpha=0.05$로 가설검정을 수행한 결과 유의확률(p-value)이 0.03으로 계산되었다. 올바른 판정은?

① 귀무가설을 기각하고 대립가설을 채택한다.
② p-value가 0보다 크므로 귀무가설을 채택한다.
③ 귀무가설이 참일 확률이 3%라고 결론 내린다.
④ 판정할 수 없으므로 표본을 더 수집해 재검정한다.

✓ 정답 및 해설

정답: ①

- ① p-value(0.03) < α(0.05) → 귀무가설 기각, 대립가설 채택. ← 정답
- ② 판정 기준은 "p가 0보다 큰가"가 아니라 **α와의 비교**다. p<α이므로 기각해야 한다.
- ③ p-value는 "귀무가설이 참일 확률"이 아니라, **귀무가설이 참이라는 가정 아래** 관측된 값 이상으로 극단적인 결과가 나올 확률이다. 대표적 오개념.
- ④ p<α로 판정 근거가 충분하므로 재검정이 필요하다는 결론은 부적절.

출제 포인트: 판정 공식 — **p < α → 기각 / p ≥ α → 기각 못 함**. "p-value = 귀무가설이 참일 확률"은 항상 틀린 선지.

근거: 유의확률(p-value)은 귀무가설이 참이라는 가정 하에 표본에서 관측된 검정통계량 이상으로 극단적인 값이 나올 확률로, 유의수준보다 작으면 귀무가설을 기각한다.

Q2-055 [난이도: 중] [태그: 2과목/통계기법이해/신뢰구간해석]

모평균에 대한 95% 신뢰구간(confidence interval)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 동일한 방법으로 표본추출을 반복하여 신뢰구간을 만들면 그중 약 95%의 구간이 모평균을 포함한다.
② 다른 조건이 같을 때 신뢰수준을 95%에서 99%로 높이면 구간의 길이는 길어진다.
③ 하나의 표본에서 구한 신뢰구간이 [10, 20]이면, 모평균이 이 구간 안에 있을 확률이 95%이다.
④ 다른 조건이 같을 때 표본의 크기를 늘리면 구간의 길이는 짧아진다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 신뢰구간의 정의 그 자체 — 확률은 "반복 추출된 **구간들**"에 대한 것.
- ② 옳은 설명. 신뢰수준↑ → 임계값↑ → 구간 길이↑ (더 넓게 잡아야 더 자주 포함).
- ③ 이미 구해진 특정 구간에 대해 모평균은 **들어 있거나(1) 없거나(0)** 둘 중 하나다. 확률 95%를 부여할 수 없다. 틀린 설명. ← 정답
- ④ 옳은 설명. n↑ → 표준오차(σ/√n)↓ → 구간 길이↓.

출제 포인트: 신뢰구간 3대 성질 — 신뢰수준↑ 길이↑ / 표본 크기↑ 길이↓ / 확률의 주어는 "모수"가 아니라 "구간(방법)". "모수가 구간에 있을 확률 95%"는 단골 오답 선지.

근거: 95% 신뢰구간은 동일한 방법으로 반복해서 구간을 추정할 때 그 구간들 중 약 95%가 모수를 포함하게 되는 추정 방식이다.

Q2-056 [난이도: 중] [태그: 2과목/통계기법이해/1종2종오류]

다음은 가설검정의 결과를 정리한 표다. (가)~(다)에 들어갈 내용으로 옳은 것은?

구분	H_0가 참	H_0가 거짓
H_0 기각	(가)	(나)
H_0 채택	옳은 결정	(다)

① (가) 2종 오류 (나) 검정력 (다) 1종 오류
② (가) 1종 오류 (나) 2종 오류 (다) 옳은 결정
③ (가) 2종 오류 (나) 1종 오류 (다) 옳은 결정
④ (가) 1종 오류 (나) 옳은 결정 (다) 2종 오류

✓ 정답 및 해설

정답: ④

- **(가)** 참인 H_0를 기각 → **1종 오류(type I error)**, 확률 α.
- **(나)** 거짓인 H_0를 기각 → **옳은 결정**, 이 확률이 검정력(power) $1-\beta$.
- **(다)** 거짓인 H_0를 채택 → **2종 오류(type II error)**, 확률 β.
- **①·③** (가)를 2종 오류로 둔 것부터 틀림 — 2종 오류는 "기각"이 아니라 "채택" 행에서 발생.
- **②** (가)는 맞지만 (나)를 2종 오류로 바꿔치기 — 같은 "기각" 행에서는 2종 오류가 발생할 수 없다.

출제 포인트: 암기 공식 — **"참인데 기각 = 1종(α), 거짓인데 채택 = 2종(β)"**. 표에서 오류는 대각선에 위치하고, 나머지 두 칸은 옳은 결정(그중 거짓-기각 칸의 확률이 검정력 $1-\beta$).

근거: 1종 오류는 귀무가설이 참임에도 기각하는 오류이고, 2종 오류는 귀무가설이 거짓임에도 채택하는 오류다.

Q2-057 [난이도: 중] [태그: 2과목/통계기법이해/가설설정·양측단측]

가설 설정과 양측·단측 검정에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 귀무가설(null hypothesis)은 "차이가 없다·효과가 없다"처럼 기존 입장을 나타내며 등호(=)를 포함해 설정한다.
② 대립가설이 "$\mu \neq 100$" 형태이면 기각역을 한쪽에만 두는 단측 검정을 수행한다.
③ 대립가설(alternative hypothesis)은 연구자가 표본의 증거로 입증하고자 하는 새로운 주장이다.
④ 대립가설이 "$\mu > 100$" 형태이면 기각역을 오른쪽 한쪽에 두는 단측 검정을 수행한다.

✓ 정답 및 해설

정답: ②

- ① 옳은 설명. H_0는 기존 통념·현상 유지 쪽이며 "=, ≤, ≥"처럼 등호를 포함.
- ② "≠"는 크든 작든 다르기만 하면 기각하므로 기각역을 **양쪽에 α/2씩** 두는 **양측 검정**이다. 단측이라는 서술이 틀림. ← 정답
- ③ 옳은 설명. H_1은 연구자가 보이고 싶은 주장으로, 기각의 대상이 아니라 채택의 목표.
- ④ 옳은 설명. ">"는 오른쪽 단측(우측 검정), "<"는 왼쪽 단측(좌측 검정).

출제 포인트: 대립가설의 부호로 즉시 판별 — **≠ 양측 / > 우측 단측 / < 좌측 단측**. 귀무가설은 등호 포함, 대립가설은 등호 불포함.

근거: 양측 검정은 대립가설이 "같지 않다(≠)" 형태여서 기각역을 분포의 양쪽 꼬리에 두는 검정이고, 단측 검정은 대립가설의 부등호 방향 한쪽에만 기각역을 두는 검정이다.

Q2-058 [난이도: 중] [태그: 2과목/통계기법이해/ANOVA·검정기법선택]

한 학원이 A, B, C 세 가지 교수법으로 각각 다른 반을 가르친 뒤, 세 반의 시험 점수 평균에 차이가 있는지 검정하려 한다. 가장 적절한 분석 기법은?

① 독립표본 t-검정(independent samples t-test)
② 카이제곱 독립성 검정(chi-squared test)
③ 일원분산분석(one-way ANOVA)
④ 대응표본 t-검정(paired t-test)

✓ 정답 및 해설

정답: ③

- ① 독립표본 t-검정은 **두 집단**의 평균 비교. 세 집단에 반복 적용하면 1종 오류가 누적되므로 부적절.
- ② 카이제곱 검정은 **범주형 변수** 간 독립성·적합도 검정. 평균(연속형) 비교가 아님.
- ③ 분산분석(ANOVA)은 **3개 이상 집단의 모평균**이 모두 같은지를 한 번에 검정. 집단 3개·연속형 종속변수 → 일원분산분석. ← 정답
- ④ 대응표본 t-검정은 **같은 대상의 사전·사후** 비교. 서로 다른 세 반은 대응 관계가 아님.

출제 포인트: 집단 수로 판별 — **2집단 평균 = t-검정, 3집단 이상 평균 = ANOVA, 범주형×범주형 = 카이제곱**. "세 가지·네 가지 ~별 평균 차이" 사례가 나오면 무조건 ANOVA.

근거: 분산분석(ANOVA)은 세 개 이상 집단의 모평균이 모두 동일한지를 집단 간 분산과 집단 내 분산의 비(F-통계량)로 검정하는 기법이다.

Q2-059 [난이도: 상] [태그: 2과목/통계기법이해/오류와검정력]

1종 오류, 2종 오류, 검정력의 관계에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 1종 오류는 귀무가설이 참인데 기각하는 오류이며, 그 확률의 최대 허용치가 유의수준 α다.
② 다른 조건이 동일할 때 α를 작게 하면 β는 커지는 상충(trade-off) 관계가 있다.
③ 검정력(1-β)은 귀무가설이 거짓일 때 이를 올바르게 기각할 확률이다.
④ 표본의 크기를 늘리면 α와 β가 동시에 커져 검정의 정확도가 낮아진다.

> **✓ 정답 및 해설**
>
> **정답:** ④
>
> - ① 옳은 설명. 유의수준 α = 1종 오류 확률의 허용 한계로, 검정 전에 연구자가 정한다.
> - ② 옳은 설명. 같은 표본에서 기각 기준을 엄격히(α↓) 하면 거짓 H_0를 놓칠 가능성(β)이 커진다.
> - ③ 옳은 설명. 검정력 = $P(H_0$ 기각 $\mid H_0$ 거짓$) = 1-\beta$.
> - ④ 표본의 크기를 늘리면 **α를 고정한 채 β를 줄일 수(검정력을 높일 수)** 있다. 두 오류를 함께 줄이는 유일한 일반적 방법이 표본 확대이며, "동시에 커진다"는 정반대 서술. ← 정답
>
> **출제 포인트:** 관계 3줄 암기 — **α↓ ⇒ β↑ (상충) / 검정력 = 1-β / n↑ ⇒ (α 고정 시) β↓·검정력↑**. "표본을 늘리면 오류가 커진다"류는 함정 선지.
>
> **근거:** 검정력(1-β)은 거짓인 귀무가설을 올바르게 기각할 확률로, 유의수준을 고정한 상태에서 표본의 크기를 늘리면 2종 오류 확률 β가 줄어 검정력이 커진다.

Q2-060 [난이도: 상] [태그: 2과목/통계기법이해/검정기법선택]

다음 상황 ㄱ~ㄹ에 적용할 검정 기법을 옳게 짝지은 것은?

- ㄱ. 모분산을 알고 있는 대표본에서 모평균을 검정
- ㄴ. 모분산을 모르는 소표본(n<30)에서 모평균을 검정
- ㄷ. 성별(남/여)과 구매 여부(구매/비구매) 두 범주형 변수의 독립성을 검정
- ㄹ. 네 개 지점의 일평균 매출액이 모두 같은지 검정

① ㄱ-Z검정, ㄴ-t검정, ㄷ-카이제곱 검정, ㄹ-분산분석
② ㄱ-t검정, ㄴ-Z검정, ㄷ-카이제곱 검정, ㄹ-분산분석
③ ㄱ-Z검정, ㄴ-t검정, ㄷ-분산분석, ㄹ-카이제곱 검정
④ ㄱ-t검정, ㄴ-Z검정, ㄷ-분산분석, ㄹ-카이제곱 검정

✓ 정답 및 해설

정답: ①

- ㄱ 모분산 기지(旣知)·대표본 → **Z-검정**(표준정규분포 이용).
- ㄴ 모분산 미지·소표본 → **t-검정**(자유도 n-1의 t-분포 이용).
- ㄷ 범주형 × 범주형 독립성 → **카이제곱(chi-squared) 검정**.
- ㄹ 4개 집단(3집단 이상)의 평균 동시 비교 → **분산분석(ANOVA)**.
- ②·④ ㄱ과 ㄴ을 바꿔치기 — "분산을 알면 Z, 모르면(소표본) t"가 원칙.
- ③·④ ㄷ과 ㄹ을 바꿔치기 — 카이제곱은 범주형, ANOVA는 연속형 평균 비교.

출제 포인트: 선택 공식 — **분산 알고 대표본 = Z / 분산 모르는 소표본 = t / 범주형 = 카이제곱 / 3집단 이상 평균 = ANOVA**. ※ 교재별 표기 차이 있음 — 대표본(n≥30)에서는 분산을 몰라도 Z-검정으로 근사할 수 있다고 서술하는 교재도 있다.

근거: 검정 기법은 자료의 척도와 조건에 따라 선택하며, Z-검정은 모분산을 아는 경우(또는 대표본), t-검정은 모분산을 모르는 소표본, 카이제곱 검정은 범주형 자료, 분산분석은 3개 이상 집단의 평균 비교에 사용한다.

이 문서는 LLM으로 생성 후 3중 검증(사실·논리·규격 / 중복 / 교체분 재검증)을 거친 학습 자료입니다. 교재별 표기가 갈리는 항목은 본문에 "※ 교재별 표기 차이 있음"으로 표시했으며, 상세 목록은 부록의 검증 필요 항목을 참고하세요.