빅데이터분석기사 필기 문제집

3과목 · 빅데이터 모델링 — 60문항 (Q3-001 ~ Q3-060)

the0ne 학습용 · 2026-09-01 생성 · KDATA 공개 출제기준 기반 신규 창작 문항 (기출 복원 아님)

3-1 분석 절차 수립

> 3과목 · 빅데이터 모델링 / 주요항목: 분석 모형 설계
> 문항 수: 8 (Q3-001 ~ Q3-008) · 난이도 하2/중4/상2 · 정답 분포 ①2 ②2 ③2 ④2

Q3-001 [난이도: 하] [태그: 3과목/분석모형설계/비지도학습]

다음 중 비지도학습(unsupervised learning)에 해당하는 것은?

① 로지스틱 회귀(logistic regression)
② K-평균 군집(K-means clustering)
③ 의사결정나무(decision tree)
④ 서포트 벡터 머신(SVM)

✓ 정답 및 해설

정답: ②

- ① 로지스틱 "회귀"라는 이름이지만 범주를 예측하는 **지도학습의 분류** 기법. 이름만 보고 고르게 하는 단골 함정.
- ② 레이블 없이 데이터를 유사한 그룹으로 묶는 군집화 → 비지도학습. ← 정답
- ③ 레이블이 있는 데이터로 분류·회귀를 수행 → 지도학습.
- ④ 마진을 최대화하는 초평면으로 분류·회귀를 수행 → 지도학습.

출제 포인트: 비지도 3대장 = **군집(K-means·계층적·DBSCAN·SOM), 연관 규칙(Apriori), 차원 축소(PCA)**. 로지스틱 회귀는 이름과 달리 **지도학습·분류**임을 반드시 암기.

근거: 비지도학습은 정답(레이블) 없이 데이터 자체의 구조·패턴을 찾는 학습 방식으로 군집화, 연관 규칙 학습, 차원 축소가 대표적이다.

Q3-002 [난이도: 하] [태그: 3과목/분석모형설계/강화학습]

에이전트(agent)가 환경(environment)과 상호작용하면서 행동에 대한 보상(reward)을 받고, 누적 보상을 최대화하는 행동 정책을 스스로 학습해 나가는 머신러닝 방식은?

① 지도학습(supervised learning)
② 비지도학습(unsupervised learning)
③ 강화학습(reinforcement learning)
④ 준지도학습(semi-supervised learning)

✓ 정답 및 해설

정답: ③

- ① 지도학습: 입력과 정답(레이블) 쌍으로 학습. 보상·에이전트 개념이 없음.
- ② 비지도학습: 레이블 없이 데이터의 구조·패턴 탐색. 환경과의 상호작용이 없음.
- ③ 환경–행동–보상의 상호작용으로 보상을 최대화하는 정책 학습 → 강화학습. ← 정답
- ④ 준지도학습: 소량의 레이블 데이터 + 대량의 무레이블 데이터를 함께 사용하는 방식. 보상 개념이 없음.

출제 포인트: 키워드 즉시 연결 — "레이블·정답" = 지도, "군집·패턴·구조" = 비지도, "에이전트·보상·정책·환경" = 강화.

근거: 강화학습은 에이전트가 환경과 상호작용하며 행동의 결과로 받는 보상을 최대화하도록 행동 정책을 학습하는 머신러닝 방식이다.

Q3-003 [난이도: 중] [태그: 3과목/분석모형설계/분류회귀구분]

다음 분석 과제 중 지도학습의 분류(classification)에 해당하는 것은?

① 고객의 계약·이용 데이터를 학습하여 서비스 해지 여부(이탈/유지)를 예측한다.
② 지역·면적 등의 정보를 학습하여 아파트의 매매 가격을 예측한다.
③ 과거 판매 실적을 학습하여 매장의 다음 달 매출액을 예측한다.
④ 기온 데이터를 학습하여 아이스크림 판매량을 예측한다.

✓ 정답 및 해설

정답: ①

- ① 목표변수가 "이탈/유지"라는 **범주형**이므로 소속 범주를 맞히는 **분류** 과제. ← 정답
- ② 매매 가격은 **연속형 수치** → 값을 예측하는 회귀(regression) 과제.
- ③ 매출액도 연속형 수치 → 회귀 과제.
- ④ 판매량도 연속형 수치 → 회귀 과제.

출제 포인트: 분류·회귀의 구분 기준은 기법의 이름이 아니라 **목표변수(종속변수)의 형태** — 범주형이면 분류, 연속형 수치면 회귀. "여부·등급·합격/불합격·스팸/정상" = 분류, "가격·매출액·판매량·수요량" = 회귀로 즉시 연결할 것.

근거: 분류는 목표변수가 범주형일 때 어느 범주에 속하는지를 예측하는 지도학습 과제이고, 회귀는 목표변수가 연속형 수치일 때 그 값을 예측하는 지도학습 과제이다.

Q3-004 [난이도: 상] [태그: 3과목/분석모형설계/학습유형구분]

머신러닝의 학습 유형에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 지도학습은 정답(레이블)이 있는 데이터로 학습하며, 분류(classification)와 회귀(regression)로 구분된다.
② 비지도학습은 레이블 없는 데이터에서 구조·패턴을 찾으며 군집화, 연관 규칙 학습, 차원 축소가 대표적이다.
③ 강화학습은 행동에 대한 보상을 통해 정책을 학습하며, 명시적인 정답 레이블을 사용하지 않는다.
④ 준지도학습(semi-supervised learning)은 소량의 레이블 데이터와 대량의 무레이블 데이터를 함께 사용하며, 학습 데이터의 대부분이 무레이블이므로 비지도학습의 한 유형으로 분류된다.

> **✓ 정답 및 해설**
>
> **정답: ④**
>
> - ① 옳은 설명. 지도학습의 2대 과제 = 분류(범주 예측) + 회귀(수치 예측).
> - ② 옳은 설명. 비지도학습의 3대 과제 = 군집·연관·차원 축소.
> - ③ 옳은 설명. 강화학습은 레이블 대신 보상 신호(reward)로 학습한다.
> - ④ 앞부분(소량 레이블 + 대량 무레이블 병용)은 옳지만, 결론이 틀림. 준지도학습은 **레이블 정보를 실제로 활용**하므로 비지도학습의 하위 유형이 아니라 지도학습과 비지도학습의 **중간에 위치한 별도의 학습 유형**으로 분류된다. ← 정답
>
> **출제 포인트:** 상급 함정은 "절반은 맞는 서술 뒤에 틀린 결론"을 붙이는 패턴. 분류 기준은 데이터의 비율이 아니라 **레이블 정보의 사용 여부** — 조금이라도 레이블을 활용하면 비지도학습이 아니다. 준지도학습은 지도·비지도·강화와 나란히 놓이는 독립 유형(또는 지도학습의 확장)으로 본다.
>
> **근거:** 준지도학습은 소량의 레이블 데이터와 대량의 무레이블 데이터를 함께 사용하는 학습 방식으로, 지도학습과 비지도학습의 중간적 성격을 갖는 별도의 학습 유형이다.

Q3-005 [난이도: 중] [태그: 3과목/분석모형설계/모형구분]

분석 모형의 분류에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 회귀 분석, 분산 분석 등 통계 기반 모형은 가설 검정 없이 수행되므로 결과의 확률적 해석이 불가능하다.
② 데이터 마이닝(data mining) 모형은 대용량 데이터에서 유의미한 패턴·규칙을 발견하는 것으로 분류·예측·군집·연관 분석 등이 있다.
③ 머신러닝(machine learning) 모형은 데이터로부터 학습하여 성능을 개선하며, 지도·비지도·강화학습으로 구분된다.
④ 회귀 분석처럼 하나의 기법이 통계 기반 모형이면서 동시에 머신러닝의 지도학습 기법으로 분류되기도 한다.

✓ 정답 및 해설

정답: ①

- ① 통계 기반 모형은 오히려 **확률분포 가정과 가설 검정(유의성 검정)에 기반**하여 결과를 확률적으로 해석하는 것이 특징. 정반대 서술이라 틀림. ← 정답
- ② 옳은 설명. 데이터 마이닝의 4대 과제 = 분류·예측·군집·연관.
- ③ 옳은 설명. 머신러닝은 학습 방식에 따라 지도/비지도/강화로 3분류.
- ④ 옳은 설명. 통계·마이닝·머신러닝의 경계는 배타적이지 않으며 회귀 분석 등은 양쪽에 모두 속한다.

출제 포인트: 구분 기준 — 통계 기반은 "**가정·검정·추론**", 데이터 마이닝은 "**대용량에서 패턴 발견**", 머신러닝은 "**데이터로 학습·성능 개선**". 분류 체계가 상호 배타적이지 않다는 점도 함정 소재. ※ 교재별 표기 차이 있음 — 데이터 마이닝의 과제 구분(분류·예측·군집·연관)은 교재에 따라 추정·기술 등을 추가하기도 한다.

근거: 통계 기반 분석 모형은 확률분포 가정 위에서 가설 검정과 추론을 통해 결과를 확률적으로 해석하는 모형이다.

Q3-006 [난이도: 중] [태그: 3과목/분석모형설계/변수선정]

분석 모형 정의 및 변수 선정에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 분석 모형 정의 단계에서는 분석 목적에 맞는 기법을 선정하고, 모형에 사용할 데이터와 변수를 정의한다.
② 예측에 도움이 되는지와 무관하게 수집 가능한 모든 변수를 투입할수록 모형 성능은 항상 좋아진다.
③ 목표변수(종속변수)와의 관련성이 높고, 독립변수 간 중복(다중공선성(multicollinearity))이 적은 변수를 선정하는 것이 바람직하다.
④ 변수 선택 기법에는 전진 선택법(forward selection), 후진 소거법(backward elimination), 단계적 선택법(stepwise method)이 있다.

✓ 정답 및 해설

정답: ②

- ① 옳은 설명. 모형 정의 = 목적에 맞는 기법 선정 + 데이터·변수 정의.
- ② 무관한 변수를 늘리면 **과대적합(overfitting)**, 차원의 저주, 해석력 저하가 발생 → "항상 좋아진다"는 틀림. ← 정답
- ③ 옳은 설명. 좋은 변수의 조건 = 목표변수와 관련성 높음 + 변수 간 중복 낮음.
- ④ 옳은 설명. 변수 선택 3대 기법 = 전진 선택·후진 소거·단계적 선택.

출제 포인트: "많을수록/항상 좋다" 류의 극단 서술은 대부분 오답. 변수 선택 3대 기법(전진·후진·단계적)은 명칭 그대로 암기.

근거: 변수 선정은 목표변수 예측에 기여하는 변수를 선별하는 과정으로, 불필요한 변수의 투입은 과대적합(overfitting)과 모형 복잡도 증가를 초래한다.

Q3-007 [난이도: 중] [태그: 3과목/분석모형설계/모형구축절차]

다음은 분석 모형 구축 절차의 각 단계다. 순서대로 옳게 나열한 것은?

- ㄱ. 모델링
- ㄴ. 요건 정의
- ㄷ. 적용
- ㄹ. 검증 및 테스트

① ㄴ → ㄹ → ㄱ → ㄷ
② ㄱ → ㄴ → ㄹ → ㄷ
③ ㄴ → ㄱ → ㄷ → ㄹ
④ ㄴ → ㄱ → ㄹ → ㄷ

✓ 정답 및 해설

정답: ④

- ① 모델을 만들기(ㄱ) 전에 검증(ㄹ)할 수 없으므로 틀림.
- ② 요건 정의(ㄴ)가 모든 절차의 출발점이므로 모델링(ㄱ)이 먼저 올 수 없음.
- ③ 검증되지 않은 모형을 먼저 적용(ㄷ)하는 순서라 틀림.
- ④ **요건 정의 → 모델링 → 검증 및 테스트 → 적용**. ← 정답

출제 포인트: "요·모·검·적"으로 암기. 만들기 전에 요구부터, 적용하기 전에 검증부터 — 상식적 흐름으로도 복원 가능. ※ 교재별 표기 차이 있음 — 단계 명칭을 '요구사항 정의', '검증·테스트' 등으로 달리 쓰는 교재가 있으나 4단계 골격은 동일.

근거: 분석 모형 구축 절차는 요건 정의 → 모델링 → 검증 및 테스트 → 적용의 4단계로 진행된다.

Q3-008 [난이도: 상] [태그: 3과목/분석모형설계/모형구축절차]

분석 모형 구축 절차의 단계별 수행 활동에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 요건 정의 단계에서는 분석 요구사항을 도출하고 우선순위를 정하여 분석 추진 계획을 수립한다.
- ㄴ. 모델링 단계에서는 분석용 데이터(마트)를 준비하고 탐색적 분석과 모델링을 수행한다.
- ㄷ. 검증 및 테스트 단계에서는 학습 데이터와 검증 데이터를 분리하지 않고 전체 데이터를 그대로 사용해 성능을 평가한다.
- ㄹ. 적용 단계에서는 모형을 운영 시스템에 배포하고 주기적인 모니터링과 재학습(모델 업데이트)을 수행한다.

① ㄱ, ㄴ, ㄷ
② ㄴ, ㄷ, ㄹ
③ ㄱ, ㄴ, ㄹ
④ ㄱ, ㄹ

✓ 정답 및 해설

정답: ③

- **ㄱ (O)** 요건 정의 = 요구사항 도출·분석·우선순위화 + 추진 계획 수립.
- **ㄴ (O)** 모델링 = 데이터 마트 구성 → 탐색적 분석(EDA) → 모형 개발.
- **ㄷ (X)** 검증은 **학습(train)·검증(validation) 데이터를 분리**하여 일반화 성능을 평가해야 한다. 전체 데이터를 그대로 쓰면 과대적합(overfitting)을 탐지할 수 없다.
- **ㄹ (O)** 적용 = 운영 시스템 배포 + 모니터링 + 주기적 재학습.

따라서 옳은 것은 ㄱ, ㄴ, ㄹ → ③. (①·②는 틀린 ㄷ을 포함, ④는 옳은 ㄴ을 누락)

출제 포인트: 단계–활동 매칭 문제는 "검증 단계에서 데이터 분리 안 함", "적용 후 방치" 같은 서술이 오답 신호. 검증의 핵심은 **분리된 데이터로 일반화 성능 확인**.

근거: 검증 및 테스트 단계는 구축된 모형을 학습에 사용하지 않은 별도의 데이터로 평가하여 일반화 성능과 비즈니스 적합성을 확인하는 단계다.

3-2 분석 환경 구축

> 3과목 · 빅데이터 모델링 / 주요항목: 분석모형 설계
> 문항 수: 4 (Q3-009 ~ Q3-012) · 난이도 하1/중2/상1 · 정답 분포 ①1 ②1 ③1 ④1
> 범위: 분석 도구(R·Python·SAS·SPSS) 선정과 특징 비교, 데이터 분할(훈련·검증·평가)

Q3-009 [난이도: 하] [태그: 3과목/분석모형설계/데이터분할]

분석가 A는 확보한 전체 데이터를 60:20:20의 비율로 세 부분으로 나누어 모델링을 진행하려 한다. 이 중 모델의 하이퍼파라미터(hyperparameter)를 튜닝하고 과대적합(overfitting) 발생 여부를 확인하는 데 사용하는 데이터는?

① 훈련 데이터(training data)
② 검증 데이터(validation data)
③ 평가 데이터(test data)
④ 원시 데이터(raw data)

✓ 정답 및 해설

정답: ②

- ① 훈련 데이터: 모델의 파라미터(가중치)를 **학습**시키는 데 사용. 튜닝·과적합 확인 용도가 아님.
- ② 검증 데이터: 학습 중간에 성능을 점검하며 **하이퍼파라미터 튜닝 + 과대적합 여부 확인**에 사용. ← 정답
- ③ 평가 데이터: 학습·튜닝이 모두 끝난 모델의 **최종 일반화 성능 측정**에만 사용.
- ④ 원시 데이터: 분할 이전의 가공되지 않은 수집 데이터를 가리키는 말로, 분할 3종에 속하지 않음.

출제 포인트: 데이터 3분할 역할 = **훈련(학습) / 검증(튜닝·과적합 확인) / 평가(최종 성능)**. "튜닝"이 보이면 무조건 검증 데이터.

근거: 검증 데이터(validation data)는 훈련 데이터로 학습된 모델의 하이퍼파라미터를 조정하고 과대적합 여부를 확인하기 위해 학습 과정에서 사용하는 데이터다.

Q3-010 [난이도: 중] [태그: 3과목/분석모형설계/분석도구]

빅데이터 분석 환경으로서 R과 Python(파이썬)에 대한 설명으로 가장 적절한 것은?

① R은 통계 분석에 특화된 오픈소스 언어이며, Python은 범용 언어로 웹 개발 등 다른 시스템과의 연동·확장에 유리하다.
② Python의 pandas는 R의 CRAN에 해당하는 것으로, 패키지를 배포·설치하는 중앙 저장소 역할을 한다.
③ R은 데이터를 메모리에 올려 처리하는 인메모리(in-memory) 방식이 아니므로, 대용량 데이터 처리 시 메모리 용량의 제약을 받지 않는다.

④ R은 웹 개발 등 여러 분야에서 쓰이도록 설계된 범용 언어이고, Python은 통계학자를 위해 개발된 통계 전용 언어이다.

> **✓ 정답 및 해설**
>
> **정답:** ①
>
> - ① R = 통계·시각화 특화, Python = 범용 언어(웹·시스템 연동·확장성). 두 도구의 표준적 비교. ← 정답
> - ② pandas는 데이터 분석용 **라이브러리**다. CRAN에 대응하는 Python의 패키지 **저장소**는 PyPI(Python Package Index). 라이브러리와 저장소 개념을 바꿔치기한 틀린 설명.
> - ③ R은 기본적으로 데이터를 메모리에 적재해 처리하는 **인메모리 방식**이므로, 메모리 용량이 대용량 처리의 제약이 된다. 두 사실을 모두 뒤집은 틀린 설명.
> - ④ R과 Python의 성격을 **서로 바꿔치기**한 서술. 통계학자 기반의 통계 특화 언어가 R, 범용 언어가 Python이다. 틀린 설명.
>
> **출제 포인트:** R = 통계 특화 + 인메모리 처리 + **저장소 CRAN** / Python = 범용 + **저장소 PyPI** + 라이브러리(pandas, scikit-learn 등). "특화 vs 범용", "저장소 vs 라이브러리"의 짝을 바꿔치기하는 선지에 주의.
>
> **근거:** R은 통계 분석과 시각화에 특화된 오픈소스 언어이고, Python은 범용 프로그래밍 언어로서 라이브러리를 통해 데이터 분석을 지원하며 다른 시스템과의 연동성이 높다.

Q3-011 [난이도: 중] [태그: 3과목/분석모형설계/데이터분할]

훈련·검증·평가 데이터의 역할에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 훈련 데이터는 모델의 파라미터(가중치)를 학습시키는 데 사용된다.
② 검증 데이터는 하이퍼파라미터 튜닝과 과대적합(overfitting) 발생 여부 확인에 사용된다.
③ 평가 데이터는 학습과 튜닝에 관여하지 않은 데이터로, 완성된 모델의 최종 성능 측정에 사용된다.
④ 평가 데이터로 하이퍼파라미터를 조정한 뒤 같은 평가 데이터로 최종 성능을 측정하면 일반화 성능을 객관적으로 평가할 수 있다.

> **✓ 정답 및 해설**
>
> **정답:** ④
>
> - ① 옳은 설명. 훈련 데이터의 역할은 모델 학습(파라미터 추정) 그 자체.
> - ② 옳은 설명. 튜닝·과적합 확인은 검증 데이터의 고유 역할.
> - ③ 옳은 설명. 평가 데이터는 모델 구축 과정에 한 번도 노출되지 않아야 최종 성능 측정이 유효하다.
> - ④ 하이퍼파라미터 튜닝은 **검증 데이터**의 역할이다. 평가 데이터를 튜닝에 쓰면 모델이 그 데이터에 맞춰지므로, 같은 데이터로 잰 성능은 일반화 성능을 **과대평가**하게 된다. ← 정답
>
> **출제 포인트:** 검증 데이터(튜닝) ↔ 평가 데이터(최종 측정)의 역할 바꿔치기가 단골 함정. "평가 데이터는 학습·튜닝 어디에도 쓰지 않는다"만 기억하면 걸러진다.
>
> **근거:** 평가 데이터(test data)는 모델의 학습과 하이퍼파라미터 튜닝 어디에도 사용되지 않은 데이터로, 최종 모델의 일반화 성능을 측정하는 데만 사용하는 데이터다.

Q3-012 [난이도: 상] [태그: 3과목/분석모형설계/분석도구선정]

빅데이터 분석 도구의 선정에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. R과 Python은 오픈소스(open source) 언어로 라이선스 비용 없이 사용할 수 있으며, 커뮤니티가 개발한 패키지를 통해 기능을 확장한다.
- ㄴ. SAS와 SPSS는 라이선스를 구매하여 사용하는 상용(commercial) 분석 도구로, 공급 업체(벤더)의 공식 기술 지원을 받을 수 있다.
- ㄷ. SPSS는 메뉴 선택 방식의 그래픽 사용자 인터페이스(GUI)를 제공하여 프로그래밍에 익숙하지 않은 사용자도 비교적 쉽게 사용할 수 있다.
- ㄹ. 상용 분석 도구는 오픈소스 도구보다 최신 분석 기법이 더 신속하게 반영되는 것이 일반적이다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄴ, ㄷ ④ ㄱ, ㄷ, ㄹ

✓ 정답 및 해설

정답: ③

- **ㄱ (O)** R·Python = **오픈소스·무료** + 커뮤니티 기반 패키지 생태계(CRAN·PyPI)로 기능 확장.
- **ㄴ (O)** SAS·SPSS = **상용 라이선스** 도구로, 벤더의 공식 기술 지원·유지보수를 받을 수 있는 것이 장점.
- **ㄷ (O)** SPSS는 메뉴(GUI) 방식 조작이 특징이라 코딩 부담이 적어 비전공자 접근성이 높다.
- **ㄹ (X)** 반대다. **오픈소스 도구는 전 세계 커뮤니티의 기여로 최신 분석 기법이 패키지 형태로 빠르게 반영**되는 것이 장점이고, 상용 도구는 벤더의 정식 배포 절차를 거치므로 상대적으로 반영이 느린 편이다.

따라서 옳은 것은 ㄱ, ㄴ, ㄷ → **③**. (①은 옳은 ㄷ을 누락, ②·④는 틀린 ㄹ을 포함)

출제 포인트: 오픈소스(R·Python) = 무료 + 커뮤니티 패키지 + 최신 기법 반영 빠름 + 공식 기술 지원은 없음 / 상용(SAS·SPSS) = 라이선스 비용 + 벤더 기술 지원 + (SPSS) GUI 친화. 두 진영의 장단점을 서로 바꿔치기한 선지가 단골 함정.

근거: R과 Python은 오픈소스 기반의 무료 분석 도구로 커뮤니티 패키지를 통해 최신 기법이 빠르게 반영되고, SAS와 SPSS는 벤더의 공식 기술 지원이 제공되는 상용 분석 도구이며, SPSS는 메뉴 방식의 GUI로 사용 편의성이 높다.

3-3 분석기법

> 3과목 · 빅데이터 모델링 / 주요항목: 분석기법 적용
> 문항 수: 22 (Q3-013 ~ Q3-034) · 범위: 회귀분석·로지스틱 회귀·의사결정나무·인공신경망·SVM·연관분석·군집분석

Q3-013 [난이도: 하] [태그: 3과목/분석기법적용/회귀분석가정]

선형 회귀분석(linear regression)에서 잔차의 **독립성(비상관성)** 을 검정하기 위해 사용하는 통계량은?

① 샤피로-윌크(Shapiro-Wilk) 검정
② 더빈-왓슨(Durbin-Watson) 통계량
③ 분산팽창지수(VIF)
④ 콜모고로프-스미르노프(Kolmogorov-Smirnov) 검정

✓ 정답 및 해설

정답: ②

- ① 샤피로-윌크 검정: 잔차의 **정규성** 검정에 사용. 독립성과 무관.
- ② 더빈-왓슨 통계량: 잔차 간 **자기상관(autocorrelation)** 존재 여부 검정. 2에 가까우면 독립(자기상관 없음). ← 정답
- ③ 분산팽창지수(VIF): 독립변수 간 **다중공선성(multicollinearity)** 진단 지표. 잔차 검정이 아님.
- ④ 콜모고로프-스미르노프 검정: 분포의 **정규성(적합도)** 검정에 사용.

출제 포인트: 회귀 가정별 진단 도구 매칭 — 독립성=더빈-왓슨(≈2이면 OK), 정규성=샤피로-윌크·K-S·Q-Q 플롯, 등분산성=잔차 산점도, 다중공선성=VIF. "독왓, 정샤, 등산(점도), 다V"로 암기.

근거: 더빈-왓슨(Durbin-Watson) 통계량은 회귀모형 잔차의 자기상관 여부를 검정하여 오차항의 독립성 가정을 진단하는 통계량이다.

Q3-014 [난이도: 중] [태그: 3과목/분석기법적용/다중공선성]

다중공선성(multicollinearity)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 일반적으로 분산팽창지수(VIF)가 10 이상이면 다중공선성이 있다고 판단한다.
② 다중공선성이 존재하면 회귀계수 추정치의 분산이 커져 해석의 신뢰성이 떨어진다.
③ 상관관계가 높은 변수 제거, 주성분 분석(PCA), 릿지(Ridge) 회귀 등으로 완화할 수 있다.
④ 다중공선성은 종속변수와 독립변수 사이의 상관관계가 지나치게 높을 때 발생한다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. VIF > 10이면 다중공선성 의심이 일반적 기준. ※ 교재별 표기 차이 있음(5를 기준으로 보는 교재도 있음).
- ② 옳은 설명. 회귀계수의 분산(표준오차)이 커져 계수의 부호·크기가 불안정해진다.
- ③ 옳은 설명. 해결법 3종 = 변수 제거 / 차원 축소(주성분 분석) / 규제 회귀(릿지 등).
- ④ 다중공선성은 **독립변수들 사이**의 강한 선형 관계 때문에 발생한다. 종속-독립 간 상관이 높은 것은 오히려 바람직. 틀린 설명. ← 정답

출제 포인트: "독립변수 vs 독립변수"의 문제라는 점이 핵심. 정의(독립변수 간 상관), 진단(VIF>10), 해결(제거·PCA·릿지) 3단 세트로 암기.

근거: 다중공선성(multicollinearity)은 회귀모형의 독립변수들 사이에 강한 선형 상관관계가 존재하여 회귀계수 추정이 불안정해지는 현상이다.

Q3-015 [난이도: 하] [태그: 3과목/분석기법적용/시그모이드]

로지스틱 회귀(logistic regression)에서 출력값을 0과 1 사이의 확률로 변환하기 위해 사용하는 시그모이드(sigmoid) 함수의 식은?

① $f(x) = 1 / (1 + e^{-x})$
② $f(x) = (e^{x} - e^{-x}) / (e^{x} + e^{-x})$
③ $f(x) = \max(0, x)$
④ $f(x) = e^{(x_i)} / \Sigma_j e^{(x_j)}$ (i번째 클래스 점수의 지수를 모든 클래스 j의 지수합으로 나눔)

✓ 정답 및 해설

정답: ①

- ① 시그모이드 함수. 출력 범위 **0~1**, S자 곡선. 로지스틱 회귀의 확률 변환 함수. ← 정답
- ② 하이퍼볼릭 탄젠트(tanh) 함수. 출력 범위 **-1~1**.
- ③ ReLU 함수. 출력 범위 0~∞, 인공신경망 은닉층에서 주로 사용.
- ④ 소프트맥스(softmax) 함수. 다중 클래스 확률(합=1) 출력용.

출제 포인트: 함수-식-범위 3종 세트 — 시그모이드 $1/(1+e^{-x})$은 0~1, tanh는 -1~1, ReLU는 max(0,x), 소프트맥스는 지수/지수합. 로지스틱 회귀의 종속변수는 **범주형**이라는 점도 함께 기억.

근거: 시그모이드(sigmoid) 함수는 $f(x)=1/(1+e^{-x})$로 정의되며 임의의 실수를 0과 1 사이의 값으로 변환하는 S자형 함수다.

Q3-016 [난이도: 중] [태그: 3과목/분석기법적용/오즈]

어떤 마케팅 캠페인에서 고객이 상품을 구매할 확률이 0.8이라고 한다. 이때 구매에 대한 오즈(odds)는?

① 0.25 ② 0.8 ③ 4 ④ 5

✓ 정답 및 해설

정답: ③

- 오즈(odds) = 성공 확률 / 실패 확률 = p / (1-p) = 0.8 / 0.2 = **4**
- ① 0.25는 (1-p)/p, 즉 실패 오즈(역수)를 구한 값. 분자·분모를 뒤집은 오답.
- ② 0.8은 확률(p) 그 자체. 오즈와 확률을 혼동한 오답.
- ③ 0.8/0.2 = 4. ← 정답
- ④ 5는 1/(1-p) = 1/0.2를 계산한 오답. 분자에 p가 아닌 1을 쓴 실수.

출제 포인트: 오즈 = p/(1-p). "성공이 실패의 몇 배인가". 오즈비(odds ratio)는 두 집단의 오즈를 나눈 값이며, 로지스틱 회귀계수를 지수 변환(e^{β})하면 오즈비가 된다는 것까지 연결해 암기.

근거: 오즈(odds)는 어떤 사건이 일어날 확률을 일어나지 않을 확률로 나눈 값 p/(1-p)로 정의된다.

Q3-017 [난이도: 하] [태그: 3과목/분석기법적용/의사결정나무알고리즘]

의사결정나무(decision tree) 알고리즘과 분리(분할) 기준의 연결로 옳은 것은?

① CART - 카이제곱 통계량
② C4.5 - 엔트로피(entropy)
③ CHAID - 지니 지수(Gini index)
④ CART - 엔트로피(entropy)

✓ 정답 및 해설

정답: ②

- ① CART의 분리 기준은 카이제곱이 아니라 **지니 지수**(분류 기준). 카이제곱은 CHAID.
- ② C4.5(및 전신 ID3)는 **엔트로피** 기반 정보이득(정보이득비)을 분리 기준으로 사용. ← 정답
- ③ CHAID의 분리 기준은 지니 지수가 아니라 **카이제곱 통계량**.
- ④ CART는 엔트로피가 아니라 **지니 지수**를 사용.

출제 포인트: 단골 암기 매칭 — **CART=지니, C4.5=엔트로피, CHAID=카이제곱**. "카트는 지니가 몰고, C4.5는 엔진(엔트로피), 차이(CHAID)는 카이(카이제곱)"로 암기. CART는 이진 분리, CHAID는 다지 분리라는 것도 부가 포인트.

근거: 의사결정나무 알고리즘의 대표적 분리 기준은 CART의 지니 지수, C4.5의 엔트로피(정보이득), CHAID의 카이제곱 통계량이다.

Q3-018 [난이도: 중] [태그: 3과목/분석기법적용/불순도가지치기]

의사결정나무(decision tree)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 지니 지수(Gini index)가 낮을수록 노드의 순도(purity)가 높다.
② 각 노드는 분리 전후의 정보이득(information gain)이 최대가 되는 변수와 기준으로 분리한다.
③ 가지치기(pruning)는 나무가 지나치게 복잡해져 발생하는 과대적합(overfitting)을 방지하기 위해 수행한다.
④ 엔트로피(entropy)가 0이면 노드의 불순도가 최대인 상태를 의미한다.

> **✓ 정답 및 해설**
>
> **정답:** ④
>
> - ① 옳은 설명. 지니 지수·엔트로피 같은 불순도 지표는 **낮을수록 순수**(한 범주로 쏠림).
> - ② 옳은 설명. 정보이득 = 분리 전 불순도 - 분리 후 불순도. 이득이 최대인 분리를 선택.
> - ③ 옳은 설명. 가지치기는 불필요한 가지를 제거해 일반화 성능을 높인다.
> - ④ 엔트로피 0은 모든 관측치가 한 범주뿐인 **완전히 순수한 상태**다. 불순도 최대는 범주가 반반 섞인 경우(이진 분류 시 엔트로피 1). 틀린 설명. ← 정답
>
> **출제 포인트:** 불순도 지표의 방향 — "0이면 순수, 클수록 혼합". 이진 분류 기준 최대값은 지니 0.5, 엔트로피 1. 분리는 "불순도 감소량(정보이득) 최대" 방향.
>
> **근거:** 엔트로피(entropy)는 노드 안에 서로 다른 범주가 섞여 있는 정도(불순도)를 나타내는 지표로, 한 범주만 존재하면 0이 되고 범주가 고르게 섞일수록 커진다.

Q3-019 [난이도: 중] [태그: 3과목/분석기법적용/인공신경망]

인공신경망(artificial neural network)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 단층 퍼셉트론(single-layer perceptron)은 XOR 문제와 같은 비선형 분류 문제를 해결할 수 있다.
② 다층 퍼셉트론(multi-layer perceptron)은 은닉층(hidden layer)을 추가하여 XOR 문제를 해결한다.
③ 역전파(backpropagation)는 출력층의 오차를 입력층 방향으로 거꾸로 전파하며 가중치를 갱신하는 학습 방법이다.
④ 시그모이드 계열 활성화 함수를 깊은 신경망에 사용하면 기울기 소실(gradient vanishing)이 발생할 수 있으며, ReLU 함수가 이를 완화한다.

✓ 정답 및 해설

정답: ①

- ① 단층 퍼셉트론은 **선형 분리 가능한** 문제(AND, OR)만 풀 수 있고, 비선형인 **XOR은 해결 불가**. 이 한계가 다층 퍼셉트론 등장의 배경. 틀린 설명. ← 정답
- ② 옳은 설명. 은닉층으로 비선형 결정 경계를 만들어 XOR 해결.
- ③ 옳은 설명. 오차를 뒤로 전파하며 경사하강법으로 가중치 조정.
- ④ 옳은 설명. 시그모이드 미분값의 최대가 0.25로 작아 층이 깊어지면 기울기가 소실됨. ReLU는 양수 구간 기울기가 1이라 이를 완화.

출제 포인트: 신경망 역사 스토리로 암기 — 단층 퍼셉트론의 XOR 한계 → 다층 퍼셉트론(은닉층) → 역전파 학습 → 기울기 소실 문제 → ReLU 등으로 완화.

근거: 단층 퍼셉트론은 하나의 선형 결정 경계만 학습할 수 있어 선형 분리가 불가능한 XOR 문제를 해결하지 못하며, 이는 은닉층을 갖는 다층 퍼셉트론으로 해결된다.

Q3-020 [난이도: 하] [태그: 3과목/분석기법적용/활성화함수]

인공신경망의 다중 클래스 분류 문제에서 출력층에 사용되며, 각 클래스에 속할 확률을 출력하고 그 확률의 합이 1이 되도록 하는 활성화 함수는?

① 시그모이드(sigmoid) ② ReLU ③ 소프트맥스(softmax) ④ 하이퍼볼릭 탄젠트(tanh)

✓ 정답 및 해설

정답: ③

- ① 시그모이드: 출력 0~1. **이진 분류** 출력층에 사용. 여러 클래스 확률의 합을 1로 만들지는 않음.
- ② ReLU: max(0, x). 은닉층에서 기울기 소실 완화용으로 사용. 확률 출력이 아님.
- ③ 소프트맥스: 각 클래스의 지수값을 전체 합으로 나눠 **확률 분포(합=1)** 를 출력. 다중 클래스 출력층 전용. ← 정답
- ④ tanh: 출력 -1~1. 은닉층용. 확률로 해석 불가.

출제 포인트: 출력층 함수 선택 공식 — 이진 분류=시그모이드, 다중 분류=소프트맥스, 회귀=항등함수. "합이 1"이라는 표현이 보이면 무조건 소프트맥스.

근거: 소프트맥스(softmax) 함수는 각 클래스 점수를 지수 변환한 뒤 전체 합으로 나누어 모든 클래스 확률의 합이 1이 되는 확률 분포를 출력하는 함수다.

Q3-021 [난이도: 중] [태그: 3과목/분석기법적용/SVM]

서포트 벡터 머신(SVM, Support Vector Machine)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 두 클래스 사이의 마진(margin)을 최대화하는 결정 경계(초평면)를 찾는다.
② 서포트 벡터(support vector)는 결정 경계에서 가장 멀리 떨어져 있는 데이터들이다.
③ 커널 트릭(kernel trick)은 저차원에서 선형 분리가 어려운 데이터를 고차원 공간으로 매핑하여 분리하는 기법이다.
④ 슬랙 변수(slack variable)를 도입하면 일부 오분류를 허용하는 소프트 마진(soft margin) 분류가 가능하다.

> **✓ 정답 및 해설**
>
> **정답:** ②
>
> - ① 옳은 설명. SVM의 목적 함수 자체가 마진 최대화.
> - ② 서포트 벡터는 결정 경계에 **가장 가까이** 있어 경계(마진)를 결정하는 데이터다. "가장 멀리"는 정반대 서술. ← 정답
> - ③ 옳은 설명. 실제 고차원 변환 계산 없이 커널 함수로 내적을 대신 계산하는 것이 커널 트릭의 핵심.
> - ④ 옳은 설명. 슬랙 변수 = 오차 허용량. 하드 마진(오류 불허) ↔ 소프트 마진(일부 허용).
>
> **출제 포인트:** SVM 4대 키워드 — 마진 **최대화**, 서포트 벡터는 경계에 **가장 가까운** 점, 커널 트릭은 **고차원 매핑**, 슬랙 변수는 **오분류 허용**. "가깝다/멀다"를 바꿔치기하는 함정이 단골.
>
> **근거:** 서포트 벡터(support vector)는 결정 경계(초평면)에 가장 가까이 위치하여 마진의 폭을 결정하는 관측치들을 말한다.

Q3-022 [난이도: 상] [태그: 3과목/분석기법적용/연관분석계산]

전체 거래 10건 중 상품 A를 포함한 거래가 5건, 상품 B를 포함한 거래가 4건, A와 B를 모두 포함한 거래가 2건이다. 연관규칙 "A → B"의 지지도(support), 신뢰도(confidence), 향상도(lift)를 순서대로 구한 것은?

① 지지도 0.2, 신뢰도 0.4, 향상도 1.0
② 지지도 0.2, 신뢰도 0.5, 향상도 1.25
③ 지지도 0.4, 신뢰도 0.2, 향상도 0.5
④ 지지도 0.5, 신뢰도 0.4, 향상도 0.8

✓ 정답 및 해설

정답: ①

- 지지도 = P(A∩B) = 2/10 = **0.2**
- 신뢰도 = P(A∩B)/P(A) = 2/5 = **0.4**
- 향상도 = 신뢰도/P(B) = 0.4/(4/10) = 0.4/0.4 = **1.0** → ① ← 정답
- ② 신뢰도를 P(A∩B)/P(B) = 2/4로 잘못 계산한 오답(분모는 조건부의 기준인 A).
- ③ 지지도와 신뢰도의 값을 서로 뒤바꾼 오답.
- ④ 지지도 자리에 P(A) = 0.5를 쓴 오답. 지지도는 A·B 동시 구매 비율이다.

출제 포인트: 공식 3종 — 지지도 P(A∩B), 신뢰도 P(A∩B)/P(A), 향상도 신뢰도/P(B). 향상도 = 1이면 A와 B는 **서로 독립**, > 1이면 양의 연관, < 1이면 음의 연관. 아프리오리(Apriori) 원리: 빈발하지 않은 항목집합의 상위집합은 빈발할 수 없다(최소 지지도로 후보 가지치기).

근거: 연관분석에서 지지도는 전체 거래 중 두 품목이 동시에 포함된 비율 P(A∩B), 신뢰도는 A 구매 시 B도 구매할 조건부확률 P(B|A), 향상도는 신뢰도를 P(B)로 나눈 값이다.

Q3-023 [난이도: 상] [태그: 3과목/분석기법적용/군집분석]

군집분석(clustering)에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. K-평균 군집(K-means)은 초기 중심값의 선택과 이상값(outlier)에 민감하다.
- ㄴ. 단일 연결법(single linkage)은 두 군집 간 관측치 쌍의 거리 중 가장 먼 거리를 군집 간 거리로 사용한다.
- ㄷ. DBSCAN은 밀도 기반 군집 방법으로, 군집 수를 사전에 지정할 필요가 없고 노이즈(noise)를 별도로 식별한다.
- ㄹ. 실루엣 계수(silhouette coefficient)는 -1에서 1 사이의 값을 가지며 1에 가까울수록 군집화가 잘 된 것이다.

① ㄱ, ㄴ, ㄷ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄴ ④ ㄱ, ㄷ, ㄹ

✓ 정답 및 해설

정답: ④

- **ㄱ (O)** K-평균의 대표 단점 — 초기 중심값에 따라 결과가 달라지고, 평균 기반이라 이상값에 민감하며, 군집 수 K를 미리 정해야 한다.
- **ㄴ (X)** 단일 연결법은 **가장 가까운(최단)** 거리를 군집 간 거리로 사용한다. 가장 먼 거리는 **완전 연결법(complete linkage)**. 이 밖에 평균 연결법(평균 거리), 와드 연결법(Ward, 군집 내 분산 증가분 최소)이 있다.
- **ㄷ (O)** DBSCAN은 밀도가 높은 영역을 군집으로 묶고, 어느 군집에도 속하지 않는 저밀도 점을 노이즈로 분류한다.
- **ㄹ (O)** 실루엣 계수는 군집 내 응집도와 군집 간 분리도를 함께 반영하며 범위는 -1 ~ 1, 1에 가까울수록 좋다.

따라서 옳은 것은 ㄱ, ㄷ, ㄹ → ④. (①·③은 틀린 ㄴ을 포함, ②도 ㄴ을 포함하고 옳은 ㄱ을 누락)

출제 포인트: 연결법은 이름-거리 매칭으로 — 단일=최단, 완전=최장, 평균=평균, 와드=분산. 계층적 군집의 결과는 덴드로그램(dendrogram)으로 표현. "군집 수 미지정 + 노이즈"가 보이면 DBSCAN.

근거: 단일 연결법(single linkage)은 두 군집에 속한 관측치 쌍 사이 거리 중 최솟값(최단 거리)을 군집 간 거리로 정의하는 계층적 군집의 연결 방법이다.

Q3-024 [난이도: 하] [태그: 3과목/분석기법적용/회귀분석가정]

선형 회귀분석의 가정 중 '잔차(오차항)의 분산이 독립변수의 값에 관계없이 일정해야 한다'는 것은?

① 선형성(linearity)
② 등분산성(homoscedasticity)
③ 정규성(normality)
④ 독립성(independence)

✓ 정답 및 해설

정답: ②

- ① 선형성: 종속변수와 독립변수의 관계가 **선형(직선적)** 이어야 한다는 가정. 분산과 무관.
- ② 등분산성: 잔차의 **분산이 일정**해야 한다는 가정. 잔차 산점도가 특정 패턴 없이 고르게 퍼져 있어야 만족. ← 정답
- ③ 정규성: 잔차가 **정규분포**를 따라야 한다는 가정(샤피로-윌크, Q-Q 플롯으로 확인).
- ④ 독립성: 잔차들 사이에 **자기상관이 없어야** 한다는 가정(더빈-왓슨 통계량으로 확인).

출제 포인트: 회귀 가정 5종 세트 — 선형성·독립성·등분산성·정규성·비상관성. "분산이 일정"이라는 표현이 보이면 즉시 등분산성. 위배되어 잔차가 깔때기 모양으로 퍼지면 이분산(heteroscedasticity).

근거: 등분산성(homoscedasticity)은 회귀모형에서 오차항의 분산이 모든 독립변수 값에 대해 동일하다는 가정이다.

Q3-025 [난이도: 중] [태그: 3과목/분석기법적용/회귀분석가정]

선형 회귀분석의 가정과 진단에 대한 설명으로 옳지 **않은** 것은?

① 선형성은 종속변수와 독립변수 사이에 선형 관계가 존재해야 한다는 가정이다.
② 정규성은 잔차가 정규분포를 따라야 한다는 가정으로, Q-Q 플롯이나 샤피로-윌크(Shapiro-Wilk) 검정으로 확인한다.
③ 잔차 산점도가 깔때기 모양으로 퍼지는 형태이면 등분산성 가정이 만족된 것이다.
④ 더빈-왓슨(Durbin-Watson) 통계량이 2에 가까우면 잔차의 자기상관이 없다고 판단한다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 선형성 위배 시 변수 변환(로그·제곱 등)이나 비선형 모형을 고려한다.
- ② 옳은 설명. 정규성 확인 도구 = Q-Q 플롯, 샤피로-윌크, 콜모고로프-스미르노프.
- ③ 깔때기 모양(잔차의 퍼짐이 점점 커지거나 작아짐)은 분산이 일정하지 않다는 뜻, 즉 **등분산성 위배(이분산)** 의 신호다. 등분산성 만족 시 잔차는 0을 중심으로 **패턴 없이 고르게** 흩어진다. 틀린 설명. ← 정답
- ④ 옳은 설명. 더빈-왓슨 ≈ 2이면 독립, 0에 가까우면 양의 자기상관, 4에 가까우면 음의 자기상관.

출제 포인트: 잔차 산점도 판독 — "패턴 없음 = 정상, 깔때기 = 이분산, 곡선 패턴 = 비선형성 위배". 더빈-왓슨의 0/2/4 구간 해석까지 세트로 암기.

근거: 잔차 산점도에서 잔차의 퍼짐이 독립변수 값에 따라 체계적으로 변하는 깔때기 형태는 오차항의 분산이 일정하지 않은 이분산성을 나타낸다.

Q3-026 [난이도: 중] [태그: 3과목/분석기법적용/로지스틱회귀]

로지스틱 회귀(logistic regression)에 대한 설명으로 옳지 **않은** 것은?

① 종속변수가 범주형(예: 구매/미구매)일 때 사용하는 회귀 기법이다.
② 회귀계수 β를 지수 변환한 값 e^β는 오즈비(odds ratio)로 해석된다.
③ 시그모이드(sigmoid) 함수를 통해 출력값을 0과 1 사이의 확률로 변환한다.
④ 오즈(odds)는 확률과 마찬가지로 항상 0과 1 사이의 값을 가진다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. 종속변수가 **범주형**이라는 점이 선형 회귀(연속형)와의 핵심 차이.
- ② 옳은 설명. 독립변수가 1단위 증가할 때 오즈가 e^β배 변한다는 의미.
- ③ 옳은 설명. 시그모이드 $1/(1+e^{-x})$로 확률(0~1)을 출력한다.
- ④ 오즈 = p/(1-p)의 범위는 **0 ~ ∞** 다. 예를 들어 p=0.8이면 오즈는 4로 1을 넘는다. 0~1 사이인 것은 확률. 틀린 설명. ← 정답

출제 포인트: 범위 3종 구분 — 확률 0~1, 오즈 0~∞, 로짓(log odds) -∞~+∞. "확률 → 오즈 → 로짓" 순서로 범위가 넓어진다고 암기.

근거: 오즈(odds)는 성공 확률을 실패 확률로 나눈 p/(1-p)로 정의되어 0 이상 무한대까지의 값을 가지며, 확률처럼 1을 상한으로 하지 않는다.

Q3-027 [난이도: 하] [태그: 3과목/분석기법적용/SOM]

고차원의 입력 데이터를 저차원(주로 2차원)의 격자 형태 뉴런으로 매핑하여 입력 패턴 간의 위상적(topological) 관계를 보존하는 비지도학습 신경망 기법은?

① 자기조직화지도(SOM, Self-Organizing Map)
② DBSCAN
③ 다층 퍼셉트론(multi-layer perceptron)
④ 서포트 벡터 머신(SVM)

✓ 정답 및 해설

정답: ①

- ① SOM: 입력층과 경쟁층(2차원 격자)으로 구성된 **비지도 신경망**. 유사한 입력은 격자 위 가까운 뉴런으로 매핑되어 위상 관계가 보존된다. 군집화·시각화에 활용. ← 정답
- ② DBSCAN: 밀도 기반 **군집 알고리즘**. 신경망이 아니며 격자 매핑과 무관.
- ③ 다층 퍼셉트론: 정답(레이블)을 학습하는 **지도학습** 신경망. 비지도가 아님.
- ④ SVM: 마진 최대화 초평면을 찾는 **지도학습** 분류 기법.

출제 포인트: SOM 3대 키워드 = "저차원 격자", "위상 보존", "비지도 신경망". 신경망인데 비지도라는 점이 함정 포인트 — 역전파를 쓰지 않고 경쟁학습(승자독식)으로 학습한다.

근거: 자기조직화지도(SOM)는 고차원 입력을 저차원 격자의 뉴런으로 매핑하면서 입력 공간의 위상적 구조를 보존하는 코호넨(Kohonen)의 비지도학습 신경망이다.

Q3-028 [난이도: 중] [태그: 3과목/분석기법적용/K-means절차]

K-평균 군집(K-means clustering)의 수행 절차를 순서대로 바르게 나열한 것은?

- ㄱ. 군집 수 K를 정하고 초기 중심점(centroid)을 선택한다.
- ㄴ. 각 관측치를 가장 가까운 중심점의 군집에 할당한다.
- ㄷ. 각 군집에 속한 관측치들의 평균으로 중심점을 갱신한다.
- ㄹ. 중심점이 더 이상 변하지 않을 때까지 할당과 갱신을 반복한다.

① ㄱ → ㄷ → ㄴ → ㄹ
② ㄱ → ㄴ → ㄷ → ㄹ
③ ㄴ → ㄱ → ㄷ → ㄹ
④ ㄱ → ㄴ → ㄹ → ㄷ

> **✓ 정답 및 해설**
>
> **정답: ②**
>
> - 올바른 순서: **초기화(ㄱ) → 할당(ㄴ) → 중심 갱신(ㄷ) → 수렴까지 반복(ㄹ)**. ← ②
> - ① 관측치를 할당하기 전에는 군집이 없어 평균(중심 갱신)을 구할 수 없다. ㄷ이 ㄴ보다 먼저 올 수 없음.
> - ③ 중심점이 없는 상태에서는 "가장 가까운 중심"으로 할당(ㄴ)할 수 없다. ㄱ이 항상 첫 단계.
> - ④ 반복(ㄹ)은 할당·갱신이 한 사이클 돈 뒤의 종료 조건이므로 ㄷ보다 앞에 올 수 없다.
>
> **출제 포인트:** "초기화 → 할당 → 갱신 → 반복" 4단계. 단점 3종도 세트로 — ① 군집 수 K를 미리 지정해야 함, ② 초기 중심값에 따라 결과가 달라짐, ③ 평균 기반이라 이상값(outlier)에 민감.
>
> **근거:** K-평균 군집은 K개의 초기 중심점을 정한 뒤 각 관측치를 최근접 중심에 할당하고 군집 평균으로 중심을 갱신하는 과정을 수렴할 때까지 반복하는 비계층적 군집 방법이다.

Q3-029 [난이도: 하] [태그: 3과목/분석기법적용/계층적군집연결법]

계층적 군집분석에서 두 군집을 병합할 때 '군집 내 오차제곱합(분산)의 증가분이 최소가 되는 군집끼리 병합'하는 연결 방법은?

① 단일 연결법(single linkage)
② 완전 연결법(complete linkage)
③ 평균 연결법(average linkage)
④ 와드 연결법(Ward linkage)

✓ 정답 및 해설

정답: ④

- ① 단일 연결법: 두 군집 간 관측치 쌍의 **최단 거리**를 군집 간 거리로 사용. 분산과 무관.
- ② 완전 연결법: 관측치 쌍의 **최장 거리**를 군집 간 거리로 사용.
- ③ 평균 연결법: 모든 관측치 쌍 거리의 **평균**을 군집 간 거리로 사용.
- ④ 와드 연결법: 병합 시 **군집 내 분산(오차제곱합)의 증가분이 최소**인 쌍을 병합. 거리 기반이 아닌 분산 기반. ← 정답

출제 포인트: 연결법 매칭 암기 — **단일=최단, 완전=최장, 평균=평균, 와드=분산**. "분산·오차제곱합"이라는 단어가 보이면 무조건 와드. 병합 과정은 덴드로그램(dendrogram)으로 표현된다.

근거: 와드 연결법(Ward linkage)은 두 군집을 병합했을 때 군집 내 오차제곱합의 증가량이 가장 작은 군집 쌍을 병합하는 계층적 군집의 연결 방법이다.

Q3-030 [난이도: 중] [태그: 3과목/분석기법적용/군집분석]

군집분석에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 계층적 군집의 결과는 덴드로그램(dendrogram)으로 시각화하며, 절단 높이에 따라 군집 수를 사후에 결정할 수 있다.
② DBSCAN은 반경(ε)과 최소 관측치 수(minPts)로 밀도를 정의하여 군집을 형성하고, 저밀도 지역의 점은 노이즈(noise)로 분류한다.
③ 병합적 계층 군집에서는 한 번 같은 군집으로 병합된 관측치도 이후 단계에서 다른 군집으로 재배정될 수 있다.
④ 실루엣 계수(silhouette coefficient)가 0에 가까운 관측치는 두 군집의 경계 부근에 위치함을 의미한다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 군집 수를 미리 정하지 않아도 되는 것이 계층적 군집의 장점.
- ② 옳은 설명. DBSCAN은 군집 수 사전 지정이 불필요하고 임의 모양의 군집·노이즈 탐지가 가능.
- ③ 계층적 군집은 **한 번 병합(또는 분리)되면 되돌리거나 재배정할 수 없다**. 재배정이 가능한 것은 K-평균 같은 비계층적(분할적) 군집의 특징. 틀린 설명. ← 정답
- ④ 옳은 설명. 실루엣 계수는 -1~1 범위로, 1에 가까우면 군집화 양호, 0 부근이면 경계, 음수면 잘못 배정된 것.

출제 포인트: 계층적 vs 비계층적 핵심 대비 — 계층적은 "병합 후 번복 불가 + 군집 수 사후 결정", K-평균은 "반복마다 재할당 + 군집 수 사전 지정". 실루엣 해석은 1/0/-1 세 지점으로 암기.

근거: 계층적 군집분석은 관측치를 순차적으로 병합하거나 분할하는 방법으로, 일단 병합된 관측치는 이후 단계에서 다른 군집으로 재배정되지 않는다.

Q3-031 [난이도: 중] [태그: 3과목/분석기법적용/향상도해석]

편의점 거래 데이터에서 연관규칙 "라면 → 김밥"의 신뢰도(confidence)는 0.6이고, 전체 거래 중 김밥이 포함된 거래의 비율은 0.3이다. 이 규칙의 향상도(lift)와 그 해석으로 옳은 것은?

① 향상도는 2이며, 1보다 크므로 라면과 김밥은 서로 독립이다.
② 향상도는 2이며, 라면 구매 고객이 김밥을 살 확률이 전체 고객 평균의 2배이므로 양(+)의 연관관계가 있다.
③ 향상도는 2이며, 1보다 크므로 라면 구매가 김밥 구매를 억제하는 음(-)의 연관관계가 있다.
④ 향상도는 신뢰도에 김밥 구매 비율을 곱한 0.18이다.

✓ 정답 및 해설

정답: ②

- 향상도 = 신뢰도 / P(김밥) = 0.6 / 0.3 = **2**
- ① 계산은 맞지만 해석이 틀림. 독립은 향상도가 **정확히 1**일 때다.
- ② 향상도 > 1 → 규칙의 조건(라면)이 결과(김밥)의 구매 확률을 **높이는 양의 연관**. ← 정답
- ③ 음의 연관은 향상도가 **1보다 작을 때**다. 방향을 뒤집은 오답.
- ④ 향상도는 신뢰도를 P(B)로 **나누는** 것이지 곱하는 것이 아니다. 공식 오류.

출제 포인트: 향상도 해석 3구간 — **>1 양의 연관, =1 독립, <1 음의 연관**. "우연히 같이 팔릴 확률 대비 몇 배인가"로 이해하면 안 헷갈린다.

근거: 향상도(lift)는 신뢰도를 결과 항목의 지지도 P(B)로 나눈 값으로, 1이면 두 품목이 독립이고 1보다 크면 양의 연관, 작으면 음의 연관을 의미한다.

Q3-032 [난이도: 상] [태그: 3과목/분석기법적용/Apriori]

연관분석의 아프리오리(Apriori) 알고리즘에 대한 설명으로 옳은 것은?

① 항목집합 {A, B}가 최소 지지도를 만족하지 못하면, {A, B, C}는 후보 항목집합에서 제외할 수 있다.
② 어떤 항목집합의 지지도가 낮으면 그 부분집합(subset)의 지지도도 반드시 더 낮다.
③ 최소 향상도(lift)를 기준으로 후보 항목집합을 가지치기하여 탐색 공간을 줄인다.
④ 가능한 모든 항목집합 조합을 빠짐없이 탐색하므로 항목 수가 늘어도 계산량은 변하지 않는다.

✓ 정답 및 해설

정답: ①

- ① 아프리오리 원리: **빈발하지 않은 항목집합의 상위집합(superset)은 절대 빈발할 수 없다**. {A,B}가 탈락하면 이를 포함하는 {A,B,C}, {A,B,D} 등은 계산 없이 제외. ← 정답
- ② 방향이 반대다. 부분집합의 지지도는 원래 집합보다 **크거나 같다**({A}를 산 거래는 {A,B}를 산 거래를 항상 포함).
- ③ 후보 가지치기의 기준은 향상도가 아니라 **최소 지지도(minimum support)** 다.
- ④ 아프리오리 원리로 후보를 가지치기하는 것이 알고리즘의 존재 이유다. 모든 조합을 탐색하지 않으므로 계산량이 크게 줄어든다.

출제 포인트: 아프리오리 = "비빈발 집합의 상위집합은 비빈발" + "가지치기 기준은 최소 지지도". 지지도의 반단조성(부분집합 지지도 ≥ 원집합 지지도)까지 이해하면 ②형 함정을 피할 수 있다.

근거: 아프리오리(Apriori) 원리는 어떤 항목집합이 빈발하면 그 모든 부분집합도 빈발하고, 빈발하지 않으면 그 모든 상위집합도 빈발하지 않는다는 성질로, 최소 지지도 기반 후보 가지치기에 이용된다.

Q3-033 [난이도: 중] [태그: 3과목/분석기법적용/활성화함수]

인공신경망의 활성화 함수(activation function)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 하이퍼볼릭 탄젠트(tanh) 함수의 출력 범위는 -1에서 1 사이다.
② ReLU 함수는 f(x) = max(0, x)로, 양수 구간의 기울기가 1이어서 기울기 소실(gradient vanishing) 문제를 완화한다.
③ 시그모이드(sigmoid) 함수는 입력의 절댓값이 커지면 기울기가 0에 가까워져 깊은 신경망에서 기울기 소실을 유발할 수 있다.
④ ReLU 함수는 출력 범위가 0과 1 사이이므로 이진 분류의 출력층에서 확률로 바로 사용된다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. tanh는 -1~1 출력으로 시그모이드(0~1)보다 출력의 중심이 0이라 학습에 유리한 면이 있다.
- ② 옳은 설명. ReLU는 은닉층의 표준 선택. 단, 음수 입력이 계속되면 뉴런이 죽는(dying ReLU) 단점도 있다.
- ③ 옳은 설명. 시그모이드 미분값의 최댓값이 0.25라 층을 거칠수록 기울기가 급격히 작아진다.
- ④ ReLU의 출력 범위는 **0 ~ ∞** 다. 확률(0~1) 출력용이 아니며, 이진 분류 출력층에는 **시그모이드**를 쓴다. 틀린 설명. ← 정답

출제 포인트: 함수별 출력 범위 암기표 — 시그모이드 0~1, tanh -1~1, ReLU 0~∞, 소프트맥스 0~1(합=1). 용도는 "은닉층=ReLU, 이진 출력=시그모이드, 다중 출력=소프트맥스".

근거: ReLU 함수는 f(x)=max(0,x)로 정의되어 출력이 0 이상 무한대까지의 값을 가지므로 확률 출력이 필요한 분류 출력층이 아닌 은닉층에서 주로 사용된다.

Q3-034 [난이도: 상] [태그: 3과목/분석기법적용/지도비지도귀속]

분석기법과 학습 유형의 연결이 옳은 것만 모두 고른 것은?

- ㄱ. 로지스틱 회귀(logistic regression) – 지도학습
- ㄴ. K-평균 군집(K-means) – 지도학습
- ㄷ. 연관분석(association analysis) – 비지도학습
- ㄹ. 서포트 벡터 머신(SVM) – 지도학습
- ㅁ. 자기조직화지도(SOM) – 비지도학습

① ㄱ, ㄴ, ㄷ, ㄹ
② ㄱ, ㄷ, ㄹ
③ ㄱ, ㄷ, ㄹ, ㅁ
④ ㄴ, ㄷ, ㅁ

✓ 정답 및 해설

정답: ③

- **ㄱ (O)** 로지스틱 회귀는 정답(범주 레이블)이 있는 데이터를 학습 → 지도학습.
- **ㄴ (X)** K-평균은 레이블 없이 거리 기반으로 묶는 **비지도학습**. "K를 미리 정한다"는 것과 지도학습은 별개다.
- **ㄷ (O)** 연관분석은 레이블 없이 품목 간 규칙을 찾는 비지도학습.
- **ㄹ (O)** SVM은 클래스 레이블로 결정 경계를 학습 → 지도학습.
- **ㅁ (O)** SOM은 신경망이지만 레이블 없이 경쟁학습으로 매핑 → 비지도학습.

따라서 옳은 것은 ㄱ, ㄷ, ㄹ, ㅁ → ③. (①·④는 틀린 ㄴ 포함, ②는 옳은 ㅁ 누락)

출제 포인트: 귀속 기준은 단 하나 — "정답(레이블)을 주고 학습하는가". 지도 = 회귀·로지스틱·의사결정나무·SVM·인공신경망(분류/예측), 비지도 = 군집·연관분석·SOM·주성분분석. "신경망 = 지도"로 일반화하면 SOM 함정에 걸린다.

근거: 지도학습은 입력과 정답 레이블의 쌍으로 모형을 학습하는 방식이고, 비지도학습은 레이블 없이 데이터의 구조·패턴(군집, 연관규칙 등)을 찾는 방식이다.

3-4 고급 분석 기법

> 3과목 · 빅데이터 모델링 / 주요항목: 분석기법 적용
> 문항 수: 26 (Q3-035 ~ Q3-060) · 범위: 범주형 자료 분석 · 시계열 분석 · 나이브베이즈 · 딥러닝 · 비정형 데이터 분석 · SNA · 앙상블 · 비모수 검정

Q3-035 [난이도: 하] [태그: 3과목/분석기법적용/카이제곱검정]

하나의 표본을 두 개의 범주형 변수로 교차분류한 분할표(contingency table)를 이용하여, 두 변수 사이에 연관성이 있는지를 검정하는 카이제곱 검정의 용도는?

① 적합도 검정 ② 독립성 검정 ③ 동질성 검정 ④ 등분산 검정

✓ 정답 및 해설

정답: ②

- ① 적합도 검정: **한 개의 범주형 변수**의 관측 분포가 이론(기대) 분포와 일치하는지 검정. 두 변수의 연관성과 무관.
- ② 독립성 검정: **한 표본**을 두 범주형 변수로 교차분류하여 두 변수의 연관(독립) 여부를 검정. ← 정답
- ③ 동질성 검정: **여러 모집단에서 각각 표본을 추출**하여 범주형 변수의 분포가 모집단 간에 동일한지 검정. 표본 추출 방식이 다름.
- ④ 등분산 검정: 분산의 동일성 검정(F-검정 등)으로, 카이제곱 검정의 3용도에 속하지 않음.

출제 포인트: 카이제곱 3용도 = **적합도(변수 1개, 이론분포와 비교) / 독립성(표본 1개, 변수 2개) / 동질성(표본 여러 개, 분포 비교)**. "표본 수와 변수 수"로 구분.

근거: 독립성 검정(test of independence)은 하나의 표본을 두 범주형 변수로 교차분류한 분할표에서 두 변수가 서로 독립인지(연관이 있는지)를 카이제곱 통계량으로 검정하는 방법이다.

Q3-036 [난이도: 중] [태그: 3과목/분석기법적용/피셔정확검정]

신약 투여 여부와 부작용 발생 여부를 2×2 분할표로 정리하였더니 표본 수가 매우 작아 기대빈도가 5 미만인 셀이 다수 발생하였다. 이 경우 두 변수의 연관성을 검정하기에 가장 적절한 방법은?

① 피셔 정확 검정(Fisher's exact test)
② 카이제곱 독립성 검정
③ 런 검정(run test)
④ F-검정

> **✓ 정답 및 해설**
>
> **정답:** ①
>
> - ① 피셔 정확 검정: 기대빈도가 작은(관례적으로 5 미만 셀이 많은) 분할표에서 카이제곱 근사 대신 **정확한 확률을 직접 계산**하여 검정. ← 정답
> - ② 카이제곱 독립성 검정: 기대빈도가 충분히 클 때 근사가 성립. 기대빈도가 작으면 근사가 부정확해져 부적절.
> - ③ 런 검정: 자료의 배열이 **무작위인지**를 검정하는 비모수 기법. 분할표 연관성 검정이 아님.
> - ④ F-검정: 분산비 비교(등분산·분산분석)에 사용. 범주형 연관성 검정이 아님.
>
> **출제 포인트:** "표본이 작다 + 기대빈도 5 미만" 키워드가 보이면 즉시 피셔 정확 검정. 카이제곱은 대표본 근사 검정이라는 점과 대비해 암기.
>
> **근거:** 피셔 정확 검정(Fisher's exact test)은 분할표의 셀 기대빈도가 작아 카이제곱 근사를 쓰기 어려울 때 초기하분포에 기반해 정확한 유의확률을 직접 계산하는 검정 방법이다.

Q3-037 [난이도: 하] [태그: 3과목/분석기법적용/분할표기대빈도]

전체 200명을 성별과 찬반으로 교차분류한 분할표에서 '남성' 행의 합계는 80명, '찬성' 열의 합계는 50명이다. 독립성 검정을 위한 (남성, 찬성) 셀의 기대빈도는?

① 10 ② 16 ③ 20 ④ 25

> **✓ 정답 및 해설**
>
> **정답:** ③
>
> 기대빈도 = (행 합계 × 열 합계) ÷ 전체 = (80 × 50) ÷ 200 = **20**
>
> - ① 10: 80×50÷400처럼 전체를 잘못 넣은 값. 오답.
> - ② 16: 80×0.2처럼 비율을 잘못 곱한 값. 오답.
> - ③ 20: (80×50)/200. 공식 그대로 계산한 값. ← 정답
> - ④ 25: 열 합계 50의 절반을 취한 값으로 공식과 무관. 오답.
>
> **출제 포인트:** 기대빈도 공식 = **(행 합 × 열 합) ÷ 전체 합**. 카이제곱 통계량은 Σ(관측−기대)²/기대 로 이 기대빈도를 사용한다.
>
> **근거:** 독립성 검정에서 각 셀의 기대빈도는 두 변수가 독립이라는 가정 하에 (해당 행의 합계 × 해당 열의 합계) ÷ 전체 표본 수로 계산된다.

Q3-038 [난이도: 중] [태그: 3과목/분석기법적용/시계열정상성]

시계열의 정상성(stationarity)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 정상 시계열의 평균은 시점에 관계없이 일정하다.
② 공분산은 시점 자체가 아니라 시차(lag)에만 의존한다.
③ 평균이 일정하지 않은 비정상 시계열은 차분(differencing)으로 정상화할 수 있다.
④ 정상 시계열의 분산은 시점에 따라 증가하거나 감소할 수 있다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. 평균 일정은 정상성의 기본 조건.
- ② 옳은 설명. 공분산이 시점이 아닌 시차에만 의존하는 것도 정상성 조건.
- ③ 옳은 설명. 평균의 비정상성은 차분으로 제거한다. (분산의 비정상성은 로그 변환 등 변환으로 안정화)
- ④ 정상 시계열은 **분산도 시점에 관계없이 일정**해야 한다. 틀린 설명. ← 정답

출제 포인트: 정상성 3조건 = **평균 일정 / 분산 일정 / 공분산은 시차에만 의존**. 처방 매칭: 평균 비정상 → 차분, 분산 비정상 → 로그(자연로그) 변환.

근거: 정상성이란 시계열의 평균과 분산이 시점에 관계없이 일정하고 공분산이 시차에만 의존하는 성질로, 시계열 모형 적합의 전제 조건이 된다.

Q3-039 [난이도: 하] [태그: 3과목/분석기법적용/시계열분해]

시계열 분해(decomposition)의 구성 요소 중, 아이스크림 판매량이 매년 여름마다 증가하는 것처럼 '일정한 주기(1년 이내)로 반복되는 변동'에 해당하는 것은?

① 계절 요인(seasonal factor)
② 추세 요인(trend factor)
③ 순환 요인(cyclical factor)
④ 불규칙 요인(irregular factor)

✓ 정답 및 해설

정답: ①

- ① 계절 요인: 계절·월·요일처럼 **고정된 주기로 반복**되는 변동. ← 정답
- ② 추세 요인: 장기적으로 증가·감소하는 **방향성 있는 흐름**. 반복 주기가 아님.
- ③ 순환 요인: 경기 변동처럼 **주기가 일정하지 않고 1년보다 긴** 장기 반복 변동. 매년 여름 반복과 다름.
- ④ 불규칙 요인: 추세·계절·순환으로 설명되지 않는 **예측 불가능한 우연 변동**.

출제 포인트: 시계열 분해 4요소 = **추세·계절·순환·불규칙**. 계절 vs 순환 구분이 단골 — "주기 고정·1년 이내 = 계절 / 주기 불규칙·장기 = 순환". ※ 교재별 표기 차이 있음 — 순환 요인의 주기 기준(1년 이상 등)은 교재마다 서술이 다를 수 있음.

근거: 시계열 분해는 시계열을 추세 요인, 계절 요인, 순환 요인, 불규칙 요인의 네 가지 변동 요인으로 나누어 설명하는 분석 방법이다.

Q3-040 [난이도: 중] [태그: 3과목/분석기법적용/ARIMA]

ARIMA(p, d, q) 모형의 각 차수에 대한 설명으로 옳은 것은?

① p는 이동평균 부분의 차수를 의미한다.
② d는 시계열을 정상화하기 위해 수행한 차분의 횟수를 의미한다.
③ q는 자기회귀 부분의 차수를 의미한다.
④ d는 계절 주기의 길이를 의미한다.

✓ 정답 및 해설

정답: ②

- ① p는 이동평균이 아니라 **자기회귀(AR)** 부분의 차수. 오답.
- ② d는 정상성 확보를 위한 **차분(I, integrated) 횟수**. ← 정답
- ③ q는 자기회귀가 아니라 **이동평균(MA)** 부분의 차수. 오답.
- ④ 계절 주기는 계절 ARIMA(SARIMA)의 별도 표기이며 d의 의미가 아님. 오답.

출제 포인트: ARIMA(p, d, q) = **p: AR 차수 / d: 차분 횟수 / q: MA 차수**. d=0이면 ARMA, p=0이면 IMA, q=0이면 ARI 모형과 같아진다.

근거: ARIMA(p, d, q) 모형은 비정상 시계열을 d회 차분하여 정상화한 뒤 자기회귀 차수 p와 이동평균 차수 q의 ARMA 모형을 적합하는 자기회귀 누적 이동평균 모형이다.

Q3-041 [난이도: 상] [태그: 3과목/분석기법적용/시계열모형]

시계열 모형에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. AR 모형은 자기 자신의 과거 관측값들의 선형결합으로 현재 값을 설명한다.
- ㄴ. MA 모형은 과거 예측 오차(백색잡음)들의 선형결합으로 현재 값을 설명한다.
- ㄷ. 백색잡음(white noise)은 평균이 0, 분산이 일정하며 자기상관이 없는 시계열이다.
- ㄹ. 평균이 일정하지 않은 비정상 시계열에는 차분 없이 ARMA 모형을 바로 적합하는 것이 원칙이다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄴ, ㄷ ④ ㄱ, ㄷ, ㄹ

✓ 정답 및 해설

정답: ③

- **ㄱ (O)** AR(자기회귀, autoregressive): 과거 **자기 값**의 선형결합.
- **ㄴ (O)** MA(이동평균, moving average): 과거 **오차항(백색잡음)**의 선형결합.
- **ㄷ (O)** 백색잡음의 정의 그대로 — 평균 0, 일정 분산, 자기상관 없음.
- **ㄹ (X)** 비정상 시계열은 **차분·변환으로 정상화한 후** 모형을 적합해야 한다. ARMA는 정상 시계열용 모형.

따라서 옳은 것은 ㄱ, ㄴ, ㄷ → ③. (①은 옳은 ㄷ 누락, ②·④는 틀린 ㄹ 포함)

출제 포인트: "과거 **자기 값** = AR / 과거 **오차** = MA / 둘 다 = ARMA / 차분까지 = ARIMA". 백색잡음은 MA 모형의 재료이자 모형 진단(잔차)의 기준.

근거: AR 모형은 과거 자기 관측값의 선형결합, MA 모형은 과거 백색잡음 오차의 선형결합으로 현재 값을 표현하며, 두 구조를 결합한 것이 ARMA 모형이다.

Q3-042 [난이도: 중] [태그: 3과목/분석기법적용/나이브베이즈]

나이브베이즈(naive Bayes) 분류에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 베이즈 정리(Bayes' theorem)를 이용해 사후확률이 가장 큰 범주로 분류한다.
② 클래스가 주어졌을 때 모든 입력 변수가 조건부 독립이라고 가정한다.
③ 계산이 단순하고 빨라 텍스트 분류(스팸 필터링 등)에 널리 사용된다.
④ 변수 간 상관관계가 강할수록 독립 가정이 더 잘 충족되어 분류 성능이 향상된다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. 사전확률과 우도로 사후확률을 계산해 최대 사후확률 범주로 분류.
- ② 옳은 설명. 이 "순진한(naive)" 조건부 독립 가정이 모델 이름의 유래.
- ③ 옳은 설명. 단순·고속이라 스팸 필터 등 텍스트 분류의 고전적 기법.
- ④ 상관관계가 강하면 **독립 가정이 깨져** 성능이 저하될 수 있다. 인과를 뒤집은 틀린 설명. ← 정답

출제 포인트: 나이브베이즈 = **베이즈 정리 + 변수 간 조건부 독립 가정**. 독립 가정은 "충족되기 쉬운 조건"이 아니라 "계산을 단순화하기 위한 단순화 가정"임을 기억.

근거: 나이브베이즈 분류는 베이즈 정리에 기반하되 클래스가 주어지면 입력 변수들이 서로 조건부 독립이라고 가정하여 사후확률을 계산하는 확률적 분류 기법이다.

Q3-043 [난이도: 하] [태그: 3과목/분석기법적용/CNN]

합성곱(convolution) 연산으로 이미지의 지역적 특징을 추출하고 풀링(pooling)으로 차원을 줄여, 이미지 인식에 특히 뛰어난 성능을 보이는 딥러닝 모델은?

① 합성곱 신경망(CNN)
② 순환 신경망(RNN)
③ 생성적 적대 신경망(GAN)
④ 오토인코더(autoencoder)

✓ 정답 및 해설

정답: ①

- ① CNN: 합성곱층(특징 추출) + 풀링층(차원 축소·요약)으로 구성. 이미지 처리의 대표 모델. ← 정답
- ② RNN: 이전 시점의 출력을 다시 입력으로 받는 순환 구조로 **순차(sequence) 데이터** 처리에 특화.
- ③ GAN: 생성자와 판별자가 경쟁하며 학습하는 **생성 모델**. 특징 추출 구조 설명과 무관.
- ④ 오토인코더: 입력을 복원하도록 학습하는 **비지도 차원축소** 모델.

출제 포인트: 데이터-모델 매칭 = **이미지 → CNN / 순차(텍스트·음성·시계열) → RNN·LSTM / 생성 → GAN / 비지도 압축 → 오토인코더**. CNN 구성 = 합성곱층 + 풀링층 + 완전연결층.

근거: 합성곱 신경망(CNN, convolutional neural network)은 합성곱층으로 지역적 특징을 추출하고 풀링층으로 특징 맵의 크기를 축소하는 구조를 통해 이미지 데이터 처리에 특화된 심층 신경망이다.

Q3-044 [난이도: 중] [태그: 3과목/분석기법적용/LSTM]

LSTM(Long Short-Term Memory)에 대한 설명으로 옳은 것은?

① 합성곱 연산으로 이미지의 공간적 특징을 추출하기 위해 고안되었다.
② RNN의 기울기 소실(gradient vanishing)로 인한 장기 의존성 문제를 게이트 구조로 해결한 모델이다.
③ 생성자와 판별자를 적대적으로 학습시켜 새로운 데이터를 생성한다.
④ 순차 데이터를 처리할 수 없어 시계열 예측에는 사용되지 않는다.

✓ 정답 및 해설

정답: ②

- ① 합성곱·공간 특징은 CNN에 대한 설명. 오답.
- ② LSTM은 셀 상태(cell state)와 **입력·망각·출력 게이트**로 오래된 정보의 소실을 막아, RNN의 기울기 소실·장기 의존성(long-term dependency) 문제를 해결. ← 정답
- ③ 생성자·판별자의 적대 학습은 GAN에 대한 설명. 오답.
- ④ LSTM은 RNN 계열로 **순차 데이터·시계열 처리가 본업**. 정반대의 틀린 설명. 오답.

출제 포인트: "RNN의 한계(기울기 소실 → 먼 과거 정보 반영 곤란)를 **게이트(입력·망각·출력)**로 해결"이 LSTM의 핵심 한 줄. RNN vs LSTM 비교형으로 자주 출제.

근거: LSTM은 셀 상태와 입력·망각·출력 게이트를 도입하여 RNN의 기울기 소실로 인한 장기 의존성 문제를 완화한 순환 신경망 구조다.

Q3-045 [난이도: 중] [태그: 3과목/분석기법적용/GAN]

생성적 적대 신경망(GAN)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 생성자(generator)는 실제와 유사한 가짜 데이터를 만들어 낸다.
② 판별자(discriminator)는 입력된 데이터가 실제인지 생성된 것인지 구별한다.
③ 생성자와 판별자는 동일한 목적함수를 최소화하며 서로 협력하도록 학습된다.
④ 학습이 진행될수록 생성자가 만든 데이터는 실제 데이터와 구별하기 어려워진다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 생성자는 잡음(noise)으로부터 가짜 데이터를 생성.
- ② 옳은 설명. 판별자는 진짜/가짜를 구별하는 분류기 역할.
- ③ 두 네트워크는 협력이 아니라 **서로 반대 목표를 갖고 경쟁(적대)적으로** 학습한다 — 생성자는 판별자를 속이려 하고, 판별자는 속지 않으려 한다. ← 정답
- ④ 옳은 설명. 경쟁이 균형에 가까워질수록 생성 데이터의 품질이 실제에 근접.

출제 포인트: GAN = **생성자(위조지폐범) vs 판별자(경찰)**의 적대적(adversarial) 경쟁 학습. "협력·동일 목적"이라는 단어가 나오면 함정.

근거: GAN(generative adversarial network)은 가짜 데이터를 만드는 생성자와 진위를 구별하는 판별자가 서로 적대적으로 경쟁하며 학습하는 생성 모델이다.

Q3-046 [난이도: 상] [태그: 3과목/분석기법적용/오토인코더]

오토인코더(autoencoder)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 입력을 압축하는 인코더와 이를 복원하는 디코더로 구성된다.
② 은닉층의 차원을 입력보다 작게 하여 데이터의 잠재 표현(latent representation)을 학습할 수 있다.
③ 복원 오차가 큰 관측치를 찾아 이상 탐지(anomaly detection)에 활용할 수 있다.
④ 별도의 정답 라벨이 반드시 필요하므로 지도학습(supervised learning) 기법으로 분류된다.

> **✓ 정답 및 해설**
>
> **정답:** ④
>
> - ① 옳은 설명. 인코더(입력→잠재 표현)와 디코더(잠재 표현→복원)의 대칭 구조.
> - ② 옳은 설명. 병목(bottleneck) 은닉층이 차원축소된 잠재 표현을 학습 — 비선형 차원축소로 활용.
> - ③ 옳은 설명. 정상 데이터로 학습하면 이상치는 복원 오차가 커지므로 이상 탐지에 사용.
> - ④ 오토인코더는 **입력 자기 자신을 목표값으로 사용**하므로 별도 라벨이 불필요한 **비지도 학습** 기법이다. ← 정답
>
> **출제 포인트:** 오토인코더 3키워드 = **비지도 / 차원축소(잠재 표현) / 복원(입력≈출력)**. "출력을 입력과 비교하니 지도학습"이라는 선지가 대표 함정 — 라벨을 사람이 따로 만들지 않으므로 비지도로 분류한다.
>
> **근거:** 오토인코더는 입력 데이터를 저차원 잠재 표현으로 압축(인코더)했다가 다시 복원(디코더)하도록 학습하는 비지도 신경망으로, 차원축소와 이상 탐지 등에 활용된다.

Q3-047 [난이도: 상] [태그: 3과목/분석기법적용/딥러닝모델선택]

다음 각 업무에 가장 적합한 딥러닝 모델을 순서대로 바르게 연결한 것은?

- (가) 실제 인물처럼 보이는 가상의 얼굴 이미지를 새로 생성한다.
- (나) 라벨이 없는 센서 데이터를 저차원으로 압축한 뒤 복원 오차로 이상을 탐지한다.
- (다) 긴 문장에서 멀리 떨어진 앞부분의 문맥까지 반영하여 다음 단어를 예측한다.

① (가) GAN — (나) 오토인코더 — (다) LSTM
② (가) 오토인코더 — (나) GAN — (다) CNN
③ (가) LSTM — (나) 오토인코더 — (다) GAN
④ (가) CNN — (나) LSTM — (다) 오토인코더

✓ 정답 및 해설

정답: ①

- **(가)** "새로운 데이터 생성" → 생성자·판별자의 적대 학습으로 데이터를 만드는 **GAN**.
- **(나)** "라벨 없음 + 압축 + 복원 오차 기반 이상 탐지" → 비지도 차원축소 모델 **오토인코더**.
- **(다)** "긴 문장 + 멀리 떨어진 문맥(장기 의존성)" → 게이트로 장기 기억을 유지하는 **LSTM**.

따라서 ①이 정답. ②는 생성/압축 역할이 뒤바뀌고 순차 예측에 CNN을 배정해 오답, ③은 LSTM을 생성 업무에 배정해 오답, ④는 세 업무 모두 특성과 어긋나 오답.

출제 포인트: 사례형 키워드 매칭 — **"생성" → GAN / "라벨 없음·압축·복원 오차" → 오토인코더 / "긴 순차·먼 문맥" → LSTM / "이미지 분류" → CNN**.

근거: 딥러닝 모델은 처리 목적에 따라 이미지 특징 추출(CNN), 순차 데이터·장기 의존성(RNN·LSTM), 데이터 생성(GAN), 비지도 압축·복원(오토인코더)으로 역할이 구분된다.

Q3-048 [난이도: 하] [태그: 3과목/분석기법적용/TF-IDF]

텍스트 마이닝에서 '특정 문서에는 자주 등장하지만 전체 문서 집합에서는 드물게 나타나는 단어'에 높은 가중치를 부여하여 단어의 중요도를 평가하는 지표는?

① 불용어(stopword) 사전
② TF-IDF
③ 단순 단어 빈도(TF)
④ 형태소 분석(morphological analysis)

✓ 정답 및 해설

정답: ②

- ① 불용어 사전: 의미 없는 단어를 **제거하기 위한 목록**이지, 중요도를 계산하는 지표가 아님.
- ② TF-IDF = **문서 내 단어 빈도(TF) × 역문서 빈도(IDF)**. 해당 문서엔 많고 다른 문서엔 드문 단어일수록 값이 커짐. ← 정답
- ③ 단순 빈도(TF)만 쓰면 모든 문서에 흔한 단어(조사 등)도 높게 평가되는 한계가 있음.
- ④ 형태소 분석: 어절을 형태소 단위로 **분해하는 전처리** 과정이지 가중치 지표가 아님.

출제 포인트: TF-IDF = TF(그 문서에서의 빈도) × IDF(전체 문서에서 드문 정도). "여러 문서에 흔한 단어일수록 가중치가 **낮아진다**"가 핵심 — 이 방향을 뒤집는 선지가 함정 단골.

근거: TF-IDF는 단어의 문서 내 출현 빈도(TF)와 그 단어가 나타나는 문서 수의 역수에 기반한 역문서 빈도(IDF)를 곱하여, 특정 문서에서 그 단어가 갖는 상대적 중요도를 평가하는 가중치다.

Q3-049 [난이도: 중] [태그: 3과목/분석기법적용/텍스트전처리]

텍스트 마이닝의 전처리 과정에 대한 설명으로 옳지 **않은** 것은?

① 코퍼스(corpus)는 분석을 위해 수집·정리한 대량의 텍스트 자료 집합이다.
② 토큰화(tokenization)는 텍스트를 단어·형태소 등 분석 가능한 단위로 분리하는 과정이다.
③ 불용어(stopword)는 문서의 주제를 대표하는 핵심 단어이므로 분석 전에 반드시 보존해야 한다.
④ 형태소 분석은 어절을 의미를 가진 가장 작은 단위인 형태소로 분해하는 과정이다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 코퍼스(말뭉치)는 텍스트 분석의 원재료가 되는 문서 모음.
- ② 옳은 설명. 문장 → 단어/형태소 단위로 쪼개는 것이 토큰화.
- ③ 불용어는 조사·접속사처럼 **빈번하지만 의미 파악에 기여하지 않는 단어**로, 보존이 아니라 **제거** 대상이다. 정반대의 틀린 설명. ← 정답
- ④ 옳은 설명. 한국어는 교착어라 형태소 분석이 특히 중요.

출제 포인트: 전처리 흐름 = **코퍼스 구축 → 토큰화 → 불용어 제거 → 형태소 분석(어간 추출 등)**. 불용어의 정의는 "흔하지만 의미 없는 단어(제거 대상)" — 핵심 단어와 바꿔치기하는 선지 주의.

근거: 불용어는 관사·조사·접속사처럼 출현 빈도는 높지만 문서의 의미 분석에 기여하지 않아 전처리 단계에서 제거하는 단어를 말한다.

Q3-050 [난이도: 하] [태그: 3과목/분석기법적용/토픽모델링LDA]

문서가 여러 잠재 토픽(topic)의 혼합으로 구성되고 각 토픽은 단어들의 확률분포로 표현된다고 가정하여, 문서 집합에 숨어 있는 주제를 추출하는 대표적인 토픽 모델링 기법은?

① 잠재 디리클레 할당(LDA)
② 감성 분석(sentiment analysis)
③ TF-IDF
④ 형태소 분석(morphological analysis)

✓ 정답 및 해설

정답: ①

- ① LDA(latent Dirichlet allocation): "문서 = 토픽들의 혼합, 토픽 = 단어들의 확률분포"라는 가정으로 잠재 주제를 추출하는 확률적 토픽 모델. ← 정답
- ② 감성 분석: 텍스트의 **긍정·부정 감성**을 판별하는 기법. 주제 추출이 아님.
- ③ TF-IDF: 단어 **중요도 가중치** 계산 지표. 토픽을 추출하는 모델이 아님.
- ④ 형태소 분석: 텍스트를 형태소 단위로 분해하는 **전처리** 과정.

출제 포인트: 토픽 모델링 대표 기법 = **LDA**. 정의 문구 "문서는 토픽의 혼합 + 토픽은 단어의 분포"를 통째로 암기하면 정의 매칭형에서 바로 풀림.

근거: 잠재 디리클레 할당(LDA)은 각 문서가 잠재 토픽들의 혼합 비율로, 각 토픽이 단어들의 확률분포로 생성된다고 가정하여 문서 집합의 잠재 주제를 추론하는 토픽 모델링 기법이다.

Q3-051 [난이도: 중] [태그: 3과목/분석기법적용/감성분석]

감성 분석(sentiment analysis)과 오피니언 마이닝(opinion mining)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 감성 분석은 텍스트에 담긴 긍정·부정·중립 등의 감성 극성을 판별하는 기법이다.
② 오피니언 마이닝은 텍스트에서 상품·서비스 등에 대한 사용자의 의견·평판을 추출하여 분석한다.
③ 상품 리뷰 텍스트로 고객의 만족 여부를 분류하는 것은 감성 분석의 대표적 활용 사례다.
④ 감성 분석은 정형화된 수치 데이터만을 대상으로 하므로 텍스트 데이터에는 적용할 수 없다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. 감성의 극성(긍정/부정/중립) 판별이 감성 분석의 핵심.
- ② 옳은 설명. 의견·평판 추출이 오피니언 마이닝의 목적으로, 감성 분석과 밀접하게 관련.
- ③ 옳은 설명. 리뷰·SNS 글의 긍부정 분류가 전형적 사례.
- ④ 감성 분석은 리뷰·댓글 같은 **비정형 텍스트 데이터가 주된 대상**이다. 정반대의 틀린 설명. ← 정답

출제 포인트: 감성 분석 = "**긍정/부정 극성** 판별", 오피니언 마이닝 = "**의견·평판** 추출" — 둘 다 비정형 텍스트 분석 기법. "정형 데이터 전용"이라는 문구가 나오면 즉시 오답 처리.

근거: 감성 분석은 텍스트에 나타난 주관적 감성(긍정·부정·중립)을 자동으로 판별하는 비정형 데이터 분석 기법으로, 의견·평판을 추출하는 오피니언 마이닝의 핵심 요소로 활용된다.

Q3-052 [난이도: 하] [태그: 3과목/분석기법적용/SNA매개중심성]

사회 연결망 분석(SNA)에서 한 노드가 다른 노드들 사이의 최단 경로 위에 위치하여 정보 흐름을 중개하는 '다리(bridge) 역할'의 정도를 측정하는 중심성은?

① 연결 중심성(degree centrality)
② 매개 중심성(betweenness centrality)
③ 근접 중심성(closeness centrality)
④ 위세 중심성(eigenvector centrality)

> **✓ 정답 및 해설**
>
> **정답:** ②
>
> - ① 연결 중심성: 한 노드에 **직접 연결된 노드의 수**. 다리 역할과 무관.
> - ② 매개 중심성: 다른 노드 쌍들의 **최단 경로 위에 놓이는 정도** — 정보 흐름을 통제하는 다리 역할. ← 정답
> - ③ 근접 중심성: 다른 모든 노드까지의 **최단거리가 가까운** 정도(전체 도달 용이성).
> - ④ 위세 중심성: **연결된 이웃 노드의 중요도**까지 반영한 영향력.
>
> **출제 포인트:** SNA 중심성 4종 키워드 매칭 = **직접 연결 수 → 연결 / 다리·중개 → 매개 / 최단거리·가까움 → 근접 / 이웃의 중요도 → 위세**.
>
> **근거:** 매개 중심성은 네트워크에서 한 노드가 다른 노드들 간 최단 경로 위에 위치하는 빈도로, 정보나 자원의 흐름을 중개·통제하는 정도를 나타내는 중심성 지표다.

Q3-053 [난이도: 중] [태그: 3과목/분석기법적용/SNA중심성매칭]

사회 연결망 분석(SNA)의 중심성 지표에 대한 설명 (ㄱ)~(ㄷ)과 명칭을 바르게 연결한 것은?

- ㄱ. 한 노드에 직접 연결된 노드의 수로 측정한다.
- ㄴ. 다른 모든 노드까지의 최단거리가 가까울수록 값이 커진다.
- ㄷ. 연결된 이웃 노드가 중요할수록 자신의 값도 커진다.

① ㄱ: 연결 중심성 — ㄴ: 매개 중심성 — ㄷ: 위세 중심성
② ㄱ: 근접 중심성 — ㄴ: 연결 중심성 — ㄷ: 위세 중심성
③ ㄱ: 연결 중심성 — ㄴ: 근접 중심성 — ㄷ: 위세 중심성
④ ㄱ: 연결 중심성 — ㄴ: 근접 중심성 — ㄷ: 매개 중심성

✓ 정답 및 해설

정답: ③

- ㄱ "직접 연결된 노드의 수" → **연결 중심성**.
- ㄴ "모든 노드까지의 최단거리" → **근접 중심성**.
- ㄷ "이웃 노드의 중요도 반영" → **위세 중심성**.

따라서 ③이 정답. ①은 ㄴ을 매개 중심성으로 잘못 연결(매개는 '경로 위의 다리 역할'), ②는 ㄱ·ㄴ이 서로 뒤바뀜, ④는 ㄷ을 매개 중심성으로 잘못 연결(이웃 중요도는 위세).

출제 포인트: 매칭형 단서 = **"수(개수)" → 연결 / "거리" → 근접 / "경로·다리" → 매개 / "이웃의 질" → 위세**. 네 지표 중 두 개를 서로 바꿔 놓는 선지가 정형화된 함정.

근거: 연결 중심성은 직접 연결된 노드 수, 근접 중심성은 다른 노드까지의 최단거리의 가까움, 매개 중심성은 최단 경로상의 중개 정도, 위세 중심성은 연결된 이웃의 중요도를 반영해 노드의 영향력을 측정한다.

Q3-054 [난이도: 하] [태그: 3과목/분석기법적용/배깅]

원자료로부터 복원추출한 여러 부트스트랩(bootstrap) 표본에 각각 모델을 병렬로 학습시킨 뒤 그 결과를 집계함으로써, 모델의 분산(variance)을 감소시키는 앙상블 기법은?

① 배깅(bagging)
② 부스팅(boosting)
③ 스태킹(stacking)
④ 교차검증(cross validation)

✓ 정답 및 해설

정답: ①

- ① 배깅(bootstrap aggregating): **부트스트랩(복원추출) + 병렬 학습 + 결과 집계 → 분산 감소**. 랜덤포레스트가 대표. ← 정답
- ② 부스팅: 오분류 데이터에 가중치를 주며 **순차적으로** 학습. 병렬·부트스트랩 설명과 다름.
- ③ 스태킹: 여러 모델의 예측값을 **메타 모델의 입력**으로 다시 학습시키는 방식. 부트스트랩 집계가 아님.
- ④ 교차검증: 모델의 **성능 평가·검증** 방법이지 앙상블 학습 기법이 아님.

출제 포인트: 배깅 4키워드 = **부트스트랩(복원추출) / 병렬 / 집계(aggregating) / 분산 감소**. "배깅의 대표 알고리즘 = 랜덤포레스트(random forest)"까지 한 묶음으로 암기.

근거: 배깅은 원자료에서 복원추출한 부트스트랩 표본마다 모델을 독립적으로 학습시키고 그 예측을 투표·평균으로 집계하여 분산을 줄이는 앙상블 기법이다.

Q3-055 [난이도: 중] [태그: 3과목/분석기법적용/보팅]

여러 분류기가 예측한 **클래스별 확률을 평균**한 뒤, 평균 확률이 가장 높은 클래스를 최종 예측으로 선택하는 앙상블 결합 방식은?

① 하드 보팅(hard voting)
② 배깅(bagging)
③ 소프트 보팅(soft voting)
④ 부스팅(boosting)

✓ 정답 및 해설

정답: ③

- ① 하드 보팅: 각 분류기가 예측한 **클래스(표) 자체를 다수결**로 결합. 확률 평균이 아님.
- ② 배깅: 부트스트랩 표본으로 병렬 학습하는 **표본 구성 방식**이지, 확률 평균이라는 결합 규칙 자체를 지칭하지 않음.
- ③ 소프트 보팅: 분류기들의 **예측 확률을 평균**하여 최고 확률 클래스로 결정. ← 정답
- ④ 부스팅: 오분류에 가중치를 주며 **순차 학습**하는 기법. 결합 규칙 설명과 무관.

출제 포인트: 보팅 구분 = **하드(클래스 다수결) vs 소프트(확률 평균)**. "확률"이라는 단어가 보이면 소프트 보팅으로 즉시 연결.

근거: 소프트 보팅은 개별 분류기가 산출한 클래스별 예측 확률을 평균하여 가장 높은 평균 확률을 갖는 클래스로 최종 분류하는 보팅 방식이다.

Q3-056 [난이도: 중] [태그: 3과목/분석기법적용/부스팅]

부스팅(boosting)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 이전 모델이 오분류한 데이터에 가중치를 높여 다음 모델을 학습시킨다.
② AdaBoost, GBM, XGBoost는 대표적인 부스팅 계열 알고리즘이다.
③ 약한 학습기(weak learner)들을 결합하여 강한 학습기를 만드는 방식이다.
④ 각 모델이 서로 독립적으로 병렬 학습되므로 이전 모델의 결과가 다음 모델에 영향을 주지 않는다.

> **✓ 정답 및 해설**
>
> **정답: ④**
>
> - ① 옳은 설명. 오분류 관측치의 가중치를 키워 다음 학습기가 집중하도록 하는 것이 부스팅의 핵심.
> - ② 옳은 설명. AdaBoost(가중치 조정) → GBM(경사 하강으로 잔차 학습) → XGBoost(GBM 개선·규제 추가) 계보.
> - ③ 옳은 설명. 성능이 낮은 학습기를 순차 결합해 강한 학습기로 만드는 것이 부스팅의 정의.
> - ④ 부스팅은 이전 모델의 결과(오분류)에 의존하는 **순차(sequential) 학습**이다. 독립·병렬은 **배깅**의 특징. ← 정답
>
> **출제 포인트:** 부스팅 3키워드 = **순차 / 오분류 가중치 / 약한 학습기 결합**. 부정형에서 배깅의 특징(독립·병렬)을 부스팅에 붙여 놓는 것이 가장 흔한 함정.
>
> **근거:** 부스팅은 이전 학습기가 오분류한 데이터에 가중치를 부여하여 다음 학습기를 순차적으로 학습시키고, 약한 학습기들을 결합해 강한 학습기를 만드는 앙상블 기법이다.

Q3-057 [난이도: 상] [태그: 3과목/분석기법적용/배깅vs부스팅]

배깅(bagging)과 부스팅(boosting)의 비교에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 배깅은 부트스트랩 표본으로 각 모델을 서로 독립적·병렬적으로 학습시킨다.
- ㄴ. 부스팅은 이전 모델의 오분류에 가중치를 부여하며 순차적으로 학습시킨다.
- ㄷ. 배깅은 주로 분산(variance)을 줄이고, 부스팅은 주로 편향(bias)을 줄이는 효과가 있다.
- ㄹ. 랜덤포레스트(random forest)는 부스팅 계열의 대표적인 알고리즘이다.

① ㄱ, ㄴ ② ㄱ, ㄴ, ㄷ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄷ, ㄹ

✓ 정답 및 해설

정답: ②

- **ㄱ (O)** 배깅 = 복원추출 표본 + **독립·병렬** 학습 + 집계.
- **ㄴ (O)** 부스팅 = 오분류 **가중치** + **순차** 학습.
- **ㄷ (O)** 배깅은 여러 모델의 평균화로 **분산 감소**, 부스팅은 오차를 반복 보정하며 **편향 감소**가 주된 효과. ※ 교재별 표기 차이 있음 — 부스팅의 분산 감소 효과 언급 여부는 교재마다 다르나 "배깅=분산, 부스팅=편향"이 표준 대비 구도.
- **ㄹ (X)** 랜덤포레스트는 **배깅 계열**(배깅 + 변수 무작위 선택)이다. 부스팅 계열은 AdaBoost·GBM·XGBoost.

따라서 옳은 것은 ㄱ, ㄴ, ㄷ → ②. (①은 옳은 ㄷ 누락, ③·④는 틀린 ㄹ 포함)

출제 포인트: 비교표 암기 — **배깅: 병렬·독립·복원추출·분산↓·랜덤포레스트 / 부스팅: 순차·의존·오분류 가중치·편향↓·AdaBoost·GBM·XGBoost**.

근거: 배깅은 부트스트랩 표본으로 모델들을 병렬 학습해 분산을 줄이는 기법이고, 부스팅은 오분류에 가중치를 두어 순차 학습해 편향을 줄이는 기법으로, 랜덤포레스트는 배깅에 변수 무작위 선택을 더한 알고리즘이다.

Q3-058 [난이도: 중] [태그: 3과목/분석기법적용/비모수검정]

비모수 검정(non-parametric test)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 모집단의 분포에 대한 엄격한 가정 없이 사용할 수 있다.
② 관측값 자체보다 관측값의 순위(rank)나 부호(sign)를 이용해 검정한다.
③ 런 검정(run test)은 표본 자료의 배열이 무작위인지를 검정하는 비모수 기법이다.
④ 모집단이 정규분포를 따르는 경우에도 비모수 검정이 모수 검정보다 검정력이 항상 높다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. 정규성 등 분포 가정이 필요 없어 "분포 무관(distribution-free)" 검정이라고도 함.
- ② 옳은 설명. 순위·부호 기반이므로 이상값의 영향도 적게 받음.
- ③ 옳은 설명. 런 검정은 배열의 **무작위성(randomness)** 검정.
- ④ 모수 검정의 가정(정규성 등)이 **충족될 때는 모수 검정의 검정력이 더 높다**. 비모수 검정은 가정이 깨졌거나 표본이 작을 때 쓰는 대안. ← 정답

출제 포인트: 비모수 검정 = **가정 불필요 + 순위·부호 기반 + (가정 충족 시) 모수 검정보다 검정력 낮음**. 장점만 나열하다 "검정력도 항상 높다"로 끝나는 선지가 전형적 함정.

근거: 비모수 검정은 모집단 분포에 대한 가정 없이 순위나 부호 등의 정보를 이용하는 검정으로, 분포 가정이 성립하는 상황에서는 일반적으로 모수 검정보다 검정력이 낮다.

Q3-059 [난이도: 중] [태그: 3과목/분석기법적용/비모수모수대응]

서로 독립인 두 집단의 분포(중위수) 차이를 비교하는 비모수 검정으로, 모수 검정의 독립표본 t-검정에 대응하는 것은?

① 만-휘트니 U 검정(Mann-Whitney U test)
② 크루스칼-왈리스 검정(Kruskal-Wallis test)
③ 윌콕슨 부호순위 검정(Wilcoxon signed-rank test)
④ 부호 검정(sign test)

✓ 정답 및 해설

정답: ①

- ① 만-휘트니 U 검정: **독립 2표본**의 순위 비교 → 독립표본 t-검정의 비모수 대응. 윌콕슨 순위합 검정(rank-sum test)과 동등한 검정. ← 정답
- ② 크루스칼-왈리스 검정: **3개 이상 독립 집단** 비교 → 일원분산분석(one-way ANOVA)의 비모수 대응.
- ③ 윌콕슨 부호순위 검정: **대응(짝지어진) 2표본** 비교 → 대응표본 t-검정의 비모수 대응.
- ④ 부호 검정: 대응 자료에서 차이의 **부호(+/−)만** 이용하는 검정. 독립 2표본용이 아님.

출제 포인트: 대응 매칭표 — **독립 2표본: 만-휘트니 U(=윌콕슨 순위합) ↔ 독립 t / 대응 2표본: 윌콕슨 부호순위·부호 검정 ↔ 대응 t / 3집단 이상: 크루스칼-왈리스 ↔ ANOVA**. "부호순위(대응)"와 "순위합(독립)"의 이름 혼동이 최대 함정.

근거: 만-휘트니 U 검정은 서로 독립인 두 표본의 순위를 이용해 두 모집단의 분포 위치 차이를 검정하는 비모수 기법으로, 독립표본 t-검정의 비모수적 대응 방법이다.

Q3-060 [난이도: 상] [태그: 3과목/분석기법적용/비모수검정선택]

다음 각 상황에서 자료가 정규분포를 따른다고 보기 어려울 때, 가장 적절한 비모수 검정을 순서대로 바르게 연결한 것은?

- (가) 동일한 참가자들의 다이어트 프로그램 전·후 체중 차이를 비교한다.
- (나) 서로 독립인 세 지역 주민의 소득 수준을 비교한다.
- (다) 서로 독립인 두 학급의 시험 점수를 비교한다.

① (가) 부호 검정 — (나) 만-휘트니 U 검정 — (다) 크루스칼-왈리스 검정
② (가) 만-휘트니 U 검정 — (나) 크루스칼-왈리스 검정 — (다) 윌콕슨 부호순위 검정
③ (가) 윌콕슨 부호순위 검정 — (나) 크루스칼-왈리스 검정 — (다) 만-휘트니 U 검정
④ (가) 윌콕슨 부호순위 검정 — (나) 만-휘트니 U 검정 — (다) 크루스칼-왈리스 검정

✓ 정답 및 해설

정답: ③

- **(가)** "동일 대상의 전·후 비교" = **대응 2표본 → 윌콕슨 부호순위 검정**. (부호 검정도 대응 자료용이지만, 차이의 크기 정보까지 활용하는 부호순위 검정이 더 적절)
- **(나)** "독립인 **세** 집단" = 3집단 이상 → **크루스칼-왈리스 검정**.
- **(다)** "독립인 **두** 집단" = 독립 2표본 → **만-휘트니 U 검정**.

따라서 ③이 정답. ①은 (나)·(다)에 2표본용과 3집단용 검정을 서로 바꿔 배정해 오답, ②는 대응 자료에 독립 2표본 검정을 배정해 오답, ④는 (나)·(다)가 서로 뒤바뀌어 오답.

출제 포인트: 상황 판별 3단계 — **"같은 대상 전·후?" → 대응(윌콕슨 부호순위) / "독립 집단이 몇 개?" → 2개(만-휘트니 U) vs 3개 이상(크루스칼-왈리스)**. 집단 수와 대응 여부만 읽어내면 바로 풀리는 유형.

근거: 대응 2표본은 윌콕슨 부호순위 검정, 독립 2표본은 만-휘트니 U 검정, 독립 3집단 이상은 크루스칼-왈리스 검정을 사용하는 것이 비모수 검정의 표준적 선택 기준이다.

이 문서는 LLM으로 생성 후 3중 검증(사실·논리·규격 / 중복 / 교체분 재검증)을 거친 학습 자료입니다. 교재별 표기가 갈리는 항목은 본문에 "※ 교재별 표기 차이 있음"으로 표시했으며, 상세 목록은 부록의 검증 필요 항목을 참고하세요.