빅데이터분석기사 필기 문제집

4과목 · 빅데이터 결과 해석 — 60문항 (Q4-001 ~ Q4-060)

the0ne 학습용 · 2026-09-01 생성 · KDATA 공개 출제기준 기반 신규 창작 문항 (기출 복원 아님)

4-1 분석 모형 평가

> 4과목 · 빅데이터 결과 해석 / 주요항목: 분석 모형 평가 및 개선
> 문항 수: 18 (Q4-001 ~ Q4-018)
> 범위: 회귀 평가지표(SST·SSR·SSE, 결정계수, 수정 결정계수, MSE·RMSE·MAE·MAPE, AIC·BIC) / 분류 평가지표(혼동행렬, 정확도·정밀도·재현율·특이도·F1·FPR, ROC·AUC, 향상도 곡선) / 교차검증(홀드아웃·k-fold·LOOCV·부트스트랩) / 적합도 검정(카이제곱·K-S·샤피로-윌크·Q-Q 플롯)

Q4-001 [난이도: 하] [태그: 4과목/분석모형평가및개선/회귀평가지표]

오차(잔차)를 제곱하여 평균한 값에 다시 제곱근을 취한 것으로, 종속변수와 같은 단위로 오차 크기를 해석할 수 있는 회귀모형 평가지표는?

① 평균제곱오차(MSE) ② 평균제곱근오차(RMSE) ③ 평균절대오차(MAE) ④ 평균절대백분율오차(MAPE)

✓ 정답 및 해설

정답: ②

- ① MSE = 오차 제곱의 평균. 제곱근을 취하지 않아 단위가 종속변수의 **제곱** 단위가 된다.
- ② RMSE = √MSE. 제곱근으로 단위를 원래대로 되돌려 종속변수와 같은 단위로 해석 가능. ← 정답
- ③ MAE = 오차 **절댓값**의 평균. 단위는 같지만 "제곱 후 제곱근" 과정이 없다.
- ④ MAPE = 오차를 실제 값으로 나눈 절대 백분율(%)의 평균. 단위가 없는 % 지표.

출제 포인트: "제곱 평균" → MSE, "제곱 평균의 제곱근" → RMSE, "절댓값 평균" → MAE, "백분율(%)" → MAPE. 키워드 하나로 즉시 판별.

근거: 평균제곱근오차(RMSE)는 예측 오차 제곱의 평균(MSE)에 제곱근을 취한 값으로, 실제 값과 동일한 단위로 오차의 크기를 나타내는 회귀 평가지표다.

Q4-002 [난이도: 하] [태그: 4과목/분석모형평가및개선/결정계수계산]

어떤 회귀모형에서 전체제곱합(SST)이 100, 오차제곱합(SSE)이 25일 때, 결정계수(R^2)는?

① 0.25 ② 0.50 ③ 0.75 ④ 0.80

✓ 정답 및 해설

정답: ③

- $R^2 = 1 - SSE/SST = 1 - 25/100 =$ **0.75**. (또는 SSR = SST − SSE = 75 → SSR/SST = 75/100 = 0.75)
- ① 0.25는 SSE/SST, 즉 모형이 **설명하지 못한** 변동 비율. R^2와 혼동한 함정.
- ② 0.50은 근거 없는 값.
- ③ 회귀선이 전체 변동의 75%를 설명한다는 의미. ← 정답
- ④ 0.80은 근거 없는 값.

출제 포인트: $R^2 = SSR/SST = 1 - SSE/SST$. 문제에 SSE가 주어지면 "1에서 빼기"를 잊지 말 것.

근거: 결정계수(R^2)는 전체 변동(SST) 중 회귀모형이 설명하는 변동(SSR)의 비율로, $R^2 = SSR/SST = 1 - SSE/SST$로 계산된다.

Q4-003 [난이도: 중] [태그: 4과목/분석모형평가및개선/SST분해·수정결정계수]

회귀모형의 평가에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 전체제곱합(SST)은 회귀제곱합(SSR)과 오차제곱합(SSE)의 합과 같다.
② 결정계수(R^2)는 SSR/SST로, 회귀모형이 설명하는 변동의 비율을 의미한다.
③ 수정 결정계수(adjusted R^2)는 독립변수의 수가 늘어나는 것에 페널티를 부여한 지표다.
④ 결정계수(R^2)는 유의하지 않은 독립변수를 추가하면 그 값이 감소하므로 변수 선택에 그대로 사용해도 된다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. SST = SSR + SSE (전체 변동 = 설명된 변동 + 설명 못한 변동).
- ② 옳은 설명. $R^2 = SSR/SST = 1 - SSE/SST$.
- ③ 옳은 설명. 수정 결정계수는 변수 수(k)를 반영해 R^2를 보정하며, 일반적으로 R^2보다 작거나 같다.
- ④ R^2는 독립변수를 추가하면 유의하지 않은 변수라도 **감소하지 않는다(증가하거나 유지)**. 그래서 변수 수가 다른 모형 비교에는 **수정 결정계수**를 쓴다. ← 정답

출제 포인트: "R^2는 변수를 넣을수록 커진다(줄지 않는다) → 그 단점을 고치려 페널티를 준 것이 수정 R^2." 이 인과 하나로 ③④를 모두 판별.

근거: 수정 결정계수는 독립변수의 수가 증가할수록 결정계수가 커지는 문제를 보완하기 위해 변수 수에 대한 페널티를 반영하여 조정한 결정계수다.

Q4-004 [난이도: 중] [태그: 4과목/분석모형평가및개선/AIC·BIC]

모형 선택 기준인 AIC(아카이케 정보기준)와 BIC(베이즈 정보기준)에 대한 설명으로 옳은 것은?

① AIC와 BIC는 모두 값이 작을수록 좋은 모형으로 평가한다.
② AIC는 값이 클수록 적합도가 높은 좋은 모형을 의미한다.
③ BIC는 AIC보다 모형의 변수(모수) 수에 대한 벌점이 약하다.
④ AIC는 모형의 복잡도에 대한 벌점 없이 적합도만으로 계산한다.

> **✓ 정답 및 해설**
>
> **정답:** ①
>
> - ① 두 기준 모두 "적합도 손실 + 복잡도 벌점" 구조이므로 **작을수록 좋다**. ← 정답
> - ② 방향이 반대. AIC도 작을수록 좋은 모형.
> - ③ 반대. 표본 크기가 커지면 BIC의 벌점(ln n·k)이 AIC의 벌점(2k)보다 **더 커서** BIC가 더 단순한 모형을 선호한다.
> - ④ AIC도 모수 수 k에 비례하는 벌점(2k)을 포함한다. 벌점이 없는 것이 아니다.
>
> **출제 포인트:** AIC·BIC 공통 = "작을수록 좋다 + 복잡도 벌점 있음". 차이 = **BIC의 벌점이 더 크다(더 단순한 모형 선호)**.
>
> **근거:** AIC와 BIC는 모형의 적합도에 모수 개수에 따른 벌점을 더해 계산하는 모형 선택 기준으로, 값이 작을수록 좋은 모형이며 BIC가 AIC보다 복잡도에 더 큰 벌점을 부여한다.

Q4-005 [난이도: 하] [태그: 4과목/분석모형평가및개선/혼동행렬·재현율]

어떤 분류모형의 혼동행렬(confusion matrix)이 TP=40, FN=10, FP=20, TN=30일 때, 재현율(recall)은?

① 약 0.67 ② 0.80 ③ 0.70 ④ 0.40

> **✓ 정답 및 해설**
>
> **정답:** ②
>
> - 재현율 = TP / (TP + FN) = 40 / (40+10) = 40/50 = **0.80**.
> - ① 약 0.67 = 40/60 = TP/(TP+FP) → **정밀도(precision)**. 분모를 FP로 잘못 잡은 함정.
> - ② 실제 양성 50건 중 40건을 맞혔다는 의미. ← 정답
> - ③ 0.70 = (40+30)/100 → **정확도(accuracy)**.
> - ④ 0.40 = 40/100 → TP를 전체 건수로 나눈 값. 지표가 아님.
>
> **출제 포인트:** 재현율(=민감도)의 분모는 **실제 양성(TP+FN)**, 정밀도의 분모는 **예측 양성(TP+FP)**. "실제 기준이면 재현율, 예측 기준이면 정밀도."
>
> **근거:** 재현율(recall)은 실제 양성인 것(TP+FN) 가운데 모형이 양성으로 올바르게 예측한 것(TP)의 비율로, 민감도(sensitivity)와 같은 지표다.

Q4-006 [난이도: 중] [태그: 4과목/분석모형평가및개선/F1스코어계산]

어떤 분류모형의 정밀도(precision)가 0.75, 재현율(recall)이 0.5일 때, F1-점수(F1-score)는?

① 0.500 ② 0.625 ③ 0.600 ④ 0.750

✓ 정답 및 해설

정답: ③

- F1 = 2 × (정밀도 × 재현율) / (정밀도 + 재현율) = 2 × (0.75 × 0.5) / (0.75 + 0.5) = 0.75 / 1.25 = **0.6**.
- ① 0.500 = 재현율 값 그대로. F1이 아님.
- ② 0.625 = (0.75+0.5)/2 → **산술평균**. F1은 산술평균이 아니라 **조화평균**이므로 함정.
- ③ 조화평균으로 계산한 정답. F1은 항상 산술평균보다 작거나 같다. ← 정답
- ④ 0.750 = 정밀도 값 그대로. F1이 아님.

출제 포인트: F1 = 정밀도·재현율의 **조화평균** = 2PR/(P+R). 산술평균으로 낸 값이 선지에 있으면 그것이 대표 함정.

근거: F1-점수는 정밀도와 재현율의 조화평균으로 정의되는 분류 평가지표로, 두 지표가 모두 높아야 값이 커지는 특성을 갖는다.

Q4-007 [난이도: 중] [태그: 4과목/분석모형평가및개선/정밀도vs특이도]

혼동행렬 기반 분류 평가지표에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 특이도(specificity)는 양성으로 예측한 것 중 실제 양성의 비율이다.
② 정밀도(precision)는 양성으로 예측한 것 중 실제 양성의 비율이다.
③ 재현율(recall)은 민감도(sensitivity)와 같은 지표로, 실제 양성 중 양성으로 예측한 비율이다.
④ 거짓긍정률(FPR)은 1 − 특이도와 같다.

✓ 정답 및 해설

정답: ①

- ① "예측 양성 중 실제 양성"은 **정밀도**의 정의다. 특이도는 **실제 음성(TN+FP) 중 음성으로 예측(TN)한 비율** = TN/(TN+FP). 정의 바꿔치기 함정. ← 정답
- ② 옳은 설명. 정밀도 = TP/(TP+FP).
- ③ 옳은 설명. 재현율 = 민감도 = TP/(TP+FN).
- ④ 옳은 설명. FPR = FP/(FP+TN) = 1 − 특이도.

출제 포인트: 함정 단골 = 정밀도(예측 양성 기준)와 특이도(실제 음성 기준) 바꿔치기. "정밀도는 P(예측)줄, 특이도는 N(실제 음성)줄"로 암기. FPR = 1 − 특이도까지 세트로.

근거: 특이도(specificity)는 실제 음성인 것(TN+FP) 가운데 모형이 음성으로 올바르게 예측한 것(TN)의 비율이다.

Q4-008 [난이도: 상] [태그: 4과목/분석모형평가및개선/ROC·AUC·향상도곡선]

분류모형의 시각적 평가 도구에 대한 설명으로 옳지 **않은** 것은?

① ROC 곡선은 x축에 거짓긍정률(FPR), y축에 참긍정률(TPR, 민감도)을 놓고 그린다.
② AUC는 0.5~1의 값을 가지며, 1에 가까울수록 좋은 모형이고 0.5는 랜덤 분류 수준을 의미한다.
③ 향상도 곡선(lift curve)은 무작위 선택 대비 모형의 예측 성과가 얼마나 향상되었는지를 보여준다.
④ ROC 곡선이 대각선(45도 직선)에 가까울수록 분류 성능이 좋은 모형이다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. ROC의 축 = (x: FPR = 1 − 특이도, y: TPR = 민감도).
- ② 옳은 설명. AUC는 ROC 곡선 아래 면적으로, 0.5(무작위)~1(완벽) 범위에서 클수록 좋다.
- ③ 옳은 설명. 향상도(lift) = 모형 사용 시 반응률 / 무작위 선택 시 반응률.
- ④ 반대. 대각선은 **무작위 분류(AUC=0.5)**를 의미하며, 곡선이 **왼쪽 위 모서리에 가까울수록** 좋은 모형이다. ← 정답

출제 포인트: ROC는 "x=FPR, y=TPR, 왼쪽 위로 붙을수록 좋다, 대각선=랜덤"의 4요소를 한 세트로 암기. AUC 범위(0.5~1)와 함께 출제된다.

근거: ROC 곡선은 임곗값 변화에 따른 거짓긍정률(x축)과 참긍정률(y축)의 관계를 나타낸 곡선으로, 곡선 아래 면적인 AUC가 1에 가까울수록 분류 성능이 우수하다.

Q4-009 [난이도: 상] [태그: 4과목/분석모형평가및개선/교차검증·부트스트랩]

모형 평가를 위한 데이터 분할·재추출 기법에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 홀드아웃(hold-out)은 데이터를 학습용과 평가용으로 한 번만 나누므로, 분할 방식에 따라 평가 결과가 달라질 수 있다.
- ㄴ. k-겹 교차검증(k-fold cross validation)은 데이터를 k개의 폴드로 나누어 각 폴드를 한 번씩 평가용으로 사용하고 k번의 결과를 평균한다.
- ㄷ. LOOCV(leave-one-out cross validation)는 k-겹 교차검증에서 k를 전체 데이터 개수 n과 같게 한 특수한 경우다.
- ㄹ. 부트스트랩(bootstrap)에서 어떤 관측치가 하나의 부트스트랩 표본에 한 번도 포함되지 않을 확률은 표본이 충분히 클 때 약 63.2%다.

① ㄱ, ㄴ ② ㄱ, ㄴ, ㄷ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄴ, ㄷ, ㄹ

✓ 정답 및 해설

정답: ②

- ㄱ **(O)** 홀드아웃은 1회 분할이라 계산이 간단한 대신, 어떤 데이터가 평가용에 들어가느냐에 따라 결과가 흔들린다.
- ㄴ **(O)** k-fold의 정의 그대로. 모든 데이터가 한 번씩 평가에 사용된다.
- ㄷ **(O)** LOOCV = k-fold에서 k = n. 매번 1개만 평가용으로 남긴다. (p개를 남기면 LpOCV)
- ㄹ **(X)** 복원추출이므로 한 관측치가 **한 번도 뽑히지 않을 확률은 약 36.8%**(= 1/e)다. 63.2%는 반대로 **한 번 이상 포함될 확률**이다. ※ 교재별 표기 차이 있음(63.2% 포함 확률로 서술하는 교재도 있음 — "미포함 36.8% / 포함 63.2%"는 같은 사실의 양면).

따라서 옳은 것은 ㄱ, ㄴ, ㄷ → ②. (①은 옳은 ㄷ을 누락, ③·④는 틀린 ㄹ을 포함)

출제 포인트: 부트스트랩 = **복원추출** + "미포함 약 36.8%, 포함 약 63.2%". 숫자만 바꿔 낸 함정에 대비해 두 수를 쌍으로 암기. LOOCV는 "k=n인 k-fold" 한 줄로 정리.

근거: 부트스트랩은 원본 데이터에서 같은 크기의 표본을 복원추출로 반복 생성하는 재추출 기법으로, 표본이 충분히 크면 특정 관측치가 한 표본에 포함되지 않을 확률이 약 36.8%(1/e)에 수렴한다.

Q4-010 [난이도: 하] [태그: 4과목/분석모형평가및개선/혼동행렬·정밀도]

어떤 분류모형의 혼동행렬(confusion matrix)이 TP=30, FP=10, FN=20, TN=40일 때, 정밀도(precision)는?

① 0.60 ② 0.75 ③ 0.70 ④ 0.80

✓ 정답 및 해설

정답: ②

- 정밀도 = TP / (TP + FP) = 30 / (30+10) = 30/40 = **0.75**.
- ① 0.60 = 30/50 = TP/(TP+FN) → **재현율(recall)**. 분모를 FN으로 잘못 잡은 함정.
- ② 양성으로 예측한 40건 중 30건이 실제 양성이라는 의미. ← 정답
- ③ 0.70 = (30+40)/100 → **정확도(accuracy)**.
- ④ 0.80 = 40/50 = TN/(TN+FP) → **특이도(specificity)**.

출제 포인트: 정밀도의 분모는 **예측 양성(TP+FP)**. "양성이라고 말한 것 중 진짜 양성"이 정밀도, "실제 양성 중 잡아낸 것"이 재현율.

근거: 정밀도(precision)는 모형이 양성으로 예측한 것(TP+FP) 가운데 실제 양성(TP)의 비율이다.

Q4-011 [난이도: 하] [태그: 4과목/분석모형평가및개선/카이제곱적합도검정]

관측도수와 기대도수의 차이를 이용하여 표본 데이터가 가정한 분포(비율)에 적합한지를 검정하는 방법은?

① 콜모고로프-스미르노프(K-S) 검정 ② 샤피로-윌크(Shapiro-Wilk) 검정 ③ 카이제곱(χ^2) 적합도 검정 ④ Q-Q 플롯(Q-Q plot)

✓ 정답 및 해설

정답: ③

- ① K-S 검정은 **경험적 누적분포함수(ECDF)**와 이론적 분포의 누적분포함수 간 최대 차이로 검정. "도수" 기반이 아님.
- ② 샤피로-윌크 검정은 표본의 **정규성** 검정에 특화된 방법. 관측·기대도수 개념을 쓰지 않음.
- ③ 범주별 $(\text{관측도수} - \text{기대도수})^2 / \text{기대도수}$의 합으로 검정통계량을 만든다. ← 정답
- ④ Q-Q 플롯은 분위수(quantile) 대응점을 그려 **시각적으로** 분포 적합 여부를 보는 도구. 검정통계량이 없다.

출제 포인트: 키워드 매칭 — "관측도수 vs 기대도수" → 카이제곱, "누적분포함수 최대 거리" → K-S, "정규성 전용" → 샤피로-윌크, "분위수 그림" → Q-Q 플롯.

근거: 카이제곱 적합도 검정은 각 범주의 관측도수와 기대도수의 차이를 제곱해 기대도수로 나눈 값의 합을 검정통계량으로 하여 표본이 특정 분포에 적합한지를 판단하는 검정이다.

Q4-012 [난이도: 중] [태그: 4과목/분석모형평가및개선/특이도·FPR계산]

어떤 분류모형의 혼동행렬이 TP=30, FN=20, FP=5, TN=45일 때, 거짓긍정률(FPR, false positive rate)은?

① 0.10 ② 0.90 ③ 0.40 ④ 0.60

✓ 정답 및 해설

정답: ①

- FPR = FP / (FP + TN) = 5 / (5+45) = 5/50 = **0.10**. (특이도 = 45/50 = 0.90 → FPR = 1 − 특이도 = 0.10으로 검산)
- ① 실제 음성 50건 중 5건을 양성으로 잘못 예측했다는 의미. ← 정답
- ② 0.90 = TN/(TN+FP) → **특이도(specificity)**. "1에서 빼기"를 빠뜨린 함정.
- ③ 0.40 = FN/(TP+FN) → 거짓부정률(FNR). 분자를 FN으로 잘못 잡은 값.
- ④ 0.60 = 30/50 = TP/(TP+FN) → **재현율(민감도)**.

출제 포인트: FPR = FP/(FP+TN) = **1 − 특이도**. 특이도를 먼저 구한 뒤 1에서 빼면 계산 실수를 잡아낼 수 있다.

근거: 거짓긍정률(FPR)은 실제 음성인 것(FP+TN) 가운데 양성으로 잘못 예측한 것(FP)의 비율로, 1 − 특이도와 같다.

Q4-013 [난이도: 중] [태그: 4과목/분석모형평가및개선/회귀지표공식식별]

다음 공식으로 계산되는 회귀모형 평가지표는? (y_i: 실제 값, $\hat{y}_i$: 예측 값, n: 데이터 수)

$(1/n) \times \Sigma \mid y_i - \hat{y}_i \mid$ ($i = 1 \dots n$ 합산)

① 평균제곱오차(MSE) ② 평균제곱근오차(RMSE) ③ 평균절대백분율오차(MAPE) ④ 평균절대오차(MAE)

✓ 정답 및 해설

정답: ④

- ① MSE = $(1/n)\Sigma(y_i - \hat{y}_i)^2$ → 절댓값이 아니라 **제곱**의 평균.
- ② RMSE = $\sqrt{MSE}$ → 제곱 평균에 다시 **제곱근**을 취한 값.
- ③ MAPE = $(100/n)\Sigma|(y_i - \hat{y}_i)/y_i|$ → 오차를 **실제 값으로 나눈** 백분율(%)의 평균.
- ④ 오차 **절댓값의 평균** = MAE. 이상값의 영향이 MSE보다 작다. ← 정답

출제 포인트: 공식에서 보는 곳은 세 군데 — "제곱(^{2})이면 MSE 계열, √가 있으면 RMSE, 실제 값(y_i)으로 나누면 MAPE, 절댓값만 있으면 MAE."

근거: 평균절대오차(MAE)는 실제 값과 예측 값 차이의 절댓값을 평균한 회귀 평가지표다.

Q4-014 [난이도: 중] [태그: 4과목/분석모형평가및개선/홀드아웃·LpOCV]

데이터 분할과 교차검증에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 홀드아웃(hold-out)에서 평가(test) 데이터는 모형 학습에 사용하지 않는다.
② 검증(validation) 데이터는 하이퍼파라미터 조정 등 모형 최적화 과정에 사용된다.
③ k-겹 교차검증에서 k를 크게 할수록 학습·평가 반복 횟수가 늘어나 계산량이 증가한다.
④ LpOCV(leave-p-out)는 LOOCV보다 반복 횟수가 적어 계산량이 항상 더 적다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. 평가 데이터는 최종 성능 측정 전까지 학습에 쓰지 않아야 일반화 성능을 공정하게 잰다.
- ② 옳은 설명. 학습(train)/검증(validation)/평가(test) 3분할에서 검증 데이터의 역할은 튜닝.
- ③ 옳은 설명. k번 학습·평가를 반복하므로 k가 클수록 계산 비용이 커진다.
- ④ 반대. LpOCV는 n개 중 p개를 남기는 **모든 조합($_nC_p$)**에 대해 반복하므로, $p \geq 2$이면 n번만 반복하는 LOOCV보다 계산량이 **훨씬 많다**. ← 정답

출제 포인트: 반복 횟수 비교 — 홀드아웃 1회 < k-fold k회 < LOOCV n회 < LpOCV $_nC_p$회. "LOOCV는 LpOCV에서 p=1인 특수한 경우"로 묶어 암기.

근거: LpOCV(leave-p-out 교차검증)는 전체 n개 데이터 중 p개를 평가용으로 남기는 모든 조합($_nC_p$)에 대해 학습과 평가를 반복하는 교차검증 기법이다.

Q4-015 [난이도: 중] [태그: 4과목/분석모형평가및개선/향상도계산]

어떤 마케팅 반응 예측 모형으로 점수 상위 10% 고객을 추출했더니 반응률이 20%였다. 전체 고객의 평균 반응률이 5%일 때, 이 구간의 향상도(lift)는?

① 0.25 ② 2 ③ 4 ④ 15

✓ 정답 및 해설

정답: ③

- 향상도 = 해당 구간의 반응률 / 전체 평균 반응률 = 20% / 5% = **4**.
- ① 0.25 = 5/20 → 분자·분모를 **거꾸로** 나눈 함정.
- ② 2는 근거 없는 값.
- ③ 무작위로 고객을 골랐을 때보다 반응 고객을 4배 더 잘 찾아낸다는 의미. ← 정답
- ④ 15 = 20 − 5 → 비율이 아니라 **차이**를 구한 함정. 향상도는 나눗셈 지표다.

출제 포인트: 향상도(lift) = "모형으로 고른 집단의 반응률 ÷ 전체(무작위) 반응률". 1보다 크면 무작위보다 낫고, 1이면 모형이 무의미.

근거: 향상도(lift)는 모형이 선별한 집단의 반응(양성) 비율을 전체 평균 반응 비율로 나눈 값으로, 무작위 선택 대비 모형의 개선 정도를 나타낸다.

Q4-016 [난이도: 중] [태그: 4과목/분석모형평가및개선/적합도검정종합]

적합도 검정과 관련 도구에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 카이제곱 적합도 검정은 관측도수와 기대도수의 차이를 이용한다.
② 콜모고로프-스미르노프(K-S) 검정은 경험적 누적분포함수와 이론적 분포의 누적분포함수 간 최대 차이를 검정통계량으로 사용한다.
③ Q-Q 플롯에서 점들이 대각 직선에 가깝게 늘어서면 데이터가 비교 대상 분포를 따른다고 볼 수 있다.
④ 샤피로-윌크(Shapiro-Wilk) 검정은 두 범주형 변수 간의 독립성을 검정하는 방법이다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. Σ(관측 − 기대)²/기대가 카이제곱 검정통계량.
- ② 옳은 설명. K-S 검정은 누적분포함수(CDF) 간 **최대 거리**로 분포 적합·정규성을 판단한다.
- ③ 옳은 설명. Q-Q 플롯은 분위수 대응점이 직선에서 벗어나는 정도로 분포 적합을 **시각적으로** 확인한다.
- ④ 샤피로-윌크 검정은 표본이 **정규분포를 따르는지 보는 정규성 검정**이다. 범주형 변수의 독립성 검정은 **카이제곱 독립성 검정**의 역할. ← 정답

출제 포인트: 샤피로-윌크 = 정규성 전용. 카이제곱은 용도가 갈린다 — "적합도(도수 비교)"와 "독립성(범주형 두 변수)"을 구분해 두면 바꿔치기 함정을 피한다.

근거: 샤피로-윌크 검정은 표본 데이터가 정규분포를 따르는지에 대한 귀무가설을 검정하는 정규성 검정 방법이다.

Q4-017 [난이도: 상] [태그: 4과목/분석모형평가및개선/불균형데이터·지표선택]

전체 데이터 중 양성이 1%뿐인 희귀 사건 분류 문제에서의 평가지표 선택에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 이런 불균형 데이터에서는 정확도(accuracy)가 항상 가장 신뢰할 수 있는 평가지표다.
② 질병 진단처럼 실제 양성을 놓치는(FN) 비용이 클 때는 재현율(민감도)을 중시한다.
③ 스팸 필터처럼 정상을 양성으로 잘못 분류하는(FP) 비용이 클 때는 정밀도를 중시한다.
④ F1-점수는 정밀도와 재현율을 함께 반영하므로 불균형 데이터에서 정확도의 한계를 보완할 수 있다.

✓ 정답 및 해설

정답: ①

- ① 반대. 양성 1% 데이터에서 **전부 음성으로만 예측해도 정확도는 99%**가 되므로, 불균형 데이터에서 정확도는 성능을 과대평가할 수 있다. ← 정답
- ② 옳은 설명. FN(놓친 양성)이 치명적이면 재현율 = TP/(TP+FN)을 우선.
- ③ 옳은 설명. FP(잘못 잡은 양성)가 치명적이면 정밀도 = TP/(TP+FP)를 우선.
- ④ 옳은 설명. F1은 정밀도·재현율의 조화평균이라 한쪽만 높아서는 좋은 값이 나오지 않는다.

출제 포인트: 사례 → 지표 연결: "놓치면 큰일(진단) → 재현율", "오탐이 큰일(스팸) → 정밀도", "불균형 → 정확도 대신 F1·재현율". "전부 음성 예측 = 정확도 99%" 반례 하나로 ①을 즉시 격파.

근거: 정확도(accuracy)는 전체 예측 중 올바르게 예측한 비율(TP+TN)/(전체)로, 범주 비율이 심하게 불균형하면 다수 범주만 맞혀도 높게 나오는 한계가 있다.

Q4-018 [난이도: 상] [태그: 4과목/분석모형평가및개선/ROC좌표계산]

어떤 분류모형의 혼동행렬이 TP=40, FN=10, FP=20, TN=80일 때, 이 모형이 ROC 공간에 찍히는 점의 좌표 (x, y)는?

① (0.8, 0.2) ② (0.2, 0.8) ③ (0.67, 0.8) ④ (0.2, 0.67)

✓ 정답 및 해설

정답: ②

- ROC의 축은 **x = FPR, y = TPR**. FPR = FP/(FP+TN) = 20/100 = **0.2**, TPR = TP/(TP+FN) = 40/50 = **0.8** → 점 (0.2, 0.8).
- ① (0.8, 0.2) = x·y **축을 바꿔치기**한 함정. ROC에서 x가 TPR이 아니다.
- ② 왼쪽 위 모서리 (0,1)에 가까운 점이므로 좋은 성능의 모형. ← 정답
- ③ 0.67 ≈ 40/60 = TP/(TP+FP) → x에 **정밀도**를 넣은 값. ROC 축이 아님.
- ④ y에 정밀도 0.67을 넣은 값. TPR 자리에 정밀도를 쓰면 안 된다.

출제 포인트: ROC 좌표 계산 절차 — (1) FPR = FP/(FP+TN), (2) TPR = TP/(TP+FN), (3) (FPR, TPR) 순서로 쓰기. "x축 먼저·FPR 먼저"를 세트로 암기하면 축 바꿔치기 함정을 피한다.

근거: ROC 곡선은 분류 임곗값을 변화시키며 x축에 거짓긍정률(FPR), y축에 참긍정률(TPR)을 대응시켜 그린 곡선으로, 하나의 혼동행렬은 ROC 공간의 한 점 (FPR, TPR)으로 표현된다.

4-2 분석모형 개선

> 4과목 · 빅데이터 결과 해석 / 주요항목: 분석모형 평가 및 개선
> 문항 수: 14 (Q4-019 ~ Q4-032) · 난이도 하4/중7/상3 · 정답 분포 ①4 ②3 ③4 ④3

Q4-019 [난이도: 하] [태그: 4과목/분석모형평가및개선/과대적합]

어떤 분류 모형이 훈련 데이터에서는 정확도 98%를 기록했지만, 별도의 평가 데이터에서는 정확도가 70%에 그쳤다. 이 모형이 보이는 현상은?

① 과소적합(underfitting)
② 과대적합(overfitting)
③ 기울기 소실(gradient vanishing)
④ 차원의 저주(curse of dimensionality)

> **✓ 정답 및 해설**
>
> **정답:** ②
>
> - ① 과소적합은 모형이 너무 단순해 **훈련 데이터에서조차 성능이 낮은** 현상. 훈련 98%와 모순.
> - ② 훈련 데이터에만 지나치게 맞춰져 새 데이터(평가)에서 성능이 급락 → 과대적합. ← 정답
> - ③ 기울기 소실은 역전파 시 기울기가 0에 가까워져 **학습 자체가 안 되는** 신경망 학습 문제. 성능 격차 현상이 아님.
> - ④ 차원의 저주는 변수(차원)가 늘수록 데이터가 희소해져 분석이 어려워지는 문제. 훈련·평가 성능 격차의 직접 명칭이 아님.
>
> **출제 포인트:** "훈련↑ 평가↓ = 과대적합, 훈련↓ 평가↓ = 과소적합"으로 즉시 판별. 두 성능의 **격차**가 크면 과대적합이다.
>
> **근거:** 과대적합(overfitting)은 모형이 훈련 데이터의 잡음까지 학습하여 훈련 데이터 성능은 높지만 새로운 데이터에 대한 일반화 성능이 떨어지는 현상이다.

Q4-020 [난이도: 하] [태그: 4과목/분석모형평가및개선/L1규제]

회귀 계수의 절댓값 합을 벌점(penalty)으로 부과하여 일부 계수를 정확히 0으로 만들고, 이를 통해 변수 선택 효과를 갖는 규제 기법은?

① L1 규제(라쏘, Lasso)
② L2 규제(릿지, Ridge)
③ 드롭아웃(dropout)
④ 조기 종료(early stopping)

✓ 정답 및 해설

정답: ①

- ① 절댓값 합(|w|) 벌점 → 일부 계수가 정확히 0 → 희소성(sparsity)·변수 선택 효과 → L1 규제(라쏘). ← 정답
- ② L2 규제(릿지)는 **제곱합** 벌점으로 계수를 0에 가깝게 **축소**만 할 뿐, 정확히 0으로 만들지 않는다.
- ③ 드롭아웃은 신경망 학습 시 뉴런을 무작위로 제외하는 기법. 회귀 계수 벌점과 무관.
- ④ 조기 종료는 검증 성능이 나빠지기 전에 학습을 멈추는 기법. 벌점 부과 방식이 아님.

출제 포인트: L1 = 절댓값·계수 0·희소·변수 선택(라쏘) / L2 = 제곱·계수 축소·0은 안 됨(릿지). "절댓값→라쏘, 제곱→릿지"로 암기.

근거: L1 규제(라쏘)는 회귀 계수의 절댓값 합을 벌점으로 부과해 일부 계수를 정확히 0으로 만들어 변수 선택 효과를 갖는 규제 기법이다.

Q4-021 [난이도: 하] [태그: 4과목/분석모형평가및개선/드롭아웃]

신경망 학습 과정에서 매 반복(iteration)마다 일부 뉴런(노드)을 무작위로 제외하고 학습시켜 과대적합을 방지하는 기법은?

① 배치 정규화(batch normalization)
② 조기 종료(early stopping)
③ 드롭아웃(dropout)
④ 데이터 증강(data augmentation)

✓ 정답 및 해설

정답: ③

- ① 배치 정규화는 미니배치 단위로 층의 입력을 **정규화**하는 기법. 뉴런 제외가 아님.
- ② 조기 종료는 검증 오차가 증가하기 시작하면 **학습을 중단**하는 기법. 뉴런 제외가 아님.
- ③ 학습 시 뉴런을 확률적으로 꺼서(제외) 특정 뉴런 의존을 막는 과대적합 방지 기법 → 드롭아웃. ← 정답
- ④ 데이터 증강은 원본 데이터를 변형해 **훈련 데이터 양을 늘리는** 기법. 뉴런 제외가 아님.

출제 포인트: "뉴런 무작위 제외 = 드롭아웃". 단, 드롭아웃은 **학습 시에만** 적용하고 예측(추론) 시에는 모든 뉴런을 사용한다는 점이 함정 선지로 출제된다.

근거: 드롭아웃(dropout)은 신경망 학습 시 일부 뉴런을 무작위로 제외하여 특정 뉴런에 대한 의존을 줄임으로써 과대적합을 방지하는 기법이다.

Q4-022 [난이도: 하] [태그: 4과목/분석모형평가및개선/하이퍼파라미터]

다음 중 사용자가 설정하는 하이퍼파라미터(hyperparameter)가 아니라, 모형이 학습을 통해 스스로 결정하는 파라미터(parameter)에 해당하는 것은?

① 학습률(learning rate)
② 에폭(epoch) 수
③ 은닉층(hidden layer)의 수
④ 가중치(weight)와 편향(bias)

✓ 정답 및 해설

정답: ④

- ① 학습률은 학습 전에 사람이 정하는 값 → 하이퍼파라미터.
- ② 에폭 수(전체 데이터 반복 학습 횟수)는 사람이 정하는 값 → 하이퍼파라미터.
- ③ 은닉층 수(모형 구조)는 사람이 정하는 값 → 하이퍼파라미터.
- ④ 가중치·편향은 학습 과정에서 데이터로부터 **자동으로 추정**되는 값 → 파라미터. ← 정답

출제 포인트: "사람이 정하면 하이퍼파라미터(학습률·에폭·배치 크기·은닉층 수·규제 강도), 학습이 정하면 파라미터(가중치·편향·회귀 계수)". 가중치를 하이퍼파라미터로 두는 선지가 단골 함정.

근거: 파라미터는 모형이 학습을 통해 데이터로부터 추정하는 값(가중치·편향)이고, 하이퍼파라미터는 학습 전에 사용자가 설정하는 값(학습률·에폭·배치 크기 등)이다.

Q4-023 [난이도: 중] [태그: 4과목/분석모형평가및개선/과대적합해결]

과대적합(overfitting)을 완화하기 위한 방법으로 적절하지 **않은** 것은?

① 은닉층과 노드 수를 늘려 모형의 복잡도를 높인다.
② 원본 데이터를 변형·확장하는 데이터 증강(data augmentation)으로 훈련 데이터를 늘린다.
③ L1·L2 규제(regularization)를 적용해 가중치가 과도하게 커지지 않도록 한다.
④ 검증 오차가 증가하기 시작하면 학습을 멈추는 조기 종료(early stopping)를 적용한다.

✓ 정답 및 해설

정답: ①

- ① 복잡도를 **높이면** 훈련 데이터에 더 밀착되어 과대적합이 **심해진다**. 과대적합에는 모형 단순화가 해결책이고, 복잡도 증가는 **과소적합**의 해결책. ← 정답
- ② 적절. 훈련 데이터가 많아지면 잡음에 덜 민감해져 일반화 성능이 좋아진다.
- ③ 적절. 규제는 가중치 크기에 벌점을 주어 모형을 단순하게 유지한다.
- ④ 적절. 검증 오차가 나빠지기 전에 멈춰 과도한 학습을 차단한다.

출제 포인트: 과대적합 해결 = 데이터 증강 / 모형 단순화 / 규제 / 드롭아웃 / 조기 종료. 과소적합 해결 = 모형 복잡화 / 변수 추가 / 학습 횟수 증가. 두 처방을 바꿔치기한 선지가 정답이 되는 패턴.

근거: 과대적합의 대표적 완화 방법은 훈련 데이터 확대(데이터 증강), 모형 단순화, 규제 적용, 드롭아웃, 조기 종료이다.

Q4-024 [난이도: 중] [태그: 4과목/분석모형평가및개선/경사하강법]

경사하강법(gradient descent)의 세 가지 방식에 대한 설명으로 옳은 것은?

① 배치 경사하강법(batch GD)은 매 갱신마다 데이터 1건만 사용하므로 계산이 가장 빠르다.
② 확률적 경사하강법(SGD)은 전체 데이터를 모두 사용하므로 갱신 방향이 가장 안정적이다.
③ 미니배치 경사하강법(mini-batch GD)은 전체와 1건의 절충으로, 일정 크기의 묶음 단위로 갱신한다.
④ 확률적 경사하강법(SGD)은 배치 경사하강법보다 항상 안정적으로 수렴한다.

✓ 정답 및 해설

정답: ③

- ① 배치 경사하강법은 **전체 데이터**로 기울기를 계산해 1회 갱신. "1건만 사용"은 SGD의 설명.
- ② SGD는 **1건(또는 소수)** 씩 사용해 빠르지만 갱신 방향이 **불안정(진동)**. "전체 사용·안정"은 배치의 설명.
- ③ 미니배치는 전체(배치)와 1건(SGD)의 절충으로, 일정 크기 묶음(예: 32, 64건)마다 갱신 → 속도와 안정성의 균형. ← 정답
- ④ SGD는 빠르지만 진동이 커서 **불안정**하다. "항상 안정적"은 틀린 설명.

출제 포인트: 배치 = 전체·안정·느림 / SGD = 1건·빠름·불안정 / 미니배치 = 묶음·절충(실무 표준). "사용 데이터 양"과 "안정성"을 서로 바꿔치기한 선지를 주의.

근거: 경사하강법은 1회 갱신에 사용하는 데이터 양에 따라 배치(전체), 확률적(1건), 미니배치(일정 크기 묶음) 방식으로 구분된다.

Q4-025 [난이도: 중] [태그: 4과목/분석모형평가및개선/옵티마이저]

다음 설명에 해당하는 옵티마이저(optimizer)는?

> 이전 갱신에서 이동하던 방향을 관성(inertia)처럼 현재 갱신에 반영하여, 진동을 줄이고 지역 최소값(local minimum)을 지나칠 수 있도록 돕는다.

① AdaGrad
② 모멘텀(Momentum)
③ RMSProp
④ Adam

> **✓ 정답 및 해설**
>
> **정답: ②**
>
> - ① AdaGrad는 변수별로 **학습률을 조정**하는 방식(기울기 누적이 클수록 학습률 감소). 관성 개념이 아님.
> - ② "이전 이동 방향을 관성처럼 반영" → 모멘텀. ← 정답
> - ③ RMSProp은 AdaGrad의 학습률 누적 감소 문제를 지수이동평균으로 **보완**한 방식. 관성 개념이 아님.
> - ④ Adam은 모멘텀 + RMSProp을 **결합**한 방식. 관성만을 설명한 지문보다 범위가 넓다.
>
> **출제 포인트:** 매칭 키워드 — 모멘텀 = "관성·이전 방향" / AdaGrad = "학습률 누적 감소" / RMSProp = "AdaGrad 보완·지수이동평균" / Adam = "모멘텀+RMSProp 결합".
>
> **근거:** 모멘텀(Momentum)은 이전 갱신의 이동 방향을 관성으로 반영하여 경사하강법의 진동을 줄이고 수렴을 가속하는 옵티마이저다.

Q4-026 [난이도: 중] [태그: 4과목/분석모형평가및개선/기울기소실]

심층 신경망의 역전파(backpropagation) 과정에서 출력층에서 입력층 방향으로 갈수록 기울기가 0에 가까워져 앞쪽 층의 가중치가 거의 갱신되지 않는 문제와, 이를 완화하기 위해 은닉층에 널리 사용되는 활성화 함수를 옳게 짝지은 것은?

① 기울기 소실(gradient vanishing) — ReLU
② 기울기 소실(gradient vanishing) — 시그모이드(sigmoid)
③ 과대적합(overfitting) — ReLU
④ 기울기 폭주(gradient exploding) — 시그모이드(sigmoid)

✓ 정답 및 해설

정답: ①

- ① "역전파 시 기울기가 0에 수렴 → 앞쪽 층 학습 정지" = 기울기 소실. ReLU는 양수 입력 구간에서 기울기가 1로 유지되어 소실을 완화한다. ← 정답
- ② 문제 명칭은 맞지만, 시그모이드는 도함수의 최댓값이 작아(최대 0.25) 층을 거칠수록 기울기가 급격히 작아지는 **소실의 원인**이지 해결책이 아니다.
- ③ 과대적합은 훈련 데이터에는 잘 맞고 새 데이터에서 성능이 떨어지는 **일반화 문제**로, 역전파 기울기 현상과 다른 개념이다.
- ④ 기울기 폭주는 기울기가 비정상적으로 **커져** 학습이 발산하는 문제로, 지문의 "0에 가까워지는" 현상과 반대이며 시그모이드가 해결책도 아니다.

출제 포인트: 매칭 공식 — "기울기가 0에 수렴 = 소실 → ReLU로 완화" / "기울기가 폭발적으로 증가 = 폭주". 시그모이드·tanh를 해결책 자리에 놓는 원인↔해결 바꿔치기 선지가 단골 함정.

근거: 기울기 소실(gradient vanishing)은 심층 신경망의 역전파 시 기울기가 층을 거치며 0에 가까워져 입력층 부근 가중치가 학습되지 않는 문제로, 양수 구간에서 기울기 1을 유지하는 ReLU 활성화 함수가 대표적인 완화 방법이다.

Q4-027 [난이도: 중] [태그: 4과목/분석모형평가및개선/학습률]

경사하강법의 학습률(learning rate)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 학습률이 지나치게 크면 최적값을 지나쳐 진동하거나 발산할 수 있다.
② 학습률이 지나치게 작으면 수렴 속도가 매우 느려지고 지역 최소값에 머무를 수 있다.
③ 학습률은 학습 전에 사용자가 설정하는 하이퍼파라미터다.
④ 학습률은 클수록 항상 더 정확한 최적해에 도달한다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. 과대 학습률 → 보폭이 커서 최소점을 계속 지나침 → 진동·발산.
- ② 옳은 설명. 과소 학습률 → 보폭이 작아 학습이 느리고 지역 최소값 탈출이 어렵다.
- ③ 옳은 설명. 학습률은 사람이 정하는 대표적 하이퍼파라미터.
- ④ 학습률이 크면 발산 위험이 커진다. "클수록 항상 정확"은 틀린 설명 → 적절한 크기 설정이 핵심. ← 정답

출제 포인트: 학습률 과대 = 발산·진동, 학습률 과소 = 느린 수렴·지역해. "항상", "무조건"이 들어간 선지는 함정일 확률이 높다.

근거: 학습률은 경사하강법에서 가중치를 한 번에 갱신하는 보폭을 결정하는 하이퍼파라미터로, 과대하면 발산하고 과소하면 수렴이 느려진다.

Q4-028 [난이도: 중] [태그: 4과목/분석모형평가및개선/하이퍼파라미터튜닝]

하이퍼파라미터 탐색 기법인 그리드 서치(grid search)와 랜덤 서치(random search)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 그리드 서치는 사용자가 지정한 후보 값들의 모든 조합을 빠짐없이 탐색한다.
② 랜덤 서치는 지정된 범위 안에서 하이퍼파라미터 값을 무작위로 추출해 탐색한다.
③ 그리드 서치는 하이퍼파라미터의 종류와 후보 값이 늘어나도 탐색해야 할 조합의 수가 증가하지 않는다.
④ 랜덤 서치는 탐색 공간이 넓을 때 그리드 서치보다 효율적일 수 있다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 그리드 서치는 격자(grid)의 전 조합을 전수 탐색한다.
- ② 옳은 설명. 랜덤 서치는 정해진 횟수만큼 무작위 표본을 추출해 시험한다.
- ③ 그리드 서치의 조합 수는 후보 값 수의 **곱**으로 늘어난다(예: 3종 × 각 4개 후보 = 4×4×4 = 64조합). 종류·후보가 늘수록 **기하급수적으로 증가**하는 것이 그리드 서치의 한계. ← 정답
- ④ 옳은 설명. 랜덤 서치는 시도 횟수를 고정할 수 있어 넓은 공간에서 효율적일 수 있다.

출제 포인트: 그리드 = 전 조합·정확하지만 조합 폭발 / 랜덤 = 무작위 추출·빠르지만 최적 보장 없음. "조합 수가 늘지 않는다"류의 상식 반전 선지가 정답 패턴.

근거: 그리드 서치는 지정한 하이퍼파라미터 후보 값의 모든 조합을 전수 탐색하는 기법이고, 랜덤 서치는 지정 범위에서 무작위로 추출한 조합만 탐색하는 기법이다.

Q4-029 [난이도: 중] [태그: 4과목/분석모형평가및개선/배치정규화조기종료]

배치 정규화(batch normalization)와 조기 종료(early stopping)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 배치 정규화는 미니배치 단위로 층의 입력 분포를 정규화하여 학습을 안정화한다.
② 조기 종료는 훈련 오차가 증가하기 시작하는 시점에 학습을 중단하는 기법이다.
③ 배치 정규화는 층을 지날 때마다 입력 분포가 변하는 문제를 완화해 학습 속도를 높인다.
④ 조기 종료는 불필요하게 오래 학습하여 발생하는 과대적합을 방지한다.

✓ 정답 및 해설

정답: ②

- ① 옳은 설명. 미니배치의 평균·분산으로 입력을 정규화해 학습을 안정화한다.
- ② 조기 종료의 중단 기준은 **검증(validation) 오차**다. 훈련 오차는 학습을 계속하면 대개 계속 감소하므로 기준이 될 수 없다. ← 정답
- ③ 옳은 설명. 내부 공변량 변화(internal covariate shift)를 완화해 높은 학습률 사용과 빠른 학습을 가능하게 한다.
- ④ 옳은 설명. 검증 성능이 나빠지기 전에 멈추므로 과대적합 방지 기법으로 분류된다.

출제 포인트: 조기 종료의 기준은 "훈련 오차"가 아니라 "**검증 오차** 증가 시점". 훈련↔검증 바꿔치기가 이 유형의 핵심 함정.

근거: 조기 종료(early stopping)는 학습 중 검증 오차가 증가하기 시작하는 시점에 학습을 중단하여 과대적합을 방지하는 기법이다.

Q4-030 [난이도: 상] [태그: 4과목/분석모형평가및개선/규제비교]

규제(regularization) 기법에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 라쏘(Lasso)는 L1 벌점을 사용하여 희소(sparse)한 모형을 만든다.
② 릿지(Ridge)는 계수를 0에 가깝게 축소하지만 정확히 0으로 만들지는 않는다.
③ 엘라스틱넷(Elastic Net)은 L1과 L2 벌점을 함께 사용하는 절충 기법이다.
④ L2 규제는 일부 계수를 정확히 0으로 만들기 때문에 변수 선택 목적으로 주로 사용된다.

✓ 정답 및 해설

정답: ④

- ① 옳은 설명. L1(절댓값 합) 벌점은 다수의 계수를 0으로 만들어 희소 모형을 생성한다.
- ② 옳은 설명. L2(제곱합) 벌점은 계수를 골고루 축소(shrinkage)할 뿐 0으로 만들지 않는다.
- ③ 옳은 설명. 엘라스틱넷 = L1 + L2 결합, 두 규제의 절충.
- ④ "계수를 정확히 0으로 만들어 변수 선택"은 **L1(라쏘)** 의 특징이다. L2는 축소만 한다. ← 정답

출제 포인트: L1 = 0으로 만듦·변수 선택·희소성(라쏘) / L2 = 축소만·다중공선성에 강건(릿지) / L1+L2 = 엘라스틱넷. 두 규제의 특징을 맞바꾼 선지가 상급 문제의 정답 패턴.

근거: L2 규제(릿지)는 계수의 제곱합을 벌점으로 부과해 계수를 0에 가깝게 축소하되 0으로 만들지는 않는 규제 기법으로, 변수 선택 효과는 L1 규제(라쏘)의 특징이다.

Q4-031 [난이도: 상] [태그: 4과목/분석모형평가및개선/옵티마이저계보]

옵티마이저(optimizer)의 발전 과정에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 모멘텀(Momentum)은 이전 이동 방향을 관성으로 반영해 갱신의 진동을 줄인다.
- ㄴ. AdaGrad는 기울기 제곱을 계속 누적하므로 학습이 진행될수록 학습률이 감소해 0에 가까워지는 문제가 있다.
- ㄷ. RMSProp은 지수이동평균을 사용하여 AdaGrad의 학습률 소실 문제를 보완했다.
- ㄹ. Adam은 AdaGrad와 배치 정규화(batch normalization)를 결합한 방식이다.

① ㄱ, ㄴ, ㄷ ② ㄱ, ㄹ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄴ, ㄷ, ㄹ

> **✓ 정답 및 해설**
>
> **정답: ①**
>
> - **ㄱ (O)** 모멘텀 = 관성으로 진동 완화·수렴 가속.
> - **ㄴ (O)** AdaGrad = 기울기 제곱 누적으로 변수별 학습률 조정, 누적이 커질수록 학습률이 0에 가까워져 학습이 멈추는 한계.
> - **ㄷ (O)** RMSProp = 누적 대신 지수이동평균(최근 기울기에 가중)으로 AdaGrad의 소실 문제 보완.
> - **ㄹ (X)** Adam = **모멘텀 + RMSProp**의 결합이다. 배치 정규화는 옵티마이저가 아니라 학습 안정화 기법.
>
> 따라서 옳은 것은 ㄱ, ㄴ, ㄷ → **①**. (②·④는 틀린 ㄹ 포함 여부와 옳은 항목 누락, ③은 틀린 ㄹ을 포함)
>
> **출제 포인트:** 계보 흐름 — GD → 모멘텀(관성 개선) / AdaGrad(학습률 개선) → RMSProp(AdaGrad 보완) → Adam(모멘텀+RMSProp). Adam의 결합 대상을 바꿔치기(AdaGrad, 배치 정규화 등)한 선지가 단골.
>
> **근거:** 옵티마이저는 관성을 도입한 모멘텀과 학습률을 적응 조정하는 AdaGrad, 이를 보완한 RMSProp을 거쳐 두 계열을 결합한 Adam으로 발전했다.

Q4-032 [난이도: 상] [태그: 4과목/분석모형평가및개선/최종모형선정]

분석모형 융합과 최종모형 선정에 대한 설명으로 옳은 것은?

① 최종모형은 훈련 데이터에서의 성능이 가장 높은 모형으로 선정하면 충분하다.
② 여러 모형을 융합(앙상블)하면 단일 모형보다 예측 결과의 해석이 항상 쉬워진다.
③ 최종모형 선정 시 평가 데이터의 성능 지표와 함께 해석 가능성, 운영 환경 적용 가능성 등 비즈니스 요건을 종합적으로 고려한다.
④ 보팅(voting)은 여러 모형의 예측을 결합하는 방법이 아니라 하나의 모형을 반복 학습시키는 방법이다.

✓ 정답 및 해설

정답: ③

- ① 훈련 성능만 보면 과대적합 모형을 선정할 위험이 있다. 선정 기준은 **평가(검증) 데이터의 일반화 성능**.
- ② 앙상블은 성능은 좋아질 수 있으나 여러 모형이 결합되어 **해석은 오히려 어려워지는** 경향이 있다. "항상 쉬워진다"는 틀림.
- ③ 성능 지표 + 해석 가능성 + 운영 적용성(속도·비용·유지보수) + 비즈니스 목표 부합을 종합 고려하는 것이 최종모형 선정의 원칙. ← 정답
- ④ 보팅은 서로 다른 여러 모형의 예측을 **다수결·평균으로 결합**하는 융합 방법이다. "반복 학습"은 부스팅 계열에 가까운 설명.

출제 포인트: 최종모형 선정 3요소 — **평가 데이터 성능 / 해석 가능성 / 운영(비즈니스) 적용성**. "훈련 성능만", "항상"이 들어간 선지는 함정.

근거: 최종모형 선정은 평가 데이터 기반 성능 지표에 해석 가능성과 운영 환경 적용 가능성 등 비즈니스 요건을 더해 종합적으로 판단하는 과정이다.

4-3 분석결과 해석

> 4과목 · 빅데이터 결과 해석 / 주요항목: 분석결과 해석 및 활용
> 문항 수: 8 (Q4-033 ~ Q4-040) · 난이도 하2/중4/상2 · 정답 분포 ①2 ②2 ③2 ④2

Q4-033 [난이도: 하] [태그: 4과목/분석결과해석및활용/분석모형해석]

분석모형의 결과를 비즈니스 관점에서 해석·전달하는 방법으로 가장 적절한 것은?

① 정확성을 위해 통계 용어와 수식을 가공 없이 그대로 사용하여 보고한다.
② 분석 결과가 비즈니스 목표(KPI)에 미치는 영향과 기대 효과를 중심으로 전달한다.
③ 모형의 하이퍼파라미터 튜닝 과정을 상세히 나열하는 데 집중한다.
④ 의사결정자의 관심사보다 분석가가 사용한 알고리즘의 우수성을 우선 강조한다.

✓ 정답 및 해설

정답: ②

- ① 통계 용어·수식 나열은 비전문가인 의사결정자의 이해를 방해한다. 비즈니스 언어로 번역해야 함.
- ② 분석 결과를 비즈니스 목표·기대 효과와 연결해 전달하는 것이 분석모형 해석의 핵심. ← 정답
- ③ 튜닝 과정은 기술 문서의 영역. 비즈니스 보고의 중심이 아님.
- ④ 전달의 중심은 알고리즘이 아니라 **의사결정자의 관심사(문제 해결·성과)**여야 한다.

출제 포인트: 분석 결과 해석의 원칙 = "기술 언어 → 비즈니스 언어" 번역, 목표(KPI)·기대 효과 중심, 의사결정자 관점.

근거: 분석모형 해석은 분석 결과를 통계·기술 용어가 아닌 비즈니스 목표와 기대 효과 중심의 언어로 변환하여 의사결정자에게 전달하는 활동이다.

Q4-034 [난이도: 하] [태그: 4과목/분석결과해석및활용/IRR]

투자안의 순현재가치(NPV)가 0이 되도록 만드는 할인율을 의미하는 비즈니스 기여도 평가 지표는?

① 투자 대비 이익률(ROI)
② 총 소유 비용(TCO)
③ 내부수익률(IRR)
④ 투자 회수 기간(payback period)

✓ 정답 및 해설

정답: ③

- ① ROI(Return On Investment): 투자 비용 대비 순이익의 **비율**. 할인율이 아님.
- ② TCO(Total Cost of Ownership): 자산의 도입부터 폐기까지 드는 **총 비용**. 수익률 개념이 아님.
- ③ IRR(Internal Rate of Return): **NPV = 0이 되는 할인율**. ← 정답
- ④ payback period: 누적 이익이 투자비에 도달하는 **기간**. 할인율이 아님.

출제 포인트: "NPV=0이 되는 할인율"이라는 문구가 보이면 무조건 IRR. 비율=ROI, 금액=NPV, 할인율=IRR, 비용=TCO, 기간=회수 기간으로 단위 감각으로 구분.

근거: 내부수익률(IRR, Internal Rate of Return)은 투자안의 순현재가치(NPV)를 0으로 만드는 할인율이다.

Q4-035 [난이도: 중] [태그: 4과목/분석결과해석및활용/기여도평가지표]

비즈니스 기여도 평가 지표에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 투자 대비 이익률(ROI)은 순현재가치가 0이 되도록 하는 할인율을 의미한다.
② 순현재가치(NPV)는 미래 현금흐름의 현재가치에서 투자 비용을 뺀 값이다.
③ 총 소유 비용(TCO)은 자산의 획득뿐 아니라 운영·유지보수 등 전 기간의 비용을 합산한 것이다.
④ 투자 회수 기간(payback period)은 누적 이익이 투자 비용에 도달하는 데 걸리는 기간이다.

✓ 정답 및 해설

정답: ①

- ① "NPV=0이 되는 할인율"은 ROI가 아니라 **IRR(내부수익률)**의 정의다. ROI는 투자 비용 대비 순이익의 **비율**. ← 정답 (IRR↔ROI 바꿔치기 함정)
- ② 옳은 설명. NPV(Net Present Value) = 미래 현금흐름의 현재가치 − 투자비.
- ③ 옳은 설명. TCO(Total Cost of Ownership)는 구매비 + 운영·유지보수 등 총 비용.
- ④ 옳은 설명. payback period는 투자비를 회수하는 데 걸리는 기간.

출제 포인트: 단골 함정 = ROI와 IRR의 정의 바꿔치기. ROI는 "비율(%)", IRR은 "NPV=0인 할인율"로 즉시 구분할 것.

근거: 투자 대비 이익률(ROI, Return On Investment)은 투자 비용 대비 순이익의 비율로 투자 효과를 평가하는 지표다.

Q4-036 [난이도: 중] [태그: 4과목/분석결과해석및활용/ROI계산]

어느 기업이 빅데이터 분석 프로젝트에 총 2,000만 원을 투자하여 500만 원의 순이익을 얻었다. 이 프로젝트의 투자 대비 이익률(ROI)은?

① 15% ② 20% ③ 40% ④ 25%

✓ 정답 및 해설

정답: ④

- ROI = (순이익 ÷ 총 투자 비용) × 100 = (500 ÷ 2,000) × 100 = **25%**
- ① 15%: 계산 근거 없음(오답 유도용).
- ② 20%: 분모를 2,500(투자+이익)으로 잘못 놓으면 나오는 값.
- ③ 40%: 분자·분모를 뒤집은 400%(2,000÷500)를 자릿수 착오로 잘못 축소했을 때 나올 수 있는 오답 유도 값.
- ④ 정의대로 계산한 값. ← 정답

출제 포인트: ROI 공식 = 순이익/투자비 × 100. 분모는 항상 "투자 비용"이다. 투자+이익의 합계를 분모로 쓰는 실수 주의.

근거: ROI(Return On Investment)는 총 투자 비용 대비 순이익의 비율(순이익 ÷ 투자비 × 100)로 산출하는 투자 효과 평가 지표다.

Q4-037 [난이도: 중] [태그: 4과목/분석결과해석및활용/투자회수기간]

어느 기업이 분석 시스템 구축에 1억 2,000만 원을 투자하였고, 이 시스템으로 매년 3,000만 원의 순이익이 균등하게 발생한다. 투자 회수 기간(payback period)은?

① 3년 ② 4년 ③ 5년 ④ 6년

✓ 정답 및 해설

정답: ②

- 투자 회수 기간 = 투자 비용 ÷ 연간 순이익 = 12,000만 ÷ 3,000만 = **4년**
- ① 3년: 누적 이익 9,000만 원 → 아직 투자비 미달.
- ② 4년: 누적 이익 1억 2,000만 원 = 투자비 도달. ← 정답
- ③, ④ 이미 4년에 회수가 완료되므로 초과 기간.

출제 포인트: 연간 이익이 균등하면 "투자비 ÷ 연간 순이익"으로 즉시 계산. 회수 기간은 짧을수록 유리하다.

근거: 투자 회수 기간(payback period)은 누적 이익(현금흐름)이 초기 투자 비용에 도달하는 데 걸리는 기간이다.

Q4-038 [난이도: 중] [태그: 4과목/분석결과해석및활용/기여도평가판단]

분석 결과의 비즈니스 기여도 평가에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 순현재가치(NPV)가 0보다 크면 해당 투자는 타당성이 있다고 판단한다.
② 내부수익률(IRR)이 요구수익률보다 크면 투자 매력이 있다고 판단한다.

③ 투자 회수 기간(payback period)은 길수록 투자 위험이 낮다고 판단한다.
④ 총 소유 비용(TCO)은 도입 비용뿐 아니라 운영·유지보수 비용까지 포함하여 비교한다.

> **✓ 정답 및 해설**
>
> **정답:** ③
>
> - ① 옳은 설명. NPV > 0 → 미래 현금흐름의 현재가치가 투자비보다 크므로 타당.
> - ② 옳은 설명. IRR > 요구수익률(자본비용) → 투자 채택.
> - ③ 회수 기간은 **짧을수록** 투자금을 빨리 회수하므로 위험이 낮다. "길수록 위험이 낮다"는 반대로 쓴 틀린 설명. ← 정답
> - ④ 옳은 설명. TCO는 전 기간 총 비용 관점의 비교 지표.
>
> **출제 포인트:** 판단 기준 3종 세트 = NPV > 0 채택 / IRR > 요구수익률 채택 / 회수 기간 짧을수록 유리. 방향을 뒤집는 부정형 함정 주의.
>
> **근거:** 순현재가치(NPV)가 0보다 크면 투자로 얻는 현금흐름의 현재가치가 투자 비용을 초과하므로 투자 타당성이 있다고 판단한다.

Q4-039 [난이도: 상] [태그: 4과목/분석결과해석및활용/NPV·IRR비교]

순현재가치(NPV)와 내부수익률(IRR) 등에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 내부수익률(IRR)은 적용하는 할인율이 높아질수록 함께 커지는 지표다.
② 순현재가치(NPV)는 미래 현금흐름을 할인율로 현재가치화한 값에서 투자비를 뺀 것으로, 일반적인 투자안에서 할인율이 높아지면 작아진다.
③ 일반적인(초기 투자 후 이익이 발생하는) 투자안에서 IRR이 요구수익률보다 크면 그 투자안의 NPV는 0보다 크다.
④ 투자 회수 기간(payback period)은 화폐의 시간가치를 고려하지 않는 한계가 있다.

> **✓ 정답 및 해설**
>
> **정답:** ①
>
> - ① IRR은 투자안의 **현금흐름 자체**로부터 산출되는 값(NPV=0이 되는 할인율)이므로, 외부에서 적용하는 할인율과 **무관**하게 정해진다. 할인율 변화에 따라 커지는 것은 IRR이 아님. ← 정답
> - ② 옳은 설명. 할인율↑ → 미래 현금흐름의 현재가치↓ → NPV↓.
> - ③ 옳은 설명. IRR > 요구수익률이면 요구수익률로 할인한 NPV > 0 (일반적 현금흐름 가정).
> - ④ 옳은 설명. 단순 회수 기간법은 시간가치와 회수 이후의 이익을 반영하지 못한다.
>
> **출제 포인트:** NPV는 "할인율을 넣어 계산하는 금액", IRR은 "현금흐름이 정해주는 할인율". NPV는 할인율에 따라 변하지만 IRR은 변하지 않는다는 대비가 핵심.
>
> **근거:** 내부수익률(IRR)은 투자안의 현금흐름만으로 결정되는, 순현재가치(NPV)를 0으로 만드는 할인율이므로 외부 할인율의 선택과 무관하다.

Q4-040 [난이도: 상] [태그: 4과목/분석결과해석및활용/지표사례적용]

빅데이터 분석 시스템 도입을 검토하는 회의에서 나온 다음 발언을 비즈니스 기여도 평가 지표와 짝지은 것으로 옳은 것은?

- ㄱ. "서버 구매비뿐 아니라 5년간의 운영·유지보수·교육 비용까지 전부 합산해 봅시다."
- ㄴ. "누적 이익이 초기 투자비와 같아지는 시점이 언제인지 확인해 봅시다."
- ㄷ. "미래 현금흐름을 현재가치로 환산한 금액에서 투자비를 빼 봅시다."
- ㄹ. "투자 비용 대비 순이익이 몇 %인지 계산해 봅시다."

① ㄱ-ROI, ㄴ-투자 회수 기간, ㄷ-NPV, ㄹ-TCO
② ㄱ-TCO, ㄴ-IRR, ㄷ-NPV, ㄹ-ROI
③ ㄱ-TCO, ㄴ-투자 회수 기간, ㄷ-IRR, ㄹ-ROI
④ ㄱ-TCO, ㄴ-투자 회수 기간, ㄷ-NPV, ㄹ-ROI

✓ 정답 및 해설

정답: ④

- **ㄱ** 도입~운영 전 기간의 총 비용 합산 → **TCO(Total Cost of Ownership, 총 소유 비용)**
- **ㄴ** 누적 이익 = 투자비가 되는 시점 → **투자 회수 기간(payback period)**
- **ㄷ** 현금흐름의 현재가치 − 투자비 → **NPV(Net Present Value, 순현재가치)**
- **ㄹ** 투자비 대비 순이익의 비율(%) → **ROI(Return On Investment, 투자 대비 이익률)**
- ① ㄱ·ㄹ이 서로 바뀜(비용 합산은 TCO, 비율은 ROI).
- ② ㄴ이 틀림. IRR은 "NPV=0인 할인율"이지 회수 시점이 아님.
- ③ ㄷ이 틀림. 현재가치−투자비라는 "금액"은 NPV. IRR은 할인율.
- ④ 네 개 모두 정의와 일치. ← 정답

출제 포인트: 발언 속 단서 단어로 판별 — "총 비용"=TCO, "시점·기간"=회수 기간, "현재가치−투자비(금액)"=NPV, "비율(%)"=ROI, "NPV=0인 할인율"=IRR.

근거: 비즈니스 기여도 평가 지표는 ROI(투자 대비 이익률), NPV(순현재가치), IRR(내부수익률), TCO(총 소유 비용), 투자 회수 기간(payback period)으로 구성되며 각각 비율·금액·할인율·비용·기간을 측정한다.

4-4 분석 결과 시각화

> 4과목 · 분석 결과 해석 및 활용 / 주요항목: 분석 결과 시각화
> 문항 수: 12 (Q4-041 ~ Q4-052) · 난이도 하4/중6/상2 · 정답 분포 ①3 ②3 ③3 ④3
> 범위: 시각화 5유형(시간·분포·관계·비교·공간)과 차트 매칭, 차트별 특징(카토그램·체르노프 페이스·평행 좌표), 인포그래픽, 시각화 절차 3단계

Q4-041 [난이도: 하] [태그: 4과목/분석결과해석및활용/시간시각화]

시간의 흐름에 따른 데이터의 변화·추세(trend)를 표현하는 시간 시각화 기법에 해당하는 것은?

① 파이 차트(pie chart)
② 선 그래프(line graph)
③ 산점도(scatter plot)
④ 히트맵(heatmap)

✓ 정답 및 해설

정답: ②

- ① 전체에서 각 부분이 차지하는 비율을 표현 → 분포 시각화.
- ② 시간 축을 따라 값의 변화·추세를 표현 → 시간 시각화. ← 정답
- ③ 두 변수 간의 관계를 점으로 표현 → 관계 시각화.
- ④ 값의 크기를 색상으로 표현해 여러 항목을 비교 → 비교 시각화.

출제 포인트: 시간 시각화 = 막대그래프·선그래프·영역 차트·계단식 그래프. "추세·시계열"이 보이면 시간 시각화로 연결.

근거: 시간 시각화는 시간의 흐름에 따른 데이터의 변화와 경향(추세)을 표현하는 시각화 유형으로 막대그래프·선그래프·영역 차트·계단식 그래프가 대표적이다.

Q4-042 [난이도: 하] [태그: 4과목/분석결과해석및활용/카토그램]

지역별 데이터 값(인구, 선거인 수 등)에 비례하도록 지도의 면적을 의도적으로 왜곡하여 표현하는 공간 시각화 기법은?

① 도트맵(dot map)
② 등치지역도(choropleth map)
③ 버블 플롯맵(bubble plot map)
④ 카토그램(cartogram)

✓ 정답 및 해설

정답: ④

- ① 지도 위에 데이터 값을 같은 크기의 점의 개수·밀도로 표현. 면적 왜곡 없음.
- ② 지역별 값을 색상의 음영·농도로 구분해 표현. 면적은 실제 지도 그대로.
- ③ 지도 위 해당 위치에 원(버블)의 크기로 값을 표현. 면적 왜곡 없음.
- ④ 값에 비례해 지역의 면적 자체를 확대·축소(왜곡)해 그린 변형 지도. ← 정답

출제 포인트: 공간 시각화 구분 키워드 — 색상 농도=등치지역도, 점의 밀도=도트맵, 원의 크기=버블 플롯맵, **면적 왜곡=카토그램**.

근거: 카토그램(cartogram)은 특정 데이터 값에 비례하여 지역의 면적을 의도적으로 왜곡해 표현하는 변형 지도 형태의 공간 시각화 기법이다.

Q4-043 [난이도: 하] [태그: 4과목/분석결과해석및활용/분포시각화]

다음 중 분포 시각화 기법에 해당하지 **않는** 것은?

① 산점도(scatter plot)
② 파이 차트(pie chart)
③ 도넛 차트(donut chart)
④ 트리맵(treemap)

✓ 정답 및 해설

정답: ①

- ① 두 변수 간 상관관계를 점으로 표현 → 관계 시각화. 분포 시각화가 아님. ← 정답
- ② 원 전체를 100%로 두고 부분의 비율을 부채꼴로 표현 → 분포 시각화.
- ③ 파이 차트의 가운데를 비운 형태로 비율을 표현 → 분포 시각화.
- ④ 전체를 사각형 영역으로 나누고 면적으로 비율·계층을 표현 → 분포 시각화.

출제 포인트: 분포 시각화 = 파이·도넛·트리맵·누적 영역 차트. "전체 대비 비율·구성"이 핵심 키워드.

근거: 분포 시각화는 전체에서 각 부분이 차지하는 비율이나 분류를 표현하는 시각화 유형으로 파이 차트·도넛 차트·트리맵·누적 영역 차트가 대표적이다.

Q4-044 [난이도: 하] [태그: 4과목/분석결과해석및활용/체르노프페이스]

다변량 데이터를 눈·코·입·귀 등 사람 얼굴의 각 요소에 대응시켜, 얼굴 모양의 차이로 여러 대상을 비교하는 시각화 기법은?

① 스타 차트(star chart)
② 평행 좌표 그래프(parallel coordinates)

③ 체르노프 페이스(Chernoff faces)
④ 히트맵(heatmap)

✓ 정답 및 해설

정답: ③

- ① 중심에서 뻗은 방사형 축에 변수 값을 표시해 다각형으로 비교. 얼굴 요소와 무관.
- ② 여러 개의 평행한 세로 축에 변수를 배치하고 선으로 연결해 다변량을 비교. 얼굴 요소와 무관.
- ③ 변수 값을 얼굴 요소(눈 크기, 입 모양 등)에 대응시켜 표현 → 체르노프 페이스. ← 정답
- ④ 행렬 형태의 칸을 색상으로 채워 값의 크기를 비교. 얼굴 요소와 무관.

출제 포인트: 비교 시각화 3대 특징 매칭 — 얼굴 요소=체르노프 페이스, 방사형(거미줄) 축=스타 차트, 평행한 다변량 축=평행 좌표 그래프.

근거: 체르노프 페이스(Chernoff faces)는 다변량 데이터의 각 변수를 사람 얼굴의 요소에 대응시켜 얼굴 형태의 차이로 데이터를 비교하는 비교 시각화 기법이다.

Q4-045 [난이도: 중] [태그: 4과목/분석결과해석및활용/시각화절차]

빅데이터 시각화 절차 3단계를 순서대로 바르게 나열한 것은?

① 시각화 → 구조화 → 시각표현
② 구조화 → 시각화 → 시각표현
③ 구조화 → 시각표현 → 시각화
④ 시각표현 → 구조화 → 시각화

✓ 정답 및 해설

정답: ②

- ① 시각화 도구 적용보다 데이터·목표의 구조화가 먼저여야 하므로 틀림.
- ② 구조화(목표 설정·데이터 정리) → 시각화(도구·기법으로 표현) → 시각표현(그래픽 요소 다듬어 완성도 제고). ← 정답
- ③ 시각표현은 마지막 보정 단계이므로 시각화보다 앞설 수 없음.
- ④ 시각표현이 첫 단계가 될 수 없음.

출제 포인트: "구·시·표"로 암기 — 구조화(무엇을 보여줄지 정리) → 시각화(차트로 만들기) → 시각표현(색·레이블·인터랙션 등으로 다듬기).

근거: 빅데이터 시각화 절차는 데이터와 시각화 목표를 정리하는 구조화, 시각화 도구·기법으로 표현하는 시각화, 그래픽 요소를 보정해 정보 전달력을 높이는 시각표현의 3단계로 수행된다.

Q4-046 [난이도: 중] [태그: 4과목/분석결과해석및활용/비교시각화]

다음 중 비교 시각화 기법에 해당하지 **않는** 것은?

① 히트맵(heatmap)
② 스타 차트(star chart)
③ 평행 좌표 그래프(parallel coordinates)
④ 등치지역도(choropleth map)

✓ 정답 및 해설

정답: ④

- ① 색상으로 여러 항목·변수의 값 크기를 한눈에 비교 → 비교 시각화.
- ② 방사형 축의 다각형으로 여러 대상의 다변량 값을 비교 → 비교 시각화.
- ③ 평행한 변수 축들을 선으로 연결해 다변량 데이터를 비교 → 비교 시각화.
- ④ 지도 위 지역별 값을 색상 농도로 표현 → 공간 시각화. 비교 시각화가 아님. ← 정답

출제 포인트: 비교 시각화 = 히트맵·체르노프 페이스·스타 차트·평행 좌표 그래프. "지도"가 나오면 무조건 공간 시각화.

근거: 비교 시각화는 여러 변수·항목 간 값의 차이를 비교하기 위한 시각화 유형으로 히트맵·체르노프 페이스·스타 차트·평행 좌표 그래프가 대표적이다.

Q4-047 [난이도: 중] [태그: 4과목/분석결과해석및활용/관계시각화]

다음 중 관계 시각화 기법으로만 묶인 것은?

① 산점도, 버블 차트, 히스토그램
② 산점도, 파이 차트, 히트맵
③ 버블 차트, 트리맵, 선 그래프
④ 히스토그램, 도넛 차트, 카토그램

> **✓ 정답 및 해설**
>
> **정답:** ①
>
> - ① 산점도·버블 차트·히스토그램 모두 관계 시각화. ← 정답
> - ② 산점도는 관계 시각화이나, 파이 차트는 분포·히트맵은 비교 시각화.
> - ③ 버블 차트는 관계 시각화이나, 트리맵은 분포·선 그래프는 시간 시각화.
> - ④ 히스토그램은 관계 시각화이나, 도넛 차트는 분포·카토그램은 공간 시각화.
>
> **출제 포인트:** 관계 시각화 = 산점도·산점도 행렬·버블 차트·히스토그램. 버블 차트는 산점도에 크기(제3의 변수)를 더한 확장형.
> ※ 교재별 표기 차이 있음 — 히스토그램을 분포 시각화로 분류하는 교재도 있으나, KDATA 계열 교재는 관계 시각화로 분류하는 것이 다수.
>
> **근거:** 관계 시각화는 변수 간의 연관성·상관관계를 표현하는 시각화 유형으로 산점도·산점도 행렬·버블 차트·히스토그램이 대표적이다.

Q4-048 [난이도: 중] [태그: 4과목/분석결과해석및활용/공간시각화]

다음 중 공간 시각화 기법으로만 묶인 것은?

① 도트맵, 트리맵, 카토그램
② 등치지역도, 히트맵, 버블 플롯맵
③ 등치지역도, 도트맵, 카토그램
④ 카토그램, 버블 차트, 계단식 그래프

> **✓ 정답 및 해설**
>
> **정답:** ③
>
> - ① 도트맵·카토그램은 공간 시각화이나, 트리맵은 분포 시각화.
> - ② 등치지역도·버블 플롯맵은 공간 시각화이나, 히트맵은 비교 시각화.
> - ③ 등치지역도·도트맵·카토그램 모두 지도 기반의 공간 시각화. ← 정답
> - ④ 카토그램은 공간 시각화이나, 버블 차트는 관계·계단식 그래프는 시간 시각화.
>
> **출제 포인트:** 공간 시각화 4총사 = 등치지역도(코로플레스)·도트맵·카토그램·버블 플롯맵. 지도 위가 아닌 버블 "차트"는 관계 시각화라는 점이 단골 함정.
>
> **근거:** 공간 시각화는 지도 위에 위치 정보와 결합하여 데이터를 표현하는 시각화 유형으로 등치지역도·도트맵·카토그램·버블 플롯맵이 대표적이다.

Q4-049 [난이도: 중] [태그: 4과목/분석결과해석및활용/평행좌표그래프]

여러 노트북 제품을 가격·무게·성능·배터리 시간 등 4개 이상의 변수에 대해 한 화면에서 동시에 비교하려고 한다. 각 변수를 평행한 세로 축으로 배치하고 제품마다 축 위의 값을 선으로 이어 표현하기에 가장 적절한 기법

은?

① 평행 좌표 그래프(parallel coordinates)
② 파이 차트(pie chart)
③ 선 그래프(line graph)
④ 도트맵(dot map)

> **✓ 정답 및 해설**
>
> **정답:** ①
>
> - ① 다변량(변수 여러 개) 데이터를 평행한 변수 축 위의 꺾은선으로 표현해 여러 대상을 비교 → 상황에 정확히 부합. ← 정답
> - ② 한 변수의 구성 비율만 표현 가능. 다변량 비교 불가.
> - ③ 가로 축이 시간인 추세 표현용. 변수별 평행 축 개념이 없음.
> - ④ 지도 위 분포 표현용 공간 시각화. 제품 비교와 무관.
>
> **출제 포인트:** 평행 좌표 그래프의 시그니처 = "다변량 + 평행한 축 + 선으로 연결". 선 그래프(시간 축 1개)와 혼동시키는 함정에 주의.
>
> **근거:** 평행 좌표 그래프(parallel coordinates)는 여러 변수를 평행한 축에 나란히 배치하고 각 개체의 값을 선으로 연결하여 다변량 데이터를 비교하는 비교 시각화 기법이다.

Q4-050 [난이도: 중] [태그: 4과목/분석결과해석및활용/인포그래픽]

인포그래픽(infographic)에 대한 설명으로 옳지 **않은** 것은?

① 정보(information)와 그래픽(graphic)의 합성어로, 복잡한 정보를 그래픽으로 표현한 것이다.
② 도표·일러스트 등을 활용해 정보를 쉽고 빠르게 전달하며 대중의 흥미를 유발한다.
③ 스토리텔링 방식으로 메시지를 전달할 수 있어 홍보·보도 자료 등에 널리 활용된다.
④ 분석 전문가를 대상으로 원시 데이터와 통계 수치를 표 형태로 빠짐없이 나열하는 것을 목적으로 한다.

> **✓ 정답 및 해설**
>
> **정답:** ④
>
> - ① 옳은 설명. 인포그래픽의 어원이자 기본 정의.
> - ② 옳은 설명. 쉽고 빠른 전달과 흥미 유발이 인포그래픽의 핵심 장점.
> - ③ 옳은 설명. 스토리텔링 기반 전달로 기억에 오래 남는다.
> - ④ 인포그래픽은 **일반 대중**이 정보를 **쉽게 이해**하도록 요약·시각화하는 것이 목적이다. 전문가용 수치 나열은 정반대의 설명. ← 정답
>
> **출제 포인트:** 인포그래픽 키워드 = 대중·쉬움·빠른 전달·흥미·스토리텔링. "전문가·상세 수치·표 나열"이 나오면 틀린 선지.
>
> **근거:** 인포그래픽은 정보와 그래픽의 합성어로, 복잡한 정보를 도표·이미지 등으로 시각화하여 일반 대중이 쉽고 빠르게 이해하도록 전달하는 시각화 방법이다.

Q4-051 [난이도: 상] [태그: 4과목/분석결과해석및활용/시각화유형매칭]

시각화 유형과 차트의 매칭에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 계단식 그래프(step chart)는 시간 시각화 기법이다.
- ㄴ. 트리맵(treemap)은 비교 시각화 기법이다.
- ㄷ. 버블 차트(bubble chart)는 관계 시각화 기법이다.
- ㄹ. 히트맵(heatmap)은 비교 시각화 기법이다.

① ㄱ, ㄴ, ㄷ ② ㄱ, ㄷ, ㄹ ③ ㄴ, ㄷ, ㄹ ④ ㄱ, ㄴ, ㄹ

✓ 정답 및 해설

정답: ②

- **ㄱ (O)** 계단식 그래프는 값이 유지되다 특정 시점에 변하는 모습을 표현하는 시간 시각화.
- **ㄴ (X)** 트리맵은 전체 대비 비율·계층을 면적으로 표현하는 **분포** 시각화.
- **ㄷ (O)** 버블 차트는 산점도에 원의 크기(제3의 변수)를 더한 관계 시각화.
- **ㄹ (O)** 히트맵은 색상으로 여러 변수·항목의 값을 비교하는 비교 시각화.

따라서 옳은 것은 ㄱ, ㄷ, ㄹ → **②**. (①·④는 틀린 ㄴ을 포함, ③은 옳은 ㄱ을 누락하고 ㄴ을 포함)

출제 포인트: 5유형 매칭 총정리 — 시간(막대·선·영역·계단) / 분포(파이·도넛·트리맵·누적영역) / 관계(산점도·버블·히스토그램) / 비교(히트맵·체르노프·스타·평행좌표) / 공간(등치지역도·도트맵·카토그램·버블플롯맵).

근거: 데이터 시각화는 표현 목적에 따라 시간·분포·관계·비교·공간 시각화의 5유형으로 나뉘며 각 유형마다 대표 차트가 정해져 있다.

Q4-052 [난이도: 상] [태그: 4과목/분석결과해석및활용/공간시각화특징]

공간 시각화 기법의 특징에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 등치지역도(choropleth map)는 지역별 값을 색상의 음영·농도로 표현하며, 면적이 큰 지역이 실제 값보다 강조되어 보이는 왜곡이 생길 수 있다.
② 도트맵(dot map)은 데이터 값을 지도 위 점의 개수·밀도로 표현하여 분포 양상을 보여준다.
③ 카토그램(cartogram)은 지역의 실제 면적을 그대로 유지한 채 색상만으로 데이터 값을 표현한다.
④ 버블 플롯맵(bubble plot map)은 지도 위 해당 위치에 원의 크기로 데이터 값을 표현한다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 등치지역도는 색상 농도 방식이라 면적이 큰 지역이 과대 강조되는 단점이 있고, 이를 보완하는 것이 카토그램이다.
- ② 옳은 설명. 점의 개수·밀도로 분포를 표현하는 것이 도트맵.
- ③ 카토그램은 면적을 유지하는 것이 아니라 **값에 비례해 면적을 왜곡**하는 기법이다. "실제 면적 유지 + 색상 표현"은 등치지역도의 설명. ← 정답
- ④ 옳은 설명. 위치 + 원의 크기로 값을 표현하는 것이 버블 플롯맵.

출제 포인트: 함정 패턴 = 등치지역도와 카토그램의 특징 바꿔치기. "색상 농도·면적 유지=등치지역도, 면적 왜곡=카토그램"으로 짝을 고정해 암기.

근거: 카토그램은 등치지역도의 면적에 따른 왜곡 문제를 보완하기 위해 데이터 값에 비례하여 지역 면적 자체를 변형해 표현하는 공간 시각화 기법이다.

4-5 분석 결과 활용

> 4과목 · 분석 결과 해석 및 활용 / 주요항목: 분석 결과 활용
> 범위: 분석모형 전개(운영 적용·배포) · 분석 결과 활용 시나리오 개발 · 분석모형 모니터링 · 분석모형 리모델링 · 서비스 적용 절차
> 문항 수: 8 (Q4-053 ~ Q4-060) · 난이도 하2/중4/상2 · 정답 분포 ①2 ②2 ③2 ④2

Q4-053 [난이도: 하] [태그: 4과목/분석결과해석및활용/분석모형모니터링]

운영 시스템에 적용된 분석모형이 개발 당시의 성능을 유지하고 있는지 주기적으로 성능을 측정·추적하고, 성능 저하 여부를 점검하는 활동은?

① 분석모형 모니터링 ② 분석모형 전개 ③ 탐색적 데이터 분석(EDA) ④ 데이터 전처리

✓ 정답 및 해설

정답: ①

- ① 모니터링(monitoring): 운영 중인 모형의 성능을 주기적으로 측정·추적하여 저하를 감지하는 활동. ← 정답
- ② 전개(deployment): 개발·검증된 모형을 운영 시스템에 적용·배포하는 활동. 성능 추적이 아님.
- ③ 탐색적 데이터 분석(EDA): 모델링 **이전에** 데이터의 분포·특성·이상값을 파악하는 활동.
- ④ 데이터 전처리: 분석 전에 데이터를 정제·변환하는 활동. 운영 단계의 성능 관리와 무관.

출제 포인트: "운영 중 + 주기적 성능 측정 + 저하 감지"가 보이면 모니터링. "운영 시스템에 적용·배포"가 보이면 전개.

근거: 분석모형 모니터링은 운영 환경에 배포된 분석모형의 성능을 주기적으로 측정·추적하여 성능 저하 여부를 점검하는 활동이다.

Q4-054 [난이도: 하] [태그: 4과목/분석결과해석및활용/분석모형전개]

분석모형 전개(deployment)에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 전개는 개발·검증이 완료된 분석모형을 실제 운영 환경에 적용하는 과정이다.
② 전개 시 운영 시스템과의 인터페이스, 데이터 연계, 호환성을 고려해야 한다.
③ 전개가 완료되면 분석모형에 대한 관리는 종료되며 이후 별도의 점검이 필요 없다.
④ 전개 이후에도 모형의 성능이 유지되는지 지속적으로 모니터링해야 한다.

✓ 정답 및 해설

정답: ③

- ① 옳은 설명. 전개의 정의 그 자체 — 개발·검증 완료 모형의 운영 환경 적용.
- ② 옳은 설명. 운영 시스템 연계(인터페이스·데이터 파이프라인·호환성)는 전개 시 핵심 고려사항.
- ③ 전개는 끝이 아니라 **운영·관리의 시작**이다. 전개 후 모니터링·리모델링이 이어져야 한다. 틀린 설명. ← 정답
- ④ 옳은 설명. 전개 이후 성능 추적(모니터링)은 필수 후속 활동.

출제 포인트: 전개 → 모니터링 → 리모델링으로 이어지는 운영 사이클. "배포하면 끝"이라는 선지는 항상 오답.

근거: 분석모형 전개는 개발·검증된 분석모형을 운영 시스템에 적용·배포하는 과정으로, 전개 이후에는 지속적인 모니터링과 유지 관리가 뒤따른다.

Q4-055 [난이도: 중] [태그: 4과목/분석결과해석및활용/모니터링vs리모델링]

분석모형 모니터링과 리모델링에 대한 설명으로 옳지 **<u>않은</u>** 것은?

① 모니터링은 운영 중인 모형의 성능을 주기적으로 측정하여 성능 저하를 감지하는 활동이다.
② 리모델링은 모형의 성능을 측정·기록만 할 뿐 모형 자체를 변경하지는 않는 활동이다.
③ 리모델링은 데이터나 비즈니스 환경의 변화로 성능이 저하된 모형을 재개발하는 활동이다.
④ 모니터링 결과는 리모델링 수행 여부를 판단하는 근거로 활용된다.

✓ 정답 및 해설

정답: ②

- ① 옳은 설명. 모니터링 = 주기적 성능 측정 + 저하 감지.
- ② "측정만 하고 변경하지 않는" 것은 **모니터링**의 설명이다. 리모델링은 모형을 **재개발·재학습하여 변경**하는 활동. 역할 바꿔치기 선지. ← 정답
- ③ 옳은 설명. 리모델링의 정의 — 데이터·환경 변화에 따른 성능 저하 시 재개발.
- ④ 옳은 설명. 모니터링(감지) → 리모델링(조치)의 관계.

출제 포인트: 모니터링 = **관찰**(측정·추적·감지, 모형은 그대로), 리모델링 = **조치**(재학습·재개발, 모형이 바뀜). 두 개념의 설명을 서로 바꿔치기하는 함정이 단골.

근거: 분석모형 리모델링은 데이터·비즈니스 환경의 변화로 성능이 저하된 분석모형을 최신 데이터로 재학습하거나 재개발하여 개선하는 활동이다.

Q4-056 [난이도: 중] [태그: 4과목/분석결과해석및활용/서비스적용절차]

개발이 완료된 분석모형을 서비스에 적용하여 운영하는 단계를 순서대로 옳게 나열한 것은?

- ㄱ. 분석모형을 운영 시스템에 적용·배포(전개)한다.
- ㄴ. 성능 저하를 감지한다.
- ㄷ. 주기적으로 모형의 성능을 측정한다(모니터링).
- ㄹ. 모형을 재학습·재개발한다(리모델링).

① ㄱ → ㄴ → ㄷ → ㄹ
② ㄷ → ㄱ → ㄴ → ㄹ
③ ㄱ → ㄷ → ㄹ → ㄴ
④ ㄱ → ㄷ → ㄴ → ㄹ

> **✓ 정답 및 해설**
>
> **정답: ④**
>
> - ① 전개 직후 측정도 하기 전에 저하를 감지할 수 없다 — ㄴ이 ㄷ보다 앞설 수 없음.
> - ② 운영 적용(ㄱ) 전에는 운영 성능을 측정(ㄷ)할 대상이 없다 — 순서 모순.
> - ③ 저하 감지(ㄴ) 없이 리모델링(ㄹ)부터 하는 순서 — 감지가 조치보다 앞서야 함.
> - ④ 전개(ㄱ) → 주기적 성능 측정(ㄷ) → 성능 저하 감지(ㄴ) → 리모델링(ㄹ). ← 정답
>
> **출제 포인트:** 운영 사이클 = **전개 → 모니터링(측정) → 저하 감지 → 리모델링**. "적용해야 잴 수 있고, 재야 감지하고, 감지해야 고친다"로 기억. ※ 교재별 표기 차이 있음 — 세부 단계 명칭은 교재마다 다르나 논리적 순서는 동일.
>
> **근거:** 분석모형의 서비스 적용은 운영 시스템 전개 후 모니터링으로 성능을 추적하고, 성능 저하가 감지되면 리모델링으로 이어지는 순환 절차로 수행된다.

Q4-057 [난이도: 중] [태그: 4과목/분석결과해석및활용/활용시나리오개발]

어느 통신사가 고객 이탈 예측 모형을 개발하였다. 다음 중 이 모형의 분석 결과 활용 시나리오(utilization scenario)가 가장 적절하게 수립된 사례는?

① 모형이 산출한 이탈 고위험 고객 목록을 매주 월요일 고객관리팀에 전달하고, 상담원이 해당 고객에게 맞춤 혜택을 안내하도록 업무 절차에 반영한다.
② 분석 결과를 회사 경영 전반의 발전에 다양한 방식으로 폭넓게 활용한다.
③ 모형의 예측 정확도를 95% 이상으로 끌어올리는 것을 활용 목표로 설정한다.
④ 분석 결과 보고서를 사내 공유 폴더에 업로드하여 보관하는 것으로 마무리한다.

✓ 정답 및 해설

정답: ①

- ① 활용 주체(고객관리팀·상담원), 시점(매주 월요일), 대상 업무(고객 관리), 방법(고위험 목록 전달 → 맞춤 혜택 안내)이 모두 구체적으로 정의되고 업무 프로세스에 반영됨 → 활용 시나리오의 요건 충족. ← 정답
- ② "다양하게 폭넓게 활용"은 누가·언제·어떻게가 없는 **추상적 선언**으로, 시나리오라 할 수 없다.
- ③ 예측 정확도 목표는 **모형 성능 개선 목표**이지, 분석 결과를 업무에 어떻게 쓸지 정의하는 활용 시나리오가 아니다.
- ④ 보고서 보관만으로는 결과가 업무·의사결정에 반영되지 않아 **비즈니스 가치 창출로 이어지지 않는다**.

출제 포인트: 활용 시나리오 판별 기준 = **누가(주체)·언제(시점)·어떤 업무에서(대상)·어떻게(방법)** 가 구체적으로 명시되고 업무 프로세스·의사결정 지점에 연결되는가. 추상적 선언·성능 목표·단순 보관은 시나리오가 아니다.

근거: 분석 결과 활용 시나리오 개발은 도출된 분석 결과를 활용할 주체·시점·대상 업무·방법을 구체적으로 정의하여 업무 프로세스와 의사결정에 반영되도록 설계하는 활동이다.

Q4-058 [난이도: 중] [태그: 4과목/분석결과해석및활용/활용시나리오개발]

분석 결과 활용 시나리오 개발에 대한 설명으로 적절하지 **않은** 것은?

① 분석 결과를 누가, 언제, 어떤 업무에서, 어떻게 활용할 것인지 구체적으로 정의하는 활동이다.
② 활용 시나리오는 분석모형을 폐기하는 시점에 처음 수립하는 것이 바람직하다.
③ 시나리오에는 분석 결과가 반영될 업무 프로세스와 의사결정 지점이 포함되어야 한다.
④ 활용 시나리오는 분석 결과가 실제 비즈니스 가치 창출로 이어지도록 연결하는 역할을 한다.

✓ 정답 및 해설

정답: ②

- ① 옳은 설명. 시나리오 개발의 정의 — 활용 주체·시점·업무·방법의 구체화.
- ② 활용 방안은 폐기 시점이 아니라 **분석 기획 단계부터 고려**하고, 결과 도출 후 구체화하는 것이 바람직하다. 시점이 완전히 틀린 설명. ← 정답
- ③ 옳은 설명. 결과가 꽂힐 업무 프로세스·의사결정 지점을 명시해야 실제 활용이 일어난다.
- ④ 옳은 설명. 시나리오는 "분석 결과 → 업무 적용 → 가치 창출"을 잇는 다리.

출제 포인트: 활용 시나리오 = 분석 결과의 **활용 주체(누가)·시점(언제)·대상 업무(어디서)·방법(어떻게)** 을 정의. 수립 시점은 "기획 단계부터, 늦어도 결과 도출 직후" — "폐기 시점"류의 선지는 오답.

근거: 분석 결과 활용 시나리오 개발은 도출된 분석 결과를 업무와 의사결정에 반영하기 위해 활용 주체·시점·방법을 구체적으로 설계하는 활동이다.

Q4-059 [난이도: 상] [태그: 4과목/분석결과해석및활용/분석모형모니터링]

분석모형 모니터링에 대한 설명 중 옳은 것만 모두 고른 것은?

- ㄱ. 운영 중인 분석모형의 성능을 주기적으로 측정하여 성능 저하를 감지하는 활동이다.
- ㄴ. 성능 저하가 감지되어도 운영 안정성을 위해 모형은 수정하지 않고 그대로 계속 사용해야 한다.
- ㄷ. 입력 데이터의 분포가 모형 개발 시점과 달라지면 모형의 성능이 저하될 수 있다.
- ㄹ. 모니터링 결과는 리모델링 수행 여부를 판단하는 근거가 된다.

① ㄱ, ㄴ ② ㄴ, ㄷ, ㄹ ③ ㄱ, ㄷ, ㄹ ④ ㄱ, ㄴ, ㄷ, ㄹ

✓ 정답 및 해설

정답: ③

- **ㄱ (O)** 모니터링의 정의 — 주기적 성능 측정 + 저하 감지.
- **ㄴ (X)** 성능 저하가 감지되면 원인을 분석하고 **리모델링을 검토**해야 한다. "그대로 계속 사용"은 모니터링의 목적 자체를 부정하는 설명.
- **ㄷ (O)** 입력 데이터 분포의 변화는 운영 단계 성능 저하의 대표적 원인.
- **ㄹ (O)** 모니터링(감지)이 리모델링(조치)의 판단 근거를 제공한다.

따라서 옳은 것은 ㄱ, ㄷ, ㄹ → **③**. (①은 틀린 ㄴ 포함·ㄷ ㄹ 누락, ②·④는 틀린 ㄴ을 포함)

출제 포인트: 모니터링의 존재 이유는 "저하를 **감지해서 조치로 연결**"하는 것. 감지하고도 방치한다는 선지는 항상 오답.

근거: 분석모형 모니터링은 운영 중인 모형의 성능을 주기적으로 측정·추적하여 성능 저하를 감지하고, 리모델링 등 후속 조치의 판단 근거를 제공하는 활동이다.

Q4-060 [난이도: 상] [태그: 4과목/분석결과해석및활용/분석모형리모델링]

어느 카드사가 2년 전 개발한 이상거래 탐지 모형을 운영 중이다. 최근 신종 사기 수법이 확산되면서 모니터링 결과 모형의 탐지율이 수개월째 지속적으로 하락하고 있다. 이 상황에서 가장 적절한 조치는?

① 탐지율 하락이 보고되지 않도록 성능 측정 주기를 늘리고 모니터링을 최소화한다.
② 모형은 그대로 두고, 개발 당시의 과거 데이터로 성능을 재검증하여 이상이 없음을 확인한다.
③ 신종 수법은 예외 상황이므로 기존 모형의 판정 임계값만 조정하고 재학습은 하지 않는다.
④ 신종 사기 사례가 포함된 최신 데이터를 반영하여 모형을 재학습·재개발(리모델링)한다.

✓ 정답 및 해설

정답: ④

- ① 모니터링 축소는 성능 저하의 **감지 자체를 포기**하는 것 — 문제를 숨길 뿐 해결이 아님.
- ② 과거 데이터로는 당연히 성능이 나온다. 저하의 원인은 **현재 데이터의 변화**이므로 과거 데이터 재검증은 무의미.
- ③ 데이터 자체(사기 패턴)가 변한 상황에서 임계값 조정만으로는 신종 패턴을 학습할 수 없음 — 근본 조치가 아님.
- ④ 데이터·환경 변화로 인한 지속적 성능 저하 → 최신 데이터 반영 리모델링이 정석. ← 정답

출제 포인트: 사례형 판별 공식 — "패턴·환경이 변했다 + 성능이 지속 하락한다" = 리모델링. 모니터링 축소·과거 데이터 검증·임계값 땜질은 모두 함정 선지.

근거: 분석모형 리모델링은 운영 중 데이터와 환경의 변화로 성능이 지속적으로 저하된 모형을 최신 데이터를 반영하여 재학습·재개발함으로써 성능을 회복시키는 활동이다.

이 문서는 LLM으로 생성 후 3중 검증(사실·논리·규격 / 중복 / 교체분 재검증)을 거친 학습 자료입니다. 교재별 표기가 갈리는 항목은 본문에 "※ 교재별 표기 차이 있음"으로 표시했으며, 상세 목록은 부록의 검증 필요 항목을 참고하세요.