빅데이터분석기사 필기 암기카드

과목별 치트시트 4종 · 숫자모음 · 헷갈리는쌍 108 · 공식모음 — 시험 직전 회독용

the0ne 학습용 · 2026-09-01 생성 · KDATA 공개 출제기준 기반 신규 창작 문항 (기출 복원 아님)

1과목 빅데이터 분석 기획 — 치트시트

① 세부항목별 핵심 표

DIKW (사례 판별)

계층	판별 키워드
데이터	가공 안 된 객관적 사실 (A마트 1,000원)
정보	비교·가공해 의미 부여 (200원 더 싸다)
지식	행동 방침으로 구조화 (A마트에서 사야겠다)
지혜	다른 상황까지 추론 (다른 상품도 쌀 것)

빅데이터 V

확장	구성
3V	Volume(규모)·Velocity(속도)·Variety(다양성)
5V	+Veracity(신뢰성·품질)·Value(가치)
7V	+Validity(정확성)·Volatility(휘발성=유효기간) ※교재차이

- "실시간·생성 속도"=Velocity, "형태"=Variety, "품질"=Veracity

데이터 유형

유형	판별	예	수집 기술
정형	고정 스키마 테이블	RDB 테이블	ETL·Sqoop
반정형	메타데이터(태그·키) 내장	XML·JSON·HTML·로그	Flume·Scribe·Chukwa
비정형	구조 없음	동영상·음성·이미지·텍스트	크롤링·Scrapy

- 가치 산정 곤란 3이유 = **활·창·기** (활용 다변화·새 가치 창출·기술 발전)
- 하드 스킬 = 이론 지식+분석 기술 / 소프트 스킬 = 통찰·전달(스토리텔링)·협력

분석 조직 구조 3유형

구조	누가	단점/특징
집중	별도 전담 조직	현업과 이중화·이원화
기능	해당 부서가 직접	전사 분석 곤란, 과거 실적 위주
분산	전담 인력을 현업 배치	신속 실무 적용, 역할 분담 명확화 필요

하둡 에코시스템

컴포넌트	역할 = 키워드
HDFS	블록 분산 저장+복제 (네임노드=메타데이터, 데이터노드=블록, 복제3, 블록 128MB)
MapReduce	디스크 기반 분산 처리
YARN	자원 관리·스케줄링
Spark	인메모리 처리, 반복 연산·ML 빠름
HBase	HDFS 위 컬럼 기반 NoSQL
Hive	HiveQL(SQL식·선언형) 질의
Pig	Pig Latin(스크립트·절차형)
Sqoop	RDB↔하둡 정형 전송
Flume	로그 수집, 소스–채널–싱크
Kafka	pub-sub 분산 메시징
Zookeeper	분산 코디네이션(설정·동기화·리더 선출)
Oozie	워크플로 스케줄링
Avro	데이터 직렬화

클라우드 (이용자 관리 범위)

모델	제공 범위	이용자
IaaS	인프라(서버·스토리지)	OS부터 직접 관리
PaaS	개발·실행 플랫폼	앱·데이터만 관리
SaaS	완성된 소프트웨어	전부 사업자 (웹메일·웹오피스)

제도

- 데이터 3법 = **개·망·신** (개인정보 보호법·정보통신망법·신용정보법) — 위치정보법 X

- 식별 스펙트럼: 개인정보(식별O, 법O) > 가명정보(추가 정보 결합 시 식별, **법 적용 O**) > 익명정보(식별X, **법 적용 X**)
- 가명정보 동의 없는 처리 3목적 = **통·과·공** (통계작성·과학적 연구·공익적 기록보존) — 맞춤 광고 X
- 마이데이터 = 정보주체 본인 + 전송요구권 + 기계 판독 가능 형태 (전 분야 확대)
- 개인정보 = 살아 있는 개인만, 목적 외 이용 금지, 최소 수집, 익명 우선→곤란 시 가명

비식별화 5기법

기법	예
가명처리	홍길동→임꺽정 (휴리스틱 대체)
총계처리	개별 값→평균·총합 (라운딩·재배열)
데이터 삭제	항목 자체를 없앰
데이터 범주화	33세→30대
데이터 마스킹	홍길동→홍** (가리되 남김)

데이터 품질 4기준

정확성=맞는 값 / 완전성=누락 없음 / 적시성=제때 최신 / 일관성=형식·값 체계 무모순

데이터 변환 5기법 (목적으로 판별)

평활화=노이즈 제거 / 집계=합산·요약(일별→월별) / 일반화=상위 개념 대체(나이→연령대) / 정규화=척도 변환(0~1, 최소-최대·Z-점수) / 속성 생성=새 속성(키·몸무게→BMI)

수집 기술

기술	키워드
FTP	TCP/IP 파일 전송 (제어 21 / 능동 데이터 20)
Rsync	1:1 동기화·미러링
RSS	XML 배급·구독
Open API	인터페이스 호출(pull)
크롤링	웹 방문 수집

로그 수집기 구조

척와=에이전트–컬렉터, HDFS, 하둡 서브프로젝트 / 플룸=소스–채널–싱크 / 로그스태시=입력–필터–출력, 엘라스틱 / 스크라이브=페이스북·실시간 / 플루언티드=태그 라우팅·JSON

저장소

저장소	성격
ODS	운영계 임시 통합 (DW 적재 전)
DW	전사 통합, 정형·정제, Schema-on-Write, 특징=**주통시비**(주제 지향·통합·시계열·비휘발)
데이터 마트	DW의 부서·주제별 부분집합 (완제품)
데이터 레이크	원시 데이터 무가공, Schema-on-Read (날것), ELT 궁합

NoSQL

- 유형-제품: **Key-Value=Redis / Document=MongoDB / Column=HBase·Cassandra / Graph=Neo4j**
- CAP = 일관성(모든 노드 동일 데이터)·가용성(항상 응답)·분할 허용성, **최대 2개** → 분산은 P 전제, CP vs AP 택일
- ACID(원자성·일관성·독립성·지속성)=RDBMS·은행 / BASE(기본적 가용성·소프트 상태·최종 일관성)=NoSQL·SNS

② 순서 암기

- KDD 5단계: 선택→전처리→변환→마이닝→해석·평가 (**선-전-변-마-해**)
- CRISP-DM 6단계: 업무 이해→데이터 이해→데이터 준비→모델링→평가→전개 (**업-데이-데준-모-평-전**)
- SEMMA 5단계: Sample→Explore→Modify→Model→Assess
- 단계 수 = **KDD 5 / CRISP-DM 6 / SEMMA 5 (5-6-5)**
- CRISP-DM 4계층: 단계→일반화 태스크→세분화 태스크→프로세스 실행 (**단-일-세-프**)
- 하향식 발굴: 문제 탐색→문제 정의→해결방안 탐색→타당성 검토 (**탐-정-해-타**)
- 성숙도 4단계: 도입→활용→확산→최적화
- 데이터 확보 계획: 목표 정의→요구사항 도출→예산안 수립→계획 수립 (**목-요-예-계**)
- 분석 WBS 4단계: 과제 정의→준비·탐색→모델링·검증→산출물 정리 (**정-준-모-산**)
- ETL: 추출→변환→적재 / ELT: 추출→적재→변환

③ 매칭 암기

- 사분면(준비도·성숙도): 低低=준비형 / 低高=정착형 / **高低=도입형** / 高高=확산형
- 우선순위 2기준: 시급성=전략적 중요도·목표 가치(Value) / 난이도=데이터 비용·분석 수준(3V=투자비용) → 시급성 高+난이도 易 최우선
- 하향식=문제 주어짐·수렴 / 상향식=문제 정의 곤란·데이터 기반·발산 / 프로토타이핑=시도→반복 개선 / 디자인 씽킹=발산+수렴 반복
- 분석 기획 고려 3 = 가용 데이터·유스케이스·장애요소 사전계획
- 분석 목표 정의서 3요소 = **원·방·평** (원천 데이터 조사·분석 방안 판단·성과 평가 기준)
- WBS=계층적 작업 분할 / 간트 차트=일정 막대 시각화

④ 함정 포인트

- Veracity·Value는 3V 아님(5V 추가분) / Volatility=유효기간(7V)
- 반정형은 메타데이터를 **포함**한다 (구조 파악 가능) — "메타데이터 없음"은 오답
- Pig↔Sqoop 바꿔치기: Pig=Pig Latin 처리, Sqoop=RDB 전송 / Hive=HiveQL
- 전개(Deployment)·업무 이해는 **CRISP-DM에만** 있음, "변환"이 독립 단계면 KDD
- SEMMA는 데이터(샘플)에서 출발 — 비즈니스 이해 단계 없음
- 시급성↔난이도 정의 바꿔치기: "전략적 중요도"는 시급성
- 하이퍼파라미터·서버 사양·대시보드 = 기획 단계 아님(수행 단계)
- ETL 선지에 "추출→적재→변환" 나오면 ELT 함정
- 척와·크롤링을 정형에 연결하면 오답 (척와=반정형 로그, 크롤링=비정형)
- FTP: 능동=서버가 접속 시작, 수동=클라이언트가 접속 / UDP 아님(TCP)
- 적시성↔일관성 정의 바꿔치기 주의
- 일반화↔속성 생성 바꿔치기: 일반화=위로 뭉뚱그리기, 속성 생성=새로 만들기 / 나이→연령대는 평활화 아님(노이즈 제거 목적 아님)
- 마스킹≠삭제: 마스킹=가림, 삭제=없앰
- DW는 **비**휘발성 — "휘발성·실시간 갱신" 선지는 오답
- HDFS 역할 뒤집기: 네임노드=메타데이터, 데이터노드=실제 블록
- 마트에 레이크 특징(원시 무가공) 씌우면 오답 — 레이크=날것, 마트=완제품
- 컬럼 저장소는 컬럼 조회·집계에 **유리** (불리 아님)
- 가명정보는 개인정보(법 적용 O), 익명정보는 법 밖 / 특례에 "맞춤 광고" 없음
- 부정형에서 "제한 없이·자유롭게" 절대 표현 선지가 대개 정답

2과목 빅데이터 탐색 — 치트시트

① 세부항목별 핵심 표

결측값 3유형 (판별: 결측이 무엇에 의존?)

유형	의존 대상	사례
MCAR	아무것도 아님(순수 우연)	완전분석법이 안전한 유일 경우
MAR	관측된 다른 변수	성별 따라 체중 무응답률 차이
MNAR	결측된 값 자체	고소득자가 소득 무응답

결측값 대치법

방법	한 줄 정의
완전분석법	결측 있는 행 제외(표본 감소·MCAR 아니면 편향)
평균 대치	평균으로 채움 → 분산 **과소추정**
회귀 대치	회귀 예측값으로 대치
확률적 회귀 대치	예측값+오차항 → 변동성 보완
핫덱	**같은(현재) 조사 내** 유사 응답자 값
콜드덱	**외부·과거** 자료 값
다중 대치	m회 대치→분석→결합 3단계("1회·1개" 아님)

이상값 탐지

기법	기준
ESD	평균 ±3σ (정규 가정)
Z-점수	표준화 후 |Z|>3
IQR 규칙	[Q1−1.5×IQR, Q3+1.5×IQR] 밖 = 박스플롯 수염 밖
마할라노비스	공분산 반영·**다변량**
LOF	k-이웃과 **국소 밀도** 비교
iForest	**적은 분할로 고립**되면 이상값

- 이상값 처리 4가지 = 삭제 · 대체(경계값) · 변환(로그) · 분리(그룹 나눠 각각 분석, 폐기 아님)
- 잡음 평활화 3형제 = 구간화(bin 대체) · 회귀(함수 적합) · 군집화(군집 밖 식별)

- 정제 대상 = 결측값(값 없음) / 잡음(값 왜곡, 무작위 오류) / 이상값(정상 범위 밖)

변수 선택 3방식

방식	정의	대표
필터	모델 없이 통계 측도, 비용 최저	상관계수·카이제곱·정보 이득
래퍼	부분집합마다 모델 반복 학습	전진·후진·단계적
임베디드	학습 안에 선택 내장	라쏘·릿지·엘라스틱넷

불균형 데이터

기법	대상	부작용
언더샘플링	다수 클래스 줄임	정보 손실
오버샘플링(복제)	소수 클래스 늘림	과대적합
SMOTE	소수+k-NN **보간 합성 생성**	—
토멕 링크	이질 클래스 **상호 최근접 쌍**의 다수 쪽 제거	—
ENN	이웃 다수결과 다른 관측치 제거	—
클래스 가중치	데이터 그대로, 소수 오분류 벌점↑	—

차원축소 매칭

키워드	기법
분산 최대·직교·비지도	PCA (주성분에 제1·제2 **순서 있음**)
클래스 간/내 분산비 최대·지도	LDA
거리 보존·스트레스 0에 가까울수록 좋음	MDS (계량=구간·비율 / 비계량=순서)
행렬 분해 $U\Sigma V^T$	SVD
잠재요인·요인들 **대등**	요인분석

척도 4종 (순위?→간격?→절대영점?)

척도	특징	예	통계량
명목	분류만	혈액형	최빈값
순서	순위만	만족도	+중앙값
구간	간격 일정, 영점 없음	온도	+평균
비율	절대영점, 배수 비교	무게·소득	+기하평균·CV

표본추출 4종

방법	키워드
단순 무작위	모두 동일 확률
계통	일련번호+간격 k=N/n
층화	**층 내 동질·층 간 이질**, 모든 층에서 추출
군집	**군집 내 이질**, 일부 군집만 통째로

확률분포

분포	상황	E(X), V(X)
베르누이	성공/실패 1회	p, p(1−p)
이항	n회 중 성공 횟수	np, np(1−p)
포아송	단위 시간·공간 발생 건수	λ, λ (**같음**)
t	모분산 미지 소표본 모평균, 좌우 대칭	—
카이제곱	모분산·적합도·독립성, 비대칭	—
F	두 분산비·ANOVA, 비대칭	—

추론통계 핵심

항목	정의
불편성	$E(\theta)$=모수
효율성	분산 최소
일치성	n↑ 수렴
충족성(충분성)	표본 정보 모두 담음
1종 오류 α	참인 H_0 기각
2종 오류 β	거짓 H_0 채택
검정력	$1-\beta$ = 거짓 H_0 올바르게 기각
$p<\alpha$	기각 / $p\geq\alpha$ 기각 못 함

② 순서 암기

- 다중 대치: 대치 → 분석 → 결합
- 베이즈: 경로별 결합확률 → 전확률(합) → 해당 경로÷전확률
- 척도 판별: 순위? → 간격 일정? → 절대영점? (명목→순서→구간→비율)
- 텍스트 탐색: 토큰화 → 형태소 분석 → 단어 빈도 → 워드클라우드
- 양의 왜도(오른쪽 꼬리): 평균 > 중앙값 > 최빈값 (음의 왜도는 반대)

③ 매칭 암기

- EDA 4원칙 = **저·잔·재·현** (저항성·잔차·재표현·현시성) — "정규성"은 오답
- 검정 선택: 분산 알고 대표본=Z / 모르는 소표본=t / 범주형×범주형=카이제곱 / 3집단↑ 평균=ANOVA / 2집단=t / 사전·사후=대응 t
- 상관: 피어슨=연속·선형·모수 / 스피어만=순위·단조·비모수·이상값 저항
- 계수: 신뢰도(내적 일관성)=크론바흐 α / 평가자 일치=코헨 κ / 설명력=R^2
- 공간 시각화: 색 농도=코로플레스맵 / 면적 변형=카토그램 / 원 크기=버블맵
- 비정형: 텍스트=형태소·워드클라우드 / 이미지=픽셀 행렬·히스토그램 / 오디오=파형·스펙트로그램
- 그래프: 연속형 분포=히스토그램(막대 붙임)·줄기-잎 / 범주형=막대그래프(간격) / 연속×연속=산점도 / 범주×범주=교차표·모자이크
- 대립가설 부호: ≠ 양측 / > 우측 단측 / < 좌측 단측 (H_0만 등호 포함)
- 변환: 양의 왜도→로그·제곱근 / 음의 왜도→제곱 / 정규성 계열(로그·박스콕스) vs 스케일링 계열(민맥스·표준화)

④ 함정 포인트

- MAR↔MNAR 정의 바꿔치기 최다 빈출: "결측값 자체 때문"=MNAR

- 평균 대치 → 분산 "커진다"(X) → **과소추정**(O)
- 마할라노비스 "상관 고려 못 함"(X) → 공분산 **반영**·다변량용(O)
- 래퍼가 "모델 없이 통계만"(X) → 그건 필터, 래퍼는 반복 학습·비용 큼
- PCA가 "클래스 분리·지도"(X) → 그건 LDA / PCA 주성분 "대등"(X) → 순서 있음(대등은 요인분석)
- MDS에 "목표변수 필요"(X) → 거리 행렬만 사용
- 오버샘플링이 "다수 복제"(X) → 소수를 늘림
- 구간화 "정보 손실 없음"(X) → 구간 내 차이 소실
- 상관 0 = 독립(X): 선형 관계 없음일 뿐 / 상관↑=인과(X)
- 스피어만 "정규 연속형만"(X) → 비모수, 정규성 불필요
- 박스플롯으로 최빈값 확인(X) — 5수 요약+이상값만
- 군집추출 "군집 내 동질·모든 군집"(X) → 내 이질·일부만
- 중심극한정리 "모집단 정규일 때만"(X) → 분포 무관, n≥30
- 신뢰구간 "모수가 있을 확률 95%"(X) → 확률의 주어는 반복된 구간
- p-value "H_0가 참일 확률"(X) → H_0 참 가정 하 극단값 확률
- 포아송 분산 λ^2(X) → λ / 이항 분산 np(X) → $np(1-p)$
- 표본↑이면 "α·β 동시 증가"(X) → α 고정 시 β↓·검정력↑
- 분리 처리 "이상값 폐기"(X) → 나눠서 각각 분석
- 온도=비율척도(X) → 구간척도(절대영점 없음)
- 민맥스: 분자·분모 **모두 최솟값 빼기** — $(x-min)/(max-min)$
- IQR 판정에서 음수라고 무조건 이상값 아님(하한과 비교)

3과목 빅데이터 모델링 — 치트시트

① 세부항목 핵심 표

학습 유형

유형	키워드	대표 기법
지도	레이블·정답	회귀, 로지스틱, 의사결정나무, SVM, 신경망
비지도	군집·패턴·구조	K-means·계층적·DBSCAN·SOM, 연관(Apriori), PCA, 오토인코더
강화	에이전트·보상·정책·환경	Q-learning 계열
준지도	소량 레이블+대량 무레이블	지도·비지도의 **중간 별도 유형** (비지도 아님)

- 분류 vs 회귀 = 목표변수 형태: 범주형(여부·등급·스팸)=분류 / 연속형(가격·매출액·판매량)=회귀
- 변수 선택 3기법 = 전진 선택 · 후진 소거 · 단계적 선택
- 좋은 변수 = 목표변수와 관련성↑ + 독립변수 간 중복(다중공선성)↓

데이터 3분할

데이터	역할
훈련(train)	파라미터(가중치) 학습
검증(validation)	하이퍼파라미터 튜닝 + 과대적합 확인
평가(test)	최종 일반화 성능 측정만 (학습·튜닝 금지)

분석 도구

구분	R	Python	SAS/SPSS
성격	통계 특화·인메모리	범용·연동성	상용 라이선스
저장소/특징	CRAN	PyPI (pandas=라이브러리)	벤더 기술지원, SPSS=GUI

- 오픈소스 = 무료 + 최신 기법 반영 빠름 / 상용 = 기술지원 + 반영 느림

회귀 가정 → 진단 ("독왓, 정샤, 등산, 다V")

가정	진단 도구
독립성	더빈-왓슨 ≈2 독립 / 0 양의 자기상관 / 4 음의 자기상관
정규성	샤피로-윌크, K-S, Q-Q플롯
등분산성	잔차 산점도 (깔때기=이분산=위배)
다중공선성	VIF>10 의심 → 변수제거·PCA·릿지

- 다중공선성 = **독립변수들 사이** 상관 문제 (종속-독립 아님)

로지스틱 회귀

- 종속변수 = 범주형, 시그모이드 $1/(1+e^{-x})$로 확률화
- e^β = 오즈비 / 범위: 확률 0~1, 오즈 0~∞, 로짓 -∞~+∞

활성화 함수

함수	식/범위	용도
시그모이드	$1/(1+e^{-x})$, 0~1	이진 분류 출력층
tanh	-1~1	은닉층
ReLU	max(0,x), 0~∞	은닉층, 기울기 소실 완화
소프트맥스	지수/지수합, 합=1	다중 분류 출력층

- 신경망 史: 단층(XOR 불가)→다층(은닉층)→역전파→기울기 소실(시그모이드 미분 최대 0.25)→ReLU

SVM

- 마진 **최대화** / 서포트 벡터 = 경계에 **가장 가까운** 점 / 커널 트릭 = 고차원 매핑 / 슬랙 변수 = 오분류 허용 (소프트 마진)

군집

항목	내용
K-means 단점	K 사전 지정, 초기 중심 민감, 이상값 민감
연결법	단일=최단, 완전=최장, 평균=평균, 와드=분산(오차제곱합) 증가 최소
계층적	병합 후 번복 불가, 군집 수 사후 결정(덴드로그램)
DBSCAN	밀도 기반(ε·minPts), K 불필요, 노이즈 식별
실루엣	-1~1: 1 양호 / 0 경계 / 음수 오배정
SOM	비지도 신경망, 저차원 격자, 위상 보존, 경쟁학습(역전파 X)

딥러닝 매칭

모델	키워드
CNN	이미지, 합성곱+풀링+완전연결
RNN/LSTM	순차 데이터, LSTM=게이트(입력·망각·출력)로 기울기 소실·장기 의존성 해결
GAN	생성자 vs 판별자 **적대적 경쟁** (협력 아님)
오토인코더	비지도, 인코더+디코더, 차원축소·복원오차 이상탐지

텍스트·SNA

- TF-IDF = TF×IDF, 흔한 단어일수록 가중치↓ / 불용어 = 흔하지만 무의미 → **제거**
- LDA = 문서=토픽 혼합, 토픽=단어 확률분포 / 감성분석 = 비정형 텍스트의 긍부정
- SNA 중심성: 직접 연결 수=연결 / 다리·중개=매개 / 최단거리 가까움=근접 / 이웃의 중요도=위세

앙상블

	배깅	부스팅
학습	병렬·독립 (부트스트랩 복원추출)	순차·의존 (오분류 가중치)
효과	분산↓	편향↓
대표	랜덤포레스트	AdaBoost·GBM·XGBoost

- 보팅: 하드=클래스 다수결 / 소프트=**확률 평균**

범주형·시계열·비모수

- 카이제곱 3용도: 적합도(변수1, 이론분포) / 독립성(표본1·변수2) / 동질성(표본 여러 개)

- 기대빈도 5 미만 소표본 → 피셔 정확 검정
- 정상성 3조건: 평균 일정·분산 일정·공분산은 시차에만 의존 / 평균 비정상→차분, 분산 비정상→로그 변환
- 시계열 4요소: 추세·계절(주기 고정, 1년 이내)·순환(주기 불규칙·장기)·불규칙
- ARIMA(p,d,q): p=AR(과거 자기 값) / d=차분 횟수 / q=MA(과거 오차)
- 백색잡음 = 평균 0, 분산 일정, 자기상관 없음
- 나이브베이즈 = 베이즈 정리 + 변수 조건부 독립 **가정**(단순화용)
- 비모수 대응: 대응 2표본=윌콕슨 부호순위(·부호검정)↔대응 t / 독립 2표본=만-휘트니 U(=윌콕슨 순위합)↔독립 t / 독립 3집단+=크루스칼-왈리스↔ANOVA / 런 검정=무작위성

② 순서 암기

- 모형 구축: 요건 정의 → 모델링 → 검증·테스트 → 적용 ("요·모·검·적")
- K-means: 초기화(K·중심) → 할당 → 중심 갱신 → 수렴까지 반복
- 텍스트 전처리: 코퍼스 → 토큰화 → 불용어 제거 → 형태소 분석
- 신경망: 단층 XOR 한계 → 다층 → 역전파 → 기울기 소실 → ReLU

③ 매칭 암기

- 의사결정나무: **CART=지니(이진분리) / C4.5·ID3=엔트로피 / CHAID=카이제곱(다지분리)** — "카트는 지니, C4.5는 엔진, 차이는 카이"
- 연관분석: 지지도=P(A∩B) / 신뢰도=P(A∩B)/P(A) / 향상도=신뢰도/P(B) → >1 양의 연관, =1 독립, <1 음의 연관
- Apriori: 비빈발 집합의 상위집합=비빈발, 가지치기 기준=**최소 지지도** (향상도 X), 부분집합 지지도 ≥ 원집합
- 딥러닝 사례: 생성→GAN / 라벨 없음·압축·복원오차→오토인코더 / 긴 문맥·순차→LSTM / 이미지→CNN

④ 함정 포인트

- 로지스틱 "회귀"지만 = 지도학습·**분류** / K-means K 사전 지정≠지도학습 / SOM은 신경망이지만 **비지도**
- 준지도학습 ≠ 비지도의 하위 유형 (레이블 사용 여부가 기준)
- "변수 많을수록/항상 좋다" = 오답 (과대적합·차원의 저주)
- 평가 데이터로 튜닝 → 일반화 성능 **과대평가** (튜닝은 검증 데이터)
- 엔트로피 0 = **완전 순수** (불순도 최대 아님; 이진 최대 = 지니 0.5·엔트로피 1)
- 서포트 벡터 = 가장 **가까운** 점 ("가장 먼" = 함정)
- 단일 연결법 = 최단 거리 ("가장 먼" = 완전 연결법)
- 계층적 군집 재배정 불가 (재배정은 K-means)
- 오즈는 0~1 아님 (0~∞)
- 정상 시계열 분산도 일정 ("분산은 변해도 됨" = 함정)
- 오토인코더 = 비지도 ("출력을 입력과 비교하니 지도" = 함정)
- GAN "협력·동일 목적" = 함정 (적대적 경쟁)

- 부스팅에 "독립·병렬" 붙이면 오답 (그건 배깅) / 랜덤포레스트 = 배깅 계열
- 비모수 검정 "검정력 항상 높다" = 오답 (가정 충족 시 모수 검정이 우위)
- 상용 도구가 최신 기법 반영 빠르다 = 오답 (빠른 쪽은 오픈소스)
- 통계 기반 모형 "검정 없이·확률 해석 불가" = 오답 (가정·검정·추론이 본질)

4과목 빅데이터 결과 해석 — 치트시트

1. 회귀 평가지표

지표	정의 한 줄
MSE	오차 제곱의 평균 (단위=종속변수 제곱)
RMSE	√MSE (단위=종속변수와 동일)
MAE	오차 절댓값의 평균 (이상값 영향 MSE보다 작음)
MAPE	|오차/실제값| 백분율(%)의 평균 (단위 없음)
R^2	SSR/SST = 1 − SSE/SST
수정 R^2	변수 수 페널티 반영, 항상 R^2 이하

- SST = SSR + SSE (전체 = 설명 + 오차)
- R^2 = 변수 넣을수록 감소 안 함 → 변수 수 다르면 수정 R^2로 비교
- AIC·BIC = 작을수록 좋음, 둘 다 복잡도 벌점 有. BIC 벌점(ln n·k) > AIC 벌점(2k) → BIC가 더 단순 모형 선호
- 공식 판별: 제곱=MSE / √=RMSE / 절댓값=MAE / 실제값으로 나눔=MAPE

2. 분류 평가지표 (혼동행렬)

지표	공식	기준
정확도	(TP+TN)/전체	전체
정밀도	TP/(TP+FP)	예측 양성
재현율=민감도=TPR	TP/(TP+FN)	실제 양성
특이도	TN/(TN+FP)	실제 음성
FPR	FP/(FP+TN) = 1 − 특이도	실제 음성
F1	2PR/(P+R) 조화평균	≤ 산술평균

- ROC: x=FPR, y=TPR, 왼쪽 위로 붙을수록 좋음, 대각선=랜덤
- AUC: 0.5(랜덤) ~ 1(완벽), 클수록 좋음
- ROC 좌표 = (FPR, TPR) 순서 — "x축 먼저·FPR 먼저"
- 향상도(lift) = 모형 선별 집단 반응률 ÷ 전체 평균 반응률 (1이면 무의미)
- 지표 선택: 놓치면 큰일(진단)→재현율 / 오탐이 큰일(스팸)→정밀도 / 불균형→정확도 대신 F1

3. 교차검증·재추출

기법	정의 한 줄
홀드아웃	1회 분할, 분할 따라 결과 흔들림
k-fold	k개 폴드, 각각 1회 평가, k회 평균
LOOCV	k=n인 k-fold (LpOCV의 p=1)
LpOCV	${}_nC_p$ 조합 전부 반복 → 계산량 최대
부트스트랩	복원추출, 미포함 확률 ≈36.8%(1/e), 포함 ≈63.2%

- 반복 횟수: 홀드아웃 1 < k-fold k < LOOCV n < LpOCV ${}_nC_p$
- 3분할: 학습(train)=학습 / 검증(validation)=하이퍼파라미터 튜닝 / 평가(test)=최종 성능

4. 적합도 검정 — 키워드 매칭

키워드	검정
관측도수 vs 기대도수	카이제곱 적합도 검정
누적분포함수(ECDF) 최대 거리	K-S 검정
정규성 전용	샤피로-윌크 검정
분위수 그림(시각적)	Q-Q 플롯

- 카이제곱 용도 구분: 적합도(도수) / 독립성(범주형 두 변수)

5. 과적합·규제·신경망

- 훈련↑ 평가↓ = 과대적합 / 훈련↓ 평가↓ = 과소적합
- 과대적합 해결 = 데이터 증강·모형 단순화·규제·드롭아웃·조기 종료
- 과소적합 해결 = 모형 복잡화·변수 추가·학습 횟수 증가
규제	벌점	효과
L1(라쏘)	절댓값 합	계수 정확히 0 → 변수 선택·희소
L2(릿지)	제곱합	축소만, 0은 안 됨
엘라스틱넷	L1+L2	절충
- 드롭아웃 = 학습 시 뉴런 무작위 제외 (예측 시엔 전부 사용)
- 배치 정규화 = 미니배치 단위 입력 정규화 → 학습 안정·가속
- 조기 종료 기준 = 검증 오차 증가 시점 (훈련 오차 아님)
- 기울기 소실 = 역전파 시 기울기→0, 시그모이드가 원인, ReLU가 완화
- 기울기 폭주 = 기울기 비정상 증가·발산

6. 경사하강법·옵티마이저·튜닝

방식	데이터	특성
배치 GD	전체	안정·느림
SGD	1건	빠름·불안정(진동)
미니배치	묶음	절충·실무 표준

- 학습률: 과대=발산·진동 / 과소=느린 수렴·지역해
- 옵티마이저 매칭: 모멘텀=관성·이전 방향 / AdaGrad=기울기 제곱 누적·학습률 감소→0 문제 / RMSProp=지수이동평균으로 AdaGrad 보완 / Adam=모멘텀+RMSProp
- 하이퍼파라미터(사람) = 학습률·에폭·배치 크기·은닉층 수·규제 강도 / 파라미터(학습) = 가중치·편향·회귀 계수
- 그리드 서치 = 전 조합 전수 탐색·조합 폭발 / 랜덤 서치 = 무작위 추출·넓은 공간에 효율
- 최종모형 선정 3요소 = 평가 데이터 성능 + 해석 가능성 + 운영(비즈니스) 적용성

7. 비즈니스 기여도 지표 — 단위로 구분

지표	정의	단위
ROI	순이익 ÷ 투자비 × 100	비율(%)
NPV	미래 현금흐름 현재가치 − 투자비	금액
IRR	NPV=0이 되는 할인율	할인율
TCO	도입~폐기 전 기간 총 비용	비용
회수 기간	투자비 ÷ 연간 순이익	기간

- 판단: NPV>0 채택 / IRR>요구수익률 채택 / 회수 기간 짧을수록 유리
- NPV는 할인율 따라 변함, IRR은 현금흐름이 결정(할인율 무관)
- 회수 기간법 한계 = 화폐의 시간가치 미반영
- 보고 원칙 = 기술 언어→비즈니스 언어, KPI·기대 효과 중심

8. 시각화 5유형 매칭

유형	대표 차트
시간	막대·선·영역·계단식 그래프
분포	파이·도넛·트리맵·누적 영역
관계	산점도·산점도 행렬·버블 차트·히스토그램
비교	히트맵·체르노프 페이스·스타 차트·평행 좌표
공간	등치지역도·도트맵·카토그램·버블 플롯맵

- 공간 구분: 색상 농도=등치지역도 / 점 밀도=도트맵 / 원 크기=버블 플롯맵 / 면적 왜곡=카토그램
- 비교 구분: 얼굴 요소=체르노프 / 방사형 축=스타 차트 / 평행 축+선=평행 좌표
- 시각화 절차: 구조화 → 시각화 → 시각표현 ("구·시·표")
- 인포그래픽 = 대중·쉬움·빠른 전달·흥미·스토리텔링

9. 분석 결과 활용

- 운영 사이클: 전개 → 모니터링(측정) → 저하 감지 → 리모델링
- 전개 = 검증 완료 모형의 운영 시스템 적용·배포 (배포하면 끝 아님)
- 모니터링 = 관찰(측정·추적·감지, 모형 그대로)
- 리모델링 = 조치(재학습·재개발, 모형 변경) — 데이터·환경 변화로 지속 저하 시
- 활용 시나리오 = 누가·언제·어떤 업무·어떻게 구체 정의, 기획 단계부터 고려

10. 함정 포인트

- R^2 문제에 SSE 주어지면 "1에서 빼기" 필수 (SSE/SST 선지가 함정)
- F1: 산술평균 값이 선지에 있으면 함정 (조화평균으로 계산)
- 정밀도(예측 양성 기준) ↔ 특이도(실제 음성 기준) 정의 바꿔치기 단골
- FPR 문제: 특이도 값(1−빼기 누락)이 함정 선지
- ROC 좌표: (TPR, FPR)로 축 바꿔치기 함정
- 부트스트랩: 36.8%(미포함) ↔ 63.2%(포함) 숫자 바꿔치기
- LpOCV가 LOOCV보다 계산 적다? → 반대, ${}_nC_p$로 훨씬 많음
- BIC 벌점이 AIC보다 약하다? → 반대, BIC가 더 큼
- 불균형 1% 데이터: 전부 음성 예측해도 정확도 99% → 정확도 신뢰 불가
- 향상도: 차이(20−5)나 역수(5/20)가 함정, 나눗셈(20/5)이 정답
- L2가 계수를 0으로 만든다? → L1의 특징
- 조기 종료 기준 "훈련 오차"? → 검증 오차
- Adam = AdaGrad+배치정규화? → 모멘텀+RMSProp
- 시그모이드가 기울기 소실 해결? → 원인임, 해결은 ReLU
- ROI ↔ IRR 정의 바꿔치기 ("NPV=0 할인율"은 무조건 IRR)
- ROI 분모에 투자+이익 합계 넣는 실수 (분모=투자비만)
- 회수 기간 길수록 위험 낮다? → 짧을수록 유리
- 히트맵은 비교 시각화 (공간 아님) / 버블 "차트"=관계, 버블 "플롯맵"=공간
- 트리맵 = 분포 시각화 (비교 아님) / 히스토그램 = 관계 시각화(KDATA 기준)
- 카토그램 ↔ 등치지역도 특징 바꿔치기 (면적 왜곡=카토그램)
- 드롭아웃은 예측 시에도 뉴런 제외? → 학습 시에만
- "항상·무조건" 들어간 선지는 함정 확률 높음
- 활용 시나리오 수립 시점 "폐기 시점"? → 기획 단계부터
- 모니터링 감지 후 "그대로 사용"? → 리모델링 검토가 정답

빅데이터분석기사 숫자 총정리 (한 페이지)

개념·구성요소 개수

항목	값	각주
가트너 V 확장	3V→5V→7V ※ 교재차	3V=Volume·Velocity·Variety, 5V=+Veracity·Value, 7V=+Validity·Volatility(7V 구성 교재별 차이)
DW 특징	4가지	주제 지향·통합·시계열·비휘발(주통시비)
NoSQL 유형	4유형	Key-Value(Redis)·Document(MongoDB)·Column(HBase·Cassandra)·Graph(Neo4j)
CAP 정리	3속성 중 최대 2개	분산 시스템은 P 전제 → CP vs AP 택일
데이터 사이언티스트 역량	하드 2 / 소프트 3	하드=이론 지식·분석 기술, 소프트=통찰·전달·협력
가치 산정 곤란 이유	3가지	활용 다변화·새 가치 창출·분석 기술 발전(활·창·기)
분석 기획 고려사항	3가지	가용 데이터·유스케이스·장애요소 사전계획
분석 목표 정의서 구성	3요소	원천 데이터 조사·분석 방안 판단·성과 평가 기준(원·방·평)
분석 조직 구조	3유형	집중·기능·분산
준비도·성숙도 사분면	4유형	준비형(低低)·정착형(低高)·도입형(高低)·확산형(高高)
데이터 품질 기준	4기준	정확성·완전성·적시성·일관성
데이터 변환 기법	5기법	평활화·집계·일반화·정규화·속성 생성
비식별화 기법	5기법	가명처리·총계처리·데이터 삭제·데이터 범주화·데이터 마스킹
EDA 원칙	4개	저항성·잔차·재표현·현시성
박스플롯 요약 수치	5수 요약	최소·Q1·중앙값·Q3·최대 + 이상값 점
이상값 처리 방법	4가지	삭제·대체·변환·분리
변수 선택 기법	3기법	전진 선택·후진 소거·단계적 선택
카이제곱 검정 용도	3용도	적합도·독립성·동질성(변수 수·표본 수로 구분)
정상성 조건	3조건	평균 일정·분산 일정·공분산은 시차에만 의존(평균 비정상→차분, 분산 비정상→로그)

항목	값	각주
시계열 분해 요소	4요소	추세·계절·순환·불규칙(계절=주기 고정·1년 이내, 순환=주기 불규칙·장기)
백색잡음 조건	3조건	평균 0·분산 일정·자기상관 없음(MA 모형의 재료)
SNA 중심성	4종	연결·매개·근접·위세(수→연결, 다리→매개, 거리→근접, 이웃의 질→위세)
시각화 유형	5유형	시간·분포·관계·비교·공간

방법론·절차 단계 수

항목	값	각주
분석 방법론 단계 수	KDD 5 / CRISP-DM 6 / SEMMA 5 ※교재차	'5-6-5' 암기, KDD를 9프로세스로 쓰는 교재도 있으나 시험 기준 5단계
CRISP-DM 계층 구조	4계층	단계→일반화 태스크→세분화 태스크→프로세스 실행
하향식 과제 발굴	4단계	문제 탐색→문제 정의→해결방안 탐색→타당성 검토
분석 성숙도 단계	4단계	도입→활용→확산→최적화
데이터 확보 계획 절차	4단계	목표 정의→요구사항 도출→예산안 수립→계획 수립(목·요·예·계)
분석 WBS	4단계	과제 정의→데이터 준비·탐색→모델링·검증→산출물 정리(정·준·모·산)
분석 모형 구축 절차	4단계	요건 정의→모델링→검증·테스트→적용(요·모·검·적)
다중 대치	3단계·m개 데이터셋	대치→분석→결합
시각화 절차	3단계	구조화→시각화→시각표현(구·시·표)

법령·제도

항목	값	각주
데이터 3법	3개 법률·2020년 개정	개인정보 보호법·정보통신망법·신용정보법(개·망·신), 위치정보법 제외
가명정보 특례 목적	3목적	통계작성·과학적 연구·공익적 기록보존(통·과·공)

인프라 기술 수치

항목	값	각주
FTP 포트	제어 21 / 능동 데이터 20	TCP 기반, 능동=서버가 데이터 연결 시작, 수동=클라이언트가 시작
HDFS 블록 크기	기본 128MB ※교재차	하둡 2.x 이상 기준, 1.x는 64MB
HDFS 블록 복제 계수	기본 3	복제로 장애 허용성 확보

임계값·판정 기준

항목	값	각주
ESD 이상값 기준	평균 ±3σ	정규분포 가정
Z-점수 이상값 기준	|Z| > 3	표준화 후
IQR 규칙 배수	1.5×IQR	Q1−1.5IQR ~ Q3+1.5IQR 밖이 이상값
크론바흐 알파 수용 기준	0.7 이상 ※교재차	교재에 따라 0.6
VIF 다중공선성 기준	10 이상 의심 ※교재차	교재에 따라 5 기준도 있음
더빈-왓슨 통계량	≈2 독립	0 근처=양의 자기상관, 4 근처=음의 자기상관(잔차 독립성 진단)
중심극한정리 대표본 기준	n ≥ 30	—
향상도(lift) 기준	1	>1 양의 연관 / =1 독립(무작위와 동일, 모형 무의미) / <1 음의 연관
피셔 정확 검정 조건	기대빈도 5 미만 셀 다수	소표본에서 카이제곱 근사 대신 사용
불순도 최대값(이진)	지니 0.5 / 엔트로피 1	엔트로피 0 = 완전 순수
시그모이드 도함수 최댓값	0.25	작아서 층을 거칠수록 기울기 소실 유발
양측 검정 기각역	양쪽에 α/2씩	—
p-value 판정	$p < \alpha \rightarrow H_0$ 기각	예: p=0.03 < α=0.05 → 기각

범위(Range)

항목	값	각주
민맥스 정규화 결과	[0, 1]	—
상관계수	−1 ~ +1	피어슨·스피어만 공통
실루엣 계수	−1 ~ 1	1 양호 / 0 경계 / 음수 오배정
AUC	0.5 ~ 1	0.5=랜덤, 1=완벽, 클수록 좋음
활성화 함수 출력	시그모이드 0~1 / tanh −1~1 / ReLU 0~∞ / 소프트맥스 합=1	이진=시그모이드, 다중=소프트맥스, 은닉=ReLU
확률·오즈·로짓	확률 0~1 / 오즈 0~∞ / 로짓 −∞~+∞	순서대로 범위가 넓어짐
표준정규분포	평균 0, 분산 1	N(0,1)

공식·통계량

항목	값	각주
계통추출 간격	k = N/n	—
t분포 자유도	n−1	—
변수 쌍 개수	p(p−1)/2	예: p=3이면 3쌍
AIC 벌점	2k	k=모수 수, BIC 벌점보다 작음
BIC 벌점	ln n·k	표본 크면 AIC보다 벌점 큼 → 더 단순한 모형 선호
부트스트랩 미포함 확률	약 36.8% (1/e) ※교재차	복원추출 시 한 번도 안 뽑힐 확률, 포함 확률 약 63.2%
LOOCV	k = n	k-fold의 특수 경우, LpOCV의 p=1
LpOCV 반복 횟수	${}_nC_p$회	홀드아웃 1 < k-fold k < LOOCV n < LpOCV ${}_nC_p$
데이터 3분할 비율 예시	훈련:검증:평가 = 60:20:20	검증=튜닝·과적합 확인, 평가=최종 성능만

계산 예제(함정 포함)

항목	값	각주
IQR 계산	Q1=10, Q3=30 → IQR=20, 하한 −20, 상한 60	65는 이상값, −10은 정상
민맥스 계산	min20·max100에서 60 → 0.5	(60−20)/(100−20)
평균·중앙값	자료 3,4,5,6,22 → 평균 8, 중앙값 5	22 제거 시 평균 4.5
변동계수	A: 20/100=0.2, B: 5/50=0.1	A의 상대 산포가 더 큼
조건부확률	P(A)=0.4, P(A∩B)=0.1 → P(B|A)=0.25	—
이항분포 B(100,0.2)	E=20, V=16	V=np(1−p)=100×0.2×0.8
베이즈	A 60%·불량 2%, B 40%·불량 3% → P(A|불량)=1/2	0.012/0.024
오즈 계산	p=0.8 → 오즈 = 0.8/0.2 = 4	0.25(역수)·5(1/(1−p))가 함정 선지
연관분석 계산	10건 중 A 5·B 4·A∩B 2 → 지지도 0.2, 신뢰도 0.4, 향상도 1.0	향상도 1 = 독립
향상도 계산 2	신뢰도 0.6 ÷ P(김밥) 0.3 = 2	2배 → 양의 연관
기대빈도 계산	(80×50)÷200 = 20	(행 합×열 합)÷전체
불균형 데이터 반례	양성 1% → 전부 음성 예측 시 정확도 99%	불균형에서 정확도 신뢰 불가 근거

A	B	결정적 차이 한 줄
정밀도	특이도	정밀도=예측 양성(TP+FP) 중 진짜 양성, 특이도=실제 음성(TN+FP) 중 음성 판정 — 정의 바꿔치기 단골
정밀도	재현율	분모가 다름: 정밀도=예측 양성(TP+FP), 재현율=실제 양성(TP+FN)
L1(라쏘)	L2(릿지)	L1=절댓값 벌점·계수를 정확히 0으로 만들어 변수 선택, L2=제곱 벌점·축소만 하고 0은 안 됨
배깅	부스팅	배깅=부트스트랩·병렬·독립·분산↓(랜덤포레스트), 부스팅=오분류 가중치·순차·의존·편향↓(AdaBoost·GBM·XGBoost)
MAR	MNAR	MAR=결측이 관측된 다른 변수에 의존, MNAR=결측된 값 자체에 의존(고소득 무응답) — 정의 바꿔치기 최다 빈출
ACID	BASE	ACID=RDBMS·강한 일관성(원자성·일관성·독립성·지속성), BASE=NoSQL·가용성 우선·최종 일관성
층화추출	군집추출	층화=층 내 동질·층 간 이질·모든 층에서 추출, 군집=군집 내 이질·일부 군집만 통째로 — 최다 출제 함정
1종 오류(α)	2종 오류(β)	1종=참인 H_0 기각, 2종=거짓 H_0 채택. α↓이면 β↑ 상충, 표본↑만 둘 다 개선
PCA	요인분석	PCA=주성분에 제1·제2 중요도 순서 있음, 요인분석=요인들 대등·잠재요인 규명 목적
데이터 마트	데이터 레이크	마트=DW의 부서·주제별 정제된 부분집합(Schema-on-Write), 레이크=원시 데이터 무가공(Schema-on-Read)
파라미터	하이퍼파라미터	파라미터=학습이 결정(가중치·편향), 하이퍼파라미터=사람이 설정(학습률·에폭·배치·은닉층 수)
PCA	LDA	PCA=분산 최대·직교·비지도, LDA=클래스 간/내 분산비 최대·지도(목표변수 사용)
언더샘플링	오버샘플링	언더=다수를 줄임(정보 손실), 오버=소수를 늘림(과대적합) — 대상 바꿔치기 함정
랜덤 오버샘플링	SMOTE	오버샘플링=소수 단순 복제(과대적합), SMOTE=소수+k-NN 보간으로 합성 관측치 생성
FPR	특이도	FPR = 1 − 특이도. '1에서 빼기' 누락이 함정
p-value	H_0가 참일 확률	p-value=H_0 참 가정 하 관측값 이상 극단 결과의 확률. 'H_0가 참일 확률'은 항상 오답
과대적합	과소적합	과대=훈련↑ 평가↓(단순화·규제·증강으로 해결), 과소=훈련부터↓(복잡화로 해결)
Z검정	t검정	Z=모분산 알고 대표본, t=모분산 모르는 소표본(자유도 n−1)
만-휘트니 U	윌콕슨 부호순위	U(=윌콕슨 순위합)=독립 2표본↔독립 t, 부호순위=대응 2표본↔대응 t (3집단 이상=크루스칼-왈리스)

A	B	결정적 차이 한 줄
카이제곱 검정	ANOVA	카이제곱=범주형×범주형 독립성·적합도, ANOVA=3집단 이상 연속형 평균 비교(F-통계량)
카이제곱 적합도	카이제곱 독립성·동질성	적합도=변수 1개 vs 이론분포, 독립성=표본 1개·변수 2개, 동질성=여러 모집단 표본의 분포 비교
일관성(C)	가용성(A)	CAP에서 C=모든 노드가 같은 시점에 동일 데이터, A=언제든 요청에 응답 — 정의 바꿔치기 단골
가명정보	익명정보	가명=추가 정보 결합 시 식별 가능·개인정보 보호법 적용 O, 익명=식별 불가·법 적용 X
시그모이드	소프트맥스	시그모이드=이진 분류 출력·확률 합 1 보장 안 함, 소프트맥스=다중 분류·확률 합=1
기울기 소실	기울기 폭주	소실=기울기 0에 수렴(시그모이드 원인, ReLU로 완화), 폭주=기울기 비정상 증가·발산
하드 마진	소프트 마진	하드=오분류 불허, 소프트=슬랙 변수로 일부 오분류 허용 (서포트 벡터=경계에 '가장 가까운' 점)
계층적 군집	K-평균	계층적=병합 후 번복·재배정 불가·군집 수 사후 결정, K-means=반복마다 재할당·K 사전 지정(비지도)
단일 연결법	완전 연결법	단일=군집 간 최단 거리, 완전=최장 거리 (평균=평균 거리, 와드=분산 증가 최소)
AR 모형	MA 모형	AR=과거 자기 관측값의 선형결합(p), MA=과거 오차(백색잡음)의 선형결합(q), d=차분 횟수
계절 요인	순환 요인	계절=고정 주기·1년 이내 반복, 순환=주기 불규칙·1년 초과 장기 변동
AIC	BIC	둘 다 작을수록 좋음. BIC 벌점(ln n·k)이 AIC(2k)보다 커 더 단순한 모형 선호
R^2	수정 R^2	R^2는 변수 추가 시 감소 안 함, 수정 R^2는 변수 수 페널티로 변수 수 다른 모형 비교용
F1(조화평균)	산술평균	F1=2PR/(P+R)로 항상 산술평균 이하 — 산술평균 값이 함정 선지
부트스트랩 미포함 36.8%	포함 63.2%	복원추출에서 한 번도 안 뽑힘=36.8%(1/e), 한 번 이상 포함=63.2%
피어슨 상관	스피어만 상관	피어슨=연속형·선형·모수적, 스피어만=순위·단조·비모수·이상값 저항
무상관	독립	상관 0=선형 관계 없음일 뿐 독립 보장 안 됨. '독립이면 상관 0'만 성립
구간척도	비율척도	구간=간격 일정·절대영점 없음(온도, 배수 비교 불가), 비율=절대영점 있음(무게, 배수 비교 가능)
이항분포	포아송분포	이항=정해진 n회 중 성공 횟수(V=np(1−p)), 포아송=단위 시간·공간 발생 건수(E=V=λ)
t분포	F분포	t=모분산 미지 소표본 모평균·좌우 대칭, F=두 집단 분산비·ANOVA·오른쪽 꼬리 비대칭

A	B	결정적 차이 한 줄
더빈-왓슨	샤피로-윌크	더빈-왓슨=잔차 독립성(자기상관), 샤피로-윌크=잔차 정규성 (K-S=CDF 최대 거리로 분포 적합)
CART	C4.5 / CHAID	CART=지니 지수·이진 분리, C4.5=엔트로피(정보이득), CHAID=카이제곱·다지 분리
엔트로피 0	엔트로피 최대	0=한 범주만 있는 완전 순수, 최대(이진 시 1)=반반 혼합
필터	래퍼	필터=모델 없이 통계 측도(비용 최저), 래퍼=부분집합마다 모델 반복 학습(비용 큼·성능 좋음)
검증 데이터	평가 데이터	검증=하이퍼파라미터 튜닝·과적합 확인, 평가=학습·튜닝에 미사용·최종 성능 측정만
조기 종료 기준	훈련 오차	조기 종료는 검증 오차 증가 시점에 중단. 훈련 오차는 계속 감소하므로 기준 불가
배치 GD	SGD	배치=전체 데이터·안정·느림, SGD=1건·빠름·불안정(진동). 미니배치=절충
모멘텀	AdaGrad	모멘텀=관성(이전 방향 반영), AdaGrad=기울기 제곱 누적으로 변수별 학습률 조정. Adam=둘의 결합
그리드 서치	랜덤 서치	그리드=전 조합 전수 탐색(조합 폭발), 랜덤=무작위 추출·넓은 공간에 효율
하드 보팅	소프트 보팅	하드=예측 클래스 다수결, 소프트=클래스별 확률 평균 후 최대 확률 선택
히스토그램	막대그래프	히스토그램=연속형·구간·막대 붙임, 막대그래프=범주형·막대 사이 간격
등치지역도(코로플레스)	카토그램	등치지역도=면적 유지·색 농도 표현(넓은 지역 과대 인식), 카토그램=값에 비례해 면적 자체 변형
히트맵	트리맵	히트맵=색상으로 값 비교(비교 시각화), 트리맵=면적으로 비율·계층(분포 시각화)
매개 중심성	근접 중심성	매개=최단 경로 위 다리·중개 역할, 근접=모든 노드까지 최단거리가 가까운 정도
GAN	오토인코더	GAN=생성자 vs 판별자의 적대적 경쟁으로 생성, 오토인코더=인코더·디코더 압축·복원(비지도 차원축소·이상탐지)
CNN	RNN/LSTM	CNN=이미지·합성곱+풀링, RNN·LSTM=순차 데이터(LSTM은 게이트로 기울기 소실·장기 의존성 해결)
SOM	다층 퍼셉트론	SOM=비지도·경쟁학습·저차원 격자·위상 보존(역전파 X), MLP=지도학습·역전파
단층 퍼셉트론	다층 퍼셉트론	단층=선형 분리만 가능(XOR 불가), 다층=은닉층으로 XOR 해결
로지스틱 회귀	K-평균 군집	로지스틱=이름은 회귀지만 지도·분류, K-means=K를 미리 정해도 비지도·군집
오즈	확률	오즈=p/(1−p)·범위 0~∞, 확률=0~1
핫덱 대치	콜드덱 대치	핫덱=같은(현재) 조사 내 유사 응답자 값, 콜드덱=외부·과거 자료 값

A	B	결정적 차이 한 줄
LOF	iForest	LOF=k-이웃과 국소 밀도 비교, iForest=적은 분할 횟수로 쉽게 고립되면 이상값
토멕 링크	ENN	토멕=이질 클래스 상호 최근접 쌍의 다수 쪽 제거, ENN=이웃 다수결과 클래스 다른 관측치 제거
원-핫 인코딩	레이블 인코딩	원-핫=범주당 0/1 이진 변수(차원 증가), 레이블=정수 부여(허구적 순서 관계 위험)
요약변수	파생변수	요약=집계·객관적·재활용 높음, 파생=목적 지향·주관적·타당한 근거 필요
일반화	평활화	일반화=하위 값을 상위 개념으로 대체(나이→연령대), 평활화=노이즈 제거
잡음	이상값	잡음=측정 중 섞인 무작위 오류(평활화로 완화), 이상값=실제 관측된 정상 범위 밖 값
크론바흐 알파	코헨의 카파	알파=문항 간 내적 일관성(신뢰도), 카파=평가자 간 판정 일치도(우연 보정)
불편성	일치성	불편성=기댓값이 모수와 일치, 일치성=n↑일수록 모수에 확률 수렴
양측 검정	단측 검정	대립가설 ≠이면 양측(α/2씩), >는 우측·<는 좌측 단측. H_0만 등호 포함
신뢰구간 옳은 해석	오해석	옳음=반복 추출된 구간들의 95%가 모수 포함, 틀림='특정 구간에 모수가 있을 확률 95%'
CRISP-DM	SEMMA	CRISP-DM=업무 이해에서 출발·전개 단계 있음, SEMMA=샘플링에서 출발·비즈니스 이해 단계 없음
CRISP-DM	KDD	'변환'이 독립 단계면 KDD, CRISP-DM은 데이터 준비에 흡수. 전개는 CRISP-DM에만 존재
하향식 접근	상향식 접근	하향식=문제가 주어진 상태에서 해법 탐색(수렴), 상향식=데이터에서 통찰 도출(발산)
시급성	난이도	시급성=전략적 중요도·목표 가치(Value)로 평가, 난이도=데이터 비용·분석 수준(3V=투자비용)으로 평가
ETL	ELT	ETL=적재 전 변환(DW용), ELT=원본 먼저 적재 후 목적지에서 변환(데이터 레이크용)
Hive	Pig	Hive=HiveQL(SQL식·선언형) 질의, Pig=Pig Latin(절차형 스크립트)
Pig	Sqoop	Pig=스크립트로 데이터 처리 흐름 기술, Sqoop=RDB↔하둡 정형 데이터 전송
MapReduce	Spark	MapReduce=디스크 기반 배치, Spark=인메모리 기반이라 반복 연산·ML에 빠름
Zookeeper	Oozie	Zookeeper=분산 코디네이션(설정·동기화·리더 선출), Oozie=하둡 작업 워크플로 스케줄링
플룸(Flume)	척와(Chukwa)	플룸=소스–채널–싱크 구조, 척와=에이전트–컬렉터 구조로 HDFS 저장(하둡 서브프로젝트)
네임노드	데이터노드	네임노드=메타데이터 관리(마스터), 데이터노드=실제 블록 저장(슬레이브)

A	B	결정적 차이 한 줄
DW	ODS	DW=전사 통합 분석 저장소(비휘발), ODS=DW 적재 전 운영계 데이터 임시 통합 저장소
IaaS	PaaS	IaaS=인프라 제공(이용자가 OS부터 관리), PaaS=플랫폼 제공(이용자는 앱·데이터만)
Veracity(신뢰성)	Value(가치)	둘 다 5V 추가분(3V 아님). Veracity=품질·정확성, Value=분석으로 얻는 유용성
반정형 데이터	비정형 데이터	반정형=메타데이터(태그·키) 내장으로 구조 파악 가능(XML·JSON·로그), 비정형=구조 없음(영상·음성)
집중 구조	분산 구조	집중=별도 전담 조직(현업과 이중화 단점), 분산=전담 인력을 현업 부서에 배치
도입형	정착형	도입형=준비도 高·성숙도 低(바로 도입), 정착형=준비도 低·성숙도 어느 정도(정착 우선)
데이터 마스킹	데이터 삭제	마스킹=값을 남기되 기호(*)·노이즈로 가림, 삭제=항목 자체를 없앰
WBS	간트 차트	WBS=작업의 계층적 분할 구조, 간트=분할된 작업의 일정을 막대로 시각화
FTP	Rsync	FTP=TCP 기반 파일 전송, Rsync=1:1 파일·디렉터리 동기화(미러링)
Open API	RSS	Open API=수집자가 인터페이스를 호출(pull), RSS=갱신 콘텐츠의 XML 배급 구독
적시성	일관성	적시성=필요한 시점에 최신 상태 제공, 일관성=형식·단위·값 체계의 무모순·일치
준지도학습	비지도학습	준지도는 레이블을 일부라도 사용 → 비지도의 하위가 아닌 별도 중간 유형
비모수 검정	모수 검정	비모수=분포 가정 불필요·순위/부호 기반, 가정 충족 시엔 모수 검정의 검정력이 더 높음
Apriori 가지치기	향상도	후보 가지치기는 최소 지지도 기준(향상도 아님); 비빈발 집합의 상위집합은 비빈발
불용어	핵심 단어	불용어=빈번하지만 의미 없어 제거 대상(보존 대상 아님)
다중공선성	종속-독립 상관	다중공선성=독립변수들 사이의 강한 상관(문제), 종속변수와의 높은 상관은 오히려 바람직
오픈소스(R·Python)	상용(SAS·SPSS)	오픈소스=무료·최신 기법 반영 빠름·공식 지원 없음, 상용=라이선스·벤더 지원(SPSS=GUI)
CRAN/PyPI	pandas	CRAN·PyPI=패키지 저장소, pandas=Python 분석 라이브러리
ROI	IRR	ROI=투자비 대비 순이익 비율(%), IRR=NPV를 0으로 만드는 할인율 — 정의 바꿔치기 단골
NPV	IRR	NPV=할인율 넣어 계산하는 금액(할인율↑→NPV↓), IRR=현금흐름이 결정하는 할인율

A	B	결정적 차이 한 줄
버블 차트	버블 플롯맵	버블 차트=산점도+크기(관계 시각화), 버블 플롯맵=지도 위 원 크기(공간 시각화)
평행 좌표 그래프	선 그래프	평행 좌표=평행한 변수 축 여러 개에 다변량 비교, 선 그래프=시간 축 1개의 추세
체르노프 페이스	스타 차트	체르노프=변수를 얼굴 요소에 대응, 스타 차트=방사형(거미줄) 축 다각형
모니터링	리모델링	모니터링=관찰(주기적 측정·저하 감지, 모형 그대로), 리모델링=조치(최신 데이터 재학습·모형 변경)
전개	모니터링	전개=검증 완료 모형의 운영 배포, 모니터링=전개 후 성능 추적. 순서: 전개→모니터링→감지→리모델링

빅데이터분석기사 계산 공식 암기카드

1. 확률·분포·추정

이름(원어)	공식	계산 예
조건부확률 (Conditional Probability)	P(B|A) = P(A∩B) / P(A) — 분모는 조건 사건 P(A)	P(A∩B)=0.2, P(A)=0.5 → P(B|A)=0.4
베이즈 정리 (Bayes' Theorem)	P(A|D) = P(A)P(D|A) / Σ P(원인)P(D|원인) — 분모는 전확률(모든 경로의 합)	P(A)=0.3, P(D|A)=0.8, P(B)=0.7, P(D|B)=0.2 → 0.24/(0.24+0.14)≈0.632
베르누이 기댓값·분산 (Bernoulli)	E(X)=p, V(X)=p(1−p)	p=0.3 → E=0.3, V=0.3×0.7=0.21
이항분포 기댓값·분산 (Binomial)	E(X)=np, V(X)=np(1−p) — (1−p) 빼먹으면 포아송과 혼동	n=100, p=0.2 → E=20, V=100×0.2×0.8=16
포아송 기댓값·분산 (Poisson)	E(X)=λ, V(X)=λ — 기댓값=분산이 최대 특징	λ=5 → E=5, V=5
표본평균 분포·중심극한정리 (CLT)	X̄ ~ 근사 N(μ, σ^2/n), 표준오차 = σ/√n — 모집단 분포와 무관	σ=10, n=25 → 표준오차 = 10/5 = 2
검정력 (Power)	검정력 = 1 − β = P(H0 기각 | H0 거짓)	β=0.2 → 검정력 = 0.8
계통추출 간격 (Systematic Sampling)	k = N / n (N=모집단, n=표본 크기)	N=1,000, n=50 → k=20
변수 쌍 개수 (Pairs of Variables)	p(p−1)/2 — 산점도 행렬의 서로 다른 쌍 수	p=5 → 5×4/2 = 10쌍
불편성 (Unbiasedness)	E(θ̂) = θ — 추정량의 기댓값이 모수와 같음	E(X̄)=μ 이면 X̄는 μ의 불편추정량

2. 연관분석·교차표

이름(원어)	공식	계산 예
지지도 (Support)	P(A∩B) — 전체 거래 중 A·B 동시 구매 비율	100건 중 동시 구매 20건 → 0.2
신뢰도 (Confidence)	P(A∩B)/P(A) = P(B|A) — 분모는 조건 항목 A	P(A∩B)=0.2, P(A)=0.4 → 0.5
향상도 (Lift, 연관규칙)	신뢰도/P(B) = P(A∩B)/(P(A)×P(B)) — 곱하기 아니라 나누기, 1이면 독립	신뢰도 0.5, P(B)=0.25 → 향상도 2
기대빈도 (Expected Frequency)	(행 합계 × 열 합계) ÷ 전체 표본 수 — 독립성 검정용	행합 40, 열합 50, 전체 200 → 40×50/200 = 10
카이제곱 통계량 (Chi-square Statistic)	Σ (관측도수 − 기대도수)^2 / 기대도수 — 독립성·적합도 검정 공통	관측 30, 기대 20 → (30−20)^2/20 = 5 (셀별 합산)

3. 회귀 평가 지표

이름(원어)	공식	계산 예
결정계수 (R^2, Coefficient of Determination)	$R^2 = SSR/SST = 1 - SSE/SST$ (SST=SSR+SSE)	SST=100, SSE=25 → R^2=0.75
MSE (Mean Squared Error)	(1/n) Σ (y − ŷ)^2 — 단위는 종속변수의 제곱	오차 (1, −2, 1) → (1+4+1)/3 = 2
RMSE (Root Mean Squared Error)	√MSE — 종속변수와 같은 단위	MSE=4 → RMSE=2
MAE (Mean Absolute Error)	(1/n) Σ |y − ŷ| — 절댓값 평균, 이상값 영향 작음	오차 (1, −2, 1) → (1+2+1)/3 ≈ 1.33
MAPE (Mean Absolute Percentage Error)	(100/n) Σ |(y − ŷ)/y| — % 지표, 단위 없음	실제 100, 예측 90 한 건 → 10%

4. 분류 평가 지표 (혼동행렬)

혼동행렬 (Confusion Matrix):

	예측 양성(P)	예측 음성(N)
실제 양성	TP	FN
실제 음성	FP	TN

공통 예시 행렬: TP=40, FN=10, FP=20, TN=30 (전체 100)

이름(원어)	공식	계산 예
정확도 (Accuracy)	(TP+TN) / 전체	(40+30)/100 = 0.7
정밀도 (Precision)	TP/(TP+FP) — 분모는 예측 양성	40/(40+20) ≈ 0.667
재현율·민감도·TPR (Recall, Sensitivity)	TP/(TP+FN) — 분모는 실제 양성	40/(40+10) = 0.8
특이도 (Specificity)	TN/(TN+FP) — 분모는 실제 음성	30/(30+20) = 0.6
FPR (False Positive Rate)	FP/(FP+TN) = 1 − 특이도 — 특이도 먼저 구해 검산	20/(20+30) = 0.4 = 1−0.6
F1-점수 (F1 Score)	2 × 정밀도 × 재현율 / (정밀도 + 재현율) — 조화평균	P=0.75, R=0.5 → 2×0.375/1.25 = 0.6
ROC 좌표 (ROC Coordinates)	(x, y) = (FPR, TPR) — x가 FPR, y가 TPR	FPR=0.4, TPR=0.8 → 점 (0.4, 0.8)
향상도 (Lift, 이익도표)	구간 반응률 ÷ 전체 평균 반응률 — 나눗셈이지 차이 아님	구간 20%, 전체 5% → 20/5 = 4

5. 기타 (전처리·통계요약·모형·분석기획)

이름(원어)	공식	계산 예
민맥스 정규화 (Min-Max Normalization)	(x − min) / (max − min) — 결과 [0,1], 분자·분모 모두 최솟값 빼기	x=70, min=50, max=100 → 20/50 = 0.4
Z-점수 표준화 (Z-score Standardization)	Z = (x − 평균) / 표준편차 — |Z|>3이면 이상값 의심	x=80, 평균=70, 표준편차=5 → Z=2
IQR (Interquartile Range)	IQR = Q3 − Q1, 이상값 경계 = Q1−1.5×IQR, Q3+1.5×IQR	Q1=20, Q3=40 → IQR=20, 경계 −10 ~ 70
변동계수 (CV, Coefficient of Variation)	CV = 표준편차 ÷ 평균 — 단위 없는 상대 산포, 단위 다른 자료 비교	표준편차 5, 평균 25 → 0.2
범위 (Range)	최댓값 − 최솟값 — 극단값 2개만 사용, 이상값에 민감	최대 95, 최소 40 → 55
시그모이드 (Sigmoid)	f(x) = 1 / (1 + e^(−x)) — 출력 0~1, 이진 분류 출력층	x=0 → 1/(1+1) = 0.5
tanh (Hyperbolic Tangent)	f(x) = (e^x − e^(−x)) / (e^x + e^(−x)) — 출력 −1~1	x=0 → 0/2 = 0
ReLU (Rectified Linear Unit)	f(x) = max(0, x) — 출력 0~∞, 기울기 소실 완화	x=−3 → 0, x=2 → 2
소프트맥스 (Softmax)	f(x_i) = e^(x_i) / Σ_j e^(x_j) — 다중 클래스 확률, 합=1	두 클래스 값이 같으면 각 0.5
오즈 (Odds)	odds = p / (1 − p) — 범위 0~∞, 성공이 실패의 몇 배	p=0.8 → 0.8/0.2 = 4
오즈비 (Odds Ratio)	e^β (로지스틱 회귀계수의 지수 변환) — 독립변수 1단위 증가 시 오즈 e^β배	β=0.7 → e^0.7 ≈ 2.01배
TF-IDF (Term Frequency–Inverse Document Frequency)	TF × IDF — 흔한 단어일수록 IDF↓ → 가중치↓	TF=3, IDF=2 → 6
정보이득 (Information Gain)	분리 전 불순도 − 분리 후 불순도 — 이득 최대인 분리 선택	분리 전 0.5, 분리 후 0.3 → 이득 0.2
ROI (Return on Investment)	순이익 ÷ 투자비 × 100 — 분모는 투자비만	순이익 500, 투자비 2,000 → 25%
NPV (Net Present Value)	미래 현금흐름의 현재가치 − 투자비 — 0보다 크면 투자 타당	현재가치 2,500, 투자비 2,000 → NPV=500>0 타당
투자 회수 기간 (Payback Period)	투자비 ÷ 연간 순이익 (순이익 균등 시) — 짧을수록 유리	12,000만 ÷ 3,000만 = 4년
그리드 서치 조합 수 (Grid Search Combinations)	각 하이퍼파라미터 후보 수의 곱	3종 × 각 4개 = 4×4×4 = 64조합

부록. 순서식 (계산 아님)

이름(원어)	순서	비고
ETL (Extract-Transform-Load)	추출 → 변환 → 적재	T·L을 바꾸면 ELT
ELT (Extract-Load-Transform)	추출 → 적재 → 변환	데이터 레이크 궁합, 목적지 시스템에서 변환

이 문서는 LLM으로 생성 후 3중 검증(사실·논리·규격 / 중복 / 교체분 재검증)을 거친 학습 자료입니다. 교재별 표기가 갈리는 항목은 본문에 "※ 교재별 표기 차이 있음"으로 표시했으며, 상세 목록은 부록의 검증 필요 항목을 참고하세요.